生物物理

从随机演化到分子结构与功能

MIT OpenCourseWare 选定公开材料中文重编

8.592J / HST.452J · Spring 2011

2026 年 10 月 12 日

原课程作者：Mehran Kardar、Leonid Mirny。本册按物理问题重组实际可获取的 MIT 公开资料，保留来源、课程学期和许可；题面翻译、记号统一、推导增补及图形重绘均属于改编。中文稿及编者补充采用CC BY-NC-SA 4.0，用于非商业学习；不表示 MIT 或原作者认可本稿。

读者应掌握大学微积分、线性代数、基础力学和热统计；正文在首次使用处解释新的物理量。课程主题、37 道作业的逐项状态和实际缺源见书末与 qa/coverage-completion.json；原冻结清单作为历史记录保留，后续扩展单独记录。原题解答均标出官方答案或编者独立推导；数值结果区分公开实测数据、明确的模拟数据和模型计算。

目录

1 生物状态与随机演化 **1**

1.1 从序列到概率：本卷所需的统计工具 1

1.2 离散时间、连续时间与稳态的条件 1

1.3 分子状态和时间尺度 2

1.4 随机交配、Hardy–Weinberg 与异质度 2

1.5 适合度如何进入选择递推 3

1.6 连续极限与遗传漂变 3

1.7 突变、选择与稳态 4

1.8 从有限种群核得到连续方程 4

1.9 固定事件与条件平均时间 5

1.10 酶反应的平均与涨落 5

2 序列比较与极值统计 **6**

2.1 比对中的物理信息 6

2.2 从接受替换计数构造 PAM 矩阵 6

2.3 高斯最大值与 Gumbel 极限 7

2.4 局部高分的尾部尺度 7

2.5 得分为何应比较似然 7

2.6 指数倾斜与显著性尺度的条件 8

2.7 高斯极值的有限样本修正 8

2.8 有限温路径和零温动态规划 8

3 水溶液中的静电作用 **9**

3.1 Bjerrum 长度和屏蔽 9

3.2 无盐平面双电层 9

3.3 线电荷与反离子凝聚 9

3.4 电离平衡与介电环境 9

3.5 Poisson–Boltzmann 的自由能推导 10

3.6 无盐平面解的积分与压力核对 10

3.7 有限容器与凝聚极限的次序 10

4 链构象与弹性 **11**

4.1 随机链和熵弹簧 11

4.2 排除体积和尺度 11

4.3 弯曲链与持久长度 . . . 11
4.4 真实链如何得到等效节段 . . . 12
4.5 WLC 的方向扩散与强力响应 . . . 12
4.6 从单体相互作用到维里展开 . . . 12
4.7 张力团块为何给非线性指数 . . . 13

5 蛋白折叠与能量景观 13
5.1 从氨基酸序列到二级和三级结构 . . . 13
5.2 氢键、疏水塌缩与溶剂自由能 . . . 13
5.3 Anfinsen 热力学假说与 Levinthal 时间问题 . . . 14
5.4 构象数和随机能量模型 . . . 14
5.5 折叠动力学和势垒 . . . 14
5.6 REM 的态密度、冻结和比热 . . . 15
5.7 序列设计的统计系综 . . . 15
5.8 首次逃逸积分与 Kramers 近似 . . . 15

6 核酸的解链与二级结构 16
6.1 DNA 中的环熵 . . . 16
6.2 RNA 配对递推 . . . 16
6.3 拉力与核酸解链 . . . 16
6.4 交替段的生成函数与配对比例 . . . 17
6.5 熔融 RNA 的闭合求和 . . . 17
6.6 发夹熔解与受力 DNA . . . 17

7 识别、搜索与 DNA 弯折 18
7.1 结合概率与序列信息 . . . 18
7.2 lac、CRP 与 RNA 聚合酶的多状态招募 . . . 18
7.3 三维扩散和一维滑动 . . . 19
7.4 蛋白诱导弯折 . . . 19
7.5 反应速率与平衡亲和力 . . . 20
7.6 吸收球的通量与反应受限边界 . . . 20
7.7 滑动范围、更新过程与多人并行 . . . 20
7.8 弯曲变分的边界条件 . . . 20

8 丝状聚合物与分子马达 21

8.1 生长、缩短和动态失稳 . . . 21
8.2 马达的内部循环 . . . 21
8.3 趋化与随机游动 . . . 21
8.4 微管长度分布与边界再注入 . . . 22
8.5 随机切换产生扩散 . . . 22
8.6 帽的片段化与灾变时间 . . . 22
8.7 两态马达的准确长时统计 . . . 23
8.8 化学功、停滞与力的不同定义 . . . 23
8.9 细胞游动的低 Re 极限与 scallop 定理 . . . 23
8.10 跑动、翻滚与时间上的趋化比较 . . . 24

9 网络、集体运动与 DNA 包装 25
9.1 网络结构和阈值 . . . 25
9.2 反应网络的稳定性 . . . 25
9.3 包装能量与尺度选择 . . . 25
9.4 图的计数与随机基准 . . . 25
9.5 优先连接的度分布 . . . 26
9.6 Lyapunov 函数为何需要对称条件 . . . 26
9.7 从特征值到分岔和周期 . . . 26
9.8 Kuramoto 同步的自洽推导 . . . 27
9.9 Turing 图样：扩散为何能破坏稳定 . . . 27

10 协同结合的统计模型 28
10.1 按真实网页纲要补充：Hill 与 MWC . . . 28

11 概率、固定与序列题解 29
11.1 PS1：概率 . . . 29
11.2 PS2：固定和比对 . . . 30
11.3 PS3：极值 . . . 32

12 静电、折叠与拉伸题解 33
12.1 PS4：库仑作用 . . . 33
12.2 PS5：随机能量模型 . . . 35
12.3 PS6：力与延伸 . . . 36

13 搜索、增长与马达题解 37

13.1 PS7：蛋白与 DNA 37
13.2 PS8：漂移和扩散 38

14 补充原题与公开数据分析 **42**
14.1 PS3.2：同源与异源二聚体 42
14.2 PS4.3：噬菌体包装的能量尺度 42
14.3 PS6.2：受力 DNA 模型的完整相界 43
14.4 PS1.2 与 PS1.4：公开基因组的 ORF 和相关 44
14.5 PS1.6：公开 SNP 数据与不可识别的拟合 45
14.6 PS7.1：权重矩阵和全基因组候选 47

15 对齐计数、接触结构与受力模型 **48**
15.1 PS2.3：比对数量的约定与题面缺口 48
15.2 PS5.3：接触矩阵的实际统计和 REM 48
15.3 PS5.4：由真实坐标得到 Ramachandran 图 49
15.4 PS6.3：DNA 过度伸长的模型比较 50
15.5 PS2.5 与 PS6.5：在线任务的题面和真实执行边界 51
15.6 PS2.5 实际复算：当前数据库与算法比较 51

16 课程来源与覆盖边界 **53**
16.1 实际公开资料 53
16.2 真实缺源与执行缺口 53
16.3 来源入口和改编许可 53

参考文献 **53**

1 生物状态与随机演化

1.1 从序列到概率：本卷所需的统计工具

本课程有三条相连的线索：序列中储存什么信息，分子怎样形成结构，多个分子怎样实现功能。第一条需要概率和首次到达问题，第二条需要配分函数，第三条把两者放进持续耗能的动力学。下面先建立这些工具的共同记号，避免把各章看成互不相干的公式。

设字母表有 m 种字母，位置独立且概率为 p_α。长度 N 的具体序列概率是 $\prod_{i=1}^{N} p_{\alpha_i}$；组成相同的序列有 $\Omega = N!/\prod_\alpha N_\alpha!$ 个。这里“具体序列”与“组成类别”是两个不同事件。由 Stirling 近似，若各 $N_\alpha \gg 1$，

$$\ln \Omega \simeq -N \sum_\alpha x_\alpha \ln x_\alpha, \qquad x_\alpha = N_\alpha / N.$$

在典型组成 $x = p$ 上，每字母所需的平均二进制描述长度是 $H(p) = -\sum p_\alpha \log_2 p_\alpha$。四种碱基等概率时 $H = 2$；若只有 G、C 且各占一半，$H = 1$。这是已知组成之后的不确定性，不能把低熵序列自动称为功能更强。

相对于指定背景 q_α，数据分布 p 的可区分程度用

$$D(p\|q) = \sum_\alpha p_\alpha \ln \frac{p_\alpha}{q_\alpha}$$

衡量。$-\ln x \geq 1 - x$ 给出 $D \geq 0$，等号只在 $p = q$ 时成立。对 N 个独立字母，来自 p 的典型序列在背景 q 下的对数似然比约为 ND。因此，序列显著性依赖背景模型；GC 含量不均匀的基因组不能一律用 $q = 1/4$。

对于两位置，联合分布 $p_{\alpha\beta}$ 的互信息为 $I = \sum p_{\alpha\beta} \ln[p_{\alpha\beta}/(p_\alpha p_\beta)]$。独立性使 $I = 0$，而边缘频率相同并不足以保证这一点。后面的公开基因组计算会同时报告边缘频率与相关矩阵。

热统计中，本卷采用 $\beta = 1/(k_{\mathrm{B}}T)$。离散构象的配分函数为 $Z = \sum_i \mathrm{e}^{-\beta E_i}$，自由能 $F = -k_{\mathrm{B}}T \ln Z$，平均能量 $\langle E \rangle = -\partial_\beta \ln Z$。若能量含 $-fX$，则 $\langle X \rangle = k_{\mathrm{B}}T \partial_f \ln Z$，并且 $\partial_f \langle X \rangle = \beta \,\mathrm{Var}(X) \geq 0$。这个涨落响应关系将把链的零力构象与小力弹性连接起来。化学势控制可变粒子数时用 $E - \mu n$，不可把它和固定粒子数的自由能混用。

1.2 离散时间、连续时间与稳态的条件

离散一代的转移矩阵 $\Pi_{ij} = P(i \mid j)$ 每列和为一；连续时间的生成矩阵 Q 每列和为零。若 $\Pi(\Delta t) = I + Q\Delta t + o(\Delta t)$，则 $p(t) = \mathrm{e}^{Qt} p(0)$。$Q$ 的非对角元是率，单位为时间的倒数，而 Π 的元素是无量纲概率。后文把二者区分，是为了避免把“大于一的反应率”误判为不合法的转移概率。

有限、不可约的链有唯一正的平稳分布；连续时间中的其他模态衰减。离散链还需排除周期性，才保证每代收敛。例如两个状态每代必然互换，虽有稳态 $(1/2, 1/2)$，一个纯初态仍会永远振荡。因此，原题中“很多代后等频率”的结论需要正的混合率及非周期条件。

详细平衡是逐边条件 $Q_{ij} p^*_j = Q_{ji} p^*_i$，比 $Qp^* = 0$ 强。三态环可在所有概率不变时仍有环流：这类非平衡稳态需要外部化学驱动。若 $p^*_i \propto \mathrm{e}^{-\beta E_i}$，详细平衡给出正反率比 $Q_{ij}/Q_{ji} = \mathrm{e}^{-\beta(E_i - E_j)}$，但不决定共同的尝试频率。仅由平衡分布不能推出绝对动力学时间。

1.3 分子状态和时间尺度

活细胞中的反应物不是连续液体中的一个抽象浓度，而是一批有限、可以逐个计数的分子。若某种调控蛋白只有几十个拷贝，一次结合就会明显改变可用分子的数目。相同初始条件的两次观测也不必得到相同轨迹。统计模型要预测的是轨迹的分布，而非宣称每条轨迹都满足平均方程。

在室温附近，热能 $k_{\mathrm{B}}T$ 约为 $4.1\,\mathrm{pN\,nm}$。将分子大小取为 a，扩散系数取为 D，则扩散跨越此长度所需时间约为 a^2/D；化学反应还有独立的等待时间。只有在位置混合比反应快、外部条件在观测期间近似不变时，才可把空间自由度消去，用一个常数反应率描述状态转移。

设 $p_i(t)$ 是状态 i 的概率，$W_{ij}\ge 0$ 是从 j 到 i 的每单位时间跃迁率。小时间 Δt 内从 j 到 i 的转移概率为 $W_{ij}\Delta t+o(\Delta t)$；两次以上转移属于高阶项。收集流入与流出便得到主方程

$$\dot p_i=\sum_{j\neq i}\bigl(W_{ij}p_j-W_{ji}p_i\bigr). \tag{1.1}$$

对 i 求和时，每条边的流入与流出抵消，所以归一化保持。对角元必须是该状态全部流出率的负值，不能直接填一个独立参数。

例题 1.1 单个分子在活性态 A 与非活性态 B 间以 $A\xrightarrow{a}B$、$B\xrightarrow{b}A$ 转换。初始处于 A，求活性概率和弛豫时间。

解答. $\dot p_A=-ap_A+b(1-p_A)$，故 $p_A(t)=b/(a+b)+a\mathrm{e}^{-(a+b)t}/(a+b)$。平衡由两种方向的概率流相等确定，弛豫时间为 $(a+b)^{-1}$。这不是平均停留时间：在 A 中单次停留时间的均值是 a^{-1}。 □

若 N 个分子独立转换，活性分子数的概率是二项分布。独立性同时决定方差 $Np_A(1-p_A)$；有共享酶、竞争结合或协同反应时，不可继续套用这一方差。对 $A+B\to C$ 之类双分子反应，状态转移率还随两种反应物的拷贝数变化。

1.4 随机交配、Hardy–Weinberg 与异质度

前面的状态概率描述一个随机对象；种群遗传学则还要区分个体、配子和等位基因拷贝。一个二倍体位点有等位基因 A,a，令配子中 A 的频率为 p、a 为 $q=1-p$。若雌雄配子库频率相同、配子独立随机结合，则下一代合子的三类基因型概率为

$$P(AA)=p^2,\qquad P(Aa)=2pq,\qquad P(aa)=q^2.$$

中间的因子 2 来自母方给 A/父方给 a 与相反组合。合子中的 A 频率为 $p^2+(2pq)/2=p$，因此在没有选择、突变、迁移和有限抽样漂变时，这一分布下一代仍保持。这就是 Hardy–Weinberg 平衡。它不是所有种群的稳态定律；近亲交配、分层混合、性别频率差和选择都能使基因型比例偏离上述式子。随机交配可使给定配子频率的合子在一代达到该比例，但不能消除随后发生的等位频率变化。

异质度 $H=2pq$ 是随机取两个基因拷贝不同的概率，在 HW 条件下也等于杂合个体比例。多等位情形为 $H=1-\sum_i p_i^2$，先选第一个拷贝为 i、再选第二个同为 i 的概率相加即可得到。它测量一个位点的多样性，不能与一个

个体全基因组的杂合位点比例不加条件地互换。

在含 N 个二倍体个体的 Wright–Fisher 模型中，下一代有 $2N$ 个独立抽样的基因拷贝，$K \sim \mathrm{Bin}(2N, p)$，$p' = K/(2N)$。由 $\langle p' \rangle = p$ 和 $\mathrm{Var}(p') = pq/(2N)$，

$$\langle H' \mid p \rangle = 2\langle p'(1-p') \rangle = \left(1 - \frac{1}{2N}\right) H.$$

反复取期望给 $\langle H \rangle_t = (1 - 1/(2N))^t H_0$。等位频率的平均值不变而异质度下降，是漂变把概率逐渐推向固定/消失端点的表现；它与后面的吸收边界首次到达时间属于同一过程。这里 N 指二倍体个体数；若把 N 定义成基因拷贝数，系数应相应改为 $1 - 1/N$，不能混用。

1.5 适合度如何进入选择递推

适合度 w 表示一个基因型在指定生命史阶段对下一代配子的相对贡献，包含存活和繁殖。绝对后代数同时乘同一常数不会改变频率递推，故频率动力学依赖相对适合度。设出生时基因型为 HW 比例，而 AA, Aa, aa 的贡献分别为 $w_{AA}, w_{Aa}, w_{aa} > 0$。选择后总权重为

$$\bar{w} = p^2 w_{AA} + 2pq w_{Aa} + q^2 w_{aa}, \qquad p_s = \frac{p^2 w_{AA} + pq w_{Aa}}{\bar{w}}.$$

分子中的杂合项只有一半是 A 拷贝。减去 p 并整理，

$$p_s - p = \frac{pq}{\bar{w}} \{ p(w_{AA} - w_{Aa}) + q(w_{Aa} - w_{aa}) \}.$$

取 $w_{AA} = 1 + s, w_{Aa} = 1 + hs, w_{aa} = 1$，在弱选择 $|s| \ll 1$ 下漂移项为 $\Delta p \simeq spq[p(1-h) + qh]$。h 编码杂合贡献，并不等于该性状所有表型的显隐性结论。若 $h = 1/2$，本参数化给 $\Delta p \simeq (s/2)pq$；若用每个 A 拷贝增加 s 的另一参数化，系数会成为 s，题解必须先说明定义。

杂合优势 $w_{Aa} > w_{AA}, w_{aa}$ 时，括号可能在内点变号，确定性选择可维持多态；有限漂变仍可能越过这一屏障而导致固定。若另有 $A \to a$ 率 u、$a \to A$ 率 v，在选择与突变按此顺序发生的模型中，下一代配子频率为 $(1-u)p_s + v(1-p_s)$。再以此参数进行二项抽样，就把选择、突变与漂变连接到同一个转移核。

所谓“选择提高适合度”有条件。在简单单倍体、固定类型适合度 w_i 的一步选择中，$p_i' = p_i w_i/\bar{w}$，故选择后的平均适合度为 $\bar{w}' = \sum_i p_i w_i^2/\bar{w} = \bar{w} + \mathrm{Var}_p(w)/\bar{w}$。这是一条可直接验证的恒等式；环境变化、频率依赖、重组或随后突变会改变下一步的适合度，不能据此宣称所有演化历史的适合度单调增加。本节依据原课程种群遗传纲要补出推导，作为后续扩散方程的生物学入口。

1.6 连续极限与遗传漂变

随机繁殖提供另一个离散模型。取一个固定大小为 N 的单倍体种群，当前等位基因频率为 x。下一代独立抽样，则拷贝数 $m \sim \mathrm{Bin}(N, x)$，$\Delta x = m/N - x$ 满足 $\langle \Delta x \rangle = 0$ 和 $\langle (\Delta x)^2 \rangle = x(1-x)/N$。没有选择优势仍会出现频率漂移，因为一次有限抽样不等于其期望。

将转移核对小频率增量展开，并以一代为时间单位，二阶连续近似给出

$$\partial_t p = -\partial_x [A(x)p] + \tfrac{1}{2}\partial_x^2 [B(x)p], \qquad B(x) = \frac{x(1-x)}{N}. \tag{1.2}$$

这里 A 是每代平均频率变化，B 是每代频率变化的方差，而不是通常写成 $2D$ 之后的 D。中性模型 $A=0$。$x=0,1$ 是吸收态：失去的等位基因不能由纯抽样重新产生。连续密度的积分会下降，失去的质量转移到边界的概率原子，不能把它误判为概率不守恒。

设 $u(x)$ 为最终固定到 1 的概率。从第一步条件期望 $u(x)=\langle u(x+\Delta x)\rangle$ 展开，得到后向方程 $Au'+Bu''/2=0$。中性情形与边界 $u(0)=0, u(1)=1$ 给出 $u(x)=x$。平均吸收时间 T 的第一步式为 $T(x)=1+\langle T(x+\Delta x)\rangle$，因此

$$\frac{x(1-x)}{2N}T''=-1,\qquad T(x)=-2N[x\ln x+(1-x)\ln(1-x)].$$

积分常数由两个吸收边界确定，$x\ln x\to 0$ 保证极限有限。若是二倍体且 N 指个体数，应把基因拷贝数改为 $2N$；不同教材中的因子二常来自这一约定。

1.7 突变、选择与稳态

对称突变率 μ 加入漂移 $A=\mu(1-2x)$。零概率流稳态满足 $Ap-(Bp)'/2=0$，积分后为 $p_*(x)\propto[x(1-x)]^{2N\mu-1}$。当 $2N\mu<1$ 时密度在两端高，但只要 $\mu>0$，边界奇性仍可积；它反映种群常常几乎单型，而不意味着已经永久吸收。选择优势 s 又加入 $sx(1-x)$，稳态多出因子 e^{2Nsx}。

用数据反推 $N\mu$ 时必须考虑取样数量、低频变异漏检以及人群历史。将两个群体的直方图差异直接解释为一种生物机制，超出了这个平稳、恒定种群模型。8.592J 的相关公开数据可用于讨论这些限制，本卷没有把未经拟合的数据比较写成已经取得的实验结论。

1.8 从有限种群核得到连续方程

Wright–Fisher 抽样并不是上一节独立分子转换的重复：每代的所有后代从同一个上一代频率抽样，因而累积漂变。若含突变或选择，下一代抽样参数为 $q(x)=x+A(x)+\cdots$，转移核

$$K(m\mid x)=\binom{N}{m}q(x)^m[1-q(x)]^{N-m}$$

给出新的频率 m/N。对光滑检验函数 g 展开 $\langle g(x+\Delta x)\rangle-g(x)$，有 $Ag'+Bg''/2$；将导数移到概率密度上便得到式(1.2)。这解释前向算子与后向算子为什么不同，却描述同一随机过程。

展开要求单代变化小、所考察频率尺度大于 $1/N$，并且高阶矩项可忽略。很近吸收边界时离散态仍是更可靠的表示；强选择、一次突变很多位点或瓶颈事件也可能破坏扩散近似。把不同机制都叫作“随机噪声”会遮蔽这些适用条件。

设 $A=\mu_+(1-x)-\mu_-x+sx(1-x)$，$B=x(1-x)/N$。概率流 $J=Ap-(Bp)'/2$；零流条件积分为

$$p_*(x)=\frac{C}{B(x)}\exp\!\left[\int^x\frac{2A(y)}{B(y)}\,\mathrm{d}y\right]=C'x^{2N\mu_+-1}(1-x)^{2N\mu_--1}\mathrm{e}^{2Nsx}.$$

在 $s=0$ 时它是 Beta 分布，平均值 $\mu_+/(\mu_++\mu_-)$。密度的边界峰来自漂变，峰的左右不对称来自突变或选择；仅一个形状不能唯一识别机制。这里 N 是基因拷贝数，和采用二倍体个体数的课源因子保持对应。

1.9 固定事件与条件平均时间

吸收区间 $[a,b]$ 上，固定到右边的概率 u 解 $Au' + Bu''/2 = 0$。令 $\Psi(x) = \exp[-\int^x 2A/B\,\mathrm{d}y]$，一次积分给出

$$u(x) = \frac{\int_a^x \Psi(y)\,\mathrm{d}y}{\int_a^b \Psi(y)\,\mathrm{d}y}.$$

对常数选择 $A = sx(1-x)$，边界 $0,1$，结果为 $u = (1-\mathrm{e}^{-2Nsx})/(1-\mathrm{e}^{-2Ns})$；$s \to 0$ 恢复 x。优势增加固定概率，但一个新突变仍可能因抽样失去。

前面给出的 $T(x)$ 是到任一吸收边界的时间。若只统计最后固定到 1 的样本，先定义带事件权重的 $g(x) = \langle\rangle x[\tau\,\mathbf{1}_{\{X_\tau=1\}}]$。第一步分解给出 $Ag' + Bg''/2 = -u$，$g(0) = g(1) = 0$，条件时间为 $T_1 = g/u$。中性时 $u = x$，积分得到

$$g(x) = -2N(1-x)\ln(1-x), \qquad T_1(x) = -\frac{2N(1-x)}{x}\ln(1-x).$$

相反事件的加权函数是 $h = -2Nx\ln x$，且 $T = g + h$。这个恒等式是有用的核对：$uT_1 + (1-u)T_0 = T$，不允许把两个条件时间直接相加。$x \to 0$ 时条件固定时间趋于 $2N$，而无条件时间趋零；稀有的成功轨迹与大量很快失败的轨迹解释了差异。

1.10 酶反应的平均与涨落

若 n 为活性分子数，减少率 an、增加率 $b(N-n)$，主方程与所选 PS1.5 一致。对它乘 n 求和得到 $\mathrm{d}\langle n\rangle/\,\mathrm{d}t = -a\langle n\rangle + b(N - \langle n\rangle)$。因为率对 n 线性，平均方程在此处精确闭合。再乘 n^2 可检验二项方差；非线性双分子反应的平均方程一般含 $\langle n_A n_B\rangle$，不能未经说明替成 $\langle n_A\rangle\langle n_B\rangle$。

以 $E + S \rightleftarrows ES \to E + P$ 为编者桥接模型，若酶复合物快速弛豫且总酶浓度固定，$\dot{c}_{ES} \simeq 0$ 给出 $c_{ES} = E_0 c_S/(K_M + c_S)$、$K_M = (k_{-1} + k_2)/k_1$、产物速率 $v = k_2 E_0 c_S/(K_M + c_S)$。这一 Michaelis–Menten 形式需要时间尺度分离；少量酶分子的随机占据、起始瞬态以及底物明显耗尽都应回到状态模型。这里的桥接推导用于说明怎样选择粗粒化变量，不冒充未下载的额外讲次。

2 序列比较与极值统计

2.1 比对中的物理信息

DNA 字母顺序保存了历史信息，但相同片段也可能偶然出现。一个得分函数必须同时描述匹配收益、替换代价和插入删除代价。设两条序列为 $a_1\cdots a_n$、$b_1\cdots b_m$，替换得分 $s(a_i,b_j)$，每个空位罚分 $g>0$。全局比对得分 F_{ij} 是两个前缀的最优得分，递推为

$$F_{ij}=\max\{F_{i-1,j-1}+s(a_i,b_j),F_{i-1,j}-g,F_{i,j-1}-g\}.$$

边界 $F_{i0}=-ig,F_{0j}=-jg$。最后一步只可能匹配两个末字母、删除第一个末字母或删除第二个末字母；删除该步后必须留下最优子问题，否则能以更优前缀改善当前结果。这一论证说明递推为何确实枚举全部可允许路径。

局部比对允许任何位置开始和结束，所以递推再与 0 取最大，边界也置零。最终从全矩阵最大元回溯，而全局比对从 F_{nm} 回溯。得分并列时必须保留并列前驱；只返回一个回溯路径不意味着比对唯一。空位开罚与延长罚不同的模型需要额外状态，本式不包含这种仿射罚分。

同源关系还需要统计显著性检验。评分越高不一定越可靠，因为搜索数据库越大，随机产生一次高分的机会也越大。将得分转成一个不考虑数据库大小的百分数，会丢失此处最重要的比较条件。

2.2 从接受替换计数构造 PAM 矩阵

一个氨基酸替换评分需要两个问题：相关序列在指定进化距离下如何产生一对残基；随机背景下这一对残基有多常见。PAM 的起点是高相似、可可靠比对的同源蛋白及其系统发育关系，从近距离资料推断接受替换，减少把多个隐藏替换误当成一次变化的风险。“接受” 指在观察到的演化序列中保留下来的变化，不等于实验直接测到的所有瞬时突变。

采用行向量频率约定，M_{ij} 表示祖先残基 i 一步后变成 j 的条件概率，$\sum_j M_{ij}=1$。令背景频率为 $f_i>0$，从计数得到对称的无对角交换流 $c_{ij}=c_{ji}\ge 0$。一个便于说明构造的可逆模型为

$$M_{ij}=\lambda c_{ij}/f_i\quad(i\neq j),\qquad M_{ii}=1-\lambda\sum_{j\neq i}c_{ij}/f_i.$$

对角项补足未替换的概率，λ 还须使所有对角项非负。因为 $f_iM_{ij}=\lambda c_{ij}=f_jM_{ji}$，此构造满足详细平衡，f 是稳态。历史 PAM 估计还使用残基可变性和谱系校正；这里给出其 “计数、归一化、未变化概率、背景稳态” 的统计结构，未杜撰原课程没有给出的二十乘二十经验表。

PAM1 把一个步骤定标成平均每 100 个残基一次接受替换，即 $\sum_i f_i(1-M_{ii})=.01$。在时间齐次 Markov、各位点使用同一替换核的近似下，PAMn 的条件核为 M^n。距离 n 是累计接受替换的期望尺度；PAM250 不表示 250% 的可观察残基不同。一个位点可多次变化甚至变回原类型，直接差异会饱和。

同源模型的成对概率为 $Q_{ij}^{(n)}=f_i(M^n)_{ij}$，独立背景为 f_if_j。于是对数优势评分为

$$S_{ij}^{(n)}=\log\frac{Q_{ij}^{(n)}}{f_if_j}=\log\frac{(M^n)_{ij}}{f_j}.$$

可按所选底数、尺度取整，必须把约定与缺口罚分一起保存。可逆性保证 Q 对称，故相应替换评分对称，虽然条件矩阵 M 通常不对称。低频残基的匹配在背景下更罕见，因而相同匹配概率可以得到更高分；这正是直接把身份匹配全部给同一分值会丢失的信息。零计数应使用明确的先验/伪计数，不能凭一次样本的零观察断言该替换绝不可能。

附带代码用两种符号的教学核演示这一过程：$f=(.7,.3)$，平衡交换流均为 .005，得到

$$M=\begin{pmatrix} 1-.005/.7 & .005/.7 \\ .005/.3 & 1-.005/.3 \end{pmatrix}.$$

它满足平均一步变化率.01 和 $fM=f$。M^{100} 的差异概率已明显低于 1，而累计接受替换尺度为 1；更长距离趋向各行均为 f，使同源成对分布趋于随机背景、优势评分趋于零。这一教学例子检验矩阵约定，不冒充真实蛋白的 PAM100 数值。随后 BLAST 的种子搜索与显著性估计使用替换评分，但搜索算法本身不等于 PAM 模型。

2.3 高斯最大值与 Gumbel 极限

设 r_i 独立，分布函数为 F，最大值 $M_N=\max_i r_i$。事件 $M_N\le x$ 等价于全部 $r_i\le x$，因而 $P(M_N\le x)=F(x)^N$。高分端用尾概率 $\overline{F}=1-F$ 表示，若 $N\overline{F}$ 有限，则 $(1-\overline{F})^N\simeq\exp(-N\overline{F})$。

对零均值、标准差 σ 的高斯分布，分部积分给出 $\overline{F}(x)\sim\sigma\mathrm{e}^{-x^2/(2\sigma^2)}/(\sqrt{2\pi}x)$。选中心 b_N 使 $N\overline{F}(b_N)=1$，尺度 $a_N=\sigma^2/b_N$。在 $x=b_N+a_Nz$ 附近，平方指数的一阶变化为 z，而尾部前因子相对变化趋零，因此

$$P\!\left(\frac{M_N-b_N}{a_N}\le z\right)\longrightarrow\exp(-\mathrm{e}^{-z}).$$

主尺度 $b_N\sim\sigma\sqrt{2\ln N}$，但 $\ln\ln N$ 修正影响有限数据拟合。最可能值、均值和分位点也相差 $O(a_N)$，不可在有限样本中一概等同。最小能量对应 $-M_N$，符号翻转后尾部方向必须一起翻转。

2.4 局部高分的尾部尺度

无空位比对可看成随机得分增量的部分和。若平均增量为负，路径通常向下，却偶尔达到较高正值。令 $\lambda>0$ 满足 $\langle\mathrm{e}^{\lambda s}\rangle=1$，则 $\mathrm{e}^{\lambda S_n}$ 是均值保持的乘法过程。越过高度 S 的概率因而具有 $\mathrm{e}^{-\lambda S}$ 的指数尺度，越界细节影响前因子。把约 nm 个搜索起点合并，高分累计分布常近似为 $\exp[-Knm\mathrm{e}^{-\lambda S}]$，相应期望高分次数为 $Knm\mathrm{e}^{-\lambda S}$。

这个推导解释 λ 和数据库长度的位置，但没有证明任意有空位、相关序列都服从同一公式。低复杂度序列、周期性疏水模式以及相关数据库条目会破坏独立背景。实际检索中的背景校正与数据库版本必须记录。

2.5 得分为何应比较似然

设同源模型中字母对概率为 $p(a,b)$，随机背景为 $q(a)q(b)$。一个独立列的证据是对数似然比 $s(a,b)=\ln[p(a,b)/(q(a)q(b))]$；累积证据相加，因而自然得到比对总分。空位率可通过状态转移概率引入，这也解释仿射空位罚分为什么需要“刚开空位”与“延长空位”两种状态。整数打分只是将这些实数按比例取整的模型近似，不能从任意罚分直接声称概率校准。

局部检索要让随机背景的平均分为负，否则一条足够长的随机路径也倾向累积正分，局部高分的稀有事件图像不成立。以原题等概率 DNA 为例，$P(s=1)=1/4$、$P(s=0)=1/4$、$P(s=-\mu)=1/2$，平均为 $1/4-\mu/2$，所以

必须 $\mu > 1/2$。原题把 transition/transversion 的英文标签与通常生物命名反置；本卷保留题面分组并标出这一点，数值概率没有依赖这个命名差异。

2.6 指数倾斜与显著性尺度的条件

定义 $M(\lambda) = \langle \mathrm{e}^{\lambda s} \rangle$。$M(0) = 1$，$M'(0) = \langle s \rangle < 0$，而只要存在正分，$M(\lambda)$ 在大 λ 增长；凸性保证有唯一正根 $M(\lambda) = 1$。把每次步进概率改为 $p_\lambda(s) = p(s)\mathrm{e}^{\lambda s}$ 后，其归一化成立，稀有向上的原随机路径变成倾斜分布中的典型路径。原路径到达高度 S 的权重多出约 $\mathrm{e}^{-\lambda S}$；过冲与路径重复计数进入 K。

若期望超过得分 S 的随机片段数为 $E = Knm\mathrm{e}^{-\lambda S}$，Poisson 稀有事件近似给“至少一个”为 $1 - \mathrm{e}^{-E}$。$E \ll 1$ 时它约等于 E，$E = 1$ 时却为约 0.632；因此 E 值是期望次数，不能总当概率。也不能在数据库扩充之后沿用旧的显著性数值而不更新 m。

2.7 高斯极值的有限样本修正

令 $L = \ln N$，由 $N\overline{F}(b_N) = 1$ 保留尾部的 $1/b_N$ 因子，得到

$$b_N = \sigma\left[\sqrt{2L} - \frac{\ln L + \ln(4\pi)}{2\sqrt{2L}} + o(L^{-1/2})\right], \qquad a_N = \frac{\sigma^2}{b_N}.$$

Gumbel 标准变量的均值为 Euler 常数 γ、方差 $\pi^2/6$，所以 $\langle M \rangle_N \simeq b_N + \gamma a_N$，标准差约 $\pi a_N/\sqrt{6}$。最可能值约 b_N。在蛋白结合能问题中，若单构象方差随链长 N 增长而构象数指数增长，则最低能量为 $O(N)$，宽度为 $O(1)$；这里宽度小的原因是两个不同的 N 依赖相消，而非普通中心极限定理直接给出。

对高度相关的能量，不能机械地把所有构象数塞进独立极值公式。环移位相互共享接触、相邻蛋白构象共享链段，可能有成簇极端值。所补同源/异源二聚体题会明确采用原题的独立高斯近似，并指出它不能只由单个接触方差推出。

2.8 有限温路径和零温动态规划

仅找一个最优比对相当于保留最高分路径；有限温模型对所有允许路径求统计和。令路径分数 $S(\mathcal{P})$，形式逆温度 $\beta_a > 0$ 控制偏爱高分的程度，$Z_{ij} = \sum_{\mathcal{P}:(0,0)\to(i,j)} \mathrm{e}^{\beta_a S(\mathcal{P})}$。按末一步分解，

$$Z_{ij} = \mathrm{e}^{\beta_a s(a_i, b_j)} Z_{i-1,j-1} + \mathrm{e}^{-\beta_a g} Z_{i-1,j} + \mathrm{e}^{-\beta_a g} Z_{i,j-1}.$$

$Z_{00} = 1, Z_{i0} = \mathrm{e}^{-\beta_a g i}, Z_{0j} = \mathrm{e}^{-\beta_a g j}$。这是二维路径的转移算子；沿一个方向逐列推进时，另一方向的 Z 组成向量。若空位开/延长代价不同，应按匹配 M、上空位 I、下空位 D 构成带内部状态的转移矩阵，单一 Z 递推不能保存空位历史。

定义有限温有效分数 $F^{(\beta_a)} = \beta_a^{-1} \ln Z$，递推右端成为 log-sum-exp。对三个值 x_k，$\max x_k \le \beta_a^{-1} \ln \sum \mathrm{e}^{\beta_a x_k} \le \max x_k + \ln 3/\beta_a$，所以 $\beta_a \to \infty$ 恢复最大值动态规划，有限温保留近优路径的熵。若有 g_* 条最高分路径，$\ln Z = \beta_a S_* + \ln g_* + o(1)$，次阶项能区分简并数量。

局部比对还需定义开始、结束路径的权重；添加重新开始的单位项只是一个具体配分函数选择，其零温极限产生与零取最大。形式温度 β_a^{-1} 是算法参数，不是 DNA 所在溶液温度。课源用有限温路径将统计力学与算法相连，

本节保留这条推导而不把得分温度解释成实测热量。

3　水溶液中的静电作用

3.1　Bjerrum 长度和屏蔽

生物分子常带电，但在水中的电荷作用不能按真空库仑力估计。采用 SI 单位，两个单位电荷的能量为 $e^2/(4\pi\epsilon r)$；定义 Bjerrum 长度 $\ell_B = e^2/(4\pi\epsilon k_{\mathrm{B}}T)$，使这一能量等于 $k_{\mathrm{B}}T$。讲义源文有时把 4π 吸收到介电常数中，本册用 ℓ_B 表示结果以免混淆。水中室温典型值约 $0.7\,\mathrm{nm}$，而它不是所有溶剂通用的常数。

对价态 z_α、体相密度 n_α^0 的可移动离子，平均场局部平衡给出 $n_\alpha(\mathbf{r}) = n_\alpha^0 \mathrm{e}^{-\beta z_\alpha e\phi}$。与 Poisson 方程结合便得到 Poisson–Boltzmann 方程。若 $|\beta z_\alpha e\phi| \ll 1$，在电中性的体相附近线性化有

$$(\nabla^2 - \kappa_D^2)\phi = -\frac{\rho_{\mathrm{fixed}}}{\epsilon}, \qquad \kappa_D^2 = \frac{e^2}{\epsilon k_{\mathrm{B}}T}\sum_\alpha z_\alpha^2 n_\alpha^0 .$$

点电荷的球对称解为 $\phi = q\mathrm{e}^{-\kappa_D r}/(4\pi\epsilon r)$。盐越多，屏蔽长度 $\lambda_D = \kappa_D^{-1}$ 越短。接近高电荷表面、强关联多价离子或分子尺度时，线性化和连续平均场都可能失效。

3.2　无盐平面双电层

取负表面电荷密度 $-\sigma\,(\sigma>0)$，溶液在 $y>0$，只有价态 $z>0$ 的反离子。定义 $u = \beta z e[\phi(y)-\phi(0)]$。Boltzmann 分布 $n = n_0\mathrm{e}^{-u}$ 和 Poisson 方程给 $u'' = -\beta z^2 e^2 n_0 \mathrm{e}^{-u}/\epsilon$。满足远处电场趋零的解是

$$u(y) = 2\ln(1 + y/\mu), \qquad n(y) = \frac{1}{2\pi z^2 \ell_B (y+\mu)^2}, \qquad \mu = \frac{e}{2\pi z \ell_B \sigma}.$$

边界 $E(0) = -\sigma/\epsilon$ 确定 μ，其中 $E = -\phi'$ 指向负膜。积分 $ze\int_0^\infty n\,\mathrm{d}y = \sigma$ 核查整体电中性。这种密度按幂律衰减，和有盐的指数屏蔽不同；将它随意用在含体相盐的溶液中是不一致的。

3.3　线电荷与反离子凝聚

离子位于半径 $a<r<R$ 的柱形区域，线电荷吸引产生能量 $2\zeta k_{\mathrm{B}}T\ln(r/a)$。径向面积元 $2\pi r\,\mathrm{d}r$ 与 Boltzmann 权重共同给出径向概率 $p_r(r) \propto r^{1-2\zeta}$。因此决定凝聚的是能量与二维径向熵的竞争，而非仅仅“势能在无穷远增加”。归一化积分在 $R\to\infty$ 时当且仅当 $\zeta>1$ 有限。

写线电荷数密度为 n，则 $\zeta = zn\ell_B$。Manning 图像假定部分反离子凝聚，使剩余有效线电荷达到 $zn_{\mathrm{eff}}\ell_B = 1$，故凝聚电荷比例为 $1-1/\zeta$。它是长、均匀、细线电荷的近似；有限长度、离子关联和有限盐浓度需要更细模型。其有限容器推导和径向矩的不同阈值在所选原题解答中给出。

3.4　电离平衡与介电环境

带电基团是否电离由化学自由能和溶剂决定。最简反应 $AH \rightleftarrows A^- + H^+$ 的平衡常数 $K_a = a_{A^-}a_{H^+}/a_{AH}$ 使用无量纲活度。稀溶液近似活度等于浓度与标准浓度之比，可得 $[A^-]/[AH] = 10^{\mathrm{pH}-\mathrm{p}K_a}$。表面有电势时，质子局部

浓度还带 Boltzmann 因子；因而把真空中离开一对电荷的库仑能当作水中酸度并不成立。

水的高介电常数降低电荷能，但连续介质在离子半径内不能外推到 $r=0$。一个半径 a 的离子放入介电介质，充电模型给自能尺度 $q^2/(8\pi\epsilon a)$。更换溶剂的差值能说明离子进入水相的偏好，但半径、局部溶剂结构和化学键能都影响精确值。本节重建源讲义电离讨论的物理链，不使用来源中的第三方分子图片。

3.5 Poisson–Boltzmann 的自由能推导

把固定电荷密度 ρ_f 与移动离子密度 n_α 合并。电场能为 $\frac{1}{2}\int \rho\phi\,\mathrm{d}^3r$，理想混合熵项为 $k_\mathrm{B}T\sum_\alpha \int n_\alpha[\ln(n_\alpha/n_\alpha^0)-1]\,\mathrm{d}^3r$。对 n_α 变分时电场能的变化为 $z_\alpha e\phi\,\delta n_\alpha$，所以驻点条件给 $n_\alpha = n_\alpha^0 \mathrm{e}^{-\beta z_\alpha e\phi}$。再代入 $-\epsilon\nabla^2\phi = \rho_f + \sum z_\alpha e n_\alpha$ 才得到 PB 方程。离子相关在此平均场自由能中没有被计算。

对称 1:1 盐密度各为 n_s，令 $\psi = \beta e\phi$，平面区方程为 $\psi'' = \kappa_D^2 \sinh\psi$。乘 ψ' 并利用无穷远 $\psi=\psi'=0$，得 $(\psi')^2 = 2\kappa_D^2(\cosh\psi - 1)$。一阶积分的解可写成

$$\tanh\frac{\psi(y)}{4} = \tanh\frac{\psi(0)}{4}\,\mathrm{e}^{-\kappa_D y}.$$

远场总恢复指数衰减，但近表面可能不线性。带符号表面电荷 σ_s 与边界 $-\epsilon\phi'(0)=\sigma_s$ 给 Grahame 关系

$$\sigma_s^2 = 8\epsilon k_\mathrm{B}T n_s \sinh^2\frac{\psi(0)}{2}.$$

它说明高表面电势并不与表面电荷保持简单线性关系。

3.6 无盐平面解的积分与压力核对

无盐方程中 $u'' = -C\mathrm{e}^{-u}$。乘 u' 后积分，远处电场为零使 $(u')^2 = 2C\mathrm{e}^{-u}$。取 $u(0)=0$、向溶液方向 $u'>0$，积分为 $\mathrm{e}^{u/2} = 1 + \sqrt{C/2}\,y$，故 $\mu = \sqrt{2/C}$。这样既得到正文密度，也看到 n_0 不是可任意指定的体相密度，它由表面电荷和整体中性共同确定。

平面体系法向总压力 $P = k_\mathrm{B}T\sum n_\alpha - \epsilon E^2/2$ 为常数。单面无盐远处 $P=0$，表面接触密度满足 $k_\mathrm{B}Tn(0) = \sigma^2/(2\epsilon)$。两相同带电膜之间中点 $E=0$，所以排斥压力等于中点渗透压。这是检查原题两板解的独立方法，且不需要把两个孤立单板解直接叠加；PB 是非线性方程，叠加一般不成立。

3.7 有限容器与凝聚极限的次序

柱形离子的径向归一化积分 $I = (R^{2-2\zeta} - a^{2-2\zeta})/(2-2\zeta)$，在 $\zeta=1$ 应取极限 $I=\ln(R/a)$。所谓凝聚过渡是先讨论 $R/a\to\infty$ 的分布：$\zeta>1$ 时有限半径内留住非零概率；$\zeta\le 1$ 时概率向容器尺度扩散。但平均半径的分子是 $\int r^{2-2\zeta}\,\mathrm{d}r$，要到 $\zeta>3/2$ 才收敛。因此“已经凝聚”与“平均半径有限”是不同阈值。将每个矩的阈值分别计算，比只凭一条曲线认定相态可靠。

裸 DNA 电荷间距 b 给 $\zeta = z\ell_B/b$。在 Manning 有效电荷近似下，剩余电荷比例 $1/\zeta$；对于多价离子这只是长线平均场的估计。多价离子的局部桥接、强关联甚至电荷反转都超出本文模型，不能用简单凝聚比例代替这些机制。

4 链构象与弹性

4.1 随机链和熵弹簧

一条柔性链由 N 段长度 a 的独立、各向同性键组成。端到端向量 $\mathbf{R}=\sum_{i}\mathbf{a}_i$，交叉项平均为零，所以 $\langle R^2\rangle = Na^2$。当 $N\gg 1$、延伸远小于轮廓长 Na 时，各分量的中心极限定理给出高斯构象密度

$$P_0(\mathbf{R})=\left(\frac{3}{2\pi N a^2}\right)^{3/2}\exp\!\left(-\frac{3R^2}{2Na^2}\right).$$

取 $-k_{\mathrm{B}}T\ln P_0$ 得到自由能中的二次项 $3k_{\mathrm{B}}TR^2/(2Na^2)$。这个弹簧来自可用构象数减少，刚度随温度增加；它不同于一根金属弹簧的键能伸缩。

拉力 $F\hat{z}$ 引入能量 $-FR_z$。配平方可得 $\langle R_z\rangle = Na^2F/(3k_{\mathrm{B}}T)$。若需要接近完全拉直，应从单键角分布计算，得到自由连接链的 Langevin 函数

$$\frac{\langle R_z\rangle}{Na}=\coth(\beta Fa)-\frac{1}{\beta Fa}.$$

这是对每个键积分 $\int \mathrm{e}^{\beta Fa\cos\theta}\,\mathrm{d}\Omega$ 后对 F 求导的结果。小力展开恢复高斯弹簧，大力趋于 1，不会像高斯模型那样无限延伸。

4.2 排除体积和尺度

好溶剂中的单体不能互相穿透。用第二维里系数 $v>0$ 表示排斥，大小 R 的链平均单体密度为 N/R^d。两体排斥自由能估计为 $k_{\mathrm{B}}TvN^2/R^d$，与熵弹性相加：

$$\frac{F(R)}{k_{\mathrm{B}}T}\sim\frac{R^2}{Na^2}+\frac{vN^2}{R^d}.$$

对 R 最小化给 $R\sim N^{3/(d+2)}$；三维指数约 3/5，是尺度近似而非精确证明。上临界维数 $d=4$ 以上恢复理想链指数 1/2。差溶剂中 v 变负，两体项单独会导致塌缩，必须加入正的三体项稳定有限密度，不能继续用好溶剂公式。

处于拉力 F 下的自回避链可按“张力团块”分组。团块大小 $\xi=k_{\mathrm{B}}T/F$，内部尚不感受拉力，$\xi\sim ag^{\nu}$；链有 N/g 个团块，大尺度排列沿力方向，所以 $X\sim(N/g)\xi\sim Na(Fa/k_{\mathrm{B}}T)^{1/\nu-1}$。适用窗口是零力链大小远大于 ξ 且 $\xi\gg a$；达到键尺度后必须转向饱和模型。

4.3 弯曲链与持久长度

DNA 在几十纳米尺度内不能自由折角。用弧长 s、单位切向量 $\mathbf{t}(s)$ 描述轮廓长 L 的不可伸长链，弯曲能为 $H_b=\kappa\int_0^L|\partial_s\mathbf{t}|^2\,\mathrm{d}s/2$。三维 WLC 模型定义持久长度 $\ell_p=\kappa/(k_{\mathrm{B}}T)$，切向关联为 $\langle\mathbf{t}(s)\cdot\mathbf{t}(0)\rangle=\mathrm{e}^{-s/\ell_p}$。对两次弧长积分有

$$\langle R^2\rangle = 2\ell_pL-2\ell_p^2(1-\mathrm{e}^{-L/\ell_p}).$$

$L\ll\ell_p$ 时近似刚棒，$L\gg\ell_p$ 时等效随机链的 Kuhn 长度是 $2\ell_p$。

在强拉力、弱弯曲近似中，两个横向方向的 Fourier 模有能量 $(\kappa q^2+F)|\theta_q|^2/2$。由等分配积分得到 $1-X/L\simeq\frac{1}{2}\sqrt{k_{\mathrm{B}}T/(F\ell_p)}$。此式只给强拉力渐近；常用的整段插值不是从此渐近式严格推出的精确 WLC 解。原题中的蛋白诱

导局部弯折会提供一个额外、可分离的延伸亏损。

4.4 真实链如何得到等效节段

化学键不是每一步都任意转向。旋转异构体模型把键角与二面角的允许状态离散化，由传递矩阵记录相邻局部状态的统计权重。若简化为各键的方向相关 $\langle \mathbf{a}_i \cdot \mathbf{a}_{i+k}\rangle = a^2 c^k$，$|c|<1$，则

$$\langle R^2\rangle = a^2\left[N + 2\sum_{k=1}^{N-1}(N-k)c^k\right] \simeq Na^2\frac{1+c}{1-c} \quad (N \gg (1-|c|)^{-1}).$$

所谓有效链长不是把化学键改长，而是将局部相关吸收到较大的 Kuhn 节段。若轮廓长为 Na，等效 Kuhn 长为 $a_K = a(1+c)/(1-c)$；节段数为 Na/a_K，两者乘积仍保持轮廓长。具有很长相关时，必须等到尺度超过相关长度才可用高斯模型。

回转半径定义为 $R_g^2 = N^{-1}\sum_i \langle|\mathbf{r}_i - \mathbf{r}_{\mathrm{cm}}|^2\rangle = (2N^2)^{-1}\sum_{ij}\langle|\mathbf{r}_i-\mathbf{r}_j|^2\rangle$。独立理想链中 $\langle|\mathbf{r}_i-\mathbf{r}_j|^2\rangle = a^2|i-j|$，求和给大 N 极限 $R_g^2 = Na^2/6$。端到端长度与回转半径不能在散射实验解释中互换而忽略因子六。

4.5 WLC 的方向扩散与强力响应

WLC 构象权重为 $\exp[-\ell_p\int|\partial_s\mathbf{t}|^2\,\mathrm{d}s/2]$，可看成单位球面上沿弧长的方向扩散，生成元为 $\nabla^2_{S^2}/(2\ell_p)$。球谐函数 $l=1$ 模的衰减率是 $1/\ell_p$，所以方向相关是 e^{-s/ℓ_p}。这从能量权重解释正文相关式，并说明三维与二维定义可能差因子二。

强力下令横向切线为两分量 $\boldsymbol{\theta}$，$t_z \simeq 1-|\boldsymbol{\theta}|^2/2$。去掉常数 $-FL$ 后，二次 Hamilton 量为 $\frac{1}{2}\int[\kappa|\boldsymbol{\theta}'|^2 + F|\boldsymbol{\theta}|^2]\,\mathrm{d}s$。长链可用连续波数，单分量方差

$$\langle\theta_x^2\rangle = k_{\mathrm{B}}T\int_{-\infty}^{\infty}\frac{\mathrm{d}q}{2\pi(\kappa q^2+F)} = \frac{k_{\mathrm{B}}T}{2\sqrt{\kappa F}}.$$

两个分量合并后 $1-X/L = \langle|\boldsymbol{\theta}|^2\rangle/2 = k_{\mathrm{B}}T/(2\sqrt{\kappa F})$。这要求 $L \gg \sqrt{\kappa/F}$、横向角小，并忽略骨架伸长；非常大力下真实 DNA 的焓弹性不能忽略。

4.6 从单体相互作用到维里展开

设两个单体的短程势为 $U(r)$，Mayer 函数 $f_M(r) = \mathrm{e}^{-\beta U(r)} - 1$。有效排除体积 $v = -\int f_M(r)\,\mathrm{d}^d r$ 对纯排斥为正，对吸引增强时减小。低密度自由能展开的相互作用部分为 $k_{\mathrm{B}}T[v\rho^2/2 + w\rho^3/6 + \cdots]V$；其中 $w>0$ 可稳定差溶剂下的塌缩。

把一条链近似放进大小 R 的均匀体积，得到 $\beta F \sim R^2/(Na^2) + vN^2/(2R^d) + wN^3/(6R^{2d})$。好溶剂保留前两项，驻点 $R^{d+2} \sim va^2N^3$。若此式在 $d>4$ 给出的指数小于理想链 $1/2$，表明相互作用不改变理想尺度，应恢复 $1/2$，不能继续外推成受排斥反而缩小。

差溶剂中 $v<0$，大链内部密度由后两项平衡，数量级 $\rho \sim |v|/w$，所以 $R \sim N^{1/d}$。表面还损失接触并产生界面自由能，影响有限链的塌缩与成核。$v=0$ 附近是 θ 条件，理想链尺度恢复但三体项和有限链修正仍存在。这把热统计中的相互作用展开与几何尺度真正连接起来。

4.7 张力团块为何给非线性指数

一个团块内的热涨落能约 $k_{\mathrm{B}}T$；力在其尺度上做功 $F\xi$，相等定义 ξ。团块包含 $g \sim (\xi/a)^{1/\nu}$ 个单体，链有 N/g 个团块，故 $X \sim Na(Fa/k_{\mathrm{B}}T)^{1/\nu-1}$。这一中等力关系两端有不同机制：当 $\xi \gtrsim aN^{\nu}$ 时，应回到各向同性零力构象的线性响应；当 $\xi \lesssim a$ 时，团块内部已无尺度区间，应由单键饱和描述。所谓“强力”在尺度论中通常只是相对整链热尺度强，并非可以令 $F \to \infty$。

5 蛋白折叠与能量景观

5.1 从氨基酸序列到二级和三级结构

蛋白的一级结构是氨基酸序列，序列同时决定主链几何和侧链相互作用。肽键近似平面，主链仍可绕两类键改变二面角 ϕ, ψ；空间排斥使它们不能任意独立取值。因此二级结构不是在一条无结构直线上加标签，而是反复出现的局部主链几何及氢键排列。α 螺旋约每圈 3.6 个残基，主链第 i 位羰基与第 $i+4$ 位的 N–H 形成规则氢键；β 片层则由伸展链段之间的氢键联结，链段可平行或反平行。转角和无规则区也有受几何限制的构象，不能把“无规则”解释成没有相互作用。

三级结构是这些局部单元在空间中的整体排列及远程接触，包括疏水核心、表面极性基团和功能口袋。不同序列可以保留相似整体折叠，同源与相似结构也不是同一证据。螺旋中相邻残基每步绕轴约 100 度，因而两亲性螺旋的疏水残基有约 3–4 位的周期；片层侧链交替朝两侧，可出现约 2 位的疏水周期。这把序列相关分析与结构联系起来，但周期信号本身不足以唯一确定结构。

5.2 氢键、疏水塌缩与溶剂自由能

主链和侧链间的静电、氢键、色散及排斥共同限制构象。色散吸引可在远距离近似为 $-C_6/r^6$，短程电子云重叠给强排斥；简化 LJ 形式有一个最优距离，真实角度和化学环境仍影响相互作用。氢键具有方向性和受体/供体几何要求，因此比各向同性接触模型更容易稳定螺旋与片层。

在水中形成一根蛋白内部氢键时，原有蛋白–水和水–水氢键也在重排。不能只给新氢键一个负能量、却忽略脱溶剂代价。疏水效应同样不是两个“疏水粒子”之间多出一条真空基本力：非极性表面改变周围水的可用状态，聚集减少暴露面积并改变溶剂的自由能。一个粗略有效模型以 $G_{\mathrm{solv}} \simeq \gamma A_{\mathrm{exposed}}$ 描述较大尺度的暴露代价；γ 和适用尺度取决于温度、溶剂与几何，不是所有原子尺度接触共享的常数。

把溶剂自由度积分掉后，某构象坐标 q 的有效自由能由 $\mathrm{e}^{-\beta G(q)}$ 与给定 q 附近所有蛋白和溶剂状态的统计权重决定。它包含链构象熵和溶剂贡献，不等于一张接触表的势能。疏水塌缩先减少链的空间体积和暴露面积，却可能形成许多紧密误折叠态；正确二级结构、侧链堆积和特异性接触再决定天然态的优势。后面的 HP 模型和 REM 各自保留其中部分机制，不能被理解成完整的水溶液力场。

5.3 Anfinsen 热力学假说与 Levinthal 时间问题

Anfinsen 对核糖核酸酶的变性、还原及复性实验支持：在适宜的化学环境下，特定序列可重新到达有活性的天然结构，序列包含决定该结构的重要信息。可表述为天然构象族在给定溶剂、温度和化学约束下具有较低自由能。这里的约束包括氧化还原状态、配体等；这一论断不等于每条蛋白在任意条件下都能无辅助迅速折叠，也不排除动力学陷阱、聚集、伴侣蛋白和亚稳构象。

Levinthal 问题强调另一侧。假定 N 个残基各有 m 种独立构象选择，朴素状态数为 m^N。作为数量级示意，$N=100, m=3$ 给约 5×10^{47} 种；即使每 10^{-12} 秒独立试一个状态，枚举也需约 5×10^{35} 秒。这里的 m 与尝试时间只是说明指数增长的教学假设，不是实测折叠速率。有限时间折叠说明运动不是无偏穷举，而受局部结构、协同接触、能量下降及中间态引导。

因此热力学问题是天然态能否胜过竞争构象族，动力学问题是从典型初态到它是否有可达路径和不过高的势垒。漏斗景观把两者联系起来，但不要求每个微观步都降低自由能：热运动仍可回退、进入陷阱；多个反应坐标和溶剂摩擦影响实际时间。接下来 REM 比较态数与能隙，首次逃逸公式计算势垒代价，两段模型分别回答这两个问题。本节按原课程结构、分子作用力和折叠纲要补出连接，不冒称纲要之外存在未取得的详细 PDF。

5.4 构象数和随机能量模型

氨基酸序列确定相互作用，但一条链有指数多种构象。低能构象是否能在热涨落中保持优势，取决于能量与构象熵的竞争。随机能量模型把不同紧密构象的能量视为独立高斯变量。这一独立性忽略真实构象间相关性，却能分清“有最低能量”和“能稳定折叠到特定结构”两件事。

设构象数 $\Omega=\mathrm{e}^{Ns_0/k_\mathrm{B}}$，能量方差 $\Sigma^2=Nu^2$。能量 E 附近的平均构象数正比于 $\Omega\mathrm{e}^{-E^2/(2\Sigma^2)}$，所以微正则熵为 $S(E)=k_\mathrm{B}\ln\Omega-k_\mathrm{B}E^2/(2\Sigma^2)$，只在 $S\geq0$ 的区间可信。低能截断为 $E_c=-\Sigma\sqrt{2\ln\Omega}$。以 $F=E-TS$ 最小化，鞍点 $E_*(T)=-\Sigma^2/(k_\mathrm{B}T)$；当它越过截断，真实能量停在 E_c，不能继续把负的构象熵当作实际态数。

冻结温度为 $k_\mathrm{B}T_c=\Sigma/\sqrt{2\ln\Omega}$。高温自由能 $F_\mathrm{mis}=-k_\mathrm{B}T\ln\Omega-\Sigma^2/(2k_\mathrm{B}T)$，低温为 E_c。对一个设计良好的序列，另有唯一的天然态 $E_N<E_c$。比较 E_N 与 F_mis 能确定折叠温度：过低的天然能量开出能隙，降低误折叠态竞争。序列设计使用的“温度”是挑选序列的统计参数，不是细胞的实际温度。

5.5 折叠动力学和势垒

自由能最低并不保证快速抵达。以构象坐标 q 的有效自由能 $G(q)$ 描述折叠，过阻尼随机运动满足 $\dot q=-MG'(q)+\sqrt{2Mk_\mathrm{B}T}\,\eta(t)$，其中 M 为迁移率，白噪声满足 $\langle\eta(t)\eta(t')\rangle=\delta(t-t')$。相应概率流是 $J=-M(G'p+k_\mathrm{B}Tp')$；零流分布为 $p\propto\mathrm{e}^{-\beta G}$，这也核对噪声强度。

对高势垒 $\Delta G\gg k_\mathrm{B}T$，逃逸时间的主指数为 $\mathrm{e}^{\beta\Delta G}$。指数可从准平衡势阱权重与势垒附近稀有概率的比值看出；更精确的 Kramers 前因子还依赖势阱和势垒曲率及阻尼机制。不能仅据一个自由能差写出绝对折叠时间。多个中间态、陷阱和并行路径会破坏单指数弛豫。

一个可检验的两态模型令未折叠和已折叠概率分别为 p_U,p_F，速率 k_f,k_u。$\dot p_F=k_f(1-p_F)-k_up_F$，弛豫率为 k_f+k_u，平衡折叠比例 $k_f/(k_f+k_u)$；详细平衡要求 $k_f/k_u=\mathrm{e}^{-\beta(G_F-G_U)}$。平衡比例能约束速率比，不能独立确

定两个速率。这里的动力学解释是对课程主题的编者补充，不冒称缺少详细 PDF 的折叠讲次逐页翻译。

5.6 REM 的态密度、冻结和比热

高斯态密度的指数部分可写 $\rho(E) \asymp \exp[N s_0/k_{\mathrm{B}} - E^2/(2Nu^2)]$。用 $Z = \int \rho(E) \mathrm{e}^{-\beta E}\,\mathrm{d}E$，高温鞍点要求 $E_* = -\beta N u^2$ 仍在允许区间。此时 $F/N = -T s_0 - u^2/(2k_{\mathrm{B}}T)$，$\langle E\rangle/N = -u^2/(k_{\mathrm{B}}T)$，熵 $S/N = s_0 - u^2/(2k_{\mathrm{B}}T^2)$，比热 $C/N = u^2/(k_{\mathrm{B}}T^2)$。在 T_c 熵降到零，低温分支不能继续使用高温鞍点。

有限 N 的态数是离散整数，最低能量周围仍有样本涨落；“熵为零”指热力学极限中每单体的构象熵消失，并非体系真的只保留一个数学状态。真实蛋白紧密构象也有共享接触相关，REM 所预测的尖锐冻结不应未经检验就解释为实验玻璃温度。

引入天然态 $E_N = -N\epsilon_N$ 后，令 $F_{\mathrm{mis}} = E_N$。高温分支等式等价于

$$s_0 T_f^2 - \epsilon_N T_f + \frac{u^2}{2k_{\mathrm{B}}} = 0.$$

它可能有两个代数根，但只有 $T_f \geq T_c$ 的那一根属于所用分支；低温误折叠自由能已固定为 E_c。天然能量不足以低于 E_c 时不能靠选一个无效根制造稳定折叠。设计能隙与动力学可达性仍是两个条件。

5.7 序列设计的统计系综

保持目标构象的接触几何不变，从随机序列的天然能量分布 $p_0(E_N) \propto \exp[-E_N^2/(2\Sigma_N^2)]$ 出发。以设计参数 β_d 按 $\mathrm{e}^{-\beta_d E_N}$ 挑选序列，完成平方得到

$$p_d(E_N) \propto \exp\!\left[-\frac{(E_N + \beta_d \Sigma_N^2)^2}{2\Sigma_N^2}\right].$$

因此设计把平均天然能量降低为 $-\beta_d\Sigma_N^2$，方差在这个简单模型中不变。β_d 是选择序列的强度，不是测量蛋白所在溶液的 β。能量越低的选择也可能改变误折叠能量分布，因为不同构象接触并非独立；这一步独立 REM 近似必须另行说明。

晶格 HP 模型把单体简化为疏水 H/亲水 P，非相邻的 H–H 近邻接触给负能量，链构象满足自避免。它保留“疏水接触与构象数竞争”的机制，却删除二十种氨基酸、侧链取向和溶剂细节。找到最低能量后还应检查是否简并：只有一个低能构象族才有天然态特异性；大量同能构象不能凭低总能量称为成功设计。课程相关页面列出了该主题，详细 PDF 未公开，本段是明示的编者桥接模型。

5.8 首次逃逸积分与 Kramers 近似

过阻尼坐标的扩散常数 $D_q = M k_{\mathrm{B}}T$。势阱左端 a 反射、右端 b 吸收时，平均逃逸时间满足 $D_q T'' - M G' T' = -1$，$T'(a) = 0, T(b) = 0$。乘积分因子 $\mathrm{e}^{-\beta G}$ 后积分得到

$$T(x) = \frac{1}{D_q}\int_x^b \mathrm{e}^{\beta G(y)}\,\mathrm{d}y \int_a^y \mathrm{e}^{-\beta G(z)}\,\mathrm{d}z.$$

若内层积分在势阱极小点 q_m 主导、外层在势垒顶 q_b 主导，二次展开与高斯积分给出越过完整势垒的过阻尼结果：

$$T \simeq \frac{2\pi}{M\sqrt{G''(q_m)\,|G''(q_b)|}}\,\mathrm{e}^{\beta[G(q_b) - G(q_m)]}.$$

若吸收边界恰设在势垒顶，只含半个外层高斯，前因子可差二；若惯性不可忽略，又需另一个阻尼区间的理论。用公式时先说明边界和坐标的迁移率，才具有可复核的绝对时间。

6　核酸的解链与二级结构

6.1　DNA 中的环熵

双链 DNA 的每段配对有结合权重 w^{ℓ}，熔解气泡由两条单链连接同样的两个端点。对理想三维随机链，返回原点的概率按 $\ell^{-3/2}$ 衰减；更一般的环权重写成 $B(\ell)=As^{\ell}/\ell^{c}$。指数 c 包含环内和环外的排除体积效应，不能把三维高斯值用于所有 DNA 模型。

令总长度的共轭变量为 z，有 $\widetilde{R}(z)=\sum_{\ell\ge 1}(wz)^{\ell}=wz/(1-wz)$，$\widetilde{B}(z)=A\sum_{\ell\ge 1}(sz)^{\ell}/\ell^{c}$。双链段与气泡交替排列，几何级数给出的主体分母是 $1-\widetilde{R}\widetilde{B}$；两端的规定只改变分子。自由能密度由最靠近原点的正实奇点 z_{*} 决定，$f=k_{\mathrm{B}}T\ln z_{*}$。

低温时奇点是 $\widetilde{R}\widetilde{B}=1$ 的极点，高温时由气泡级数的收敛边界 $z=1/s$ 控制。若 $c\le 1$，环和在边界发散，极点不在有限参数下撞到边界；若 $1<c\le 2$，环和有限但平均环长发散，配对比例连续趋零；若 $c>2$，平均环长有限，比例可以跳变。这一分类来自 $\sum \ell^{-c}$ 与 $\sum \ell^{1-c}$ 的收敛性质，而非把一维系统简单等同于有无相变。

6.2　RNA 配对递推

单链 RNA 允许内部配对。在不考虑假结的模型中，一段配对不能与另一段交叉。这不是全部真实 RNA 结构，而是一类可递推求和的二级结构。令 Z_{ij} 为从 i 到 j 的分段配分函数，末端 j 或未配对，或与 k 配对。若配对权重为 q_{kj}，最小环长为 h，则

$$Z_{ij}=Z_{i,j-1}+\sum_{k=i}^{j-h-1} Z_{i,k-1}\,q_{kj}\,Z_{k+1,j-1},\qquad Z_{i,i-1}=1.$$

因为禁止交叉，k,j 内部和左侧区间可以独立求和。递推输出全构象统计权重，和只求最低能量的算法不同。真实能量还包括堆叠、环长、盐浓度等参数；本式的简单权重适合解释算法结构，不能直接当作实际 RNA 预测器。

6.3　拉力与核酸解链

力控制条件下，应使用 $G=H-FX$，而固定延伸时应使用 Helmholtz 自由能。两种系综中的稳定条件相互关联，但跳变区间的观测方式不同。DNA 的气泡可以承受某些拉伸几何下的两链载荷；RNA 内部配对团块则常被建模为不承受骨架拉力。这使两种解链的配分函数出现相似的交替结构，却有不同的力权重。

设不配对骨架段 $P(\ell)=g^{\ell}\exp[\beta^{2}F^{2}a^{2}\ell/6]$，配对团块 $R(\ell)=Af^{\ell}/\ell^{3/2}$。在 $z_{c}=1/f$ 处，团块和有限但导数发散。当极点撞到此边界时，开始连续解链。所选原题中给出临界力、线性起始奇性和此高斯链近似的适用范围。DNA 受力模型的完整相界在追加原题 PS6.2 中推导；旧在线 RNA 服务任务仍未取得可复算结果。

6.4 交替段的生成函数与配对比例

设两端均为双链段，则构象的生成函数为 $\widetilde{Z}=\widetilde{R}/(1-\widetilde{R}\widetilde{B})$；改变端点只改变解析的端因子。一个长链的系数由最小正奇点控制，$Z_N\sim z_*^{-N}$。结合权重 w 的导数计算平均配对单体数，故比例

$$\theta=\lim_{N\to\infty}\frac{1}{N}w\partial_w\ln Z_N=-w\partial_w\ln z_*.$$

在极点分支对 $\ln\widetilde{R}+\ln\widetilde{B}=0$ 隐式微分，可把它写成 $\theta=\langle\ell_R\rangle/(\langle\ell_R\rangle+\langle\ell_B\rangle)$。其中段长平均来自 $z\partial_z\ln\widetilde{R}$、$z\partial_z\ln\widetilde{B}$。这解释为什么平均气泡长度发散会使配对比例消失。

令 $\delta=1-sz$。对 $1<c<2$，$\widetilde{B}(1/s)-\widetilde{B}(z)\propto\delta^{c-1}$，而杆段在临界附近解析。控制参数偏离 t 因此满足 $t\propto\delta^{c-1}$，平均气泡长度 $\langle\ell\rangle_B\propto\delta^{c-2}$，从而

$$\theta\propto t^{(2-c)/(c-1)}.$$

理想环 $c=3/2$ 给线性起始。$c=2$ 边界具有对数修正；$c>2$ 时均值有限，配对比例跳变；$c\le1$ 没有同样的有限临界撞击。这些推导假设各环相互独立，真实排除体积改变 c 的含义。

6.5 熔融 RNA 的闭合求和

在不分序列、每对权重为 q 的模型中，令长度 n 的配分函数为 Z_n，$Z_0=Z_1=1$。末端或空着，或与前面一个点配对，给

$$Z_n=Z_{n-1}+q\sum_{k=0}^{n-2}Z_kZ_{n-2-k}.$$

生成函数 $G(z)=\sum_{n\ge0}Z_nz^n$ 满足 $G=1+zG+qz^2G^2$。选择 $z\to0$ 时有限的根，

$$G(z)=\frac{1-z-\sqrt{(1-z)^2-4qz^2}}{2qz^2},\qquad z_c=(1+2\sqrt{q})^{-1}.$$

最近奇点是平方根，系数渐近 $Z_n\sim A(q)(1+2\sqrt{q})^n n^{-3/2}$。从这个精确生成函数能独立得到 3/2 指数，无需采用原讲义被移除的第三方图。

也可把结构画成非负“山形路径”：未配对一步水平，配对两端各为上/下一步且权重 $\sqrt{q}$。无约束回到原点的随机游走概率按 $n^{-1/2}$；把曾走到 -1 的路径在首次越界前反射，和从 -2 起步回到零的路径一一对应。两高斯权重相减多一个 n^{-1}，所以指数成为 3/2。反射原理在这里不是随意删掉一半路径，而是一个确定的双射。

由 $q\partial_q\ln Z_n/n$ 得每单体的配对数为 $\sqrt{q}/(1+2\sqrt{q})$，所以已配对单体比例为 $2\sqrt{q}/(1+2\sqrt{q})$。一对占两个单体，两种计数必须区分。$q=1$ 时模型仍有 2/3 单体配对，这来自模型允许的零能配对熵，并不代表高温真实 RNA 也有此比例。

6.6 发夹熔解与受力 DNA

偏爱天然发夹中的配对，可给天然对权重 $\bar{q}>q$。天然段与熔融段交替，熔融段的 $n^{-3/2}$ 权重将问题化为前述 PS 型模型，因此天然配对比例连续且线性消失。这是忽略非天然序列差异的 Gō 模型；一般异质 RNA 能量景观不由单一发夹模型覆盖。

DNA 被两端拉时，一段长度 $a\ell$ 的刚杆方向积分是 $\sinh(h\ell)/(h\ell)$，$h=\beta Fa$。双链杆权重 w^{ℓ} 乘此因子。两条单链环各自高斯位移且共享端点，乘积位移密度与 $\mathrm{e}^{\beta\mathbf{F}\cdot\mathbf{R}}$ 积分给环力权重 $\mathrm{e}^{h^2\ell/12}$，不是单链的 $\mathrm{e}^{h^2\ell/6}$。后一因子差二来自两条链共同约束。补充原题 PS6.2 会把这个结果用于完整模型相界，区分它和可伸长 WLC 真实 DNA 的相界。

7 识别、搜索与 DNA 弯折

7.1 结合概率与序列信息

一个转录因子必须在大量背景位点中找到少数调控位点。设结合能为 E，蛋白化学势为 μ，两态配分函数 $1+\mathrm{e}^{-\beta(E-\mu)}$ 给出占据概率 $p_{\mathrm{occ}}=1/[1+\mathrm{e}^{\beta(E-\mu)}]$。降低能量或提高浓度都能提高占据，但二者不能只靠一条占据曲线完全区分。

若各位置近似独立，结合序列分布为 $P(\mathbf{b})=\prod_i p_i(b_i)$，背景为 $P_0=\prod_i q(b_i)$，对数似然比分数为 $S(\mathbf{b})=\sum_i \ln[p_i(b_i)/q(b_i)]$。其平均 $I=\sum_{i,b} p_i(b)\log_2[p_i(b)/q(b)]$ 是相对信息量，单位为比特。零频率必须用明确的伪计数处理，否则一条新序列的分数可能被任意置为负无穷。

统计权重矩阵并不自动等于物理结合能：若假设序列选择服从有效演化温度 T_*，才可设 $E=-k_{\mathrm{B}}T_*S+$ 常数。$T_*=T$ 是额外模型假设。序列相关、基因位置和调控环境还会影响实际功能，不能把所有高分片段当作已经验证的生物位点。

7.2 lac、CRP 与 RNA 聚合酶的多状态招募

单一位点的占据只回答“蛋白是否结合”；基因表达还依赖哪些蛋白能同时结合、它们之间是否相互促进，以及聚合酶占据是否启动转录。lac 系统提供一个入口：LacI 阻遏蛋白抑制转录，CRP 结合可促进 RNA 聚合酶招募，诱导物改变活性阻遏蛋白的比例。原课程相关页面实际列出 lac 阻遏、CRP 激活和聚合酶招募，本节用明示的最小状态模型连接这些机制。

令 p、c、r 分别为 RNA 聚合酶 P、活性 CRP C、活性阻遏蛋白 R 的无量纲结合活度，如 $p=[P]/K_P$。假定 R 与 P 相互排斥，R 与 C 可独立共存，C 与 P 同时结合有额外作用能 ϵ_{CP}，权重因子 $\omega=\mathrm{e}^{-\beta\epsilon_{CP}}$。相容状态及权重为

状态	$\varnothing$	P	C	R	RC	CP
权重	1	p	c	r	rc	ωcp

RP 与 RCP 在所假设几何中不允许。逐状态求和给

$$Z=(1+r)(1+c)+p(1+\omega c),\qquad P_{\mathrm{pol}}=\frac{p(1+\omega c)}{Z}.$$

吸引作用 $\epsilon_{CP}<0$ 使 $\omega>1$；把分子分母同时除以 $1+c$，可见 C 把有效聚合酶活度提高为 $p(1+\omega c)/(1+c)$。当 $\omega=1$ 时，C 独立结合的权重从占据率中消去，不能仅因“CRP 已结合”就宣布表达上升。增大 r 增加无聚合酶状态权重而压低转录，减小 r 则解除阻遏。

在绑定弛豫比转录和 mRNA 降解快、聚合酶结合后的起始率近似相同的情形，可写 $\dot{m} = k_{\mathrm{tr}} P_{\mathrm{pol}} - \gamma_m m$，稳态 $m_* = k_{\mathrm{tr}} P_{\mathrm{pol}}/\gamma_m$。转录本身消耗化学能，这里只有快速结合状态采用准平衡统计；不能把整个细胞转录循环说成热平衡。若起始速率也受 CRP 影响，应对每个含 P 状态分别加速率权重，而不是只改占据概率。

诱导物可使 LacI 转为不易结合 DNA 的状态，故 r 应写成总 LacI 浓度乘活性分数。一个供比较的经验形式为 $r = r_{\max}/[1 + (L/K_L)^h]$，参数 h 与 MWC 机制或拟合假设分开说明；CRP 活度也取决于 cAMP 结合和其活性构象。这样改变糖源与诱导物通过不同入口改变 c 和 r，能够产生联合调控。附带教学计算取 $p = .1, \omega = 20$，逐状态核对不同 c、r 下的 P_{pol}；它不是某菌株的实测表达曲线。

实际 lac 有多个操纵位点和 DNA 环化。一个 LacI 四聚体同时桥接两位点时，环化态权重只支付一次分子的化学势，再乘有效局部浓度和弯曲代价；不能把这一态误写成两个独立分子的 r^2。两个独立 LacI 占据与一个桥接分子是不同状态，必须分别列入 Z。序列特异性决定结合能，DNA 弯曲改变环化代价，因而本章的序列信息和下一段弹性模型共同进入调控统计。

7.3 三维扩散和一维滑动

球形蛋白直径 d，黏度 η，Stokes–Einstein 关系给 $D_3 = k_{\mathrm{B}}T/(3\pi\eta d)$。这把热运动与同一阻力 $3\pi\eta d$ 联系起来，需要稀溶液、连续黏性流体近似。细胞拥挤介质中的有效扩散可能依赖尺度。

蛋白在 DNA 停留 τ_1，在溶液重新定位耗时 τ_3，一次一维滑动探索的长度尺度为 $\ell \sim \sqrt{D_1 \tau_1}$。若每次重定位近似独立，则在总轮廓长 L_g 上搜索时间 $t \sim (L_g/\ell)(\tau_1 + \tau_3)$。最小化得到 $\tau_1 = \tau_3$。过短停留反复支付三维寻找代价，过长停留则浪费在已扫过的区间。

真实一维随机游走的已访问区间长度有不同的数值前因子；本式是明确采用的尺度模型。若解离后以概率 p 回到原处，就必须把多次局部滑动视作同一有效扫描阶段。搜索时间的 p 依赖由所选原题给出，不能把所有跳跃都当成独立重新抽样。

7.4 蛋白诱导弯折

局部结合的蛋白可以改变 DNA 方向。设 DNA 在外力 $F\hat{x}$ 下，切线与 x 轴夹角为 $\theta(s)$，能量

$$H[\theta] = \int \left[\frac{\kappa}{2} (\theta')^2 - F \cos\theta \right] \mathrm{d}s.$$

变分给出 $\kappa\theta'' = F \sin\theta$。小角时曲线从局部角度 θ_0 按 e^{-s/ℓ_F} 衰减，$\ell_F = \sqrt{\kappa/F}$。相应延伸亏损 $\int (1 - \cos\theta)\,\mathrm{d}s$ 按 $F^{-1/2}$ 缩小，额外能量按 $F^{1/2}$ 增大；因此足够大的力可以驱使蛋白脱离。实际脱离还受动力学势垒控制，静态能量相等给的是热力学估计。



7.5 反应速率与平衡亲和力

设自由蛋白浓度为 c_P，可用位点为 c_D，复合物为 c_{PD}，$\dot c_{PD}=k_a c_P c_D-k_d c_{PD}$。在自由蛋白近似恒定且总位点 $D_0=c_D+c_{PD}$ 时，占据率 $p=c_{PD}/D_0$ 满足 $\dot p=k_a c_P(1-p)-k_d p$。因此 $p_*=c_P/(c_P+K_d)$、$K_d=k_d/k_a$，弛豫率 $k_a c_P+k_d$。同样的 K_d 可以由很快或很慢的两种率产生，平衡亲和力并不直接等于识别时间。

若只问第一位蛋白到达一个未占据位点，早期结合是吸收事件；其典型时间约 $1/(k_a c_P)$。若只问一位蛋白找到许多目标中的任意一个，则时间约 $1/(k_a c_D)$。两种叙述中的浓度不能交换。源讲义早期时间式附近有浓度符号不一致，本卷采用具体事件定义核对量纲。

7.6 吸收球的通量与反应受限边界

在半径 b 的目标外、R 的容器内求稳态 $\nabla^2 c=0$，$c(b)=0, c(R)=c_R$。球对称解 $c=c_R(1-b/r)/(1-b/R)$，总吸收通量为 $4\pi D_3 b c_R/(1-b/R)$，故大容器中 $k_a=4\pi D_3 b$，单位体积/时间。换为摩尔浓度需要乘 Avogadro 常数和升与立方米的转换，不能把 $\mathrm{m^3/s}$ 原值直接标成 $\mathrm{M^{-1}s^{-1}}$。

完美吸收表示每次接触都成功。若表面本征反应速度为 k_s，边界为 $D_3 c'(b)=k_s c(b)$，通量积分可得

$$\frac{1}{k_a}=\frac{1}{4\pi D_3 b}+\frac{1}{4\pi b^2 k_s}.$$

两项像串联阻力：扩散受限与反应受限的等待都存在。核对限值 $k_s\to\infty$、$D_3\to\infty$ 比单记一个速率常数更能避免错误。

7.7 滑动范围、更新过程与多人并行

一维 Brown 运动时长 t 的平均已访问范围是 $4\sqrt{D_1 t/\pi}$，它和末端均方位移的平方根 $\sqrt{2D_1 t}$ 不同。若解离时间为指数分布，平均时长 τ_1，再对范围平均得到 $2\sqrt{D_1\tau_1}$。DNA 轮廓长为 L_g，一次随机重新定位命中比例 $q\simeq 2\sqrt{D_1\tau_1}/L_g$。

每轮耗时虽与其命中概率相关，但首步更新式 $t_s=\langle\tau_1\rangle+\tau_3+(1-\langle q\rangle)t_s$ 给

$$t_s=\frac{L_g}{2\sqrt{D_1\tau_1}}(\tau_1+\tau_3),\qquad \frac{\mathrm{d}t_s}{\mathrm{d}\tau_1}\propto\frac{\tau_1-\tau_3}{2\tau_1^{3/2}}.$$

因此最优 $\tau_1=\tau_3$ 是此独立重新定位模型的精确最优条件。若多数解离只是回原处，轮与轮不独立，要用有效扫描阶段；若靶点已占据、各蛋白相互阻挡或 DNA 有不均匀可达性，亦需修改。

若单人搜索时间近似指数且 n_p 个蛋白独立，最快到达时间的存活概率为 $\prod_j \mathrm{e}^{-t/t_s}=\mathrm{e}^{-n_p t/t_s}$，平均 t_s/n_p。并行加速来自独立性；一个共同的限速激活步骤不能因多放蛋白就缩短为 $1/n_p$。

7.8 弯曲变分的边界条件

对 $H[\theta]$ 的变分，边界项是 $[\kappa\theta'\delta\theta]$。固定结合角时 $\delta\theta=0$；自由端力矩为零时应设 $\theta'=0$。二者对应不同物理装置。无穷长一侧、固定局部角 θ_0、远处平行于力的弱角解为 $\theta=\theta_0\mathrm{e}^{-s/\ell_F}$。

相对于直链的额外能量为 $\int[\kappa\theta'^2/2+F\theta^2/2]\,\mathrm{d}s=\theta_0^2\sqrt{\kappa F}/2$，延伸亏损为 $\theta_0^2\ell_F/4$。$-\partial_F$ 作用在最小 Gibbs 能的完整 $-FL$ 项上给 X，可检查这两个式子的符号。若 DNA 在蛋白两侧各形成一段尾巴，两个贡献相加；不声明

几何就给脱离力，可能差四。

8　丝状聚合物与分子马达

8.1　生长、缩短和动态失稳

细胞骨架并非静止支架。聚合末端可以添加或失去单体，整个链长是随机过程。固定增长率 a、缩短率 b 的最简模型若允许长度从 1 开始，在长度 1 处禁止进一步缩短，则稳态可归一化的条件是 $a<b$，几何分布 $p_\ell=(1-a/b)(a/b)^{\ell-1}$。当 $a>b$ 时概率向大长度迁移，不存在此半无限状态空间上的归一化稳态。

微管还在快速生长态与快速缩短态间切换。令灾变率 α、恢复率 γ，增长速度 $v_+>0$、缩短速度的大小 $v_->0$。长期处于两态的比例为 $\pi_+=\gamma/(\alpha+\gamma)$、$\pi_-=\alpha/(\alpha+\gamma)$，有效漂移

$$v=\frac{\gamma v_+-\alpha v_-}{\alpha+\gamma}.$$

速度涨落的关联按 $\mathrm{e}^{-(\alpha+\gamma)t}$ 衰减，方差幅度是 $\pi_+\pi_-(v_++v_-)^2$。将速度关联对时间积分得到附加扩散 $D_{\mathrm{switch}}=\alpha\gamma(v_++v_-)^2/(\alpha+\gamma)^3$。这说明即使每种状态内部没有随机位移，随机切换也会产生长期扩散。

8.2　马达的内部循环

分子马达消耗 ATP 等化学燃料沿丝前进。一轮步进距离为 d，若要通过 m 个独立等速率 u 的内部阶段，等待时间是 m 个指数变量之和，均值 m/u、方差 m/u^2。更新过程给出 $v=du/m$、$D=d^2u/(2m^2)$，所以随机度 $r=2D/(dv)=1/m$。低随机度支持多个限速阶段，但有分支、逆步和非指数等待时，不能直接把 $1/r$ 当作精确内部状态数。

有逆向跃迁的循环须满足局部详细平衡。一轮前后速率乘积比通常含化学驱动力与负载功之差：

$$\ln\frac{\prod_i u_i}{\prod_i w_i}=\beta(\Delta\mu-Fd).$$

零平均速度的停滞力可反映这一比值，然而停滞也可能仍有无效耗能循环。平均速度为零不等于整个系统热平衡。

8.3　趋化与随机游动

大肠杆菌的奔跑和翻滚使方向不断更新。每段奔跑时长 t_r、速度 v，随后的翻滚时长 t_t，新方向均匀抽取。在 d_s 个空间维度中，不同奔跑位移交叉平均为零，因此长期

$$D=\frac{v^2\langle t_r^2\rangle}{2d_s(\langle t_r\rangle+\langle t_t\rangle)}.$$

这里出现二阶矩，而非仅平均奔跑时间，因为长奔跑对位移平方贡献更大。若沿营养梯度的方向平均奔跑时间稍长，每轮的位移期望不再为零，便出现漂移。将 $\tau_r(\hat n)=\tau_0+g\hat n\cdot\hat z$ 代入 $\langle\hat n(\hat n\cdot\hat z)\rangle=\hat z/d_s$，得到 $v_{\mathrm{drift}}=vg/[d_s(\tau_0+\tau_t)]$。局部营养感知的时间记忆是更细的机制，不能由此简化模型直接证明。

8.4 微管长度分布与边界再注入

增长/缩短态长度密度满足

$$\partial_t p_+ = -\alpha p_+ + \gamma p_- - v_+ \partial_x p_+,$$

$$\partial_t p_- = \alpha p_+ - \gamma p_- + v_- \partial_x p_-.$$

此处 v_- 为正的缩短速率大小。总长度流为 $J = v_+ p_+ - v_- p_-$。若到零处立即重新进入增长态，边界要求零净流；若微管消失或有独立成核，则另有吸收/源项，不能沿用相同稳态。

零流稳态令 $p_+/p_- = v_-/v_+$，代回得到 $p_\pm = C_\pm \mathrm{e}^{-\lambda x}$，

$$\lambda = \frac{\alpha v_- - \gamma v_+}{v_+ v_-}, \qquad \langle x \rangle = \lambda^{-1}.$$

要求 $\lambda > 0$，等价于无限直线上的长期漂移为负。值得注意：有限长度边界稳态的增长/缩短态比例是速度比，而不是无限空间中仅内部切换的 γ/α；到零再注入改变了时间占据。把两种比值混用会破坏零流条件。

8.5 随机切换产生扩散

在远离边界的长时间极限，内部指示变量 $I_+(t)$ 的均值为 π_+，协方差 $\pi_+\pi_- \mathrm{e}^{-(\alpha+\gamma)|t|}$。速度 $V = (v_+ + v_-) I_+ - v_-$。位移涨落方差

$$\operatorname{Var} X(t) = 2 \int_0^t (t-s) \langle \delta V(s) \delta V(0) \rangle \, \mathrm{d}s \simeq 2t \frac{\alpha\gamma (v_+ + v_-)^2}{(\alpha+\gamma)^3}.$$

这个推导保留内部状态弛豫修正；只把每态概率代成瞬时平衡再相加通常会漏掉二阶扩散项。下面的马达模型也有同样问题。

8.6 帽的片段化与灾变时间

若 GTP 帽只在末端加长、在后边界水解，帽长像漂移扩散过程，正漂移会无限长大，不能解释更复杂的灾变观测。源讲义引入每单位长度水解率 r：长度 x 的帽被任意内部水解事件截短，损失率 rx，来自更长帽的生成率为 $r \int_x^\infty p(y) \, \mathrm{d}y$。

$$\partial_t p = -v \partial_x p + D_c \partial_x^2 p - r x p + r \int_x^\infty p(y) \, \mathrm{d}y.$$

定义尾积分 $P(x) = \int_x^\infty p(y) \, \mathrm{d}y$，对上式积分得到 $\partial_t P = -v P' + D_c P'' - r x P$。这一步把非局部项变成局部方程，而不是忽略片段化。

在富含单体、$v > 0$ 且先忽略 D_c 时，稳态 $P_* = \mathrm{e}^{-r x^2/(2v)}$，所以 $p_* = (rx/v) \mathrm{e}^{-r x^2/(2v)}$，平均帽长 $\sqrt{\pi v/(2r)}$。小扩散使概率穿过零帽长，首阶灾变率约 $D_c r/v$；它是对漂移主导稳态的扰动结果，并非所有参数下精确。

换到贫单体溶液，$v < 0$。从足够长初帽开始，能够在时刻 t 前导致灾变的水解事件构成 (x, τ) 平面面积 $|v| t^2/2$ 的三角域。Poisson 无事件概率为 $\mathrm{e}^{-r|v|t^2/2}$，故

$$p_{\mathrm{cat}}(t) = r|v| t \mathrm{e}^{-r|v|t^2/2}, \qquad \langle t \rangle_{\mathrm{cat}} = \sqrt{\frac{\pi}{2r|v|}}.$$

它不依赖原帽长，前提是初帽足以覆盖这段事件域；短帽仍会受初始边界影响。这是利用随机几何解释等待时间分布的例子。

8.7 两态马达的准确长时统计

记轨道步长 d，内部状态 T、D，T 到同格 D 率为 d_0、到右格 D 率为 r；D 到同格 T 率为 u、到左格 T 率为 l。内部总弛豫率 $S=u+d_0+r+l$。倾斜矩阵的非对角元为 $u+l\mathrm{e}^{-kd}$ 与 $d_0+r\mathrm{e}^{kd}$，最大特征值 $\Lambda(k)$ 是位移累积量生成率，其方程

$$\Lambda^2+S\Lambda-ru(\mathrm{e}^{kd}-1)-ld_0(\mathrm{e}^{-kd}-1)=0.$$

在 $k=0$ 求导，得到

$$v=\frac{d(ru-ld_0)}{S},\qquad D=\frac{d^2(ru+ld_0)}{2S}-\frac{d^2(ru-ld_0)^2}{S^3}.$$

最后负项描述等待时间与内部状态的相关。原讲义先作瞬时局部平衡后给出的扩散表达一般不等于此精确长时 D，所选 PS8 题解已采用倾斜生成元复核，并在 QA 记录此差异；漂移式则一致。

8.8 化学功、停滞与力的不同定义

一周期净化学自由能 $\Delta\mu$ 与反负载功 Fd 决定循环亲和力 $\mathcal{A}=\beta(\Delta\mu-Fd)=\ln(ru/(ld_0))$。紧耦合单循环的停滞条件为 $\mathcal{A}=0$，给 $F_s=\Delta\mu/d$。若有无位移耗 ATP 的旁路，停滞时仍可消耗燃料，不能从零速度推导零耗散。

定义 $F_E=k_{\mathrm{B}}Tv/D$ 是将马达数据套进平衡粒子的 Einstein 关系得到的比较尺度。主动马达一般不在平衡线性响应区，此值不自动等于真实外力或最大负载；应明确采用准确的 D 或近似的 D。功率为 $P=Fv$，停滞点功率为零，最大功率通常位于更小负载。热力学效率 $Fv/(J_{\mathrm{ATP}}\Delta\mu)$ 还需独立知道耗燃料通量，不能只由 v,D 唯一推出。

8.9 细胞游动的低 Re 极限与 scallop 定理

分子马达把化学功变为内部运动，但整个细胞怎样在水中前进，还取决于流体响应。细胞尺度 a、速度 U、流体黏度 η 与密度 ρ 给 $Re=\rho Ua/\eta$。当它小、形变周期长于黏性扩散时间 $\tau_\nu=\rho a^2/\eta$，忽略流体惯性得到瞬时 Stokes 方程

$$-\nabla p+\eta\nabla^2\mathbf{u}=0,\qquad \nabla\cdot\mathbf{u}=0.$$

附加无滑移运动边界与远场条件后，速度场和牵引力线性依赖边界速度。游动者不靠惯性滑行：形变停下、驱动力撤去后，它不能按宏观船只的惯性继续远行。布朗运动和方向扩散也会限制保持方向的时间。

用 q 描述体形，U 描述沿固定轴的整体平移，线性阻力可写 $F=-R_{UU}(q)U-R_{Uq}(q)\dot q$。无外力游动要求 $F=0$，因此 $U=A(q)\dot q$，$A=-R_{Uq}/R_{UU}$。若一个往返周期只沿同一个形状参数区间先开再合，

$$\Delta X=\oint A(q)\,\mathrm{d}q=0.$$

返程的积分恰好抵消去程；快开慢合不会改变这一结论，因为在瞬时线性、无记忆模型中速度变化与持续时间相抵。这是 scallop 定理的最小形式。包括旋转的完整刚体运动也具有相应的时间反演性：沿同一形状路径逆向返回会撤销前进过程。原课程明确以低 Re 细胞运动和此定理为主题，此处为编者方程化说明。

两种独立形变 q_1, q_2 可以在形状空间围成环。仍只考虑沿固定轴的平移，小振幅闭路有 $\Delta X \simeq (\partial_1 A_2 - \partial_2 A_1)\mathcal{S}$，$\mathcal{S}$ 为有向面积；交换动作次序会反转位移。这使“先伸后弯”和“先弯后伸”成为不同周期。对于带整体转动的三维运动，还应使用包含旋转的连接与非交换项，不能机械套用这一标量面积式。非 Newton 流体记忆、显著惯性或外场变化则可破坏上面的假设，须另建模型。

旋转鞭毛也不是一个铰链的往返：旋转角持续绕圈，螺旋手性使转动与平移耦合。以一个所选转动模式的有效阻力示意，

$$\begin{pmatrix} F \\ N \end{pmatrix} = -\begin{pmatrix} A & B \\ B & C \end{pmatrix}\begin{pmatrix} U \\ \Omega \end{pmatrix}, \qquad U = -\frac{B}{A}\Omega \quad (F = 0).$$

正耗散要求 $A > 0, AC - B^2 > 0$，故维持该模式所需功率为 $(C - B^2/A)\Omega^2 > 0$。非螺旋对称结构可有 $B = 0$，此时转动不能在该轴向产生推进。真实自由细胞的马达施加内力矩，细胞体反向旋转；完整问题还须把细胞体与鞭毛分别列入力和力矩平衡。这一简化阻力矩阵解释手性耦合，不冒充完整菌体流场计算。

8.10 跑动、翻滚与时间上的趋化比较

细胞太小时，对一瞬间横跨自身的浓度差进行测量很困难；跑动过程中可比较先前与当前的化学信号，调整转向概率。跑动不是始终朝正确方向；降低有利方向的终止率就可产生统计偏向，同时方向扩散和翻滚重新探索其他方向。细胞爬行还涉及 actin 重塑与基底接触力，不能用无外力液体游动的同一个边界条件解释。

一个明确的教学模型只保留一维速度 $+v_0, -v_0$，向负、向正翻转的率分别为 α_+, α_-。稳态方向概率为 $p_+ = \alpha_-/(\alpha_+ + \alpha_-)$，故

$$v_{\mathrm{drift}} = v_0\frac{\alpha_- - \alpha_+}{\alpha_+ + \alpha_-}, \qquad D_{\mathrm{eff}} = \frac{4v_0^2\alpha_+\alpha_-}{(\alpha_+ + \alpha_-)^3}.$$

后式来自速度涨落方差 $4v_0^2\alpha_+\alpha_-/(\alpha_+ + \alpha_-)^2$ 乘相关时间 $1/(\alpha_+ + \alpha_-)$。对称转向时漂移为零而扩散仍为 $v_0^2/(2\alpha)$；有利方向的 α_+ 下降后出现正漂移。这里忽略三维转角、信号适应和旋转 Brown 运动，只示范一个内部状态规则如何变成宏观输运，和前面两态马达的长时统计相接。

9 网络、集体运动与 DNA 包装

9.1 网络结构和阈值

用节点表示基因、蛋白或细胞，边表示已经定义的相互作用。度数、路径长度和聚类系数描述的是不同问题；仅凭度数分布不能推断一条边的因果作用。随机图中平均度 c 的稀疏独立连边模型，探索邻居像平均子代数为 c 的分枝过程。令 u 为沿一条边进入的分枝最终有限的概率，则 $u = \mathrm{e}^{-c(1-u)}$。巨连通分量比例 $S = 1 - u$ 在 $c > 1$ 才出现非零解。

更一般的无关联度分布 $P(k)$，沿边看到的度分布为 $kP(k)/\langle k\rangle$，可继续探索的平均新边数是 $\langle k(k-1)\rangle/\langle k\rangle$。因此阈值涉及二阶矩，而不只是平均度。这个论证假设局部近似树状；模块化、度相关和强聚类网络需要修正。

9.2 反应网络的稳定性

浓度 $\mathbf{c}$ 的动力学 $\dot{\mathbf{c}} = \mathbf{f}(\mathbf{c})$ 在稳态附近写成 $\dot{\delta\mathbf{c}} = J\delta\mathbf{c}$，其中 $J_{ij} = \partial f_i/\partial c_j$。所有特征值实部为负才保证局部渐近稳定。网络中的一条负反馈边并不单独决定稳定性，反馈强度、延迟和其他回路同样影响特征值。

以具有饱和合成和线性降解的调控模型 $\dot{c} = \alpha/[1 + (c/K)^n] - \delta c$ 为例，右端导数为负，稳态唯一且一维扰动衰减；它本身不能持续振荡。若加入转录与翻译两级、时滞或额外状态，才可能产生振荡机制。这是编者的最简单桥接模型；实际公开 lec23、lec24 含详细多变量动力学、同步与图样讲义，下文逐项展开。

9.3 包装能量与尺度选择

噬菌体衣壳内的 DNA 密度高，热运动、弯曲和排斥共同决定包装功。若长度 L 主要弯成半径 R 的环，弯曲能尺度 $E_b \sim k_{\mathrm{B}}T\ell_p L/(2R^2)$；若曲率随位置变化，应实际积分 $\kappa\int R(s)^{-2}\,\mathrm{d}s/2$，不能以最外层半径代表全部内圈。线电荷的屏蔽排斥还需要盐浓度、有效电荷和相邻链距离。

包装马达的力是相应自由能对已装入长度的导数，而不是总能量除以任意长度。随着内部空隙缩小，弯曲半径下降，力常迅速增大；由平衡自由能算出的准静态力不包含黏性耗散。将一种模型拟合得好也不表明所有能量项已唯一确定。包装数量级在追加 PS4.3 中按题给几何完整估算，明确区分裸电荷模型与实际有效电荷。

9.4 图的计数与随机基准

无向简单图用对称邻接矩阵 $A_{ij} \in \{0,1\}$，$A_{ii} = 0$，边数 $L = \sum_{i<j} A_{ij}$，度 $k_i = \sum_j A_{ij}$，所以 $\sum_i k_i = 2L$。有向调控图则分别有入度、出度；蛋白相互结合和基因调控不能不加区分地采用同一图。

Erdős–Rényi 模型每条可能边独立以概率 p 出现。一个节点度为 $\mathrm{Bin}(N-1,p)$，稀疏极限 $p = c/(N-1)$ 得 Poisson 度分布 $\mathrm{e}^{-c}c^k/k!$。三角形的期望数为 $\binom{N}{3}p^3$，长度 $\ell \geq 3$ 的简单环期望为 $(N)_\ell p^\ell/(2\ell)$。分母 2ℓ 去掉起点和方向的重复。若要求诱导子图恰好只有这些边，还需乘缺边的 $(1-p)$ 因子；统计网络模体时先确定采用哪一种定义。

连通阈值的自洽式展开为 $S = cS - c^2S^2/2 + \cdots$，所以 $S \simeq 2(c-1)$。这是巨连通分量出现的阈值 $c = 1$，不是整个有限图全连通的阈值；后者需更高平均度，约在 $c \sim \ln N$。广度优先搜索第 ℓ 层约有 c^ℓ 节点，典型距离估计

$\ln N/\ln c$；近阈值、断开分量或强聚类时不能沿用这个粗估计。

9.5 优先连接的度分布

每一步增加一个节点并连向 m 个旧节点，选择概率与度 k 成正比。t 步后度总和为 $2mt$。令 $N_k(t)\simeq tp_k$，每步度类的增减平衡为

$$p_k=\frac{k-1}{2}p_{k-1}-\frac{k}{2}p_k+\delta_{km}.$$

$k=m$ 给 $p_m=2/(m+2)$，之后 $p_k=(k-1)p_{k-1}/(k+2)$，递推消去得

$$p_k=\frac{2m(m+1)}{k(k+1)(k+2)}\quad(k\ge m).$$

这说明 k^{-3} 尾来自增长和线性优先连接的组合。修改初始吸引力、删除边或连接的非线性会改变尾指数；看到幂律并不能反推唯一机制。源讲义中度总和附近将其记为边数，本文显式保留 $2L$。

9.6 Lyapunov 函数为何需要对称条件

梯度系统 $\dot{x}_i=-\partial_i V$ 满足 $\dot{V}=-\sum_i(\partial_i V)^2\le 0$，但一般反应网络不是梯度系统。连续 Hopfield 模型 $\dot{x}_i=-x_i+f(\sum_j W_{ij}x_j+b_i)$ 中，若 f 严格单调且 $W=W^{\mathsf{T}}$，定义 $G'(x)=f^{-1}(x)$，

$$L=\sum_i[G(x_i)-b_ix_i]-\frac{1}{2}\sum_{ij}W_{ij}x_ix_j.$$

其梯度为 $\partial_iL=f^{-1}(x_i)-b_i-\sum_j W_{ij}x_j$。令 $a=f^{-1}(x_i),b=b_i+\sum_j W_{ij}x_j$，则每项 $\partial_iL\dot{x}_i=(a-b)[f(b)-f(a)]\le 0$。若状态有界，$L$ 下界有限，极限集受限于零耗散集合；要保证单一固定点仍需非退化等条件。

对非对称 W，二次项求导给的是 $(W+W^{\mathsf{T}})/2$，上述证明不成立。源讲义在此将模型允许非对称与这个能量证明并列，本卷补上其必要条件。非对称网络可振荡或具有其他吸引子；不能用一个无效的能量函数排除它们。

二值异步更新的记忆模型也用对称耦合，单次翻转按局部场降低能量。Hebb 式 $W_{ij}\propto\sum_\nu \xi_i^{(\nu)}\xi_j^{(\nu)}$ 让目标图样趋向固定点；多个记忆的交叉干扰决定吸引域和容量。完整检索性能还依赖编码及更新规则，不是只写一个耦合矩阵就证明记忆必然恢复。

9.7 从特征值到分岔和周期

一维 $\dot{y}=\varepsilon-y^2$ 在 $\varepsilon>0$ 有 $\pm\sqrt{\varepsilon}$，正根导数负、稳定，负根不稳定；在零处碰撞消失，是鞍结。$\dot{y}=\varepsilon y-y^2$ 的 $0,\varepsilon$ 交换稳定性，是横截分岔。对称 $y\to -y$ 禁止二次项，$\dot{y}=\varepsilon y-y^3$ 在正 ε 有两个稳定根，是超临界叉形。零特征值时要计算非线性项，线性化本身没有判定能力。

二维系统若复特征值实部穿零，可出现 Hopf 分岔，但是否产生稳定极限环仍需非线性系数。标准模型 $\dot{x}=\varepsilon x-\omega y-(x^2+y^2)x$、$\dot{y}=\omega x+\varepsilon y-(x^2+y^2)y$ 转成 $\dot{r}=\varepsilon r-r^3,\dot{\theta}=\omega$，所以正 ε 下半径 $\sqrt{\varepsilon}$ 的周期轨道稳定。

对实二维矩阵 J，复根条件是 $(J_{11}-J_{22})^2+4J_{12}J_{21}<0$，因而交叉项乘积必须为负；但矩阵不必是反对称矩阵。源讲义“只有反对称矩阵才可复根”的措辞应改为“需要足够的非对称耦合”。Poincaré–Bendixson 定理还要求平面、紧致极限集及无固定点等条件，不能从“有界向外螺旋”一句推出任意高维网络必有周期。

9.8 Kuramoto 同步的自洽推导

将每个稳定振子的慢变量简化为相位 θ_i，自然频率 ω_i 来自偶对称单峰密度 $g(\omega)$。全连接耦合 K/N 给 $\dot\theta_i = \omega_i + (K/N)\sum_j \sin(\theta_j-\theta_i)$。定义 $re^{i\psi} = N^{-1}\sum_j \mathrm{e}^{i\theta_j}$，方程化为 $\dot\theta_i = \omega_i - Kr\sin(\theta_i-\psi)$。

在集体旋转系中取 $\psi=0$，$|\omega|<Kr$ 的振子可锁相，稳定角满足 $\sin\theta=\omega/(Kr)$、$\cos\theta>0$。漂移振子在偶对称稳态下实部贡献相消；锁定群给

$$r=\int_{-Kr}^{Kr} g(\omega)\sqrt{1-(\omega/Kr)^2}\,\mathrm{d}\omega = Kr\int_{-\pi/2}^{\pi/2} g(Kr\sin\theta)\cos^2\theta\,\mathrm{d}\theta.$$

对小 r 展开，利用两个积分分别为 $\pi/2$ 和 $\pi/8$，有

$$1=K\left[\frac{\pi}{2}g(0)+\frac{\pi}{16}g''(0)K^2r^2+\cdots\right],\quad K_c=\frac{2}{\pi g(0)},\quad r^2\simeq -\frac{16(K/K_c-1)}{\pi g''(0)K_c^3}.$$

$g''(0)<0$ 给连续平方根起始。高斯宽度 σ 时 $K_c=\sqrt{8/\pi}\,\sigma$、$r^2\simeq\pi(K/K_c-1)$；这里完整保留二阶 Taylor 系数，避免源式中的因子二混淆。有限振子数有涨落，全连接和相位约化也可能不适合真实细胞群。

9.9 Turing 图样：扩散为何能破坏稳定

两种浓度的小扰动 $\mathbf{c}$ 满足 $\partial_t\mathbf{c}=J\mathbf{c}+\mathrm{diag}(D_1,D_2)\nabla^2\mathbf{c}$。平面波模式 $\mathrm{e}^{\lambda t+i\mathbf{k}\cdot\mathbf{r}}$ 的矩阵是 $J_k=J-\mathrm{diag}(D_1,D_2)k^2$。均匀稳定要求 $\operatorname{tr}J<0,\det J>0$。有限波数时迹更负，所以扩散驱动的定常不稳定只能由行列式变负出现。

记 $A=D_2J_{11}+D_1J_{22}$，

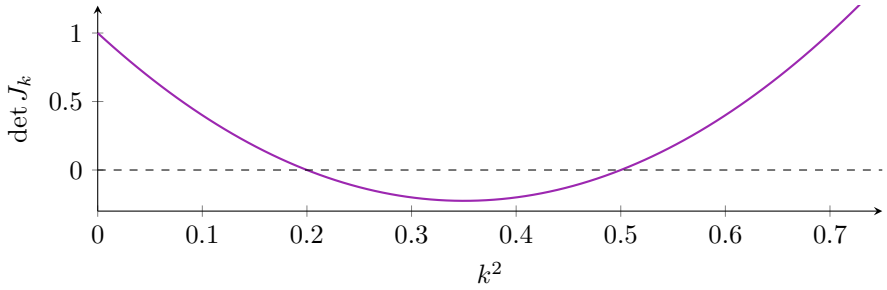
$$\det J_k=\det J-Ak^2+D_1D_2k^4.$$

此式是开口向上的二次函数（变量是 k^2）。其最小值在 $k_m^2=A/(2D_1D_2)$，故必要且充分的连续波数条件为

$$A>0,\qquad A^2>4D_1D_2\det J.$$

不稳定带由两正根 $k_\pm^2=[A\pm\sqrt{A^2-4D_1D_2\det J}]/(2D_1D_2)$ 限定。这里 k_m 是行列式最小的位置，一般不恰是最大增长率波数；源讲义将极值称为最大，本文已按实际抛物线方向修正。

若 $D_1=D_2$，每个特征值只减 Dk^2，绝不可能破坏均匀稳定。若 $J_{11}>0,J_{22}<0$，需要自抑制的第二组分扩散更快，形成短程激活、长程抑制。作为编者明确的线性例子取 $J=\begin{pmatrix}1&-2\\2&-3\end{pmatrix}$，迹 -2、行列式 1，$D_1=1,D_2=10$，则 $A=7$、$A^2-4D_1D_2\det J=9>0$，有 $k^2\in(0.2,0.5)$ 不稳定。给定有限区域边界后只有离散允许波数，若无一落入带内，实际仍稳定。



线性不稳定只解释最初选择的尺度；最终条纹/斑点、振幅和缺陷还取决于非线性饱和。这份数据是明示的模型参数，不是假装测量某种动物花纹。

10 协同结合的统计模型

10.1 按真实网页纲要补充：Hill 与 MWC

目录第 25 讲链接的 cooperativity 网页列多位点结合、血红蛋白、MWC 模型与 Hill 方程。它只有纲要和阅读链接，没有可点击的 2009 详细讲义；以下是据这些主题作的编者独立推导，与前面的十五份实际 PDF 改编分开。DNA 衣壳包装来自 PS4.3，不据这个网页标题推断。

若 m 个独立等价结合位点，配体浓度为 c、解离常数 K，单点权重 $x=c/K$，$Z=(1+x)^m$。每点占据比例 $Y=m^{-1}\partial_{\ln c}\ln Z=x/(1+x)$，无论位点多少，Hill 图 $\ln[Y/(1-Y)]$ 对 $\ln c$ 的斜率为 1。四个位点不自动意味着 Hill 系数 4。

极端全或无模型只允许完全空与完全满，$Z=1+(c/K)^m$，$Y=(c/K)^m/[1+(c/K)^m]$，Hill 斜率为 m。一般经验 Hill 式 $Y=c^{n_H}/(K_H^{n_H}+c^{n_H})$ 的 n_H 描述局部曲线陡峭程度；非整数常反映多态、异质性或有效拟合，不能当作真实结合位点的精确数量。

MWC 让整个多聚体在低亲和 T 态与高亲和 R 态之间协同切换，而每态内部位点独立。空蛋白 T/R 权重比 L_0，两态解离常数 $K_T>K_R$，则

$$Z=(1+c/K_R)^m+L_0(1+c/K_T)^m,$$

$$Y=\frac{(c/K_R)(1+c/K_R)^{m-1}+L_0(c/K_T)(1+c/K_T)^{m-1}}{(1+c/K_R)^m+L_0(1+c/K_T)^m}.$$

随浓度增加，R 态的统计权重相对增长，使结合曲线更陡。这种协同来自共享构象态，和简单叠加独立位点不同。通过 L_0,K_R,K_T 可得到多种有效 Hill 斜率，但只用一条曲线往往不能唯一确定全部参数。

由 $\partial_{\ln c}\langle n\rangle=\operatorname{Var}n$，$n_H(c)=\mathrm{d}\ln[Y/(1-Y)]/\mathrm{d}\ln c=\operatorname{Var}n/[mY(1-Y)]$。独立二项分布方差 $mY(1-Y)$ 给 1；协同增强占据涨落便提升斜率。这把生物结合、统计配分函数和可观察曲线联系起来。模型并未收录原网页链接的受限第三方血红蛋白图。

11 概率、固定与序列题解

以下题面来自 8.592J Spring 2011 公开作业的已冻结题号，全部解答由编者独立推导。未找到可下载的官方作业答案；课纲提及会提供解答不能替代实际文件。

11.1 PS1：概率

习题 11.1 （PS1.1）DNA 各位置的 A、G、T、C 独立且等概率。(a) 由遗传密码求随机三联体是终止信号的概率 p_s；(b) 求 N 个非终止三联体后紧接一个终止密码的概率；(c) 大肠杆菌每条链约 5×10^6 个碱基，基因组为闭环，考虑六个阅读框，随机情况下预期多少长度 600 的开放阅读框？

解答. 三个终止密码 TAA、TAG、TGA 在 64 种三联体中占 3 个，故 $p_s=3/64$。(b) 为 $(61/64)^N(3/64)$。六个阅读框各有约 $L/3$ 个起点，线性期望不要求不同框彼此独立；预期数为 $2L(61/64)^{600}(3/64)\simeq1.45\times10^{-7}$。如果另要求起点之前也是终止密码，使所数对象恰为相邻终止间的完整区间，还需再乘 $3/64$，得到 6.79×10^{-9}。这里 600 沿题面 (b) 按三联体数计算，若误取 600 个碱基会改变指数。随机背景下如此长的无终止区间极不常见，但显著性不自动证明其具有真实蛋白编码功能。 □

习题 11.2 （PS1.3）按 A、G、T、C 排序。A 与 G、T 与 C 之间每代以概率 q 互变；其余两类之间每种以概率 p 互变。(a) 写概率转移矩阵；(b) 求特征值；(c) 求 t 代矩阵；(d) 求稳态和弛豫代数；(e) 将 A→C、T→G 改为 p_+，逆向改为 p_-，其他保持不变，求新矩阵和稳态。原题对 transition/transversion 术语的命名与通常生物学用法互换，本题按明确的碱基对定义计算。

解答. 采用列为出发状态的约定，

$$M=\begin{pmatrix} d & q & p & p\\ q & d & p & p\\ p & p & d & q\\ p & p & q & d\end{pmatrix},\qquad d=1-q-2p.$$

归一化要求 $p,q\ge0, q+2p\le1$。四个正交特征向量可取 $(1,1,1,1),(1,1,-1,-1),(1,-1,0,0),(0,0,1,-1)$，对应特征值 $1, 1-4p, 1-2p-2q, 1-2p-2q$。将归一化向量写成 v_j，则 $M^t=\sum_j\lambda_j^t v_j v_j^T$。(d) 若非平凡模绝对值均小于 1，稳态为均匀分布；慢弛豫时间 $\tau=-1/\ln\max(|1-4p|,|1-2p-2q|)$。小概率时约由 $\min(4p,2p+2q)^{-1}$ 决定；$p=0$ 等非遍历边界不保证唯一稳态。

一般地，若每对正反转移概率相等，矩阵对称且列和为一，则行和也为一，故 $M(1,1,1,1)^T/4=(1,1,1,1)^T/4$，均匀分布是稳态。若还不可约且非周期，则它是唯一吸引稳态；断开或周期模型不能仅凭对称性声称任意初态收敛。

(e) 新矩阵为

$$M_a=\begin{pmatrix} 1-q-p-p_+ & q & p & p_- \\ q & 1-q-p-p_- & p_+ & p \\ p & p_- & 1-q-p-p_+ & q \\ p_+ & p & q & 1-q-p-p_- \end{pmatrix}.$$

对称性给 $p_A=p_T=a, p_G=p_C=c$，跨组概率流平衡 $a(q+p_+)=c(q+p_-)$，结合 $2a+2c=1$ 得 $a=(q+p_-)/[2(2q+p_++p_-)]$，$c=(q+p_+)/[2(2q+p_++p_-)]$。按原题给的 $p_+>p_-$，这个具体模型提高 GC 比例；它不能解释原题背景中 GC 较少的方向，这是原题简化参数方向的限制。 □

习题 11.3 （PS1.5）固定 N 个分子独立进行 $A \underset{b}{\overset{a}{\rightleftharpoons}} B$ 转换，$n=N_A$。(a) 写 $p_n(t)$ 的主方程；(b) 初始全部为 A，求所有时刻的分布并核验方程。

解答. $A\to B$ 使 n 减 1，率 an；逆向使 n 加 1，率 $b(N-n)$。故

$$\dot p_n=a(n+1)p_{n+1}+b(N-n+1)p_{n-1}-[an+b(N-n)]p_n,$$

边界之外的项置零。单分子活性概率 $u=b/(a+b)+a\mathrm{e}^{-(a+b)t}/(a+b)$，独立性给 $p_n=\binom{N}{n}u^n(1-u)^{N-n}$。将 $\dot u=b-(a+b)u$ 代入其导数，并用 $(n+1)\binom{N}{n+1}=(N-n)\binom{N}{n}$ 等恒等式，得到上述主方程。$u(0)=1$ 给初始条件，二项定理给归一化，均值 Nu、方差 $Nu(1-u)$。 □

11.2 PS2：固定和比对

习题 11.4 （PS2.1）固定 N 个单倍体，多等位基因有 $s+1$ 类，频率 x_i，$x_{s+1}=1-\sum_{i=1}^{s}x_i$。下一代计数服从多项分布 $P(\{m_i\})=N!\prod_i x_i^{m_i}/m_i!$。(a) 求增量的一、二阶矩；(b) 写前向方程；(c) 写给定初始频率的后向方程；(d) 求全部多态性最终消失的平均固定时间方程，并验证一个两等位结果的推广。

解答. 多项抽样给 $\langle\Delta x_i\rangle=0$、$\langle\Delta x_i\Delta x_j\rangle=(x_i\delta_{ij}-x_ix_j)/N$。前向方程为 $\partial_t p=\sum_{i,j=1}^{s}\partial_{x_i}\partial_{x_j}[(x_i\delta_{ij}-x_ix_j)p]/(2N)$；后向方程的导数作用于初始变量 y_i，系数不进入导数：$\partial_t p=\sum_{ij}(y_i\delta_{ij}-y_iy_j)\partial_{y_i}\partial_{y_j}p/(2N)$。

平均最终固定时间满足 $\mathcal{L}T=-1$，只在单型顶点取零；一个等位基因刚消失的面仍可有多态性，其边界值应等于低维问题的固定时间。令

$$T(\mathbf{y})=-2N\sum_{i=1}^{s+1}(1-y_i)\ln(1-y_i).$$

对完整约束频率使用同一个生成元，每项二阶导为 $-2N/(1-y_i)$，其扩散贡献 $-y_i$；全部频率之和为 1，所以 $\mathcal{L}T=-1$。在顶点 $T=0$，在面上零频率项消失，恰好退化为同一低维表达式。两等位时恢复第 1 章公式。源文 (d) 的 “loss or mutation” 并没有给突变率，这里按所给纯抽样模型求吸收时间。 □

习题 11.5 （PS2.2）无漂移、常扩散系数 D 的粒子被两边界吸收。(a) 在 $[0,1]$ 上求两种吸收概率；(b) 求平均首达时间及最长寿命起点；(c) 对二维同心圆 $R_0<R<R_1$ 求相同量；(d) 对三维同心球求相同量，比较维数影响。题面所有可选小问均收录。

解答. 一维概率满足 $D\Pi''=0$，故 $\Pi_1=y,\Pi_0=1-y$；时间满足 $DT''=-1$，$T=y(1-y)/(2D)$，最大在 $y=1/2$。二维径向算子为 $D(T''+T'/R)$，解为

$$\Pi_1=\frac{\ln(R/R_0)}{\ln(R_1/R_0)},\quad T=\frac{R_0^2-R^2}{4D}+\frac{R_1^2-R_0^2}{4D}\frac{\ln(R/R_0)}{\ln(R_1/R_0)}.$$

$T'=0$ 给 $R_{\max}^2=(R_1^2-R_0^2)/[2\ln(R_1/R_0)]$。三维算子为 $D(T''+2T'/R)$，于是

$$\Pi_1=\frac{R_0^{-1}-R^{-1}}{R_0^{-1}-R_1^{-1}},\quad T=\frac{R_0^2-R^2}{6D}+C(R_0^{-1}-R^{-1}),\quad C=\frac{R_0R_1(R_0+R_1)}{6D}.$$

最长寿命起点满足 $R_{\max}^3=R_0R_1(R_0+R_1)/2$。内边界概率为 $1-\Pi_1$。同样的壳层中，维数提高产生径向几何偏置，向外吸收概率提高，最大寿命的起点相对向内移动；薄壳极限都接近局部一维答案。 □

习题 11.6 （PS2.4）序列 GAATTC 和 GATTA，匹配得分 1.5，失配 -1，每个空位罚 2。计算全局、局部动态规划矩阵和最优比对，说明全局是否有歧义。

解答. 按第 2 章递推，行序列为 GAATTC，列序列为 GATTA，矩阵分别是

	–	G	A	T	T	A
–	0	-2	-4	-6	-8	-10
G	-2	1.5	-0.5	-2.5	-4.5	-6.5
A	-4	-0.5	3	1	-1	-3
A	-6	-2.5	1	2	0	0.5
T	-8	-4.5	-1	2.5	3.5	1.5
T	-10	-6.5	-3	0.5	4	2.5
C	-12	-8.5	-5	-1.5	2	3

全局矩阵

	–	G	A	T	T	A
–	0	0	0	0	0	0
G	0	1.5	0	0	0	0
A	0	0	3	1	0	1.5
A	0	0	1.5	2	0	1.5
T	0	0	0	3	3.5	1.5
T	0	0	0	1.5	4.5	2.5
C	0	0	0	0	2.5	3.5

局部矩阵

全局最优得分为 3，两条并列路径为 GAATTC/G-ATTA 和 GAATTC/GA-TTA：四个匹配、一个失配、一个空位，$4(1.5)-1-2=3$。局部最优为 ATT 与 ATT，得分 4.5。矩阵和全部并列全局回溯由附带代码实际计算，不把单条输出误称为唯一比对。 □

11.3 PS3：极值

习题 11.7 （PS3.1）N 个独立 $\mathcal{N}(0,\sigma^2)$ 变量最大值为 x。(a) 求 $P(x\le X)$；(b) 说明最可能值在大 N 时可由 $\overline{F}(x_*)\simeq 1/N$ 或 $p_1'(x_*)+Np_1(x_*)^2\simeq 0$ 定位，并求主渐近；(c) 在此附近展开得到 Gumbel 分布及其参数。

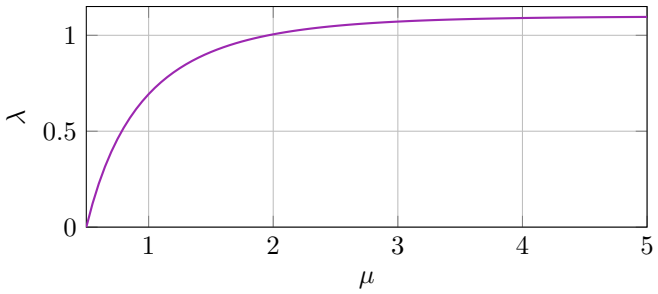
解答. (a) 为 $F(X)^N$。最大值密度 Np_1F^{N-1} 的驻点满足 $p_1'F+(N-1)p_1^2=0$；$F\to 1$ 时得到题面第二式。利用高斯尾 $\overline{F}\sim\sigma^2p_1/x$，第二式给 $N\overline{F}\simeq 1$，所以两个表达式是同阶渐近而不是有限 N 的精确等式。主尺度 $x_*\sim\sigma\sqrt{2\ln N}$。取 b_N 为 $N\overline{F}(b_N)=1$ 的解，$a_N=\sigma^2/b_N$，累计分布近似为 $\exp\{-\exp[-(X-b_N)/a_N]\}$；密度为 $a_N^{-1}\exp[-z-\mathrm{e}^{-z}]$。具体展开：令 $X=b_N+a_Nz$，高斯尾比值 $\overline{F}(X)/\overline{F}(b_N)\simeq\exp[-b_Na_Nz/\sigma^2]=\mathrm{e}^{-z}$，其中平方的二阶项与尾前因子相对变化在大 N 下趋零。于是 $F(X)^N=[1-\overline{F}(X)]^N\simeq\exp[-N\overline{F}(X)]=\exp(-\mathrm{e}^{-z})$，再对 X 求导得到上述密度。位置和尺度的次阶修正需保留高斯尾的前因子。 □

习题 11.8 （PS3.3）T 细胞受体序列 $t=(t_1,\dots,t_N)$ 对肽段 p 的结合能 $E(t,p)=\sum_i V(t_i,p_i)$。胸腺遇见 M 个独立自身肽段，负选择要求每个结合能大于 E_n，正选择要求至少一个小于 $E_p>E_n$。(a) 化成最小能量的条件；(b) 对固定受体，以 $\mathcal{E}(t_i)=\langle V(t_i,p)\rangle$、$\mathcal{V}(t_i)=\operatorname{Var}V(t_i,p)$ 写大 N 能量分布；(c) 求最小值分布；(d) 当 $\ln M\propto N$，分析中心和宽度尺度。

解答. (a) 为 $E_n<E_{\min}<E_p$。(b) 在肽段位置独立且方差有限的近似下，平均 $\mu_t=\sum_i\mathcal{E}(t_i)$，方差 $\Sigma_t^2=\sum_i\mathcal{V}(t_i)$，能量近似 $\mathcal{N}(\mu_t,\Sigma_t^2)$。(c) 设单肽累计为 F_t，则 $P(E_{\min}>E)=[1-F_t(E)]^M$，密度 $Mp_t(E)[1-F_t(E)]^{M-1}$，左尾为反向 Gumbel。(d) 中心约 $\mu_t-\Sigma_t\sqrt{2\ln M}=O(N)$，宽度约 $\Sigma_t/\sqrt{2\ln M}=O(1)$。因此单位长度能量的宽度趋零；这不表示总能量宽度也趋零。真实肽段相关和极端尾的非高斯性会影响近似。 □

习题 11.9 （PS3.4）无空位 DNA 比对的匹配分数为 1；A 与 G 或 T 与 C 替换分数为 0；其余替换分数为 $-\mu$，四种碱基等频。(a) 求 Gumbel 指数参数 $\lambda(\mu)$ 的方程；(b) 找 μ_c，作 λ 随 μ 的图。本题也按明确的碱基对计算。

解答. 三类分数概率为 $1/4, 1/4, 1/2$，所以非零正根满足 $\mathrm{e}^{\lambda}/4 + 1/4 + \mathrm{e}^{-\mu\lambda}/2 = 1$。平均分数 $(1-2\mu)/4$ 必须为负，故 $\mu_c = 1/2$；凸性保证 $\mu > 1/2$ 时唯一正根。边界附近 $\lambda \simeq (8/3)(\mu - 1/2)$；$\mu \to \infty$ 时 $\lambda \to \ln 3$。下图按隐式方程数值求根的数据绘制，边界处取连续极限 0。



□

12 静电、折叠与拉伸题解

12.1 PS4：库仑作用

习题 12.1 （PS4.1）d 维空间内大小 R、总电荷 Q 的球状体系库仑能按 Q^2/R^{d-2} 缩放。(a) 将带电链长度 N 的库仑能与熵弹性平衡，求 $R(Q,N)$；(b) 对 $Q \propto N$ 求 Flory 指数及上下临界维数；(c) 与题面给出的均匀带电链精确指数 $\nu = 2/(d-2)$ 比较；(d) 随机正负电荷的多两性链 $Q^2 \propto N$，求 Flory 估计。

解答. 对 $d > 2$，$F \sim k_{\mathrm{B}}TR^2/(Na^2) + CQ^2/R^{d-2}$。求导平衡得 $R^d \sim C(d-2)Q^2Na^2/(2k_{\mathrm{B}}T)$，故 $R \propto (Q^2N)^{1/d}$。(b)$\nu_F = 3/d$，与理想链 1/2 比较得上临界维数 6，与完全拉伸指数 1 比较得下限维数 3；物理指数不能超过 1。(c) 题面提供的 $\nu = 2/(d-2)$ 给上临界维数 6、下限维数 4，因此三维链在此图像下已经充分伸直。此“精确指数”是原题给定输入，本稿没有证明它；不能把 Flory 最小化说成对它的证明。(d)$\nu_F = 2/d$，但净电荷近似忽略了异号电荷之间局部吸引和塌缩；高维与低维仍需按理想链和轮廓长界限检查。$d = 2$ 的对数库仑势不属于题设幂律的直接代入范围。 □

习题 12.2 （PS4.2）半径 a 的均匀线电荷，每单位长度 n 个单位电荷，N 个价态 z 的反离子在长度 L、半径 R 的柱形容器中。忽略反离子互斥，其能量为 $V = 2ze^2n\sum_i \ln(r_i/L)$，源文以介电常数吸收于 e^2 的约定书写。(a) 求配分函数并识别 ζ；(b) 求径向概率及均值；(c) 分析 $R \gg a$ 下各温区；(d) 求壁面压力；(e) 双链 DNA 负电荷间距 $b = 1.7\,\text{Å}$、$\ell_B = 7\,\text{Å}$，估计 NaCl 和 $MgCl_2$ 反离子中和比例。

解答. $\zeta = zn\ell_B$，空间积分 $I = \int_a^R r^{1-2\zeta}\,\mathrm{d}r$。除去与 R 无关的因子，$Z \propto I^N$，$I = [R^{2-2\zeta} - a^{2-2\zeta}]/[2(1-\zeta)]$；$\zeta = 1$ 时为 $\ln(R/a)$。径向概率是 $p_r = r^{1-2\zeta}/I$，不是单位面积密度。均值为

$$\langle r\rangle = \frac{R^{3-2\zeta} - a^{3-2\zeta}}{(3-2\zeta)I},$$

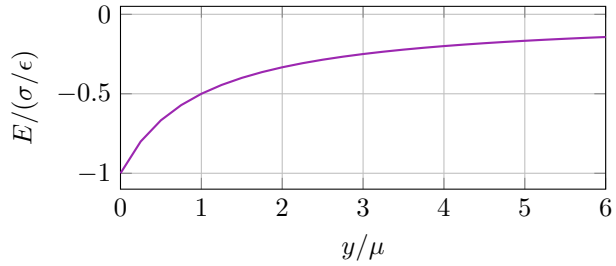
$\zeta = 3/2$ 时分子对应积分为 $\ln(R/a)$。

$\zeta < 1$ 的高温离子弥散，$\langle r\rangle \sim 2(1-\zeta)R/(3-2\zeta)$。$\zeta = 1$ 时 $\langle r\rangle \sim R/\ln(R/a)$。$\zeta > 1$ 的径向分布在无限容器中可归一化，但均值只有 $\zeta > 3/2$ 才有限，届时 $\langle r\rangle \to a(2\zeta-2)/(2\zeta-3)$；在 $1 < \zeta < 3/2$，均值仍按 $R^{3-2\zeta}$ 增长，$\zeta = 3/2$ 时按 $a\ln(R/a)$ 增长。凝聚阈值和有限一阶矩阈值不同。

壁面压力 $P = (k_\mathrm{B}T/2\pi RL)\partial_R \ln Z = Nk_\mathrm{B}TR^{-2\zeta}/(2\pi LI)$。三种渐近分别为 $Nk_\mathrm{B}T(1-\zeta)/(\pi LR^2)$、$Nk_\mathrm{B}T/[2\pi LR^2\ln(R/a)]$、$Nk_\mathrm{B}T(\zeta-1)a^{2\zeta-2}/(\pi LR^{2\zeta})$。Manning 估计中 $\zeta = z\ell_B/b$，中和比例 $1 - 1/\zeta$，Na^+ 约 0.757，Mg^{2+} 约 0.879。价态二已包含于 ζ，不能再把电荷中和比例乘二。 □

习题 12.3 （PS4.4）负膜电荷密度大小 σ，正反离子电荷 ze。(a) 求单膜密度；(b) 用表面电场确定常数并画场；(c) 检查电中性；(d) 求间距 L 的两个同样带电平板之间自洽势和密度；可选 (e) 对半径 a、线电荷 $-e/b$ 的柱求 Poisson–Boltzmann 方程形式，并联系 Manning 凝聚。

解答. (a)–(c) 由第 3 章得 $n(y) = [2\pi z^2\ell_B(y+\mu)^2]^{-1}$，$\mu = e/(2\pi z\ell_B\sigma)$，$E(y) = -2k_\mathrm{B}T/[ze(y+\mu)]$。场为负、从 $-\sigma/\epsilon$ 单调趋零，$ze\int_0^\infty n\,\mathrm{d}y = \sigma$。



(d) 将中面设为 $y = 0$，$u = \beta ze[\phi(y) - \phi(0)]$，则

$$u = 2\ln\cos(ky), \qquad n = n_m\sec^2(ky), \qquad n_m = \frac{k^2}{2\pi z^2\ell_B}, \quad k\tan(kL/2) = \mu^{-1}.$$

取 $0 < kL/2 < \pi/2$ 的唯一根；$E = 2k_\mathrm{B}Tk\tan(ky)/(ze)$，电场指向两侧负板。积分后反离子总电荷是 2σ。

(e) 柱坐标设 $u = \beta ze\phi$，$n = n_0\mathrm{e}^{-u}$，$x = \ln(r/a)$，$\psi = u - 2x$。由 $u_{rr} + u_r/r = u_{xx}/r^2$ 得 $\psi_{xx} = -C\mathrm{e}^{-\psi}$，$C = 4\pi z^2\ell_B n_0 a^2$。积分一次得 $(\psi_x)^2/2 = C\mathrm{e}^{-\psi} + K$。$K > 0$ 可写 $\mathrm{e}^{\psi/2} = \sqrt{C/K}\sinh[\sqrt{K/2}(x - x_0)]$；$K = 0$ 为 $\sqrt{C/2}(x - x_0)$；$K < 0$ 为 $\sqrt{-C/K}\sin[\sqrt{-K/2}(x - x_0)]$。只在这些函数正值区间取对数。常数由 $u_x(0) = 2z\ell_B/b$ 和容器外端中性边界 $u_x(\ln(R/a)) = 0$ 决定。线电荷强度 $z\ell_B/b$ 越过 1 时，长柱无限容器极限出现 Manning 凝聚；这是自洽分布的联系，不把独立离子近似当作全多体精确解。 □

习题 12.4 （PS4.5）单体间距 b，总长 $L=Nb$ 的直带电链弯成大半径 R 的圆。原间距 $d=b|m-n|\ll R$，相互作用 $V(d)=k_{\mathrm{B}}T\ell_B\mathrm{e}^{-d/\lambda}/d$。(a) 求距离改变量；(b) 求配对能量变化；(c) 证明总改变量按 L/R^2 缩放；(d) 求电性弯曲模量；(e) 以 $b=.17\,\mathrm{nm}$、$\ell_B=.7\,\mathrm{nm}$、$\lambda=1\,\mathrm{nm}$、$\ell_p=50\,\mathrm{nm}$ 估计 DNA 中的重要性，讨论单链。

解答. 弦长 $2R\sin(d/2R)=d-d^3/(24R^2)+O(d^5/R^4)$，所以距离变短。用 $V'=-k_{\mathrm{B}}T\ell_B\mathrm{e}^{-d/\lambda}(d^{-2}+\lambda^{-1}d^{-1})$，得到 $\delta V=k_{\mathrm{B}}T\ell_B\mathrm{e}^{-d/\lambda}d(1+d/\lambda)/(24R^2)>0$。

对无序对求和，在 $b\ll\lambda\ll L,R$ 的连续极限，$\sum_{m<n}\simeq(L/b^2)\int_0^\infty \mathrm{d}d$。积分 $\int d(1+d/\lambda)\mathrm{e}^{-d/\lambda}\,\mathrm{d}d=3\lambda^2$，故 $\Delta E=k_{\mathrm{B}}T\ell_B\lambda^2L/(8b^2R^2)$。与 $\kappa_eL/(2R^2)$ 比较，得 $\kappa_e=k_{\mathrm{B}}T\ell_B\lambda^2/(4b^2)$。数值电性持久长度 $\kappa_e/k_{\mathrm{B}}T\simeq 6.06\,\mathrm{nm}$，约为给定总持久长度的 12%。反离子凝聚会降低有效电荷；DNA 不是无限弱电荷连续链，因此这个值只是该模型估计。单链骨架本征刚度更小，电性贡献可能相对更大，须重定 b、有效电荷和 λ。 □

12.2 PS5：随机能量模型

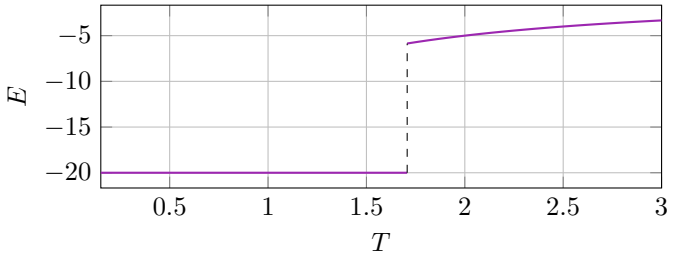
习题 12.5 （PS5.1）固定序列在 Ω_{str} 个非天然结构上的能量来自均值零、方差 Σ^2 的高斯分布，另有唯一天然态能量 E_N；可设计序列数 $\Omega_{\mathrm{seq}}\gg\Omega_{\mathrm{str}}$。(a) 求并画 $E(T)$；(b) 对固定天然结构，在设计温度 τ 下抽样序列，求并画所选天然能量 $E_N(\tau)$。

解答. 令 $S_0=\ln\Omega_{\mathrm{str}}$、$E_c=-\Sigma\sqrt{2S_0}$、$k_{\mathrm{B}}T_c=\Sigma/\sqrt{2S_0}$。非天然体系高温 $E=-\Sigma^2/(k_{\mathrm{B}}T)$，低温冻结为 E_c。若 $E_N<E_c$，天然态与高温自由能相交处满足 $E_N=-k_{\mathrm{B}}T_fS_0-\Sigma^2/(2k_{\mathrm{B}}T_f)$，物理高温根

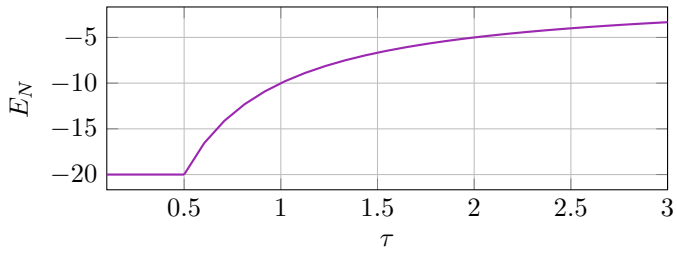
$$k_{\mathrm{B}}T_f=\frac{-E_N+\sqrt{E_N^2-2S_0\Sigma^2}}{2S_0}.$$

大体系近似下，$T<T_f$ 时 $E=E_N$，$T>T_f$ 时为非天然高温式，折叠处能量跳变；有限态数的精确配分和会把跃迁抹平。若 $E_N\geq E_c$，天然态无独立稳定区，不能强画折叠跳跃。

(b) 将态数换为 Ω_{seq}，设计能量为 $-\Sigma^2/(k_{\mathrm{B}}\tau)$，降到设计冻结温度 $k_{\mathrm{B}}\tau_c=\Sigma/\sqrt{2\ln\Omega_{\mathrm{seq}}}$ 后饱和于 $-\Sigma\sqrt{2\ln\Omega_{\mathrm{seq}}}$。由于序列库更大，可挑选的最小能量比普通构象库低。图按 $S_0=10,\Sigma=\sqrt{10},E_N=-20,k_{\mathrm{B}}=1$ 的明确示例画出，不代表实测蛋白。



设计曲线在相同 $\Sigma=\sqrt{10}$、$\ln\Omega_{\mathrm{seq}}=20$ 的示例中为



□

习题 12.6 （PS5.2）g^N 个紧密构象，能量高斯方差 $\Sigma^2 = u^2N + c(Q^2/R)^2$。(a) 求熵消失能量与冻结温度；(b) 紧密球状三维构象 $R \propto N^{1/3}$，求使冻结温度渐近不随 N 变化的 Q^2 尺度。

解答. $E_c = -\sqrt{2N\ln g}\,\Sigma$，$k_{\mathrm{B}}T_c = \Sigma/\sqrt{2N\ln g}$。有限非零冻结温度要求 $\Sigma^2 = O(N)$；额外库仑方差 cQ^4/R^2 不超过这一阶，即 $Q^2 = O(N^{5/6})$。取正好 $N^{5/6}$ 使电项与骨架项同时保持重要，增长更慢则电项渐近可忽略。指数仅对题面三维紧密构象及给定方差模型适用。 □

12.3 PS6：力与延伸

习题 12.7 （PS6.1）理想链构象数 $\Omega_N(\mathbf{R}) = g^N[3/(2\pi Na^2)]^{3/2}\mathrm{e}^{-3R^2/(2Na^2)}$，外力能为 $-\mathbf{F}\cdot\mathbf{R}$。(a) 求配分函数和平均延伸；(b) 一般各向同性链，展开到二阶证明线性响应；(c) 若 $\sqrt{\langle R^2\rangle_0} \sim aN^{\nu}$、$\nu = .59$，结合题设尺度函数及大力下延伸正比 N 求非线性力指数。

解答. 高斯配平方给 $Z = g^N\exp[Na^2\beta^2F^2/6]$，$X = k_{\mathrm{B}}T\partial_F \ln Z = Na^2F/(3k_{\mathrm{B}}T)$。(b) 零力平均位移为零，$Z(F)/Z(0) = 1 + \beta^2F_iF_j\langle R_iR_j\rangle_0/2 + O(F^4)$。各向同性 $\langle R_iR_j\rangle_0 = \delta_{ij}\langle R^2\rangle_0/3$，所以 $\mathbf{X} = \langle R^2\rangle_0\mathbf{F}/(3k_{\mathrm{B}}T) + O(F^3)$。(c) 令 $X/R_0 \sim (FR_0/k_{\mathrm{B}}T)^{\lambda}$，其 N 次幂为 $\nu(1+\lambda)$，与 1 相等得 $\lambda = 1/\nu - 1 \simeq 0.695$。这里“大力”指超出线性响应但尚未达到键尺度饱和的团块区间；真正 $F\to\infty$ 不可能一直幂律增长。 □

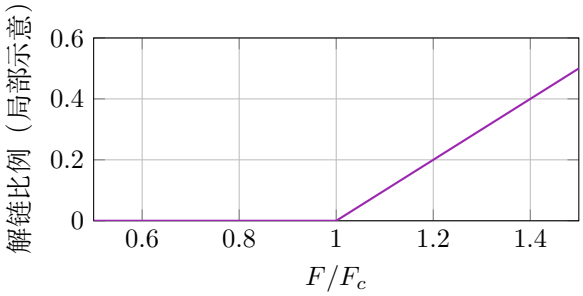
习题 12.8 （PS6.4）受力 RNA 的未配对骨架和无载荷配对团块权重为 $P(\ell) = g^{\ell}\exp[F^2a^2\ell/(6k_{\mathrm{B}}^2T^2)]$、$R(\ell) = Af^{\ell}/\ell^{3/2}$，二者交替，所有段长之和为 N。(a) 求巨配分函数；(b) 求开始解链的临界力；(c) 画解链位点比例随力的起始奇性。

解答. 设 $q = g\mathrm{e}^{\beta^2F^2a^2/6}$，$\widetilde{P} = qz/(1-qz)$、$\widetilde{R} = A\mathrm{Li}_{3/2}(fz)$。若链两端都为骨架段，$\mathcal{Z} = \widetilde{P}/(1-\widetilde{P}\widetilde{R})$；两端约定改变分子，不改变主体自由能奇点。解链开始时极点在 $z_c = 1/f$，有 $\widetilde{P}(z_c)A\zeta(3/2) = 1$，故

$$F_c^2 = \frac{6k_{\mathrm{B}}^2T^2}{a^2}\ln\frac{f}{g[1+A\zeta(3/2)]}.$$

假设 $A, f, g > 0$。正的临界力存在当且仅当 $f > g[1+A\zeta(3/2)]$。等号时临界在零力；若小于，零力已有非零骨架比例，不能写虚数临界力。整体改写每一对段的权重必须保持乘积相同，不能把 A 从团块移到骨架分母而仍沿用原来的参数定义。

设 $\epsilon = 1 - f z_*$。$\mathrm{Li}_{3/2}(1-\epsilon) = \zeta(3/2) - 2\sqrt{\pi}\sqrt{\epsilon} + O(\epsilon)$，所以极点条件给 $\sqrt{\epsilon} \propto F - F_c$。骨架比例为 $\rho = \alpha_P/(\alpha_P + \alpha_R)$，$\alpha_P = \partial_{\ln z} \ln \widetilde{P}$，$\alpha_R = \partial_{\ln z} \ln \widetilde{R} \propto \epsilon^{-1/2}$。若 $F_c > 0$，控制量 $q - q_c \propto F - F_c$，因此 $F < F_c$ 时 $\rho = 0$，$F > F_c$ 刚开始时 $\rho \propto F - F_c$，比例连续而斜率改变。若 $F_c = 0$，则 $q - q_c \propto F^2$，起始是 $\rho \propto F^2$，不能直接套非零临界力的线性式。该曲线是高斯骨架模型的起始行为，远大力的形状不应由这个近似外推。



图只表达临界前零比例与临界后的线性起始；竖向斜率按任意正比例归一化，不能从此图读取实际全程解链比例。

□

13　搜索、增长与马达题解

13.1　PS7：蛋白与 DNA

习题 13.1　(PS7.2) 转录因子直径约 10 nm，细胞质黏度约 $0.1\,\mathrm{g\,s^{-1}cm^{-1}}$，取 $D_1 \simeq 0.1 D_3$。(a) 估计 D_3；(b) 蛋白解离后以 $p = .9$ 概率在原地重新结合，求滑动加三维扩散搜索的总时间；(c) 给定 $D_1 = 1\,\mu\mathrm{m}^2/\mathrm{s}$、$\tau_3 = 10^{-3}\,\mathrm{s}$、基因组 $M = 10^6$ 碱基对，求最优搜索时间，并估计控制解离率的非特异结合能。

解答. (a) 黏度换算为 $0.01\,\mathrm{Pa\,s}$，取室温 $k_\mathrm{B}T = 4.1\,\mathrm{pN\,nm}$，$D_3 = k_\mathrm{B}T/(3\pi\eta d) \simeq 4.35\,\mu\mathrm{m}^2/\mathrm{s}$，于是相应 $D_1 \simeq .435\,\mu\mathrm{m}^2/\mathrm{s}$；(c) 另外指定 $D_1 = 1$，应按题面分别计算，不能暗中混用。

(b) 用第 7 章尺度模型，一次滑动时间 τ_1，真正三维重新定位耗时 τ_3，原地跳回耗时 τ_h。独立重定位前的滑动次数是均值 $1/(1-p)$ 的几何变量，有效扫描长度 $\ell \sim \sqrt{D_1\tau_1/(1-p)}$。每一有效轮平均耗时 $[\tau_1 + p\tau_h + (1-p)\tau_3]/(1-p)$，因此

$$t_\mathrm{loc} \sim \frac{L_g[\tau_1 + p\tau_h + (1-p)\tau_3]}{\sqrt{D_1\tau_1(1-p)}}.$$

原题未给跳回耗时。若与三维飞行同耗时，$\tau_h = \tau_3$，最优 $\tau_1 = \tau_3$，代价增为无跳回结果的 $1/\sqrt{1-p}$；若跳回时间可忽略，最优 $\tau_1 = (1-p)\tau_3$，调整停留时间后最小代价恢复无跳回尺度。把二者混为一个精确数值会隐含缺失假设。

(c) 不考虑跳回的最优时间 $2L_g\sqrt{\tau_3/D_1}$。用每碱基对 .34 nm，$L_g = 340\,\mu\mathrm{m}$，得约 21.5 秒；按同耗时跳回约 68.0 秒。扫描区间定义和端点命中给出未固定的 $O(1)$ 前因子。若 $\tau_1 = \tau_0 \mathrm{e}^{-\beta E_{ns}}$，最优结合能为 $E_{ns} = -k_\mathrm{B}T\ln(\tau_1^{\mathrm{opt}}/\tau_0)$；缺少尝试时间 τ_0，不能从题面确定一个绝对能量数值。　□

习题 13.2 （PS7.3）WLC 能量 $\kappa\int_0^L R(s)^{-2}\,\mathrm{d}s/2$，局部蛋白引入弯折，外力 F 拉伸 DNA。(a) 以切线角 $\theta(s)$ 写曲率与受力泛函；(b) 最小化后在小角近似求形状、延伸 $X(F)$ 及其逆函数；(c) 求形变能，蛋白附近角度 .5，结合能 $20k_{\mathrm{B}}T$，估计脱离力并画脱离后的力延伸关系。图示未给左右两侧的详细端点约束，须说明所用边界。

解答. (a)$R^{-1}=|\theta'|$，$H=\int[\kappa(\theta')^2/2-F\cos\theta]\,\mathrm{d}s$。(b) 变分得 $\kappa\theta''=F\sin\theta$。取一侧半无限链 $s\ge 0$，$\theta(0)=\theta_0$、$\theta(\infty)=0$，小角解 $\theta=\theta_0\mathrm{e}^{-s/\ell_F}$，$\ell_F=\sqrt{\kappa/F}$。一侧延伸亏损 $L-X=\theta_0^2\ell_F/4$；若有 m 个等角侧臂，乘 m，所以

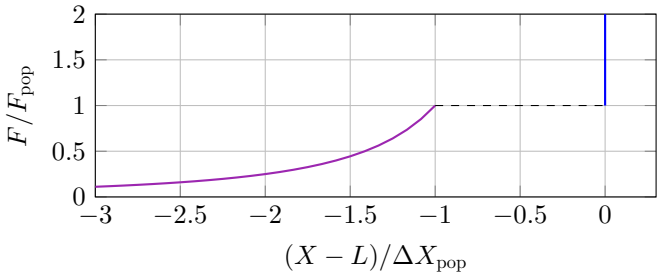
$$F(X)=\frac{m^2\kappa\theta_0^4}{16(L-X)^2}.$$

(c) 仅弯曲能为 $m\theta_0^2\sqrt{\kappa F}/4$，而含外力功的总额外 Gibbs 能是它的两倍。与结合自由能比较，得

$$F_{\mathrm{pop}}=\frac{4E_{\mathrm{bind}}^2}{m^2\kappa\theta_0^4}.$$

题面未给 κ；若另采用双链 DNA $\ell_p=50\,\mathrm{nm}$，$\kappa=k_{\mathrm{B}}T\ell_p$，则 $m=1$ 约 $2.10\,\mathrm{nN}$，$m=2$ 约 $.525\,\mathrm{nN}$。这些值很高，已超出简单不可伸长、固定角蛋白模型适用于真实 DNA 的可靠力区间；它们只是给定静态模型的估计，不是实测脱离力。

脱离前沿上述弯折分支，达到阈值后角度趋零，弯折亏损消失，延伸在力控制下跳到未结合链分支。本题不包含热 WLC 涨落，理想未结合链分支是 $X=L$；若另加入第 4 章热涨落，则以其强力渐近延伸作背景，不可把两项各自当成独立实测曲线。



此图以脱离前的弯折亏损 ΔX_{pop} 归一化，只表达选定静态模型的分支与跃迁，不是实测蛋白曲线。

□

13.2 PS8：漂移和扩散

习题 13.3 （PS8.1）丝长 $\ell=1,2,\ldots$，末端以速率 a 加单体、以速率 b 减单体，但长度 1 禁止再减。(a) 写主方程；(b) 求归一化稳态；(c) 给存在条件和平均长度；(d) 若 $a>b$、初始皆为单体，求时间依赖均值和方差，并给近似分布。

解答. $\dot p_1=bp_2-ap_1$，$\ell\ge 2$ 时 $\dot p_\ell=ap_{\ell-1}+bp_{\ell+1}-(a+b)p_\ell$。以下取 $a,b>0$。稳态零流给 $p_\ell=(1-r)r^{\ell-1}$，$r=a/b$，仅 $r<1$ 可归一化，平均长度 $1/(1-r)$；$a=b$ 也不存在归一化稳态。

(d) 不能把半直线边界删除后直接宣称 $(a-b)t$ 是所有时刻的精确均值。令 $n=\ell-1$，$P_0(t)=p_1(t)$，$m=\langle n\rangle$、

$q=\langle n^2\rangle$。由方程求矩得

$$m'=a-b+bP_0,\qquad q'=2(a-b)m+a+b-bP_0,\qquad m(0)=q(0)=0.$$

这给出可直接积分的精确均值 $1+m$ 和方差 $q-m^2$。更显式地，对时间作 Laplace 变换，令

$$r(s)=\frac{s+a+b-\sqrt{(s+a+b)^2-4ab}}{2b},$$

则 $\widetilde{p}_{n+1}=(1-r)r^n/s$，$\widetilde{m}=r/[s(1-r)]$、$\widetilde{q}=r(1+r)/[s(1-r)^2]$；逆 Laplace 即精确时刻答案。它来自空间递推的有界根，$\sum_n \widetilde{p}_{n+1}=1/s$ 核查归一化。

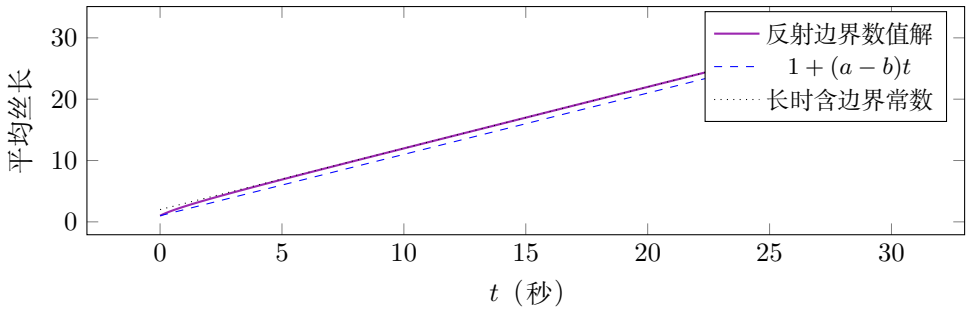
退化的 $b=0$ 情形则是纯出生过程，$p_\ell(t)=\mathrm{e}^{-at}(at)^{\ell-1}/(\ell-1)!$，均值 $1+at$、方差 at；无需使用含 b 分母的根式。

大时间 $a>b$ 时，$m=(a-b)t+b/(a-b)+o(1)$，方差 $=(a+b)t+O(1)$。中心远离边界后，正态近似均值 $1+m$、方差 $q-m^2$ 在集中区间有效，负长度尾部是近似误差；要求严格非负分布时可从上述递推计算离散概率，不能把未归一化截断高斯冒称精确分布。

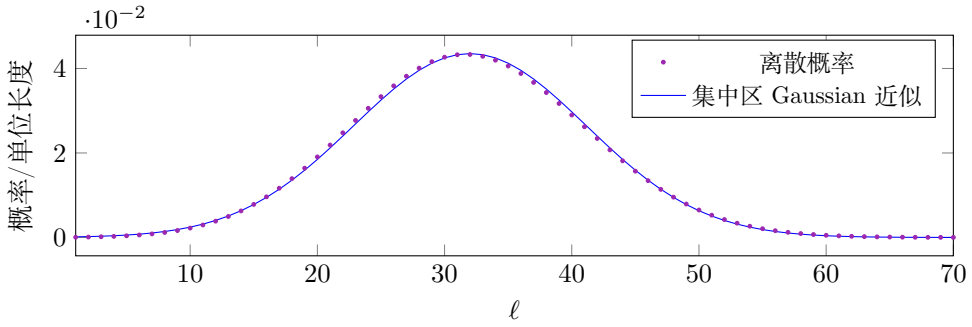
给一个可执行的有限时刻算例：教学参数 $a=2\,\mathrm{s}^{-1}, b=1\,\mathrm{s}^{-1}$，初始 $p_1=1$。附带程序按上述主方程构造生成元并计算 $p(t)=\mathrm{e}^{Qt}p(0)$；长度上限 256 与 512 的矩差小于 8×10^{-12}，前者最远端概率低于 10^{-87}，所以显示时段内的上端截断不影响这些数字。它是模型的实际数值解，不是细胞实验测量。

t (s)	.1	1	10	30
$\langle\ell\rangle$	1.19092	2.50812	11.97485	31.99974
$\mathrm{Var}\,\ell$	.19202	1.83586	24.78427	84.01898

小时间均值斜率为 a，因为单体不能再减；大时间才趋于 $a-b$，且均值的边界修正常数不消失。下图给准确模型均值与两种长时/无边界表达的比较。



在 $t=30$ 秒，用实际计算的均值 31.99974、方差 84.01898 构造集中区正态密度，与离散主方程概率比较如下。曲线是每单位丝长的密度近似，不是重新归一化后声称精确的离散分布；在短时或边界附近应直接使用离散解。



□

习题 13.4 （PS8.2）微管两态概率满足

$$\partial_t p_+ = -\alpha p_+ + \gamma p_- - \partial_x(v_+ p_+) + d\partial_x^2 p_+,$$
$$\partial_t p_- = \alpha p_+ - \gamma p_- + \partial_x(v_- p_-) + d\partial_x^2 p_-.$$

(a) 用 $\widetilde{p}(k,\omega) = \int \mathrm{e}^{\mathrm{i}(kx-\omega t)} p \,\mathrm{d}x\,\mathrm{d}t$ 求色散；(b) 展开慢模 $\omega = vk + \mathrm{i}Dk^2 + O(k^3)$；(c) $v_+ = 2\,\mu\mathrm{m/min}$、$v_- = 20\,\mu\mathrm{m/min}$、$\alpha = .004\,\mathrm{s}^{-1}$、$\gamma = .05\,\mathrm{s}^{-1}$、$d = 0$，估计漂移超过扩散的时间；(d) 单体尺寸 a_0，生长和缩短态跳跃率 r_+, r_-，写离散主方程并作连续极限。

解答. 设 $S = \alpha + \gamma$。变换后 $\mathrm{i}\omega$ 是矩阵 $\begin{pmatrix} -\alpha + \mathrm{i}kv_+ - dk^2 & \gamma \\ \alpha & -\gamma - \mathrm{i}kv_- - dk^2 \end{pmatrix}$ 的特征值，故

$$\mathrm{i}\omega_\pm = -S/2 - dk^2 + \mathrm{i}k(v_+ - v_-)/2 \pm \tfrac{1}{2}\sqrt{[\gamma - \alpha + \mathrm{i}k(v_+ + v_-)]^2 + 4\alpha\gamma}.$$

取 $k = 0$ 时为零的加号根，展开得到 $v = (\gamma v_+ - \alpha v_-)/S$，$D = d + \alpha\gamma(v_+ + v_-)^2/S^3$。另一模以 S^{-1} 时间衰减。

(c) 先换成每秒，得 $v = .00617\,\mu\mathrm{m/s}$、$D \simeq .171\,\mu\mathrm{m}^2/\mathrm{s}$；令 $vt \sim \sqrt{2Dt}$，得 $t \sim 2D/v^2 \simeq 9.0 \times 10^3$ 秒，约 150 分钟。这个自由长度模型不能判断已撞到零长度边界的微管存活条件。

(d) $\dot{p}_{+,n} = -\alpha p_{+,n} + \gamma p_{-,n} + r_+(p_{+,n-1} - p_{+,n})$，$\dot{p}_{-,n} = \alpha p_{+,n} - \gamma p_{-,n} + r_-(p_{-,n+1} - p_{-,n})$。以 $x = na_0$ 展开，漂移 $v_\pm = a_0 r_\pm$，各态内部扩散 $d_\pm = a_0^2 r_\pm/2$。若二者不同，不能严格约化为题设共同的 d；要保留两种扩散系数或声明另加相同的背景扩散。 □

习题 13.5 （PS8.3）马达每步 d 要经过 m 个同速率 u 的单向内部阶段，无逆步。(a) 将随机度 $r = \lim_{t\to\infty} \mathrm{Var}\, x/[d\langle x\rangle]$ 与 v, D 联系；(b) 求 v, D；(c) 若低负载 $r \simeq 1/2$、高负载 $r \simeq 1$，说明模型解释。

解答. 长期 $\langle x\rangle = vt$、$\mathrm{Var}\, x = 2Dt$，所以 $r = 2D/(dv)$。周期等待时间均值 m/u、方差 m/u^2，更新计数长期均值 ut/m、方差 ut/m^2，故 $v = du/m$、$D = d^2u/(2m^2)$。等速率单向模型分别对应两个和一个主要限速阶段；高负载可能使某一个阶段远慢于其他阶段。数据并不证明实际内部结构只有这些状态。 □

习题 13.6 （PS8.4）每个位置 n 有内部态 n'。正向率为 $u_1: n \to n'$、$u_2: n' \to n+1$，逆向率为 $w_1: n' \to n$、$w_2: n+1 \to n'$，步长 d。(a) 写主方程；(b) 求慢模色散；(c) 求 v, D 和 Einstein 力；(d) 负载使 $u_2 \to u_2 \mathrm{e}^{-Fd/k_{\mathrm{B}}T}$，求速度和停滞力；(e) 数据 $v \simeq 670\,\mathrm{nm/s}$、$D \simeq 1400\,\mathrm{nm^2/s}$、$F_s \simeq 5\,\mathrm{pN}$，取 $u_1 = 2000\,\mathrm{s^{-1}}, u_2 = 50\,\mathrm{s^{-1}}$、$w_i = u_i/100$，检验二态模型。以 kinesin 步长 $d = 8\,\mathrm{nm}$ 作数值比较。

解答. 设未加撇概率 p_n、加撇概率 q_n，则 $\dot{p}_n = u_2 q_{n-1} + w_1 q_n - (u_1 + w_2) p_n$，$\dot{q}_n = u_1 p_n + w_2 p_{n+1} - (u_2 + w_1) q_n$。设 $S = u_1 + u_2 + w_1 + w_2$、$A = u_1 u_2$、$B = w_1 w_2$。用与上一题同样的 Fourier 约定，慢模满足

$$\lambda(\lambda + S) = A(\mathrm{e}^{\mathrm{i}kd} - 1) + B(\mathrm{e}^{-\mathrm{i}kd} - 1), \qquad \lambda = \mathrm{i}\omega,$$

取 $k = 0$ 时为零的根，二阶展开给

$$v = d\frac{A - B}{S}, \quad D = d^2\left[\frac{A+B}{2S} - \frac{(A-B)^2}{S^3}\right], \quad F_E = \frac{k_{\mathrm{B}}Tv}{D}.$$

F_E 是定义于漂移扩散比的有效力，不必等于真实负载。负载后的 $S(F) = u_1 + w_1 + w_2 + u_2\mathrm{e}^{-\beta F d}$，速度将上述 A 换为 $A\mathrm{e}^{-\beta F d}$，停滞 $F_s = (k_{\mathrm{B}}T/d)\ln(A/B)$。

(e) 取室温 $k_{\mathrm{B}}T = 4.1\,\mathrm{pN\,nm}$，得到 $v \simeq 386\,\mathrm{nm/s}$、$D \simeq 1474\,\mathrm{nm^2/s}$、$F_s \simeq 4.72\,\mathrm{pN}$、$F_E \simeq 1.07\,\mathrm{pN}$。扩散与停滞力接近给定数据，但速度低约 42%，所以这一组率参数不能同时解释全部观测。不能因两个数接近便宣布模型完全吻合。 □

习题 13.7 （PS8.5）细菌以速度 v 奔跑 t_r，翻滚 t_t 后独立随机选三维方向。时长密度 $p_r(t) = 4t\mathrm{e}^{-2t/\tau_r}/\tau_r^2$，$p_t$ 同型。(a)$\tau_r = 2$ 秒、$\tau_t = .2$ 秒、$v = 30\,\mu\mathrm{m/s}$，求长期扩散；(b) 有营养梯度时 $\tau_r(\hat{n}) = \tau_0 + g\hat{n}\cdot\hat{z}$，求漂移。

解答. 这两种 Gamma 分布均值为 τ，二阶矩为 $3\tau^2/2$，不是均值平方。独立各向同性位移给 $D = v^2\langle t_r^2\rangle/[6(\tau_r + \tau_t)] = v^2\tau_r^2/[4(\tau_r + \tau_t)] \simeq 409\,\mu\mathrm{m^2/s}$。方向偏置使平均每轮位移 $v\langle\hat{n}\tau_r(\hat{n})\rangle = vg\hat{z}/3$，平均周期 $\tau_0 + \tau_t$，故 $\mathbf{v}_{\mathrm{drift}} = vg\hat{z}/[3(\tau_0 + \tau_t)]$。保证所有方向平均时长为正需 $|g| < \tau_0$；方向抽样本身仍是均匀的，偏置来自持续时间。 □

14 补充原题与公开数据分析

本章根据完整性复核增加七道实际公开原题。数据来自 MIT 作业页面：基因组 FASTA、Seattle SNP 项目频率文件、PurR 位点和基因表。原始数据文件保持不变，输入哈希、随机背景种子及全部输出见源码包；它们是已有公开数据的重新分析，不是本项目开展的新实验。解答仍为编者独立推导。

14.1 PS3.2：同源与异源二聚体

习题 14.1 蛋白接触面为恰含 N 个氨基酸的环，序列随机选取。两异源环 a,b 在相对移位 s 下能量 $E_s^{ab}=\sum_{i=1}^{N}V(a_i,b_{i+s})$，结合能为全部移位中的最小值。未经翻转的同源环给 $E_s^{aa}=\sum_i V(a_i,a_{i+s})$，物理上将一个环翻转后给 $E_s^{aaR}=\sum_i V(a_{N-i},a_{i+s})$（指标按环模 N 取）。假定大 N 下 E_s 是高斯变量，接触均值零、方差 σ^2。(a) 求异源最小能的均值和分布；(b) 求未经翻转同源的分布和均值，注意不同移位实现的数目；(c) 求翻转同源的对应量，注意重复接触数；(d) 随机选取时哪组最好/最差，若特别设计序列，同源是否必有优势？

解答. 题面给单个接触的两个矩，并不能严格推出共享氨基酸的不同接触及不同移位彼此独立。以下说明原题所意图的极值近似：除完全重复或对称的接触外，将接触看成独立，$V(a,b)=V(b,a)$，不同非等价移位能量近似独立。若不添加这些条件，联合分布和极值均值一般不由两个矩唯一确定。

(a) 异源每个移位方差 $N\sigma^2$，近似 N 个独立高斯；其累计最小值为 $1-[1-F(E)]^N$，中心 $-\sigma\sqrt{2N\ln N}$，宽度约 $\sigma\sqrt{N/(2\ln N)}$，是反向 Gumbel。

(b) 对未经翻转同源，s 和 $N-s$ 的接触集完全相同。排除 $s=0$ 的逐位自接触后，通常只有约 $N/2$ 个不同的能量，方差仍约 $N\sigma^2$。故最小能中心约 $-\sigma\sqrt{2N\ln(N/2)}$，分布为相同高斯最小值式但样本数换为约 $N/2$。偶数 N 的 $s=N/2$ 中每个接触重复两次，单个特殊移位方差约 $2N\sigma^2$；只有一个这样的变量，不改变大 N 的主导极值。$s=0$ 的 $V(a,a)$ 分布并未单独给定，若将它纳入，需另给其统计，不能暗中假设它与异源完全相同。

(c) 翻转接触是一个配对对合，除 $O(1)$ 个可能固定位置外，每种无序接触出现两次。因此每个能量约有 $N/2$ 个独立项，每项系数 2，方差约 $2N\sigma^2$。约 N 个非等价移位给中心 $-\sigma\sqrt{4N\ln N}$，宽度约 $\sigma\sqrt{N/\ln N}$，相应反向 Gumbel 将标准差换为 $\sqrt{2N}\sigma$。这个优势来自接触重复的方差增强，而不是平均接触能变负。

(d) 在以上随机近似下翻转同源最优，未经翻转同源稍差于异源；后两者主导阶相同，差异属于对数样本数修正。专门设计不是随机抽样的同一问题：若独立优化每个接触，两组都可偏好低能配对；同源减少序列自由度，也可能增加几何匹配限制。仅由随机模型不能证明设计后的同源必有优势，需给定可设计序列、接触势及约束。 □

14.2 PS4.3：噬菌体包装的能量尺度

习题 14.2 $\phi29$ 噬菌体将 20000 碱基对的 dsDNA 装进题面给的圆柱衣壳，半径 $r=42\,\mathrm{nm}$、高 $h=47\,\mathrm{nm}$。DNA 由外向内形成螺旋壳，相邻链约 2.3 nm，室温 300 K，公开题面给包装功约 $10^5 k_{\mathrm B}T$。(a) 取持久长约 50 nm，估计溶液 DNA 的构象熵，熵损是否足够；(b) 以 $\kappa=k_{\mathrm B}T\ell_p$ 估计螺旋弯曲能；(c) 电荷间距 $b=.17$ nm、屏蔽长 1 nm，邻链距离约 2 nm，估计 Debye–Hückel 排斥能，能否解释包装功？

解答. DNA 轮廓长 $L = 20000(.34\,\mathrm{nm}) = 6800\ \mathrm{nm}$，约有 $L/(2\ell_p) = 68$ 个 Kuhn 节段。每节段方向的构象熵依赖角分辨与约束，绝对连续熵没有无参照的数值；但每段损失 $O(k_\mathrm{B})$ 的独立构象选择给 $O(10^2 k_\mathrm{B}T)$ 的功尺度，远小于 $10^5 k_\mathrm{B}T$。它不能独自解释包装功。

若六角紧排的每链截面积 $A_c = \sqrt{3}(2.3)^2/2 \simeq 4.58\,\mathrm{nm}^2$，以题给圆柱和同心壳近似有 $\pi h(r^2 - r_i^2) = A_c L$，得 $r_i \simeq 39.4$ nm。环状壳的弯曲能

$$\frac{E_b}{k_\mathrm{B}T} = \frac{\ell_p}{2}\int \frac{\mathrm{d}L}{R^2} = \frac{\pi \ell_p h}{A_c}\ln\frac{r}{r_i} \simeq 10^2.$$

直接用 $\ell_p L/(2r^2)$ 也给相同数量级。题面的半径使包装仅占较薄外壳；若半径/直径或真实衣壳形状不同，此估计会变。这里按原题数值作答，没有修改实物尺寸来追求预设结果。

对于两平行线，电荷线密度为 $1/b$，距 d，连续线积分给单位长度相互作用

$$\frac{U_{12}}{k_\mathrm{B}TL} = \frac{\ell_B}{b^2}\int_{-\infty}^{\infty} \frac{\mathrm{e}^{-\sqrt{z^2+d^2}/\lambda}}{\sqrt{z^2+d^2}}\,\mathrm{d}z = \frac{2\ell_B}{b^2}K_0(d/\lambda).$$

六个邻链每对只数一次，总能约 $3L\,[2\ell_B K_0(d/\lambda)/b^2]$。$\ell_B = .7$ nm、$d = 2$ nm、$K_0(2) \simeq .114$ 给 $E_\mathrm{el} \simeq 1.1\times 10^5 k_\mathrm{B}T$，$d = 2.3$ nm 则约 $8\times 10^4 k_\mathrm{B}T$，所以裸电荷屏蔽模型能达到所需尺度。

但此结果不是高密度衣壳的精确自由能：凝聚会降低有效电荷，非线性屏蔽、短程水合和离子关联也可显著改变能量。若简单将有效线电荷减为 Manning 值，排斥按电荷密度平方下降。结论是裸静电具有足够数量级，而不是已唯一证明全部包装功来自 Debye 势。 □

14.3 PS6.2：受力 DNA 模型的完整相界

习题 14.3 将 Poland–Scheraga 模型推广到两端受力 F 的 DNA。(a) 对各段位置积分，证明配分函数为杆段 $R(\ell)$ 与气泡 $B(\ell)$ 的交替乘积，段长和为 N；(b) 双链段为长 $a\ell$ 的刚杆、结合权重 w^ℓ，求三维方向积分；(c) 气泡由两个长度 ℓ、共享端点的随机链构成，证明 $B(\ell) = s g^{2\ell}\ell^{-3/2}\exp(\beta^2F^2a^2\ell/12)$；(d) 以 z^N 作生成函数，用 Bose 和 $f_m^+(x) = \sum_{\ell\ge1} x^\ell/\ell^m$ 表示两段变换；(e) 求解链临界条件；(f) 取 $s = 1$，在 w/g^2 与 $\beta F a$ 平面画相界。

解答. (a) 忽略各段之间的相互作用后，外力做功 $F\sum X_i$ 可逐段分开，长度限制仍保留 $\sum \ell_i = N$；固定端型给 $\widetilde{Z} = \widetilde{R}/(1-\widetilde{R}\widetilde{B})$。

(b) 令 $h = \beta F a$，归一化方向平均 $\frac{1}{2}\int_{-1}^{1}\mathrm{e}^{h\ell u}\,\mathrm{d}u = \sinh(h\ell)/(h\ell)$，故 $R = w^\ell \sinh(h\ell)/(h\ell)$，$h\to 0$ 恢复 w^ℓ。

(c) 每条高斯链的端点权重为 $g^\ell(3/(2\pi\ell a^2))^{3/2}\exp[-3R^2/(2\ell a^2)]$。两条相乘，积分 $\int \mathrm{d}^3R\mathrm{e}^{\beta\mathbf{F}\cdot\mathbf{R}-3R^2/(\ell a^2)}$ 后高斯配平方给 $\mathrm{e}^{h^2\ell/12}$，其余长度前因子为 $\ell^{-3/2}$，微观常数归入 s。

(d) 定义 $x = g^2 z\mathrm{e}^{h^2/12}$，则 $\widetilde{B} = s f_{3/2}^+(x)$，

$$\widetilde{R} = \frac{f_1^+(wz\mathrm{e}^{h}) - f_1^+(wz\mathrm{e}^{-h})}{2h} = \frac{1}{2h}\ln\frac{1-wz\mathrm{e}^{-h}}{1-wz\mathrm{e}^{h}}.$$

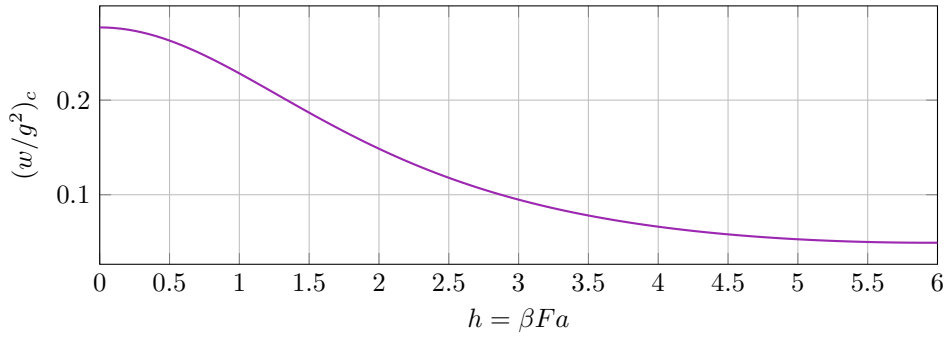
其适用收敛区需 $wz\mathrm{e}^h < 1$。当 $h = 0$ 取极限 $\widetilde{R} = wz/(1-wz)$，不要除以零。

(e) 气泡分支点为 $z_c = g^{-2}\mathrm{e}^{-h^2/12}$；极点撞击时 $\widetilde{R}(z_c)\widetilde{B}(z_c) = 1$，故 $\widetilde{R}(z_c) = 1/[s\zeta(3/2)]$。$A = wz_c$，$C = \exp[2h/(s\zeta(3/2))]$，解得 $A = (C-1)/(C\mathrm{e}^h - \mathrm{e}^{-h})$。

(f) 相界为

$$\left(\frac{w}{g^2}\right)_c = \mathrm{e}^{h^2/12}\frac{\exp[2h/(s\zeta(3/2))]-1}{\exp[h+2h/(s\zeta(3/2))]-\mathrm{e}^{-h}}, \quad \left(\frac{w}{g^2}\right)_c\Big|_{h=0} = \frac{1}{1+s\zeta(3/2)}.$$

较大结合权重位于双链分支；较小权重位于解链分支。下图用 $s=1$ 绘制模型相界。大 h 时高斯单链权重含 h^2，而刚杆含 h，造成不应直接用于真实有限伸长 DNA 的远强力行为。完整模型图与真实物质相图必须区分。



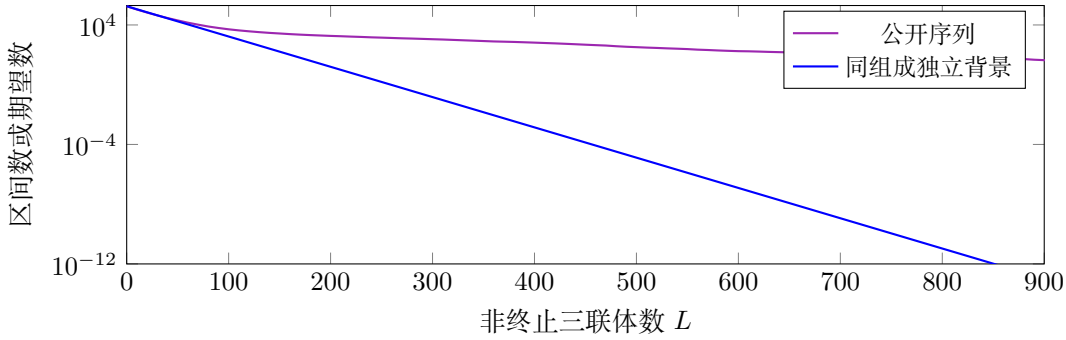
□

14.4 PS1.2 与 PS1.4：公开基因组的 ORF 和相关

习题 14.4 （PS1.2，可选）使用课程提供的 U00096.fna 大肠杆菌完整序列。(a) 对正向三种阅读框，用 5' 到 3' 方向每次读取不重叠三联体，记录连续终止密码间的距离 L，可略逆向链；(b) 画 ORF 长度分布，与随机序列比较；(c) 估计实际长 ORF 数量显著超出随机期望的长度阈值。

解答. 实际输入长 4639221 个碱基。将 L 定义为两终止间非终止三联体数，因此位置差需减 1；若原始距离按含终止计数，横轴平移一而不改变长尾结论。三正向框共有 179558 个完全观测区间。每个框首个终止前与最后终止后的截断区间不计入，三框未跨闭环拼接；相对全基因组这只影响至多六个边界区间。

等频独立模型的 $P(L=\ell)=p_s(1-p_s)^{\ell}$、尾概率 $P(L\ge\ell)=(1-p_s)^{\ell}$。为了与实际完整区间数比较，将其乘 179558；另以实测碱基频率计算独立背景 $p_s\simeq .04562$。下图显示累计尾，避免极长区间稀疏分箱掩盖信号。



以 600 三联体为一个保守阈值，实际有 176 个区间，同组成独立背景预期仅 1.22×10^{-7}，偏离极显著。这个 $L_{\mathrm{cut}}=600$ 不是从唯一统计检验优化的最小阈值，而是明确可复核、足以显示长尾的保守选择；表中其他阈值亦可比较。随机不显著不等于没有功能，随机显著也不等于已证明基因身份，需起始密码、方向和注释等信息。 □

习题 14.5 （PS1.4，可选）独立位置突变模型预测 $p_{XY}=p_Xp_Y$。(a) 计算课程 E.coli 序列的四碱基频率；(b) 计邻位 16 种碱基对，求 $c^{(1)}_{XY}=p^{(1)}_{XY}/(p_Xp_Y)$；(c) 对更远间距重复并讨论相关随距离如何变化。

解答. 按 A、C、G、T 排序，频率分别为 $.24619,.25423,.25366,.24592$。闭环序列以模基因组长度配对，邻位矩阵为

$$c^{(1)}\simeq\begin{pmatrix}1.201 & .884 & .821 & 1.103\\ 1.120 & .906 & 1.159 & .814\\ .922 & 1.283 & .905 & .883\\ .755 & .921 & 1.113 & 1.210\end{pmatrix}.$$

例如 GT、CG 与 TA 等组合并非全部接近 1，独立模型受到实际数据反驳。由于同一序列各对重叠，不能把所有二联体当成完全独立试验后直接套最简单的标准误。

用互信息 $I_n=\sum p^{(n)}_{XY}\log_2 c^{(n)}_{XY}$ 汇总，$n=1,2,3,6,9,30,100,300,1000$ 时依次约

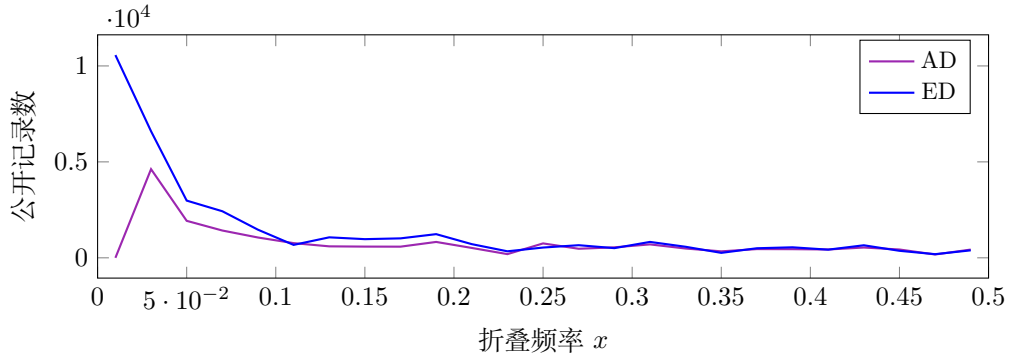
$$.01841,\ .00746,\ .00713,\ .00131,\ .00155,\ .00154,\ .00025,\ .00070,\ .000008$$

比特。总体减小但不单调，存在阅读框/长程组成等结构。几次距离的数值不足以确立一个统一指数衰减定律，源码保留各 16 元矩阵以便检查。 □

14.5 PS1.6：公开 SNP 数据与不可识别的拟合

习题 14.6 课程提供 Seattle SNP 项目的 cSNPsAfricanEuropean.dat，每行 AD、ED 两个群体等位频率。(a) 把 $x>.5$ 换成 $1-x$，画频率直方图并与课堂稳态比较，讨论 $N\mu$ 与拟合；(b) 比较两群体，取 $\mu=10^{-8}$，用约 20–30 格、忽略极稀有变体尝试估计有效种群数；(c) 用 Type.dat 比较同义/非同义变体的频率、模型适配及哪类更多，解释可能机制。

解答. 实际原始文件 37164 行。先剔除在某群体中 $x=0,1$ 的非多态记录，再折叠到 $(0,.5)$；恰为 .5 的边界记录独立处理，拟合未收入它们。用 25 格、格宽 .02 画图，并按原题忽略最低格后在 $(.02,.5)$ 的 24 格上拟合。对本卷单倍体拷贝数约定，理论零选择对称突变分布为 $p(x)\propto[x(1-x)]^{\alpha-1}$，$\alpha=2N\mu$。折叠和截断后，每格概率用 Beta 分布积分再按保留区间归一化，而不是用格中心密度当精确概率。

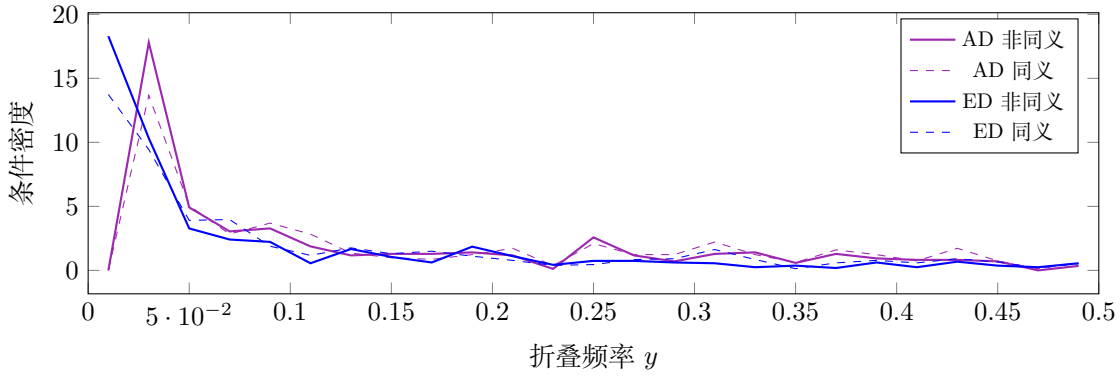


AD、ED 分别保留 19155、25782 条用于拟合。条件多项似然在搜索区间 $\alpha \in [10^{-4}, 3]$ 均将最优推到下边界，而 Pearson 形状偏差约 1252 与 2174（24 格）；采集选择与位点相关使它们不能直接作为校准后的显著性检验量。$\alpha = 10^{-4}$ 代入会形式上给 $N = 5000$，但这是人为搜索下界而非数据识别出来的种群数。本卷因此不把 5000 包装成有效种群估计，也不据两个同样贴边的拟合强断言群体大小相同。

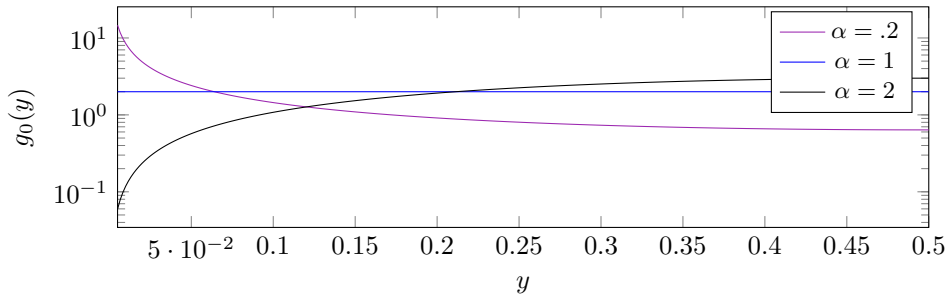
这个失败本身回答原题：当前被筛选、四舍五入、带群体结构且不包含全部不变位点的数据，不能在所采用的平稳单参数模型下可靠估计 N。改变最低频率截断或模型会改变结果；人口历史与选样过程需要额外信息。图中群体分布确有差别，但不能唯一归因于 N。

Type 文件给非编码/UTR35536 条、非同义 842 条、同义 786 条。AD 中非同义与同义的多态记录 427、406，折叠频率均值分别 .1322, .1558；ED 对应 809、768 与 .0870, .1088，这里仍按 $0 < x < .5$ 口径。非同义变体平均更低与净化选择相容，但机会位点数量、密码简并和发现偏差未知，842 比 786 不能解释成单位位点非同义突变率更高。分组原始计数和条件均值均在 QA 中，未宣称已完成现代人口遗传推断。

为回答 (c) 中的 $f(x)$，下图按群体和同义/非同义类别分别画条件密度：先折叠成 $y = \min(x, 1-x)$，仅保留 $0 < y < .5$ 的多态记录，宽.02 的每格计数除以该类别保留数及格宽。这样比较曲线形状，而不是把样本量 842 与 786 的差异混入纵轴。



课堂对称突变、恒定种群的中性模型为 $f_0(x) = [x(1-x)]^{\alpha-1}/\mathrm{B}(\alpha,\alpha)$，$\alpha = 2N\mu$ 采用基因拷贝数约定。折叠后 $g_0(y) = 2f_0(y)$，定义在 $(0, .5)$。$\alpha < 1$ 偏向低频，$\alpha = 1$ 平坦，$\alpha > 1$ 偏向中间频率。以下曲线只比较模型形状，未拟合到每类数据；数据直方图因缺失固定、极稀有记录而是另一条件分布，不能把纵轴直接当成总体位点密度。



若加入恒定选择漂移，未折叠模型还带 $\mathrm{e}^{\gamma x}$，$\gamma = 2Ns$；折叠后要把 $f_s(y) + f_s(1-y)$ 相加，不能只画前半边的 f_s。在对称突变模型中，这个折叠形状不能区分 s 的正负。非同义的低频偏移与净化选择相容，但不能从这一图

唯一反演选择系数；同义位点也不必完全中性。额外的分类条件 Beta 尝试、频率区间和保留数记录在新增 QA 中，发现偏差、连锁和人群历史使它们仍不能成为可靠的 N 或 s 估计。

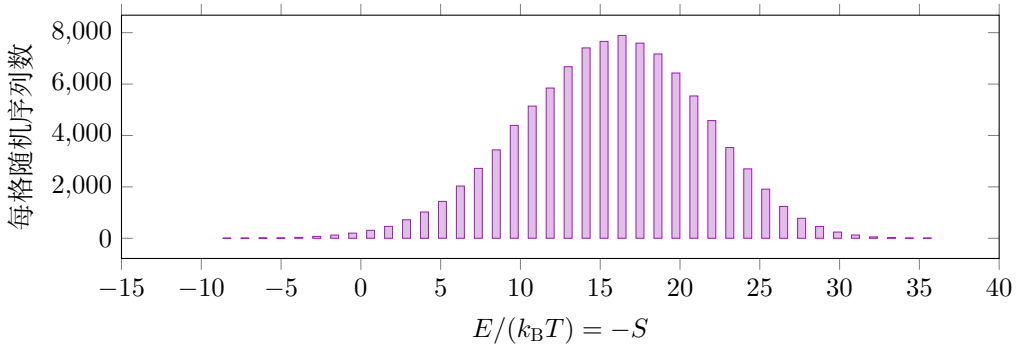
□

14.6 PS7.1：权重矩阵和全基因组候选

习题 14.7 给 PurR 结合序列 purR_sites.txt。(a) 建每位置每碱基权重并算信息量；(b) 用随机 DNA 输入权重矩阵画得分直方图，取 $T_* = T$ 将其转换为结合能分布；(c) 阈值略高于训练位点平均结合能，扫描课程 E.coli 基因组，检查训练序列是否找全、改变阈值并讨论假阳性，可参考 gene_table.txt；(d) 简化模型中长 L 共识序列每失配增加 ϵ，求信息量、随机命中共识的概率及两者联系。

解答. (a) 输入 35 条、各 16 碱基。每位置对每种碱基加伪计数 .5，所以 $p_i(b) = (n_i(b) + .5)/37$；以实测基因组频率 q_b 为背景，取 $w_i(b) = \ln[p_i(b)/q_b]$。信息量 $I = \sum p_i \log_2(p_i/q_b) \simeq 15.866$ 比特。伪计数和背景必须同时报告；零频率导致无限能量的做法会把训练未见字母全部拒绝。

(b) 用固定种子 20261012 生成 100000 条独立同组成随机 16 碱基背景模拟，$S = \sum w_i$、$E/(k_{\mathrm{B}}T) = -S$，能量零点按此定义。随机平均得分约 -15.663，训练平均 12.519。这是一组随机序列模拟，不是实测结合能；$T_* = T$ 也是原题的额外假设。



图用已经实际计算的 40 格直方图，总计 100000 条序列；这既保存稀少低能背景尾部，也显示大部分背景位点的高能区。训练平均能量约 $-12.519 k_{\mathrm{B}}T$，位于背景主峰左侧，零点由本节对数优势定义，不能与另一能量零点的矩阵直接比较。

(c) 两链全扫描，取 $E_{\mathrm{cut}} = \langle E \rangle_{\mathrm{train}} + \delta k_{\mathrm{B}}T$。$\delta = -1, 0, .5, 1$ 时阈值得分为 13.519、12.519、12.019、11.519，候选窗口数为 22、36、39、44；原始 35 条均能在该基因组的一条方向找到，但相应阈值只收入 12、19、19、24 条训练记录。故平均能量稍上方的阈值并不能找全输入，原因是低亲和训练位点也是真实训练数据的一部分。阈值下降降低假阴性，同时增加未验证候选。

“额外候选”并不等于已经证实的假阳性：原题只给部分阳性位点，没有完整阴性真值。本卷公开候选的 1 起始坐标、链方向与得分，保留注释表作核查。注释表标题长 4639675 与本 FASTA 长 4639221 不完全一致，表明版本/坐标必须先核对，不能把靠近某个注释基因就当作已验证调控关系。这里因此不给无证据的精确假阳性数和功能

名称。

(d) 均匀独立背景中唯一共识命中概率 4^{-L}，完全指定共识的信息量 $I=2L$，所以 $P=2^{-I}$。若每个位置失配代价 ϵ 并按 Boltzmann 选择，则共识字母概率 $p_c=1/[1+3\mathrm{e}^{-\beta\epsilon}]$，每个非共识字母概率 $p_m=\mathrm{e}^{-\beta\epsilon}/[1+3\mathrm{e}^{-\beta\epsilon}]$，信息量 $I=L[2+p_c\log_2 p_c+3p_m\log_2 p_m]$。有限容忍时信息量小于 $2L$，精确共识的背景概率仍是 4^{-L}；2^{-I} 估计的是具有相应典型限制的序列族规模，二者不能不加区分地相等。 □

15　对齐计数、接触结构与受力模型

15.1　PS2.3：比对数量的约定与题面缺口

习题 15.1　原作业将本题归于 Durbin 等教材第二章。本卷用独立数学表述保留问题：两有序串分别长 n,m，求保持各自内部次序、交错排列成 $n+m$ 串的数量；再讨论把比对逐列上、下符号交错读出并删空位，是否能与所有含空位比对一一对应；对两长 n 串用 Stirling 式估算相应二项系数。教材文字和版面不重新分发。

解答. 选择 $n+m$ 位置中哪 n 个属于第一串，便确定交错串，数量 $\binom{n+m}{m}$；两个等长串给 $\binom{2n}{n}\sim 4^n/\sqrt{\pi n}$。Stirling 推导是 $(2n)!/(n!)^2\simeq\sqrt{4\pi n}(2n/\mathrm{e})^{2n}/[2\pi n(n/\mathrm{e})^{2n}]$。

原题 (b) 的一一对应需要额外规范。按通常允许匹配、插入、删除三种步的全局比对定义，$n=m=1$ 已有三个比对：两个字母同列，以及两种先后相反的分列空位；交错串却只有 AB、BA 两个。因而删空位映射对普通全体比对不是双射。实际路径数为 Delannoy 数

$$D(n,m)=\sum_{k=0}^{\min(n,m)}\frac{(n+m-k)!}{k!(n-k)!(m-k)!},$$

其中 k 为同时消耗两字母的对角步数。它满足与动态规划同型的三项递推，$D(1,1)=3$。若特意定义每个交错串的规范配对方式以消去冗余，才得到题意所指的二项系数。写清约定既保留原题组合计算，也避免把错误的普遍双射当成证明。 □

15.2　PS5.3：接触矩阵的实际统计和 REM

习题 15.2　(a) 寻找 20 种氨基酸相互作用 $U(a,a')$，计算平均及方差，原题建议 Miyazawa–Jernigan1996 表 3；(b) 紧密自避免链遍历 $L^3=N$ 的立方晶格全部位置，求非骨架最近邻接触数及大 N 下的比例；(c) 紧密步数约 $g^N, g\simeq 1.85$，结合接触矩估计随机序列的冻结温度与最低能；(d，可选) 选蛋白的公开序列和接触结构，用同一势估天然能及 E_N/E_c。

解答. (a) 实际读取原题公开链接的 MJ 表 3，使用上三角及对角的 e_{ij}，再对称填充；下三角是另一个 e'_{ij}，不能直接把整张不对称印刷表当一个相互作用矩阵。对 20 种字母各 1/20、400 个有序对等权统计，得到 $\bar U=-3.1660$、$\mathrm{Var}\,U=2.1711025$，单位分别为表中的 RT 与 RT 平方。此处只发表聚合数值，不重分发表格或 400 个原值；脚本

从原公开链接临时读取以复核，保留原作者与哈希。

(b) 立方盒最近邻边数为 $3L^2(L-1)$，链骨架占 $N-1$ 条，剩下

$$n = 3L^2(L-1) - (N-1) = 2N - 3N^{2/3} + 1, \qquad n/N \to 2.$$

每个接触只数一次，不能把六个邻居直接乘 N。在独立接触 REM 中，构象能均值为 $n\bar{U}$、方差为 $n\,\mathrm{Var}\,U$。

(c) 用 $\ln \Omega = N \ln g$，

$$E_c = n\bar{U} - \sqrt{2n\,\mathrm{Var}(U) N \ln g}, \qquad k_{\mathrm{B}}T_c = \sqrt{\frac{n\,\mathrm{Var}(U)}{2N \ln g}}.$$

$n/N \to 2$ 时 $E_c/N \simeq -8.64339$ 个表能量单位，$k_{\mathrm{B}}T_c \simeq 1.87861$ 个表能量单位。表中 RT 是接触势的参考能量标度，需先规定参考温度才能换成 Kelvin，不能把经验势的“RT 单位”当成未知求解温度自身而循环定义。

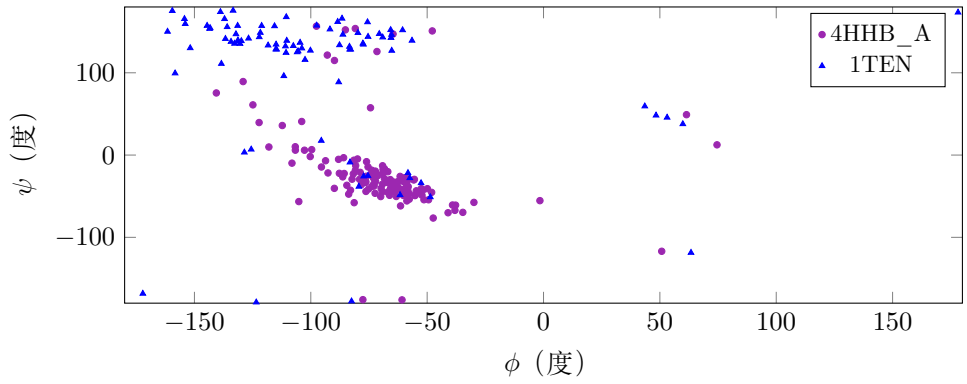
(d) 实际分析课程提供 4HHB_A 坐标。采用明示的编者接触定义：同链 Cα 距小于 8 Å，序号差超过 2，每对只数一次，141 个 Cα、368 接触给 $E_N = -1221.80$，同接触数 REM 参考 $E_c = -1537.39$，比约 .7947。1TEN 给 89 个 Cα、240 接触、$E_N = -740.43$、$E_c = -998.71$、比 .7414。真实折叠稳定性不由这两个比值证明：接触定义、能量零点、非独立接触、非立方紧排和序列设计都会改变解释。源码保留定义和实际坐标，不把模型能量标成实测热力学能。 □

15.3 PS5.4：由真实坐标得到 Ramachandran 图

习题 15.3 用公开蛋白结构求每残基的 ϕ, ψ 二面角，原题建议 Rasmol 并提供 1TEN 和 4HHB_A。(a) 画图比较螺旋、片层位置，可参考 PDB 的 HELIX/SHEET 字段；(b) 找离开主要角度簇的残基及其氨基酸类型；(c) 在结构中定位这些残基，讨论是否靠近配体。原题 Rasmol 操作的目标由下面独立坐标程序等价完成，不宣称运行了 Rasmol。

解答. 定义 $\phi = \angle(C_{i-1}, N_i, C_{\alpha i}, C_i)$、$\psi = \angle(N_i, C_{\alpha i}, C_i, N_{i+1})$。四点的两平面法向用叉积得出，再以 atan2 给带符号角，避免只用 arccos 丢掉正负。缺原子、断链或跨链的二面角不计算；程序检查肽键距离。实际得到 1TEN 的 88 组、4HHB_A 的 139 组角。

4HHB_A 的 110 个 HELIX 标注点平均约 $(-65.4°, -31.6°)$，其余点分散；1TEN 原课程文件没有 SHEET 字段，因此不伪造其二级结构标注，在 $\phi < 0°, \psi > 0°$ 的完整象限内有 70 点；再要求 $\psi > 90°$ 才得到 66 点。两种边界的计数必须分开，均不能代替正式 DSSP 赋值，几何上都与片层占优势相容。



示例用正 ϕ 来定位偏离主要负角簇的点，不能当作完整的结构质量判定。1TEN 有 GLN7、ASP12、GLY37、ASN61、ASP65、GLY77；4HHB_A 有 GLY18、GLY51、ARG92。Gly 缺大的侧链，允许的正角范围较大，因此正 ϕ 的 Gly 未必是异常；Pro 的环约束则缩小自由度。真正异常需残基类型相应的允许区与电子密度/结构质量证据。

4HHB_A 保留 43 个非水配体原子。上述三点 Cα 到最近配体原子的距离约 16.49、15.58、8.32 Å，均不在本文以 5 Å 定义的接触邻域；1TEN 课程文件无非水配体。因而这组数据并不支持“离群角总靠近配体”。全部角度和距离保存为 CSV/QA，实际数据结论与泛泛的可能机制分开。 □

15.4 PS6.3：DNA 过度伸长的模型比较

习题 15.4 B 型 DNA 每碱基对长度 3.4 Å，题给实验在 65 ± 5 pN 附近出现过度伸长。(a) 每单位独立取正常 3.4 Å 或伸长 5.8 Å，后者代价 U，忽略三维方向，求 $L(F,T)$；(b) 按原文引用的 Smith–Cui–Bustamante 实验图估 U 并比较转变宽度；(c) 若相邻单位偏好同态，转变将更尖还是更宽？受限原实验图不重新分发，本卷使用题面给定的中心力与独立模型曲线。

解答. 令 $l_0 = .34$ nm、$\Delta l = .24$ nm，单点配分函数 $z = \mathrm{e}^{\beta F l_0}[1 + \mathrm{e}^{-\beta(U - F\Delta l)}]$，所以

$$L = N\left[l_0 + \frac{\Delta l}{1 + \mathrm{e}^{\beta(U - F\Delta l)}}\right].$$

中点满足 $U = F_{1/2}\Delta l$。题给 65 pN 对应 $U \simeq 15.6\,\mathrm{pN\,nm} \simeq 3.8 k_{\mathrm{B}}T$（室温 $k_{\mathrm{B}}T \simeq 4.1\,\mathrm{pN\,nm}$）。独立模型 10% 到 90% 宽度 $\Delta F_{10-90} = 2k_{\mathrm{B}}T \ln 9/\Delta l \simeq 75$ pN，非常宽，和原题描述的明显窄平台/陡起始不相容；精确实验宽度需要原图或原数据，未编造数字化结果。

相邻同态的正协同增加域壁代价，降低混合段权重，在有限温度一维短程模型中仍无严格无限尖的有限温相变，但能显著收窄交叉区。取二状态变量并加入 $-J\sum s_i s_{i+1}$ 可用 2×2 传递矩阵计算；$J > 0$ 使同态域增长。模型也未包含 WLC 方向、序列异质和 DNA 断链/解链机制，不能仅靠 U 将过伸长归因于唯一新结构。 □

15.5 PS2.5 与 PS6.5：在线任务的题面和真实执行边界

习题 15.5 （PS2.5）使用 NCBI BLAST/PSI-BLAST。(a) 生成随机氨基酸串，长度 10–1500，重复与非冗余库做 blastp，检查偶然相似；(b) 按题给氨基酸频率生成疏水/非疏水周期串，第一十种归为疏水，解释检索；(c) 选真实蛋白，替换 $X=0$ 到 100% 残基，比较 BLAST 与 PSI-BLAST 的耐受；(d，可选) 只在同疏水类别内替换，比较阈值。频率表依 CMFILVWYAGTSQNEDHRKP 顺序为 1.660、2.370、4.100、5.810、9.430、6.580、1.240、3.190、7.580、6.840、5.670、7.130、3.970、4.440、6.360、5.270、2.240、5.160、5.940、4.920（归一化后采样）。本卷不重分发原题所引 BLAST 论文全文。

解答. 随机库中有高分片段的期望随数据库长度增加，低复杂度/周期性破坏简单独立背景，因而要记录 SEG 过滤、组成校正、得分矩阵与 E 值阈值。某条随机查询有局部命中不等于真的同源；不能由任意命中名称声称功能。

本次实际提交到 NCBI 的 nr 库：4 条随机串（10、50、150、1500），一条每四位前两疏水/后两非疏水的 150 位周期串，以及原题 SH3 串的 0、20、40、80、100% 替换串；种子 20261012，BLOSUM62，SEG 开启，组成校正 2，E 阈值 .01，每查询保留 10 条。查询 FASTA、请求 RID 与原始结果哈希在数据与 QA 中。另在当前 Swiss-Prot 库实际完成重复随机、两种替换与三轮 PSI-BLAST 任务，结果在下一节；今日 nr 远程请求的状态单独记录。

PSI-BLAST 迭代建立位置特异矩阵，能强化保守位点但也可能收入错误邻居导致模型漂移。所谓容忍 X 百分比还依赖替换位置、长度、类别和阈值，没有一个普适常数；需对每个生成串实际检索。对于未跑到的算法或失去结果的请求，本卷给机制和复算方案并标未完成，不编造耐受数值。 □

15.6 PS2.5 实际复算：当前数据库与算法比较

为完成方法任务，另从 UniProt 官方站实际下载当前 Swiss-Prot 审校蛋白序列，含 575748 条、209017843 个残基，以 NCBI 官方 BLAST+2.17.0 建立本地库。它与原题的 2011 数据库及今日 nr 不同，检索结果是明确的新数据库实验，不能冒作历史结果。原始库和官方二进制不塞进源码包，保存下载 URL/哈希、查询串、命令和结果；附带脚本可在有该数据库的环境复算。

(a) 对 10、50、150、1500 位各独立生成 3 条，共 12 条随机串，在 $E<.01$、BLOSUM62、SEG 开启、组成校正 2 条件下均无保留命中。(b) 采用题给频率、每 4 位前 2 疏水后 2 非疏水的一条 150 位周期串也无保留命中。这个实际阴性不证明所有随机串或周期串都不会得到假阳性；当前数据库、过滤与组成校正显著影响结果。本次没有虚构一个恰好命中的例子。

(c) 原题给 SH3 串长 62，每次从全体其他字母替换恰当数量，0、20、40、60、80、100% 各一次；(d) 另按题给疏水两类内替换。BLAST 批量运行，PSI-BLAST 每条单独运行最多 3 轮、收入阈值 .005，目标数上限 10。下表给各方法返回记录中的最小 E 值，PSI 包含轮次记录，因此记录总数不能当不同蛋白总数。

任意字母替换

替换比例	BLAST 最小 E	PSI 最小 E	BLAST 保留目标数
0%	4.38×10^{-36}	4.38×10^{-36}	10
20%	5.6×10^{-26}	5.6×10^{-26}	10
40%	8.5×10^{-12}	5.82×10^{-28}	7
60%	0.007	2.34×10^{-20}	4
80%	无	无	0
100%	无	无	0

同类字母替换

替换比例	BLAST 最小 E	PSI 最小 E	BLAST 保留目标数
0%	4.38×10^{-36}	4.38×10^{-36}	10
20%	2.37×10^{-24}	2.01×10^{-25}	10
40%	3.65×10^{-17}	4.31×10^{-25}	10
60%	2.72×10^{-5}	4.76×10^{-28}	5
80%	无	无	0
100%	无	无	0

本次两机制在 60% 替换仍有命中，80% 与 100% 均无；它给一个 60–80% 的当前有限测试间隔，不是通用耐受阈值。同类替换 60% 仍保留较高覆盖（最佳 BLAST 约 94%），任意替换 60% 的最佳覆盖约 77%；PSI 在已有可靠种子的 40/60% 情形明显加强匹配。完全没有合适初始种子的 80/100% 情形，迭代未凭空恢复。

“最佳”目标和 E 值会随算法/轮次改变，不能把任意谱系命中自动赋予蛋白功能。更多突变实现、不同位置、SEG 开关和不同数据库应作为进一步实验。源题的主方法已实际运行；2011 库无法按本次取源恢复，今日 nr 远程请求的完成状态另有记录，不用当前 Swiss-Prot 替代它的身份。

习题 15.6 （PS6.5，可选）用原题 UCSD 或 Ohio RNA pulling 服务，对长度接近的均匀序列、GC 交替、AU 交替及实际 RNA 序列求力延伸曲线，比较通性及与 PS6.4 理论是否相似。

解答. 该任务必须有服务或等价完整结构/受力计算的真实输出。2026 年 10 月 12 日，实际网络请求 Ohio 的 HTTP、HTTPS 入口均返回 503；UCSD 请求在代理隧道建立阶段返回 403，未取得源站响应，因此不能据此断言源站永久失效。网页检索缓存仍显示服务说明，但缓存存在不能证明今天可执行。源核验与失败记录保留，此题题面已经收录，原服务数值结果仍是明确缺口。

可合理预期的机制是：全 A 等不形成 Watson–Crick 配对的序列接近单链弹性；GC 与 AU 交替允许很多发夹/内部配对，结合能及堆叠不同；天然序列会有特定结构与多个展开阶段。但这些只是机制预期，不是所要求的四条已经测算曲线，也不能由此断言临界力大小。本卷没有用随手画的曲线替代本次无法取得的服务输出。 □

16 课程来源与覆盖边界

16.1 实际公开资料

8.592J / HST.452J Statistical Physics in Biology，Spring 2011，Mehran Kardar 和 Leonid Mirny。公开大纲以八次作业占 80%、期末项目占 20% 评分；本次核查没有得到官方考试题卷或八套官方解答。课程目录列 26 次主题，但实际取得详细讲义 PDF15 份、八套作业 PDF；其他主题页有纲要或阅读线索。目录第 25 讲 “Packing of DNA Inside Cells” 的 cooperativity 页面实际列出多位点结合、血红蛋白、MWC 与 Hill 方程纲要，并提及 2009 幻灯/讲义但没有下载超链接。不能凭目录标题把网页说成 DNA 包装详细讲义。第 26 讲协同主题在目录无独立可下载文件；本卷按网页实际纲要作明示独立补充，不能宣称取得缺失原讲义。

本册理论部分按随机演化、序列、静电、链构象、折叠、核酸、识别、马达和网络重组。折叠动力学、部分网络说明是编者独立补充，所需条件在正文给出；本版现收录八套作业的全部 37 道顶层任务，保留选项。35 道的解析/公开数据内容已给出实际推导或计算；PS2.5 另在当前 Swiss-Prot 库完成 BLAST/PSI-BLAST 方法实验，原 2011nr 数据库无法恢复且今日 nr 请求状态单列；PS6.5 原在线服务执行失败，不能据题面收录就说 37 道计算任务全部完成。第三方教材归属题以独立数学表述保留条件，第三方 MJ 只发表实际聚合统计、保留原链接；受限原实验图未重分发。

16.2 真实缺源与执行缺口

第 25/26 讲的目录、cooperativity 纲要及提及但无下载链接的 2009 材料分别记录，不宣称取得 26 份详细講義。

原课未取得八套官方作业答案，题解均标编者独立推导。Ohio/UCSD 旧 RNA 在线任务返回实际网络错误，BLAST/PSI-BLAST 实际结果及数据库角色均保留。SNP 单参数拟合落在边界，不能当人口参数成功估计；PurR 缺完整阴性真值，不能给无证据假阳性数。

16.3 来源人口和改编许可

默认公开 MIT 内容遵循 CC BY-NC-SA 4.0；独立署名的第三方图、论文或教材不由这个默认许可自动覆盖。本卷没有重新分发原 PDF 或第三方表格，没有把缺图重建成未经核实的实测图。全部题解为编者独立推导，不标作 MIT 官方解答。代码输出包括模型计算与课程公开原始数据的实际重新分析，二者分开标记；未开展新的生物实验；BLAST 提交与实际返回状态分开记录。

参考文献

[1] Kardar, Mehran; Mirny, Leonid. Statistical Physics in Biology. MIT OpenCourseWare, 8.592J / HST.452J, Spring 2011. https://ocw.mit.edu/courses/8-592j-statistical-physics-in-biology-spring-2011/.

[2] MIT OpenCourseWare. Privacy and Terms of Use. https://ocw.mit.edu/pages/privacy-and-terms-of-use/. 核查日期 2026 年 10 月 12 日.

[3] Creative Commons. Attribution–NonCommercial–ShareAlike 4.0 International. https://creativecommons.org/licenses/by-nc-sa/4.0/.