
数理统计与数据分析

MIT 18.650 中文整理本

Philippe Rigollet 原讲义; 中文重编与补充

MIT 18.650, Fall 2016

前言

观察数据并不能直接给出总体的规律. 一次调查中的比例、样本均值或拟合直线都随样本改变. 统计推断把这种变化写成数学模型, 再说明估计会偏离真值多远、拒绝假设会承担怎样的错误概率, 以及预测对模型条件有何依赖.

本书主源为 Massachusetts Institute of Technology 的 [18.650 Statistics for Applications \(Fall 2016\)](#) 当前内容页十份讲义, 原作者 Philippe Rigollet, 对应第 1–24 讲. 原件共 292 个 PDF 物理页, 含逐步显现页及来源声明; 重显部分在正文合并, 新增定义、条件、推导和例子保留并按依赖重组. 第 6 讲使用 15 页新版矩估计, 第 17–18 讲使用 18 页新版贝叶斯统计, 不采用自动资源列表中的两份旧版.

读者应已学习微积分、基础概率和矩阵运算. 概率中的大数定律、中心极限定理及其统计用途在正文准确说明; 布朗桥的构造与一般经验过程极限定理作为明确调用的概率工具. 第 1 章的抽样设计、描述统计与箱线图是本整理本自编补充, 并非 MIT 原课完整提供的基础统计实务. 各章增加的证明、边界条件及计算解释属于中文重编, 不称为原作者逐字讲授的内容. 贝叶斯、主成分和广义线性模型也完整纳入, 不把它们仅列作名词.

本书不宣称覆盖领军考试整份考纲. 已核官方招生简章包含概率与统计; 本次也实际读取用户资料库中六页考纲的第 1、4、6 页文本, 第 4 页列出抽样、基本统计量与图形、极大似然与矩估计、两类错误和 p 值、基于对称性的检验、单样本与双样本检验及一元线性回归. 本书据此优先完整展开统计应用, 并保留 MIT 原课其他实质内容. 用户提供考纲副本的读取, 不等同于取得官网原始发布文件的字节校验.

MIT OCW 原材料默认使用 [CC BY-NC-SA 4.0 International](#); 本中文改编按同一许可非商业共享, 不表示 MIT 或原作者认可. 第三方图像有单独声明时不由默认许可覆盖. PCA 原件中 Nature 出版方授权转载的基因地图不纳入本书, 相关数学内容独立推导, 本书图形均为自编数据或通用数学示意的原生 TikZ. 原件逐文件链接、物理页数、哈希及上传状态另见源码附带清单.

目录

1	数据与抽样	1
1.1	数据、总体与统计问题	1
1.2	抽样设计与偏差	1
1.3	数据的中心与离散程度	3
1.4	分位数、直方图与箱线图	4
1.5	相关、配对与初步推断	5
2	统计模型与概率工具	5
2.1	从观测到统计模型	5
2.2	收敛概念与基本运算	7
2.3	大数定律、中心极限定理与偏好比例	8
2.4	有界观测的有限样本控制	9
2.5	Delta 方法与到站间隔的估计	10
3	参数估计与最大似然	11
3.1	统计量、偏差与风险	11
3.2	置信区间与覆盖率	12
3.3	分布距离与似然原理	12
3.4	凹性与最大化的条件	13
3.5	典型模型的最大似然计算	14
3.6	得分、Fisher 信息与信息下界	15
3.7	MLE 的一致性与渐近正态性	17
3.8	参数决定支撑的非正则模型	18
4	矩估计与渐近分析	19
4.1	为什么使用矩	19
4.2	有限支撑、Vandermonde 矩阵与求积	20
4.3	矩估计的定义与存在性	22
4.4	一致性与多元 Delta 方法	23
4.5	渐近协方差的实际计算	24
4.6	矩估计与最大似然的比较	26
5	参数假设检验	27
5.1	从实际问题到拒绝规则	27

5.2	正态模型的精确检验	28
5.3	似然与最强检验	29
5.4	Wald 检验与隐式约束	29
5.5	似然比与 Wilks 定理	30
5.6	多项分布中的 Pearson 统计量	30
5.7	双样本均值比较	31
5.8	对称性与有限样本随机化检验	31
6	拟合优度检验	33
6.1	经验分布与整条分布曲线	33
6.2	Kolmogorov-Smirnov 检验	34
6.3	其他距离与估计参数的影响	35
6.4	QQ 图	35
6.5	复合多项模型的卡方检验	35
6.6	分箱、独立性与实践条件	36
7	回归与预测	37
7.1	总体的最佳直线	37
7.2	样本最小二乘与残差	38
7.3	多元回归与正交投影	38
7.4	正态固定设计模型	39
7.5	系数、均值与新观测的区间	40
7.6	联合显著性、F 检验与方差分析	40
7.7	杠杆、残差与模型诊断	41
7.8	秩亏时仍可拟合什么	41
7.9	高维变量选择与惩罚	42
7.10	非参数回归与局部平均	43
8	贝叶斯统计	44
8.1	参数、数据与先验信息	44
8.2	贝叶斯公式与共轭更新	45
8.3	平坦先验、非正常先验与 Jeffreys 先验	46
8.4	可信区域与频率覆盖	47
8.5	损失函数、贝叶斯估计与 MAP	48
8.6	作为频率估计量的贝叶斯规则	48

9 主成分分析	49
9.1 多元数据与协方差	49
9.2 中心化是一次正交投影	50
9.3 谱分解与逐方向最大方差	51
9.4 投影、重构与最小误差	51
9.5 SVD 实现与维数选择	52
9.6 可视化与协方差估计	53
10 广义线性模型	54
10.1 从线性回归到响应分布与连接函数	54
10.2 指数族与指数离散族	55
10.3 均值、方差与典则连接	56
10.4 似然、得分与严格凹性	57
10.5 二次近似、Newton 方法与 Fisher scoring	58
10.6 加权最小二乘与 IRLS 的完整推导	59
10.7 Logistic 回归与完全分离	60
10.8 Probit、Poisson 与正态回归的工作量	60
10.9 饱和模型与离差	61
参考文献	62

1 数据与抽样

1.1 数据、总体与统计问题

防洪设施的高度、保险的保费和药物的疗效都需要处理尚未发生或无法全部观察的结果。洪水高度会变化, 不同驾驶者的赔付也会变化; 在一组病人中看到疗效, 还不能保证下一组结果相同。MIT 原讲义用这些例子引入统计学。数学模型把问题分成两部分: 可解释的结构与未解释的随机变化。随机性既可能来自实际的随机机制, 也可能是复杂过程的近似描述。

定义 1.1 总体是研究所针对的全部单位或结果, 样本是实际观察的单位或结果。每一行数据对应一个观察单位, 每一列变量说明这个单位的一个特征。参数是总体或模型的固定未知量; 统计量是仅由样本计算、不包含未知参数的函数。

例如研究一个地区居民的收缩压, 总体可以是该地区在指定日期年龄在 18 岁以上的全部居民。样本中的一行可以记录一位居民的年龄、性别和收缩压。必须明确时间、对象和测量条件, 否则“平均血压”没有唯一对象。以 $X_1, \dots, X_n$ 表示样本测量值时, $\bar{X} = n^{-1} \sum_i X_i$ 是统计量, 总体均值 μ 是参数。样本得到以前 $\bar{X}$ 是随机变量, 得到以后 $\bar{x}$ 是一个已知数值; 两者不能在置信陈述中混为一谈。

分类变量的数值编码并不意味着可以作所有算术。给三种交通方式标为 1、2、3, 编码的均值不表达交通方式的平均程度。有序变量允许比较先后, 但相邻等级的差值未必相等。数值变量则需要区分离散计数与连续测量, 并保留单位。数据表中的缺失项也不是零: 未回答收入与收入为零代表不同事实。

例题 1.1 两个独立公平骰子的点数和记为 S 。若猜中一个和可获 100 元, 应选择什么数? 若只知道一批药物试验中 100 位病人有 78 位好转, 要推断未来病人的好转概率, 又缺少什么?

解答. 骰子的机制已给定。36 个有序点数组等可能, 和为 s 的组合数为 $6 - |s - 7|$, 其中 $2 \leq s \leq 12$ 。因而 $\mathbb{P}(S = s) = (6 - |s - 7|)/36$, 选择 7 的获胜概率最大, 为 $1/6$ 。这由已知分布算出结果概率, 属于概率问题。

药物问题的分布参数未知。可以先用独立同分布的 Bernoulli 变量建模好转与否, 以样本比例 0.78 估计好转概率 p 。但这个模型仍要求说明病人如何招募、何为好转、是否独立, 并需要量化估计误差。如果要判断药物的因果效果, 还需要合适对照, 不能把有好转直接解释成药物有效。后面的估计与检验处理在已声明模型条件下的量化问题。□

原课另用单个公平骰子的奖金说明期望与典型结果的区别: Alice 在点数至多为 3 时得 1 元, Bob 在点数至多为 2 时得 2 元。期望收益分别为 $1/2$ 元与 $2/3$ 元, 若以期望收益为目标应选择 Bob。Alice 的获奖概率更高, Bob 的收益更分散。期望收益、获奖频率与波动程度是不同指标。

1.2 抽样设计与偏差

本节与后面的描述统计是自编补充。参数推断中常假设独立同分布样本, 这一条件需要由数据取得方式支持。对观察单位的选择发生系统性倾斜时, 增加样本量只会使错误目标估计得更精确。

定义 1.2 有限总体有 N 个单位时, 简单随机不放回抽样指每个含 n 个单位的子集被选择的概率都为 $\binom{N}{n}^{-1}$. 分层抽样先把总体划为互不相交的层, 再在各层内分别抽样. 整群抽样随机选择若干群, 对选中的群进行调查或继续抽取单位.

简单随机抽样中的“每个子集”比“每个单位入样概率相同”强. 后者并不能排除总是把某些单位绑在一起的方案. 不放回样本还不是严格的独立样本: 已抽到某人会影响下一个人的选择. 总体很大、抽样比例很小时可以讨论独立近似, 但不能把近似写成精确等式.

命题 1.3 有限总体数值为 $x_1, \dots, x_N$, 总体均值 $\mu_N = N^{-1} \sum_j x_j$, 总体离差平方均值 $\sigma_N^2 = N^{-1} \sum_j (x_j - \mu_N)^2$. 从中简单随机不放回抽取 n 个值, 其均值 $\bar{X}$ 满足

$$\mathbb{E}\bar{X} = \mu_N, \quad \text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1} \quad (N > 1).$$

证明. 按随机排列后的前 n 个位置表示样本. 每个 X_i 都均匀取总体中的一个值, 故均值为 μ_N , 方差为 σ_N^2 . 对 $i \neq k$, 有序的不相等单位等可能, 因而

$$\text{Cov}(X_i, X_k) = \frac{1}{N(N-1)} \sum_{j \neq \ell} (x_j - \mu_N)(x_\ell - \mu_N) = -\frac{\sigma_N^2}{N-1}.$$

最后一个等式用到全部离差之和为零: 不同项的乘积之和等于全部乘积和减去对角平方和. 将 n 个方差与 $n(n-1)$ 个协方差相加, 再除以 n^2 , 就得到所述公式. $\square$

有限总体修正因子 $(N-n)/(N-1)$ 在调查比例较大时显著降低方差; 当 $n = N$ 时全部单位已观察, 抽样误差为零. 若用通常无偏总体方差 $S_N^2 = (N-1)^{-1} \sum_j (x_j - \mu_N)^2$, 同一式可写为 $(1-n/N)S_N^2/n$.

例题 1.2 某校有 900 位低年级与 100 位高年级学生, 各层平均每日自习时间分别为 2 小时和 4 小时. 调查时两层各选 50 人. 两层样本均值为 2.1 与 3.8 小时, 应如何估计全校均值?

解答. 总体目标是 $0.9\mu_1 + 0.1\mu_2$, 故分层估计为 $0.9(2.1) + 0.1(3.8) = 2.27$ 小时. 不加权平均 $(2.1 + 3.8)/2 = 2.95$ 小时将两层视为同样大, 估计了另一目标. 层内抽样均值各自无偏时, 按已知层比例加权的总体均值也无偏; 层内抽样若有系统性遗漏, 正确权重并不能消除它. $\square$

自愿答卷、只调查容易接触的人、电话调查漏掉特定人群, 都可能形成选择偏差. 未回答与研究变量有关时会出现非应答偏差. 问题措辞、记忆错误和仪器误差属于测量问题. 这些问题需要通过设计、追访、校准及明确报告处理, 不是把标准误差写得更小就能解决.

抽样与随机分配解决不同问题. 随机抽样支持从样本推广到总体; 随机分配处理与对照帮助比较因果效果. 观察性研究中, 年龄同时影响治疗选择与疗效时, 两组疗效的差异可能混有年龄作用. 回归调整可以在模型条件下比较同类对象, 却自动排除未观测混杂. 同一病人的多次测量也不能当成多个独立病人.

1.3 数据的中心与离散程度

给定实数数据 $x_1, \dots, x_n$, 排序后记为 $x_{(1)} \leq \dots \leq x_{(n)}$. 均值使用每个值, 中位数按位置刻画中心. 两者回答的不是完全相同的问题.

定义 1.4 样本均值为 $\bar{x} = n^{-1} \sum_i x_i$. 奇数 $n = 2m + 1$ 时中位数取 $x_{(m+1)}$, 偶数 $n = 2m$ 时取 $(x_{(m)} + x_{(m+1)})/2$. 当 $n \geq 2$, 样本方差与样本标准差分别为

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}.$$

方差使用平方单位, 标准差与原数据同单位. 对 $y_i = a + bx_i$, 有 $\bar{y} = a + b\bar{x}$ 与 $s_y = |b|s_x$. 所以更换计量单位会改变数值, 不能把不同单位的方差直接相加比较.

命题 1.5 均值唯一最小化平方离差和 $\sum_i (x_i - a)^2$. 所有中位数最小化绝对离差和 $\sum_i |x_i - a|$; 偶数样本时区间 $[x_{(m)}, x_{(m+1)}]$ 内的值全部取到最小值.

证明. 由于 $\sum_i (x_i - \bar{x}) = 0$, 平方和展开为

$$\sum_i (x_i - a)^2 = \sum_i (x_i - \bar{x})^2 + n(a - \bar{x})^2,$$

从而只有 $a = \bar{x}$ 最小. 对绝对离差, 将排序数据两端配成对. 每一对 $u \leq v$ 满足 $|u - a| + |v - a| \geq v - u$, 当且仅当 $a \in [u, v]$ 等号成立. 偶数情形这些区间的交为中间两值的闭区间; 奇数情形还有中间项 $|x_{(m+1)} - a|$, 必须在中间值为零才能最小. $\square$

这种优化性质说明, 单个极端值会对均值的平方误差目标产生很大影响, 而中位数主要由排序位置决定. “稳健”并不意味着中位数对所有统计目标都比均值好; 若目标就是总体期望, 仍要考虑均值及其估计误差.

命题 1.6 若 $X_1, \dots, X_n$ 独立同分布, $\mathbb{E}X_i = \mu$ 且 $\text{Var}(X_i) = \sigma^2 < \infty$, 则 $\mathbb{E}\bar{X} = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$, 而 $\mathbb{E}S^2 = \sigma^2$.

证明. 均值与方差结论分别用期望线性性与独立性. 对样本方差, 恒等式

$$\sum_i (X_i - \bar{X})^2 = \sum_i (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

给出期望 $n\sigma^2 - n(\sigma^2/n) = (n-1)\sigma^2$, 除以 $n-1$ 即可. 当不独立或总体方差不存在时, 此证明中均值方差的独立性计算或有限期望条件失效, 不能照用结论. $\square$

标准差 S 衡量单个数据的离散程度, 均值的估计标准误差 $S/\sqrt{n}$ 衡量均值在重复独立抽样中的变化. 调查报告中的“平均值加减一个标准差”与“平均值的置信区间”因此不是同一个对象.

1.4 分位数、直方图与箱线图

定义 1.7 经验分布函数为 $F_n(t) = n^{-1} \sum_i \mathbf{1}_{\{x_i \leq t\}}$. 对 $0 < u \leq 1$, 经验分位数的一种约定为 $Q_n(u) = \inf\{t : F_n(t) \geq u\} = x_{(\lceil nu \rceil)}$. 第一、第三四分位数分别记为 Q_1, Q_3 , 四分位距为 $\text{IQR} = Q_3 - Q_1$.

分位数插值方式没有唯一的统一约定. 本节画箱线图时采用“先取中位数, 再对上下半组取中位数”的常用教学约定; 奇数样本的中间值不进入两半组. 它与上面的经验逆分位数定义不一定相同. 数据量小时差异尤其可见, 软件输出须报告所用约定.

直方图先将数轴分为若干区间. 等宽时柱高可以用频数或频率; 不等宽时若要用面积表达概率, 应取柱高为“该组相对频率除以组距”. 每根柱子的面积才等于该组相对频率, 全图面积为 1. 只比较不等宽柱子的高度可能产生错误印象. 类别变量则用条形图; 条形次序与间隔没有连续数轴的含义.


箱线图的箱体从 Q_1 到 Q_3 , 中间线为中位数. 一种常用须线规则是: 下须延伸至不低于 $Q_1 - 1.5\text{IQR}$ 的最小观测值, 上须延伸至不高于 $Q_3 + 1.5\text{IQR}$ 的最大观测值, 超出须线的观测单独标记. 须端不一定等于理论围栏, 也不一定是数据的最小值与最大值. 超出围栏只是在此规则下的异常点, 不证明数据错误或来自另一总体.

例题 1.3 十个观测值为 1, 2, 3, 4, 5, 6, 7, 8, 9, 20. 计算均值、中位数、四分位距、样本标准差与箱线图须线, 并说明把最大值 20 换为 200 的影响.

解答. 总和为 65, 故均值为 6.5, 中位数为 5.5. 上下半组的中位数分别为 3 与 8, 所以 $\text{IQR} = 5$. 围栏为 -4.5 和 15.5, 须端为 1 与 9, 20 单独标记. 平方和为 $1^2 + \cdots + 9^2 + 20^2 = 285 + 400 = 685$, 因而

$$s^2 = \frac{685 - 10(6.5)^2}{9} = \frac{262.5}{9} = \frac{175}{6}, \quad s \approx 5.401.$$

若最大值换为 200, 均值变为 24.5, 而中位数和两四分位数保持原值. 新方差为 $(40285 - 10(24.5)^2)/9 = 34282.5/9$, 标准差约为 61.718. 这里中心的均值、中位数与离散指标呈现明显不同的敏感性. $\square$



这是本书自编数据的 TikZ 箱线图. 同一数据如果使用经验逆分位数, $Q_n(.25) = x_{(3)} = 3$, $Q_n(.75) = x_{(8)} = 8$, 恰与半组约定相同; 换一组样本量便不必如此.

分布的偏斜、双峰与极端尾部常常不能由一个均值和方差完整表达. 画经验分布函数、直方图或散点图可以发现这些结构, 再决定模型是否合理. 图形也需要报告样本量、单位、分组方式和缺失数据处理.

1.5 相关、配对与初步推断

对配对数据 (x_i, y_i) , 定义 $S_{xx} = \sum_i (x_i - \bar{x})^2$, $S_{yy} = \sum_i (y_i - \bar{y})^2$, $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$. 当 $S_{xx}, S_{yy} > 0$ 时, 样本相关系数为 $r = S_{xy} / \sqrt{S_{xx}S_{yy}}$.

命题 1.8 样本相关系数满足 $-1 \leq r \leq 1$. 等号 $|r| = 1$ 当且仅当两个非零中心化向量成比例, 即所有数据落在斜率非零的一条直线上.

证明. 对向量 $(x_i - \bar{x})_{i=1}^n$ 与 $(y_i - \bar{y})_{i=1}^n$ 使用 Cauchy-Schwarz 不等式得 $S_{xy}^2 \leq S_{xx}S_{yy}$. 该不等式取等当且仅当两个向量线性相关. 两者均非零时比例系数非零, 平移回去即为一条直线. $\square$

r 只度量线性关联. 对关于零对称的数据若 $y = x^2$, 可能有 $r = 0$, 但 y 完全由 x 决定. 聚合不同群体还可能改变相关方向, 因而画散点图并检查分组比只报 r 更有信息. 若每位病人都有治疗前后测量, 分析差值 $D_i = Y_{i,\text{after}} - Y_{i,\text{before}}$ 可以保留配对结构; 把两列作为独立样本会抹去同一病人的关联.

已知每位病人独立地以概率 0.8 好转时, $K \sim \text{Bin}(100, 0.8)$, 所以 $\mathbb{E}K = 80$, 而

$$\mathbb{P}(K \geq 65) = \sum_{k=65}^{100} \binom{100}{k} 0.8^k 0.2^{100-k} \approx 0.99985286.$$

原课把它写作约 99.99%, 精确求和对应约 99.9853%. 这是给定模型参数后预测样本结果的概率陈述. 换成观测结果反推未知参数, 计算方向便改变了.

MIT 原课中的 100 人有 78 人好转的例子, 用大样本正态近似构造

$$0.78 \pm 1.96 \sqrt{\frac{0.78(1-0.78)}{100}} \approx [0.6988, 0.8612].$$

此式估计的是模型中好转概率, 其“95%”来自重复抽样时区间覆盖固定真值的比例, 并非已观测区间中每个数字有 95% 的概率. 近似需要样本与概率不要过于接近边界, 也依赖独立同分布条件. 后文将推导它, 并给出不依赖正态近似的保守方法.

描述统计先忠实表达所见数据. 推断则需要由数据取得方式、概率模型和误差控制把结论延伸到未观察对象. 同一个样本比例既可写在描述表中, 也可进入参数估计与检验; 区别在于后一种用途必须说明概率保证来自何种模型.

2 统计模型与概率工具

2.1 从观测到统计模型

一次观测本身不能说明它将怎样重复. 统计推断需要给重复实验规定一个概率规律, 再讨论该规律中未知的部分. 例如, 在吻向偏好的观察中, 124 对情侣中有 80 对向右转头, 样本比例为 $80/124 \approx 0.645$. 这个数大于 $1/2$, 但三次观察中的两次向右也会给出更大的比例 $2/3$. 只有把样本数量与随机波动联系起来, 才能判断这种差异提供了多少证据.

令 R_i 表示第 i 对情侣是否向右, 向右记为 1, 向左记为 0. 因为 R_i 只取两个值, 单个观测的分布必为某个

Bernoulli 分布. 然而, 各对情侣的成功概率可能不同, 不同观察也可能相关. 以下讨论作出更强的假设: 所有成功概率等于同一个 p , 且 $R_1, \dots, R_n$ 相互独立. 此时

$$R_1, \dots, R_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad \hat{p}_n = \bar{R}_n = \frac{1}{n} \sum_{i=1}^n R_i.$$

独立性可以由在不同时间、地点采集数据来支持, 但采集方式本身不是独立性的数学证明. 同分布则要求所研究的人群与实验条件足够稳定. 对固定的复杂现象加入随机噪声, 也是一种模型选择; 后续概率结论的有效性依赖这些选择.

定义 2.1 (统计模型) 设一次观测取值于可测空间 $(E, \mathcal{E})$. 统计模型是概率测度族

$$(E, \mathcal{E}, \{\mathbb{P}_\theta : \theta \in \Theta\}),$$

其中 E 称为单次观测的样本空间, Θ 为参数空间. 独立同分布的 n 次观测所对应的实验具有样本空间 E^n 与联合分布 $\mathbb{P}_\theta^{\otimes n}$. 若 $\Theta \subset \mathbb{R}^d$ 且 d 固定, 称其为参数模型.

这里的 θ 是分布的标签, 不是随机观测. 若真实分布确为某个 $\mathbb{P}_{\theta_*}$, 就称模型设定正确, θ_* 称为真实参数. 若真实分布不属于所选族, 参数估计仍可计算, 但原来关于 θ_* 的解释与保证须重新检查.

例题 2.1 写出 Bernoulli、指数、Poisson 与正态模型的样本空间、参数空间及概率质量函数或密度.

解答. Bernoulli 模型为 $E = \{0, 1\}$, $\Theta = (0, 1)$, 质量函数为 $p^x(1-p)^{1-x}$. 指数模型为 $E = (0, \infty)$, $\lambda > 0$, 密度为 $\lambda e^{-\lambda x}$. Poisson 模型为 $E = \{0, 1, 2, \dots\}$, $\lambda > 0$, 质量函数为 $e^{-\lambda} \lambda^x / x!$. 正态模型为 $E = \mathbb{R}$, 参数 $(\mu, v) \in \mathbb{R} \times (0, \infty)$, 密度为

$$f_{\mu, v}(x) = \frac{1}{\sqrt{2\pi v}} \exp\left(-\frac{(x-\mu)^2}{2v}\right).$$

为避免方差与标准差混淆, 本章把正态方差记为 $v = \sigma^2$. □

例如, 研究大学生家庭的孩子人数时, 可以分别估计取值 $1, 2, \dots, 6, \geq 7$ 的七个类别概率, 它们的和为 1, 因而有六个自由参数. 也可以选一个只有单参数的计数模型来减少估计负担. 但包含本人后的孩子人数至少为 1, 普通 Poisson 分布仍给 0 正概率. 若坚持这一数据定义, 应使用 $1 + \text{Poiss}(\lambda)$ 或零截断 Poisson 等适当模型, 或明确承认普通 Poisson 只是近似. 参数少不等于模型正确.

定义 2.2 (可识别性) 模型可识别, 是指映射 $\theta \mapsto \mathbb{P}_\theta$ 为单射, 即

$$\mathbb{P}_\theta = \mathbb{P}_{\theta'} \implies \theta = \theta'.$$

若两个不同参数给出同一观测分布, 无论观测多少次, 数据都不能区分它们. 前述四个常见模型均可识别: Bernoulli 成功概率、指数均值的倒数、Poisson 均值、正态均值和方差分别由分布确定.

例题 2.2 设 $Y_i \sim N(\mu, \sigma^2)$, 只观察 $X_i = \mathbf{1}_{\{Y_i \geq 0\}}$. 判断 μ, σ 及比值 μ/σ 是否可识别.

解答. 若未观测的 $Y_i \sim N(\mu, \sigma^2)$, 而实际只记录 $X_i = \mathbf{1}_{\{Y_i \geq 0\}}$, 则

$$\mathbb{P}_{\mu, \sigma}(X_i = 1) = \Phi(\mu/\sigma),$$

其中 Φ 是标准正态分布函数. 将 (μ, σ) 同时乘任意正数不改变此概率. 因而 μ, σ 不能分别识别. 由于 Φ 严格递增, 比值 $\eta = \mu/\sigma$ 可识别. 这说明应根据实际记录的观测设计参数, 不能把未记录的量当作已经观察到. $\square$

2.2 收敛概念与基本运算

渐近统计讨论样本量趋于无穷时的行为. 必须区分逐条样本路径的接近、出现大误差的概率减小, 以及分布形状接近. 以下随机变量定义于同一概率空间时才讨论几乎处处、概率或 L^q 收敛; 分布收敛只比较各自的分布, 不要求这种共同实现.

定义 2.3 (四种收敛) 对随机变量 T_n, T , 几乎处处收敛指 $\mathbb{P}(\{\omega : T_n(\omega) \rightarrow T(\omega)\}) = 1$. 概率收敛 $T_n \xrightarrow{\mathbb{P}} T$ 指对每个 $\varepsilon > 0$, $\mathbb{P}(|T_n - T| > \varepsilon) \rightarrow 0$. 当 $q \geq 1$ 时, L^q 收敛指 $\mathbb{E}|T_n - T|^q \rightarrow 0$. 分布收敛 $T_n \xrightarrow{d} T$ 指在 T 的分布函数所有连续点 x 处,

$$\mathbb{P}(T_n \leq x) \rightarrow \mathbb{P}(T \leq x).$$

随机向量的前三种定义以范数代替绝对值; 分布收敛可用下述有界连续函数刻画.

定理 2.4 (分布收敛的概率先修) $T_n \xrightarrow{d} T$ 等价于对所有有界连续函数 f , $\mathbb{E}f(T_n) \rightarrow \mathbb{E}f(T)$. 对实随机变量, 也等价于对每个 $t \in \mathbb{R}$, 特征函数 $\mathbb{E}e^{itT_n} \rightarrow \mathbb{E}e^{itT}$. 若 $T_n \xrightarrow{d} T$ 且 g 在 T 几乎必然落入的点处连续, 则 $g(T_n) \xrightarrow{d} g(T)$.

本章调用概率论中的弱收敛刻画、特征函数连续性定理与连续映射定理, 不在此重建其测度论证明. 对有界连续 g , 连续映射结论直接来自对 $f \circ g$ 使用刻画; 一般连续 g 亦如此, 因为测试函数 f 有界而 $f \circ g$ 仍有界连续. 允许零概率不连续点的版本属于所调用的概率先修.

命题 2.5 (收敛间的关系) 几乎处处收敛蕴含概率收敛; L^q 收敛蕴含概率收敛及 L^r 收敛 ($1 \leq r \leq q$); 概率收敛蕴含分布收敛. 这些推出关系中的极限一致, 对共同空间的概率极限而言是一致到几乎处处相等.

证明. 几乎处处收敛使 $\mathbf{1}_{\{|T_n - T| > \varepsilon\}} \rightarrow 0$ 几乎处处, 由控制收敛定理其期望趋于 0. Markov 不等式给出

$$\mathbb{P}(|T_n - T| > \varepsilon) \leq \varepsilon^{-q} \mathbb{E}|T_n - T|^q,$$

而 Jensen 不等式给出 $\mathbb{E}|T_n - T|^r \leq (\mathbb{E}|T_n - T|^q)^{r/q}$. 对任意 $\delta > 0$,

$$\mathbb{P}(T \leq x - \delta) - \mathbb{P}(|T_n - T| > \delta) \leq \mathbb{P}(T_n \leq x) \leq \mathbb{P}(T \leq x + \delta) + \mathbb{P}(|T_n - T| > \delta).$$

先令 $n \rightarrow \infty$, 再在连续点令 $\delta \downarrow 0$, 即得分布收敛. 若 T_n 同时概率收敛到 T, U , 则 $\mathbb{P}(|T - U| > \varepsilon) \leq \mathbb{P}(|T - T_n| > \varepsilon/2) + \mathbb{P}(|T_n - U| > \varepsilon/2) \rightarrow 0$, 所以 $T = U$ 几乎处处. $\square$

连续函数保持几乎处处收敛, 因为可逐条路径应用普通连续性. 它也保持概率收敛: 先在一个概率任意接近 1 的有界区域内限制 T , 再用该区域附近的连续性控制 $g(T_n) - g(T)$. 由此, 两个几乎处处或概率收敛的序列可以相加、

相乘; 除法还需极限分母不为 0 几乎处处. 概率情形可先用并集界得到 $(U_n, V_n) \xrightarrow{\mathbb{P}} (U, V)$, 再应用连续性.

例题 2.3 构造两个各自分布收敛的随机变量序列, 使它们的和不分布收敛.

解答. 设 $Z \sim N(0, 1)$, $U_n = Z$, $V_n = (-1)^n Z$. 两个序列都具有固定的标准正态分布, 因而各自分布收敛. 但 $U_n + V_n$ 在偶数项是 $2Z$, 奇数项恒为 0, 不存在共同的分布极限. 只有获得联合分布收敛后, 才能对分布极限直接做这些运算. $\square$

定理 2.6 (Slutsky 定理) 若 $U_n \xrightarrow{d} U$, $V_n \xrightarrow{\mathbb{P}} c$, 其中 c 是常向量, 则 $(U_n, V_n) \xrightarrow{d} (U, c)$. 因此 $U_n + V_n \xrightarrow{d} U + c$, 标量情形 $U_n V_n \xrightarrow{d} cU$, 若 $c \neq 0$ 则 $U_n/V_n \xrightarrow{d} U/c$, 其中在 $V_n = 0$ 的事件上将比值任意定义为 0. 该事件的概率不超过 $\mathbb{P}(|V_n - c| \geq |c|)$, 因而趋于 0, 不改变分布极限.

证明. 由分布收敛, U_n 的分布紧: 对任意 $\varepsilon > 0$, 可取 M 使充分大的 n 满足 $\mathbb{P}(\|U_n\| > M) < \varepsilon$. 这个结论可由在连续点比较分布函数得到; 向量情形逐坐标并集界即可. 对任意有界连续 h , 在 $\{\|u\| \leq M, \|v - c\| \leq 1\}$ 上一致连续, 因而当 $\|v - c\| \leq \delta$ 时, $|h(u, v) - h(u, c)|$ 可一致地小于 ε . 在补集上用 $2 \sup |h|$ 控制, 得到

$$|\mathbb{E}h(U_n, V_n) - \mathbb{E}h(U_n, c)| \leq \varepsilon + 2 \sup |h| \{\varepsilon + \mathbb{P}(\|V_n - c\| > \delta)\}.$$

令 $n \rightarrow \infty$ 并使 $\varepsilon \downarrow 0$, 再利用 $U_n \xrightarrow{d} U$ 应用于 $u \mapsto h(u, c)$, 即得联合收敛. 后面的结论来自连续映射定理. $\square$

2.3 大数定律、中心极限定理与偏好比例

定理 2.7 (独立同分布的概率先修) 设 $X_1, X_2, \dots$ 独立同分布, $\bar{X}_n = n^{-1} \sum_i X_i$. 若 $\mathbb{E}|X_1| < \infty$, 则 $\bar{X}_n \rightarrow \mu = \mathbb{E}X_1$ 几乎处处, 因而也依概率收敛. 若另外 $0 < \sigma^2 = \text{Var}(X_1) < \infty$, 则

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2), \quad \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

这里调用独立同分布强大数定律和中心极限定理, 作为本学科概率先修. 有限方差时弱大数定律可直接证明: $\text{Var}(\bar{X}_n) = \sigma^2/n$, Chebyshev 不等式给 $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2) \rightarrow 0$. 强大数定律允许只有一阶矩, 中心极限定理则控制 $n^{-1/2}$ 尺度的波动; 两者用途不同.

对 Bernoulli 模型, $\mathbb{E}R_i = p$, $\text{Var}(R_i) = p(1-p)$, 故 $\hat{p}_n \rightarrow p$ 几乎处处. 当固定 $p \in (0, 1)$ 时,

$$\frac{\sqrt{n}(\hat{p}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{d} N(0, 1).$$

记 $z_{1-\alpha/2}$ 为标准正态的 $1 - \alpha/2$ 分位数. 极限分布在两端点连续, 因而

$$\mathbb{P}_p \left(|\hat{p}_n - p| \leq z_{1-\alpha/2} \sqrt{\frac{p(1-p)}{n}} \right) \rightarrow 1 - \alpha.$$

这是以未知 p 表示的误差概率, 还不是可由数据直接计算的区间. 利用 $p(1-p) \leq 1/4$, 可得到区间

$$I_n^{\text{cons}} = \left[\hat{p}_n - \frac{z_{1-\alpha/2}}{2\sqrt{n}}, \hat{p}_n + \frac{z_{1-\alpha/2}}{2\sqrt{n}} \right] \cap [0, 1].$$

对每个固定 p , 其覆盖概率的下极限至少为 $1-\alpha$. 若 $0 < p < 1$ 且 $p \neq 1/2$, 实际极限为 $2\Phi(z_{1-\alpha/2}/(2\sqrt{p(1-p)}))-1$, 一般更大. 124 次观察与 $\alpha = 0.05$ 给出约 $[0.557, 0.733]$. 三次观察则给出截断前约 $[0.101, 1.233]$, 这个计算不能据中心极限定理保证小样本覆盖率. 小样本可以从 $n\hat{p}_n \sim \text{Bin}(n, p)$ 的精确概率出发.

另一种处理未知方差的方法是代入 $\hat{p}_n$. 由一致性与连续性, $\hat{p}_n(1-\hat{p}_n) \xrightarrow{\mathbb{P}} p(1-p) > 0$. 在全 0 或全 1 样本上把下式标准化统计量约定为 0; 对固定内点 p , 这种事件的概率为 $(1-p)^n + p^n \rightarrow 0$. Slutsky 定理给

$$\frac{\sqrt{n}(\hat{p}_n - p)}{\sqrt{\hat{p}_n(1-\hat{p}_n)}} \xrightarrow{d} N(0, 1),$$

从而可计算的 Wald 区间

$$I_n^W = \left[\hat{p}_n - z_{1-\alpha/2} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}, \hat{p}_n + z_{1-\alpha/2} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}} \right] \cap [0, 1]$$

对固定内点 p 有极限覆盖率 $1-\alpha$. 在全 0 或全 1 样本上区间会退化; 这不影响固定内点的渐近结论, 却提示它在小样本或靠近边界时可能很差. 渐近结论不自动在随 n 接近边界的参数序列上一致成立.

2.4 有界观测的有限样本控制

引理 2.8 (Hoeffding 引理) 若 $a \leq X \leq b$ 几乎处处, 则对任意 $t \in \mathbb{R}$,

$$\mathbb{E} \exp\{t(X - \mathbb{E}X)\} \leq \exp\{t^2(b-a)^2/8\}.$$

证明. 令 $K(t) = \log \mathbb{E} e^{t(X - \mathbb{E}X)}$. 有界性允许求导与期望交换. $K(0) = K'(0) = 0$, 且 $K''(t)$ 等于以指数因子倾斜后的概率分布下 X 的方差. 任意支撑于 $[a, b]$ 的分布都有

$$\text{Var}(X) \leq \mathbb{E}(X - (a+b)/2)^2 \leq (b-a)^2/4.$$

因此 $K''(t) \leq (b-a)^2/4$. 对 $t \geq 0$ 积分两次得 $K(t) \leq t^2(b-a)^2/8$; 对 $t < 0$ 对反方向积分或对 $-X$ 使用同一结果. 指数化即得结论. $\square$

定理 2.9 (Hoeffding 不等式) 若 $X_1, \dots, X_n$ 独立同分布, $a < b$ 且 $a \leq X_i \leq b$ 几乎处处, $\mu = \mathbb{E}X_i$, 则对 $u > 0$,

$$\mathbb{P}(|\bar{X}_n - \mu| \geq u) \leq 2 \exp\left(-\frac{2nu^2}{(b-a)^2}\right).$$

证明. 由 Markov 不等式、独立性和引理, 对 $t > 0$,

$$\mathbb{P}\left(\sum_i (X_i - \mu) \geq nu\right) \leq e^{-tnu} \prod_i \mathbb{E} e^{t(X_i - \mu)} \leq \exp\{-tnu + nt^2(b-a)^2/8\}.$$

取 $t = 4u/(b-a)^2$ 给出上尾界 $e^{-2nu^2/(b-a)^2}$. 对 $-X_i$ 得下尾界, 两尾相加完成证明. $\square$

对偏好比例, 取 $a = 0, b = 1$ 并解 $2e^{-2nu^2} = \alpha$, 得到

$$I_n^H = \left[\hat{p}_n - \sqrt{\frac{\log(2/\alpha)}{2n}}, \hat{p}_n + \sqrt{\frac{\log(2/\alpha)}{2n}} \right] \cap [0, 1].$$

对每个 $n \geq 1$ 与每个 $p \in [0, 1]$, 这个区间的覆盖率至少 $1 - \alpha$. 它通常宽于正态近似区间, 换来的是不用等待 n 足够大的明确保证. 想使半宽不超过 ε , 只需 $n \geq \log(2/\alpha)/(2\varepsilon^2)$.

2.5 Delta 方法与到站间隔的估计

观察地铁到站的间隔 $T_1, \dots, T_n$, 假设它们独立且服从同一指数分布 $\text{Exp}(\lambda)$, 其中 $\lambda > 0$ 为到达率. 指数分布的无记忆性来自

$$\mathbb{P}(T > t + s \mid T > t) = \frac{e^{-\lambda(t+s)}}{e^{-\lambda t}} = e^{-\lambda s}, \quad s, t \geq 0.$$

这种模型描述等待时间的剩余部分不依赖已等待多久. 它不等于真实列车一定无记忆, 也不证明连续间隔独立. 同一个 λ 通常只应描述相对稳定的时段, 不宜混合高峰与深夜.

积分或指数分布矩公式给出 $\mathbb{E}T_i = 1/\lambda$, $\text{Var}(T_i) = 1/\lambda^2$. 因而自然估计量为

$$\hat{\lambda}_n = \frac{1}{\bar{T}_n}.$$

$\bar{T}_n > 0$ 几乎处处, 强大数定律和倒数的连续性给 $\hat{\lambda}_n \rightarrow \lambda$ 几乎处处. 中心极限定理先给出 $\sqrt{n}(\bar{T}_n - 1/\lambda) \xrightarrow{d} N(0, \lambda^{-2})$. 要求到达率的误差, 需要把这个极限传递给倒数函数.

定理 2.10 (一元 Delta 方法) 若 $\sqrt{n}(Z_n - \eta) \xrightarrow{d} N(0, \tau^2)$, 且 g 在 η 附近有定义并在 η 可微, 则

$$\sqrt{n}\{g(Z_n) - g(\eta)\} \xrightarrow{d} N(0, g'(\eta)^2 \tau^2).$$

若 $g'(\eta) = 0$, 右侧是集中于 0 的退化分布, 不能据此宣称存在非退化的正态近似.

证明. 分布收敛使 $A_n = \sqrt{n}(Z_n - \eta)$ 依概率有界, 即对每个 $\varepsilon > 0$ 可取 M 使充分大的 n 满足 $\mathbb{P}(|A_n| > M) < \varepsilon$. 因而 $Z_n - \eta \xrightarrow{\mathbb{P}} 0$. 可微性给

$$g(\eta + h) - g(\eta) = g'(\eta)h + hr(h), \quad r(h) \rightarrow 0.$$

于是左侧为 $g'(\eta)A_n + A_n r(Z_n - \eta)$. 余项依概率趋于 0: 先限制 $|A_n| \leq M$, 再用 $r(Z_n - \eta) \xrightarrow{\mathbb{P}} 0$. 用 Slutsky 定理即得结论. 若估计量偶尔不在函数定义域, 只要该事件概率趋于 0, 可在其上任意定义而不改变极限. $\square$

取 $g(t) = 1/t$, $\eta = 1/\lambda$, $g'(\eta) = -\lambda^2$, 得

$$\sqrt{n}(\hat{\lambda}_n - \lambda) \xrightarrow{d} N(0, \lambda^2).$$

未知标准差为 λ . 一种做法直接反解事件 $|\hat{\lambda}_n - \lambda| \leq c_n \lambda$, 其中 $c_n = z_{1-\alpha/2}/\sqrt{n}$. 当 $c_n < 1$ 时, 它等价于

$$\frac{\hat{\lambda}_n}{1 + c_n} \leq \lambda \leq \frac{\hat{\lambda}_n}{1 - c_n}.$$

因此反解区间为 $[\hat{\lambda}_n/(1 + c_n), \hat{\lambda}_n/(1 - c_n)]$, 两端均可计算且为正. 当 $c_n \geq 1$ 时不能沿用这个双侧反解公式; 其中上界条件不再提供有限上界.

更通用的做法是用一致估计量代替未知标准差. 因为 $\hat{\lambda}_n \xrightarrow{\mathbb{P}} \lambda > 0$, Slutsky 定理给出

$$\frac{\sqrt{n}(\hat{\lambda}_n - \lambda)}{\hat{\lambda}_n} \xrightarrow{d} N(0, 1),$$

所以 $[\hat{\lambda}_n(1 - c_n), \hat{\lambda}_n(1 + c_n)] \cap (0, \infty)$ 是渐近置信区间. 两个区间在有限样本中不同, 都有固定 λ 下的同一极限覆盖率. 如需始终为正的区间, 还可对 $\log \hat{\lambda}_n$ 使用 Delta 方法: 其渐近方差为 1, 从而得到 $[\hat{\lambda}_n e^{-c_n}, \hat{\lambda}_n e^{c_n}]$. 这是对同一极限工具的另一种应用.

3 参数估计与最大似然

3.1 统计量、偏差与风险

模型明确以后, 我们用观测构造未知参数的替代量. 估计量在观察之前是随机变量, 观察之后才成为一个确定数值. 它是否接近真实参数, 需要在 $\mathbb{P}_\theta$ 下讨论, 不能只看某次实验的结果.

定义 3.1 (统计量与估计量) 统计量是样本 $(X_1, \dots, X_n)$ 的可测函数. 参数 θ 的估计量 $\hat{\theta}_n = T_n(X_1, \dots, X_n)$ 是用于估计该参数的统计量, 其中规则 T_n 不能依赖未知的 θ . 对每个 $\theta \in \Theta$, 若在 $\mathbb{P}_\theta$ 下 $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$, 称其弱一致; 若 $\hat{\theta}_n \rightarrow \theta$ 几乎处处, 称其强一致.

样本均值、最大值、样本方差和 $X_1 + \log(1 + |X_n|)$ 都是统计量. 它们是否是有用的估计量, 取决于目标参数与模型. “能由数据计算”排除了未知参数, 可测性则确保有关它们的概率和期望有定义. 对隐式最大化问题, 还须确保选出的解是可测函数.

定义 3.2 (偏差与二次风险) 当相关期望存在时, 偏差为 $b_\theta(\hat{\theta}_n) = \mathbb{E}_\theta \hat{\theta}_n - \theta$. 若偏差为 0, 称其无偏. 二次风险为

$$R_\theta(\hat{\theta}_n) = \mathbb{E}_\theta \|\hat{\theta}_n - \theta\|^2.$$

对于向量参数, 这里使用 Euclidean 范数.

命题 3.3 (偏差与方差分解) 标量参数满足

$$R_\theta(\hat{\theta}_n) = b_\theta(\hat{\theta}_n)^2 + \text{Var}_\theta(\hat{\theta}_n).$$

向量情形右侧改为 $\|b_\theta\|^2 + \text{tr Cov}_\theta(\hat{\theta}_n)$.

证明. 将误差写成 $(\hat{\theta}_n - \mathbb{E}_\theta \hat{\theta}_n) + b_\theta$. 平方展开后, 交叉项的期望为 0. 向量情形逐坐标相加即得迹公式. $\square$

无偏不等于误差小, 一致也不等于有限样本风险小. Bernoulli 样本均值既无偏又强一致, 风险为 $p(1-p)/n$. 常数估计量 $1/2$ 在 $p = 1/2$ 时风险为 0, 却不能在所有参数处一致. 因此不能把某一个参数处的风险比较提升为整体最优性.

3.2 置信区间与覆盖率

定义 3.4 (置信区间) 对标量参数与 $\alpha \in (0, 1)$, 置信水平至少 $1 - \alpha$ 的置信区间是数据决定的随机区间 I_n , 其端点不依赖未知参数, 并满足

$$\mathbb{P}_\theta(\theta \in I_n) \geq 1 - \alpha, \quad \theta \in \Theta.$$

若对每个固定 $\theta \in \Theta$ 有 $\liminf_{n \rightarrow \infty} \mathbb{P}_\theta(\theta \in I_n) \geq 1 - \alpha$, 称其渐近置信水平至少 $1 - \alpha$.

这里参数是固定的, 随机的是由重复样本产生的区间. 观察后说“95% 置信区间”指构造规则的重复覆盖性质, 不是给固定未知参数赋予 95% 的后验概率. 若覆盖极限存在且等于 $1 - \alpha$, 可以说渐近水平恰为 $1 - \alpha$.

前章的 Bernoulli 例子展示了三种构造: 利用 $p(1-p) \leq 1/4$ 的保守渐近区间, 用样本比例代入标准误的 Wald 区间, 以及 Hoeffding 的有限样本区间. 含有真实 p 的区间 $[\hat{p}_n \pm z_{1-\alpha/2} \sqrt{p(1-p)/n}]$ 即使覆盖率正确, 仍不是这里定义的置信区间, 因为数据不足以计算其端点. 后文最大似然与矩估计的渐近分布, 都要经过同样的未知方差处理才能给出可计算区间.

3.3 分布距离与似然原理

参数误差只在选择参数坐标以后才有意义. 更直接的目标是使拟合分布 $\mathbb{P}_{\hat{\theta}_n}$ 接近真实分布 $\mathbb{P}_{\theta_*}$: 任意事件的预测概率都应相近. 这一想法引出总变差距离.

定义 3.5 (总变差距离) 对同一可测空间的概率测度 P, Q , 定义

$$\text{TV}(P, Q) = \sup_{A \in \mathcal{E}} |P(A) - Q(A)|.$$

命题 3.6 若 P, Q 关于同一测度 ν 有密度 p, q , 则

$$\text{TV}(P, Q) = \frac{1}{2} \int |p - q| d\nu.$$

离散分布的公式为 $\frac{1}{2} \sum_x |p(x) - q(x)|$, 连续分布则以 Lebesgue 积分表示. 总变差非负、对称, 为 0 当且仅当 $P = Q$, 并满足三角不等式.

证明. 令 $h = p - q$, 因为 $\int h d\nu = 0$, 其正部、负部积分相等且均为 $\frac{1}{2} \int |h| d\nu$. 任意事件的 $\int_A h$ 位于负部积分的负值与正部积分之间. 取 $A = \{h \geq 0\}$ 达到正部积分, 故得公式. 对称与非负由定义得到, 为 0 说明所有事件概率相同. 对每个 A , $|P(A) - R(A)| \leq |P(A) - Q(A)| + |Q(A) - R(A)|$, 取上确界得三角不等式. $\square$

直接最小化与真实分布的总变差需要估计整条概率规律. 对连续分布, 经验分布集中于有限个样本点, 与任何具有密度的模型分布的总变差都是 1: 取事件 $A = \{X_1, \dots, X_n\}$ 即可看出. 因而不能不加处理地用经验分布替代真实分布做总变差最小化. 最大似然改用一种期望能由样本平均替代的比较量.

定义 3.7 (Kullback–Leibler 散度) 若 P 关于 Q 绝对连续, 定义

$$\text{KL}(P, Q) = \int \log \left(\frac{dP}{dQ} \right) dP.$$

若 P 不关于 Q 绝对连续, 定为 $+\infty$. 在共同密度表示下, 它是 $\int p \log(p/q) d\nu$, 约定 $0 \log(0/q) = 0$, 而 $p > 0, q = 0$ 时该项为 $+\infty$.

命题 3.8 (KL 的非负性) $KL(P, Q) \geq 0$, 且为 0 当且仅当 $P = Q$. 一般不对称, 也不满足三角不等式.

证明. 若不绝对连续, 结论直接成立. 在密度表示中, 对 $p > 0$ 使用 $-\log u \geq 1 - u$, 得

$$\int_{p>0} p \log(p/q) d\nu \geq 1 - \int_{p>0} q d\nu \geq 0.$$

更精确地, $u - 1 - \log u \geq 0$, 仅在 $u = 1$ 取等. 若 KL 为 0, 两个非负余量均为 0, 得 $q/p = 1$ 在 P 几乎处处, 且 Q 在 $\{p = 0\}$ 无质量, 所以 $P = Q$. 反向结论立即成立. 不对称可取 $P = \text{Ber}(1/4)$, $Q = \text{Ber}(1/2)$: 两方向分别为 $\frac{1}{4} \log(1/2) + \frac{3}{4} \log(3/2)$ 与 $\frac{1}{2} \log(4/3)$, 数值不同. 对正态同方差模型, $KL(N(a, 1), N(b, 1)) = (a - b)^2/2$. 取 $a = 0, b = 1, c = 2$ 得两端散度 2, 经过中间分布的和为 1, 违反三角不等式. $\square$

设模型有共同密度 f_θ , 且所需对数期望有限. 有

$$KL(\mathbb{P}_{\theta_*}, \mathbb{P}_\theta) = \mathbb{E}_{\theta_*} \log f_{\theta_*}(X) - \mathbb{E}_{\theta_*} \log f_\theta(X).$$

第一项不依赖候选参数 θ . 对第二项用大数定律启发, 将期望换成 $n^{-1} \sum_i \log f_\theta(X_i)$. 于是最大化经验平均对数密度对应于最小化 KL 目标的经验版本. 常数项无法由此直接计算, 但不影响求最大值. 这里的逐点大数定律只是动机, 尚不能证明随机最大值点的一致性; 一致性需要后文的统一控制.

定义 3.9 (似然与最大似然估计) 对观测值 $x = (x_1, \dots, x_n)$, 独立同分布模型的似然和对数似然为

$$L_n(x; \theta) = \prod_{i=1}^n f_\theta(x_i), \quad \ell_n(x; \theta) = \sum_{i=1}^n \log f_\theta(x_i).$$

在离散模型中 f_θ 是质量函数, L_n 是这组数据的联合概率; 在连续模型中 L_n 是联合密度, 不是观察到精确点的概率. 最大似然估计是任一可测选择

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} L_n(X; \theta),$$

前提是最大值达到且可进行这种选择. 当最大似然为正时, 取对数不改变最大化点, 可等价地最大化 ℓ_n .

似然把数据固定、把参数当作自变量. 它不要求关于 θ 的积分为 1, 因而通常不是参数的概率密度. 最大值点可能不存在、可能不唯一, 这些均需针对模型检查.

3.4 凹性与最大化的条件

定义 3.10 (凹函数) 在凸集 $\Theta \subset \mathbb{R}^d$ 上, 函数 h 凹是指

$$h(tu + (1-t)v) \geq th(u) + (1-t)h(v), \quad 0 \leq t \leq 1.$$

若 $u \neq v$, $0 < t < 1$ 时严格不等号成立, 称为严格凹. 凸与严格凸分别指 $-h$ 凹与严格凹.

对 $h : \Theta \subset \mathbb{R}^d \rightarrow \mathbb{R}$, 梯度是由一阶偏导组成的列向量 $\nabla h = (\partial h / \partial \theta_j)_{j=1}^d$, Hessian 是二阶偏导组成的矩阵

$D^2h = (\partial^2 h / \partial \theta_j \partial \theta_k)_{j,k=1}^d$. 二阶偏导连续时混合偏导相等, Hessian 为对称矩阵. 沿方向 v 的一阶变化由 $\nabla h^\top v$ 给出, 二阶曲率由 $v^\top D^2h v$ 给出.

命题 3.11 (导数判别与极值) 在开凸集上, 二次连续可微的 h 凹当且仅当 Hessian $D^2h(\theta)$ 半负定. Hessian 处处负定足以保证严格凹, 但不是必要条件. 对可微凹函数, 任一满足 $\nabla h(\theta_0) = 0$ 的内点都是全局最大点. 严格凹函数最多有一个最大点; 若最大点在内点, 必满足梯度为 0.

证明. 沿任意线段考察 $\varphi(t) = h(u + t(v - u))$, 则 $\varphi''(t) = (v - u)^\top D^2h(u + t(v - u))(v - u)$. 一元二阶导数非正与凹性等价, 因而得到半负定判别. 负定使每条非平凡线段上的导数严格减小, 从而严格凹. 凹函数的切平面位于函数图像之上: $h(v) \leq h(u) + \nabla h(u)^\top (v - u)$, 这由沿线段的差商单调性得到. 在驻点右侧为 $h(u)$, 所以它是全局最大点. 两个不同最大点会使中点的函数值严格大于最大值, 因而严格凹时唯一. 内点极值的梯度为 0 来自各坐标方向的一阶必要条件. $\square$

例如 $-\theta^2$, $\sqrt{\theta}$ ($\theta > 0$), $\log \theta$ 均严格凹; $\sin \theta$ 在 $[0, \pi]$ 凹, 其内部二阶导数严格为负; $2\theta - 3$ 同时凹和凸但不严格. 函数 $-\theta^4$ 严格凹, 二阶导数在 0 却为 0, 说明负定条件不能写成严格凹的充要条件. 多元函数 $-\theta_1^2 - 2\theta_2^2$ 的 Hessian 为 $\text{diag}(-2, -4)$, 严格凹; $-(\theta_1 - \theta_2)^2$ 沿 $(1, 1)$ 方向恒定, 仅凹. 在 $\theta_1 + \theta_2 > 0$ 上, $\log(\theta_1 + \theta_2)$ 的 Hessian 为

$$-\frac{1}{(\theta_1 + \theta_2)^2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix},$$

也仅凹, 因其沿保持两坐标之和的方向不变.

严格凹不保证最大值存在, 如 $h(\theta) = \log \theta$ 在 $(0, \infty)$ 上无最大值. 最大点位于边界时, 也未必是驻点, 如在 $[0, 1]$ 上最大化 $h(\theta) = \theta$. 高次乘积 $\prod_i (\theta - X_i)$ 一般既不凹又可能有许多驻点, 求一个导数零点不能解决全局最大化. 似然计算要先认清定义域、边界及目标的形状, 再决定是否能用得分方程.

3.5 典型模型的最大似然计算

例题 3.1 分别求 Bernoulli 成功概率与 Poisson 均值的最大似然估计, 并检查开参数空间中的边界样本.

解答. 设 $S = \sum_i X_i$. Bernoulli 模型的似然为 $p^S(1-p)^{n-S}$. 若 $0 < S < n$, 则

$$\ell'_n(p) = \frac{S}{p} - \frac{n-S}{1-p} = \frac{S-np}{p(1-p)}, \quad \ell''_n(p) = -\frac{S}{p^2} - \frac{n-S}{(1-p)^2} < 0.$$

唯一最大点为 $\hat{p}_n = S/n$. 若 $S = 0$ 或 $S = n$, 在开参数空间 $(0, 1)$ 上只有分别趋于 0 或 1 的上确界, 没有 MLE. 把模型扩为 $p \in [0, 1]$ 后, 样本均值在所有样本上都是 MLE.

Poisson 模型的似然为 $e^{-n\lambda} \lambda^S / \prod_i X_i!$. 当 $S > 0$,

$$\ell'_n(\lambda) = -n + S/\lambda, \quad \ell''_n(\lambda) = -S/\lambda^2 < 0,$$

故 $\hat{\lambda}_n = S/n$. 若 $S = 0$, 开空间 $\lambda > 0$ 上同样没有达到的最大值. 若允许 $\lambda = 0$ 的退化 Poisson 分布, MLE 为 0. 真实参数为正时全零事件概率 $e^{-n\lambda}$ 趋于 0, 可在该事件上约定一个值而不影响渐近分布, 但该约定不能被称为原开模

型的 MLE. □

例题 3.2 求独立同分布指数样本的到达率 MLE, 并判断它是否无偏.

解答. 指数模型的似然为 $\lambda^n \exp(-\lambda \sum_i T_i)$, 对数似然为 $n \log \lambda - \lambda \sum_i T_i$. 其二阶导数 $-n/\lambda^2 < 0$, 且 $T_i > 0$ 几乎处处, 唯一最大点为 $\hat{\lambda}_n = n / \sum_i T_i = 1/\bar{T}_n$. 前章得到的估计因此也是 MLE. 若 $n > 1$, $\sum_i T_i$ 的 Gamma 密度给出 $\mathbb{E}\hat{\lambda}_n = n\lambda/(n-1)$, 所以一致 MLE 并不必然无偏. □

例题 3.3 求正态模型中均值与方差的联合 MLE, 检查存在条件并计算方差 MLE 的偏差.

解答. 设 $X_i \sim N(\mu, v)$, $v > 0$. 对数似然为

$$\ell_n(\mu, v) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log v - \frac{1}{2v} \sum_i (X_i - \mu)^2.$$

固定 v 时, 利用

$$\sum_i (X_i - \mu)^2 = \sum_i (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2,$$

唯一最优均值为 $\bar{X}_n$. 记 $Q = \sum_i (X_i - \bar{X}_n)^2$. 代入后关于 v 的导数为 $(Q - nv)/(2v^2)$. 若 $Q > 0$, 导数在 Q/n 左侧为正、右侧为负, 故全局最大点为

$$\hat{\mu}_n = \bar{X}_n, \quad \hat{v}_n = \frac{1}{n} \sum_i (X_i - \bar{X}_n)^2.$$

此处无需声称对 (μ, v) 联合严格凹. 若 $Q = 0$, 在 $\mu = \bar{X}_n$, $v \downarrow 0$ 时似然无界, 不存在 MLE. 对连续正态样本, $n \geq 2$ 时 $Q > 0$ 几乎处处; $n = 1$ 则必然不存在联合 MLE.

又因 $Q = \sum_i (X_i - \mu)^2 - n(\bar{X}_n - \mu)^2$, 取期望得到 $\mathbb{E}Q = (n-1)v$. 因而方差 MLE 有偏差 $-v/n$, 而 $Q/(n-1)$ 无偏. 两者都一致, 无偏版本与 MLE 分母不同的原因在这里可以直接看出. □

3.6 得分、Fisher 信息与信息下界

定义 3.12 (得分与 Fisher 信息) 在可微密度模型中, 单次观测的得分向量是 $s_\theta(X) = \nabla_\theta \log f_\theta(X)$. 当其平方可积且 $\mathbb{E}_\theta s_\theta = 0$ 时, 单次观测的 Fisher 信息为

$$I(\theta) = \mathbb{E}_\theta[s_\theta s_\theta^\top] = \text{Cov}_\theta(s_\theta).$$

独立样本的总得分是 $S_n(\theta) = \sum_i s_\theta(X_i)$, 总信息为 $nI(\theta)$.

得分表示对数密度对参数的局部敏感性, 信息矩阵衡量这种敏感性在各参数方向的均方大小. 这些等式需要正则性, 不能只凭“几乎处处二次可微”得到.

命题 3.13 (信息的两个表达式) 假设参数属于开集, 密度的支撑不依赖参数, f_θ 在共同支撑上正且二次可微, 并可

将归一化积分的一阶、二阶求导移入积分. 假设有关得分和二阶导数的期望有限. 则

$$\mathbb{E}_\theta s_\theta = 0, \quad I(\theta) = -\mathbb{E}_\theta D_\theta^2 \log f_\theta(X).$$

证明. 对 $\int f_\theta d\nu = 1$ 求导, 得 $\int \nabla f_\theta d\nu = 0$, 而 $\nabla f_\theta = f_\theta s_\theta$, 所以得分均值为 0. 再求导, 用

$$D^2 f_\theta = f_\theta \{D^2 \log f_\theta + s_\theta s_\theta^\top\},$$

积分等于零便得信息等式. 各样本得分独立且均值零, 协方差相加, 所以总信息为 $nI(\theta)$. $\square$

例题 3.4 计算 Bernoulli、Poisson、指数以及正态均值方差模型的单次 Fisher 信息.

解答. Bernoulli 得分为 $(X - p)/(p(1 - p))$, 信息为 $1/(p(1 - p))$. Poisson 得分为 $X/\lambda - 1$, 信息为 $1/\lambda$. 指数到达率的得分为 $1/\lambda - T$, 信息为 $1/\lambda^2$. 正态参数取 (μ, v) 时,

$$s_{\mu,v}(X) = \begin{pmatrix} (X - \mu)/v \\ -1/(2v) + (X - \mu)^2/(2v^2) \end{pmatrix}, \quad I(\mu, v) = \begin{pmatrix} 1/v & 0 \\ 0 & 1/(2v^2) \end{pmatrix}.$$

交叉项为 0 是因为中心正态的三阶矩为 0; 第二个对角元利用 $\mathbb{E}(X - \mu)^4 = 3v^2$ 得到. 信息会随参数化改变, 例如以标准差而非方差为坐标时, 对应的数值不同. $\square$

定理 3.14 (Cramér–Rao 下界) 考虑一维正则模型, 单次信息 $0 < I(\theta) < \infty$. 若统计量 T_n 二阶矩有限, 且可对其期望求导移入积分, 记 $m(\theta) = \mathbb{E}_\theta T_n$. 则

$$\text{Var}_\theta(T_n) \geq \frac{m'(\theta)^2}{nI(\theta)}.$$

特别地, 无偏估计量满足 $\text{Var}_\theta(T_n) \geq 1/(nI(\theta))$.

证明. 对联合密度求导得

$$m'(\theta) = \mathbb{E}_\theta[T_n S_n(\theta)] = \mathbb{E}_\theta[(T_n - m(\theta))S_n(\theta)],$$

最后使用总得分均值为 0. Cauchy–Schwarz 不等式给 $m'(\theta)^2 \leq \text{Var}_\theta(T_n) \mathbb{E}_\theta S_n(\theta)^2 = \text{Var}_\theta(T_n) nI(\theta)$, 得到结论. 若 T_n 无偏, $m(\theta) = \theta$, 导数为 1. $\square$

有偏估计量不能直接套用无偏版本; 若偏差为 $b(\theta)$, 分子应为 $(1 + b'(\theta))^2$. 等号要求中心化估计量与总得分成比例. Bernoulli 与 Poisson 的样本均值达到各自下界. 向量情形, 若 T_n 无偏估计整个参数且 I 正定, 则 $\text{Cov}(T_n) \succeq (nI)^{-1}$. 证明对向量 $T_n - \theta - (nI)^{-1} S_n$ 求协方差, 其半正定性给出该不等式; 交叉协方差 $\mathbb{E}[(T_n - \theta) S_n^\top]$ 为单位矩阵, 来自各坐标期望的求导.

3.7 MLE 的一致性与渐近正态性

可识别性、共同支撑、真实参数为内点与信息非奇异都很重要, 但单列这几条还不足以构成完整的一般 MLE 定理. 例如逐点大数定律不控制随样本移动的最大值点. 下面分别给出一致性的可检查版本和从得分展开推出正态极限的版本.

定理 3.15 (紧参数空间上的一致性) 设 $\Theta \subset \mathbb{R}^d$ 紧, $m(\theta) = \mathbb{E}_{\theta_*} \log f_\theta(X)$ 有限连续, 并有唯一最大点 θ_* . 假设经验目标 $M_n(\theta) = n^{-1} \ell_n(\theta)$ 满足

$$\sup_{\theta \in \Theta} |M_n(\theta) - m(\theta)| \xrightarrow{\mathbb{P}} 0.$$

若可测估计量满足 $M_n(\hat{\theta}_n) \geq M_n(\theta_*) - r_n$, 其中 $r_n \xrightarrow{\mathbb{P}} 0$, 则 $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_*$. 特别地, 已存在的 MLE 满足该结论.

证明. 对任意 $\varepsilon > 0$, 紧集 $K_\varepsilon = \{\theta \in \Theta : \|\theta - \theta_*\| \geq \varepsilon\}$ 上由连续性与唯一性得到严格间隙 $\delta = m(\theta_*) - \max_{K_\varepsilon} m > 0$, 若该集空则结论直接成立. 在统一误差小于 $\delta/3$ 且 $r_n < \delta/3$ 的事件上, 每个 $\theta \in K_\varepsilon$ 的经验值都比 $M_n(\theta_*) - r_n$ 小, 所以估计量不能落入该集. 该事件概率趋于 1, 得一致性. $\square$

正确设定且可识别的模型中, KL 非负性保证 m 的唯一最大点, 前提是对数期望均有定义并有限. 统一大数定律是本定理额外要求. 一项常用充分条件为 $\log f_\theta(x)$ 关于 θ 连续, 且存在可积包络 H 使 $\sup_{\Theta} |\log f_\theta(X)| \leq H(X)$. 其理由是: 紧性给有限覆盖, 连续性使局部振荡趋于 0, 包络与控制收敛使振荡期望也趋于 0, 再对有限个中心点及振荡使用大数定律. 非紧参数空间需要另行防止最大化点逃向无穷远, 不能省略这一环节.

定理 3.16 (得分展开的渐近正态性) 设 $\theta_* \in \text{int } \Theta$, $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_*$. 假设在 θ_* 的某个凸邻域 U 上对数密度二次连续可微, 单次得分均值为 0 且协方差 $I(\theta_*)$ 有限正定. 设 $\hat{\theta}_n$ 以概率趋于 1 为满足 $\nabla \ell_n(\hat{\theta}_n) = 0$ 的内点, 并假设

$$\sup_{\theta \in U} \left\| \frac{1}{n} D^2 \ell_n(\theta) - \mathbb{E}_{\theta_*} D^2 \log f_\theta(X) \right\| \xrightarrow{\mathbb{P}} 0,$$

其中期望矩阵关于 θ 在 θ_* 连续, 且其在 θ_* 为 $-I(\theta_*)$. 则

$$\sqrt{n}(\hat{\theta}_n - \theta_*) \xrightarrow{d} N_d(0, I(\theta_*)^{-1}).$$

证明. 在 $\hat{\theta}_n \in U$ 且得分为 0 的事件上, 沿线段积分导数, 得

$$0 = \frac{1}{\sqrt{n}} \nabla \ell_n(\theta_*) + H_n \sqrt{n}(\hat{\theta}_n - \theta_*), \quad H_n = \int_0^1 \frac{1}{n} D^2 \ell_n(\theta_* + t(\hat{\theta}_n - \theta_*)) dt.$$

统一收敛、一致性与期望矩阵连续性给 $H_n \xrightarrow{\mathbb{P}} -I(\theta_*)$. 正定性使其以概率趋于 1 可逆. 多元中心极限定理给 $n^{-1/2} \sum_i s_{\theta_*}(X_i) \xrightarrow{d} N_d(0, I(\theta_*))$. 多元中心极限定理在此作为概率先修调用, 可由每个线性组合的一元中心极限定理与 Cramér-Wold 定理获得. 因而

$$\sqrt{n}(\hat{\theta}_n - \theta_*) = -H_n^{-1} \frac{1}{\sqrt{n}} \sum_i s_{\theta_*}(X_i) \xrightarrow{d} N_d(0, I^{-1} I I^{-1}) = N_d(0, I^{-1}),$$

这里矩阵逆在非奇异矩阵处连续, 并用向量形式的 Slutsky 定理. 排除事件的概率趋于 0, 不改变分布极限. $\square$

这些明确假设把源讲义中的“其他技术条件”拆开了: 先以统一目标控制得到一致性, 再用统一 Hessian 控制合

法展开. 不能只用一个未经证明的“MLE 一般一致”代替第一步. 许多模型可以直接算出 MLE 并单独用大数定律验证一致性, 不必强行放进紧参数空间定理.

若 $\hat{I}_n \xrightarrow{\mathbb{P}} I(\theta_*)$ 且正定, 则对第 j 个坐标, 令 $\hat{v}_{j,n} = (\hat{I}_n^{-1})_{jj}$, 有

$$\frac{\sqrt{n}(\hat{\theta}_{n,j} - \theta_{*,j})}{\sqrt{\hat{v}_{j,n}}} \xrightarrow{d} N(0, 1).$$

可取 $\hat{I}_n = I(\hat{\theta}_n)$, 前提是 I 在真实参数处连续; 或用在 MLE 处的负样本平均 Hessian, 前提是上面的一致控制成立. 于是 Wald 区间为 $[\hat{\theta}_{n,j} \pm z_{1-\alpha/2} \sqrt{\hat{v}_{j,n}/n}]$. 一维正则 MLE 的渐近方差 I^{-1} 与无偏信息下界相呼应, 但渐近方差最优不能被理解为每个 n 下二次风险都最小.

3.8 参数决定支撑的非正则模型

例 3.5 对 $X_i \sim \text{Unif}[0, \theta]$, 求 θ 的 MLE、收敛速度和极限分布, 并构造精确置信区间.

解答. 设 $X_i \sim \text{Unif}[0, \theta]$, $\theta > 0$, 令 $M_n = \max_i X_i$. 使用闭区间密度表示, 似然为

$$L_n(\theta) = \theta^{-n} \mathbf{1}_{\{\theta \geq M_n\}}.$$

在 $\theta \geq M_n$ 上严格递减, 所以 $\hat{\theta}_n = M_n$ 是 MLE, 几乎处处 $M_n > 0$. 其分布为

$$\mathbb{P}_\theta(M_n \leq x) = (x/\theta)^n, \quad 0 \leq x \leq \theta.$$

对 $0 < \varepsilon < \theta$, $\mathbb{P}_\theta(\theta - M_n > \varepsilon) = (1 - \varepsilon/\theta)^n \rightarrow 0$, 所以它一致. 实际上 M_n 随 n 单调且不超过 θ , 该尾概率又表明其几乎处处极限必为 θ , 故强一致.

但对固定 $t \geq 0$ 与充分大的 n ,

$$\mathbb{P}_\theta \left(\frac{n(\theta - M_n)}{\theta} > t \right) = \left(1 - \frac{t}{n} \right)^n \rightarrow e^{-t}.$$

因此 $n(\theta - M_n)/\theta \xrightarrow{d} \text{Exp}(1)$, 误差尺度是 n^{-1} , 极限不是正态. 形式上对 $\log f_\theta(X) = -\log \theta$ 求导给得分 $-1/\theta$, 其均值不为 0; 这暴露了忽略移动支撑边界的求导错误. 正则信息等式与上节 MLE 定理不能应用.

利用上述分布还能构造精确区间. M_n/θ 的分布函数为 u^n , 所以

$$\mathbb{P}_\theta (M_n \leq \theta \leq M_n \alpha^{-1/n}) = \mathbb{P}_\theta (M_n/\theta \geq \alpha^{1/n}) = 1 - \alpha.$$

区间 $[M_n, M_n \alpha^{-1/n}]$ 在每个 n 都有精确覆盖, 不必借助正态近似. □

这一例说明统计模型中的支撑条件有实质作用. 参数估计可以一致且比 $n^{-1/2}$ 更快, 同时完全不服从正则 MLE 的渐近结论. 下一章将用同一模型比较矩估计, 进一步看出计算方便与统计精度之间的差异.

4 矩估计与渐近分析

4.1 为什么使用矩

最大似然通过完整密度或质量函数估计参数. 若似然难以最大化, 另一条路线是先估计几个容易计算的分布特征, 再从这些特征反解参数. 最常见的分布特征是矩: 一阶矩描述均值, 二阶矩配合均值描述方差, 更高阶矩包含偏斜与尾部的信息. 这种方法何时能区分分布, 以及需要多少个矩, 必须分别回答.

定义 4.1 (总体矩与经验矩) 若 $\mathbb{E}_\theta |X|^k < \infty$, 分布的 k 阶原点矩为 $m_k(\theta) = \mathbb{E}_\theta X^k$. 对独立同分布样本, 经验矩为

$$\hat{m}_{k,n} = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

记 $m_0 = 1$, 它表示分布的总质量. 一般而言 $\hat{m}_{k,n}$ 不是 $(\bar{X}_n)^k$: 求幂在每次观测内, 求平均在观测之间.

按大数定律, 若绝对 k 阶矩有限, $\hat{m}_{k,n} \rightarrow m_k(\theta)$ 几乎处处. 这给出估计矩的直接办法. 但即使某几个矩准确已知, 也不保证能从中唯一恢复分布. 先从紧区间上的多项式逼近理解所有矩的作用.

定理 4.2 (Weierstrass 逼近定理) 设 f 在有限闭区间 $[a, b]$ 上连续. 对任意 $\varepsilon > 0$, 存在多项式 $p(x) = \sum_{k=0}^d a_k x^k$ 使

$$\sup_{x \in [a, b]} |f(x) - p(x)| < \varepsilon.$$

证明. 线性变换后只须证明 $[0, 1]$ 的情形. 定义 Bernstein 多项式

$$B_N f(x) = \sum_{j=0}^N f(j/N) \binom{N}{j} x^j (1-x)^{N-j}.$$

对固定 x , 可写成 $\mathbb{E}f(K/N)$, 其中 $K \sim \text{Bin}(N, x)$. 连续函数在紧区间上一致连续且有界. 令 $M = \sup |f|$, 给定 $\varepsilon > 0$, 可取 $\delta > 0$ 使 $|u-v| \leq \delta$ 时 $|f(u) - f(v)| < \varepsilon/2$. 因为 $\mathbb{E}(K/N) = x$, $\text{Var}(K/N) = x(1-x)/N \leq 1/(4N)$, 有

$$|B_N f(x) - f(x)| \leq \varepsilon/2 + 2M\mathbb{P}(|K/N - x| > \delta) \leq \varepsilon/2 + \frac{M}{2N\delta^2}.$$

取 N 足够大, 此上界小于 ε 且不依赖 x , 得到一致逼近. 将多项式复合线性变换即可回到 $[a, b]$. $\square$

推论 4.3 (紧支撑上的矩确定分布) 若 P, Q 都支撑于同一个有限闭区间 $[a, b]$, 且所有原点矩相同, 则 $P = Q$.

证明. 所有矩相同意味着所有多项式积分相同. 对连续函数 h 取一致误差小于 ε 的多项式 p , 则

$$\left| \int h dP - \int h dQ \right| \leq \left| \int (h-p) dP \right| + \left| \int (p-h) dQ \right| < 2\varepsilon.$$

故连续函数积分全部相同. 为直接看出分布函数相同, 对每个 t 取连续函数 h_j , 在 $x \leq t$ 时为 1, 在 $x \geq t+1/j$ 时为 0, 中间线性下降. 它们逐点趋于 $\mathbf{1}_{\{x \leq t\}}$, 控制收敛给 $P((-\infty, t]) = Q((-\infty, t])$. 分布函数决定实直线上的概率测度, 因而 $P = Q$. $\square$

这一结论不要求密度存在, 因而离散、连续、混合分布都可使用. 在可识别参数模型中, 分布相同又推出参数相同. 但它使用所有矩, 不是只使用某个预先固定的有限 d . 每个连续函数所需的逼近次数不同, Weierstrass 定理本身

并不告诉我们统计模型需要几个矩.

例题 4.1 说明有限个矩不能在不加模型限制时唯一确定概率分布.

解答. 对称于 0 的 $\text{Unif}[-1, 1]$ 与在 $\{-1, 1\}$ 各放质量 $1/2$ 的分布均值都为 0, 却是不同分布. 因而一阶矩不能一般地识别分布. 更一般地, 给定 d , 在 $d+2$ 个不同节点上, 保持总质量与前 d 阶矩只施加 $d+1$ 个线性约束, 存在非零零空间方向. 从各节点均为正的质量出发, 沿该方向作足够小的正负扰动, 得到两个不同概率分布而前 d 阶矩相同. $\square$

例题 4.2 构造两个不同的无界支撑概率分布, 使它们的所有原点矩都相同.

解答. 设 $X = e^Y$, $Y \sim N(0, 1)$, 对数正态密度为

$$f(x) = \frac{1}{x\sqrt{2\pi}} e^{-(\log x)^2/2}, \quad x > 0.$$

对 $|\varepsilon| \leq 1$, 定义 $f_\varepsilon(x) = f(x)\{1 + \varepsilon \sin(2\pi \log x)\}$. 它非负, 且对整数 $k \geq 0$,

$$\begin{aligned} \int_0^\infty x^k f(x) \sin(2\pi \log x) dx &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{ky-y^2/2} \sin(2\pi y) dy \\ &= e^{k^2/2} \mathbb{E} \sin(2\pi(Z+k)) = 0, \end{aligned}$$

其中 $Z \sim N(0, 1)$, 完成平方得到第二行; 因 k 是整数, 正弦等于 $\sin(2\pi Z)$, 关于 0 奇对称, 期望为 0. $k=0$ 说明密度归一化, 其余 k 说明所有原点矩都与 f 相同. 不同 ε 给出不同密度. 因而不能在无界支撑上无条件援引 Weierstrass 定理宣称所有矩决定分布. $\square$

理论上若要求经验分布和某个参数分布对所有有界连续函数的积分相同, 两个分布就应完全相同. 连续模型的经验分布却是离散的, 一般不存在这样的参数. 矩估计的实用目标不是解无限个精确拟合方程, 而是挑出能在所选参数族内部识别参数的有限个特征.

4.2 有限支撑、Vandermonde 矩阵与求积

设支撑节点 $x_1, \dots, x_r$ 已知且互异. 未知量只有各节点的概率 $p_1, \dots, p_r$, 其中 $\sum_j p_j = 1$, 所以自由参数数目为 $r-1$. 前 $r-1$ 阶矩与归一化条件构成方程

$$\sum_{j=1}^r p_j x_j^k = m_k, \quad k = 0, 1, \dots, r-1.$$

写成矩阵形式为 $Vp = m$, 其中

$$V = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_r \\ \vdots & \vdots & & \vdots \\ x_1^{r-1} & x_2^{r-1} & \cdots & x_r^{r-1} \end{pmatrix}, \quad m = (1, m_1, \dots, m_{r-1})^\top.$$

命题 4.4 (已知有限支撑的矩恢复) $\det V = \prod_{1 \leq j < k \leq r} (x_k - x_j) \neq 0$. 因而若给定矩向量来自该支撑上的概率分布, 它唯一确定概率向量 $p = V^{-1}m$.

证明. 将行列式视为节点变量的多项式. 若两个节点相等, 两列相同, 行列式为 0, 所以每个差因子 $x_k - x_j$ 都整除行列式. 行列式总次数为 $0 + 1 + \cdots + (r-1)$, 与这些差因子的总次数相同, 故二者相差一个常数. 按最后一行与最后节点的最高次项递归比较, 系数为前 $r-1$ 个节点的 Vandermonde 行列式, 归纳得常数为 1. 节点互异使行列式非零, 因而线性方程有唯一解. 非负性并非矩阵可逆自动保证, 而由给定矩确实来自该支撑上的概率分布保证. $\square$

还可用 Lagrange 多项式理解该结果. 定义

$$l_j(x) = \prod_{k \neq j} \frac{x - x_k}{x_j - x_k},$$

则 $l_j(x_k) = \mathbf{1}_{\{j=k\}}$, 所以 $p_j = \mathbb{E}l_j(X)$. l_j 次数不超过 $r-1$, 因而它的期望只需要前 $r-1$ 阶矩. 在这一已知支撑模型中, 把矩换成经验矩还给出

$$\hat{p}_j = \frac{1}{n} \sum_i l_j(X_i) = \frac{1}{n} \sum_i \mathbf{1}_{\{X_i = x_j\}},$$

正是各节点的经验频率, 自动非负且和为 1. 若输入的是额外测量误差污染的矩, 解出来的概率则可能为负, 需要另作约束处理.

例题 4.3 对支撑 $\{0, 1, 2\}$ 上的概率分布, 用前两阶矩恢复三个节点的概率.

解答. 若 $E = \{0, 1, 2\}$, 则 $m_1 = p_1 + 2p_2$, $m_2 = p_1 + 4p_2$, 其中下标表示节点本身. 因而

$$p_2 = (m_2 - m_1)/2, \quad p_1 = 2m_1 - m_2, \quad p_0 = 1 - \frac{3}{2}m_1 + \frac{1}{2}m_2.$$

可实现的矩向量必须使这三个数都非负. 这展示了“方程可解”与“解属于统计模型”之间的区别. $\square$

源讲义将这一组有限支撑方程放在 Gaussian quadrature 的标题下. 上述论证准确地说是已知节点上的权重恢复. 真正的 Gaussian 求积还会选择节点, 使 r 个节点对次数最高 $2r-1$ 的多项式积分精确. 两者都把积分化为有限加权和, 但结论不同. 以下给出这种联系, 避免把前 $r-1$ 阶矩的 Vandermonde 恢复误称为完整 Gaussian 求积.

命题 4.5 (Gaussian 求积的矩匹配) 设概率测度 P 支撑于 $[a, b]$, 支撑含多于 r 个点. 则存在互异的节点 $z_1, \dots, z_r \in (a, b)$ 和正权重 $w_1, \dots, w_r$, $\sum_j w_j = 1$, 使

$$\int q dP = \sum_{j=1}^r w_j q(z_j)$$

对所有次数不超过 $2r-1$ 的多项式成立.

证明. 在次数不超过 r 的多项式空间上定义内积 $\langle u, v \rangle = \int uv dP$. 非零次数不超过 r 的多项式至多有 r 个根, 支撑点多于 r 保证平方积分严格为正. Gram-Schmidt 正交化因此给出首一的 r 次正交多项式 p_r , 它与所有低于 r 次的多项式正交.

设 p_r 在 (a, b) 中发生符号变化的不同实根为 $z_1, \dots, z_s$, 并取 $v(x) = \prod_{j=1}^s (x - z_j)$. 若 $s < r$, 则 $p_r v$ 在整个 $[a, b]$ 上不改变符号, 且只在 p_r 的根处为 0. 支撑点多于 r , 故其积分非零, 与正交性矛盾. 因而 $s = r$, p_r 的全部根均为互异的内点实根.

以这些根定义 Lagrange 多项式 l_j 并取 $w_j = \int l_j dP$. 对 $\deg q \leq 2r-1$, 多项式除法给 $q = p_r u + v$, $\deg u \leq r-1$, $\deg v \leq r-1$. 正交性使 $\int p_r u dP = 0$, 节点上 $p_r = 0$, 插值使 $v = \sum_j v(z_j) l_j$. 因而求积公式成立. 对 $q = l_j^2$ 使用这一公式, 得 $w_j = \int l_j^2 dP > 0$. 取 $q = 1$ 给 $\sum_j w_j = 1$. $\square$

该命题还说明有限个矩一般不能恢复任意分布: 一个支撑含很多点的分布与上述 r 节点分布, 前 $2r-1$ 阶矩完全相同. 唯一恢复依赖于先固定已知有限支撑, 或依赖特定参数族的额外结构.

4.3 矩估计的定义与存在性

定义 4.6 (矩估计) 设参数 $\theta \in \Theta \subset \mathbb{R}^d$, 所选择的前 d 阶矩均有限. 定义矩映射

$$\psi(\theta) = (m_1(\theta), \dots, m_d(\theta))^T.$$

若 ψ 单射, 且经验矩向量 $\widehat{M}_n = (\widehat{m}_{1,n}, \dots, \widehat{m}_{d,n})^T$ 属于 $\psi(\Theta)$, 则矩估计为

$$\widehat{\theta}_n^{\text{MM}} = \psi^{-1}(\widehat{M}_n).$$

这一定义有两个条件: 理论矩必须能区分参数, 经验矩也必须落在可反解的区域. 参数维数为 d 时选 d 个矩是常用起点, 并不是定理. 有些模型需要不同的矩或更多个特征; 有些模型缺少所需矩. 即使整体模型可识别, 某个特定的矩映射仍可能不单射, 例如均值固定而方差未知的正态模型不能仅靠一阶矩估计方差.

可以把 X^k 换成一般函数 $h_k(X)$, 建立 $\mathbb{E}_\theta h_k(X) = \widehat{h}_{k,n}$ 的方程; 使用多于参数维数的特征时, 通常不能全部精确求解, 需要明确一种加权拟合准则. 本章先研究恰好可反解的普通矩方法. 若经验矩偶尔不在像集内, 可定义一个备用值, 但应注明它在该事件上不是精确矩方程的解.

例题 4.4 求 Bernoulli、Poisson、指数及均匀上端点模型的一阶矩估计, 并与 MLE 比较.

解答. Bernoulli 的 $m_1(p) = p$, Poisson 的 $m_1(\lambda) = \lambda$, 故矩估计均为 $\overline{X}_n$, 与前章的 MLE 相同, 边界存在性仍须按参数空间处理. 指数模型 $m_1(\lambda) = 1/\lambda$, 故矩估计是 $1/\overline{X}_n$, 也与 MLE 相同. 对 $\text{Unif}[0, \theta]$, $m_1(\theta) = \theta/2$, 矩估计却为 $2\overline{X}_n$, 与 MLE M_n 不同. $\square$

例题 4.5 利用前两阶矩求正态均值与方差的矩估计, 并检查经验矩是否属于模型的矩像集.

解答. 参数为 (μ, v) , 有 $m_1 = \mu$, $m_2 = \mu^2 + v$. 因而矩映射的逆为

$$\mu = m_1, \quad v = m_2 - m_1^2.$$

将矩换成经验矩得到 $\widehat{\mu}_n = \overline{X}_n$ 与 $\widehat{v}_n = \overline{X^2}_n - (\overline{X}_n)^2 = n^{-1} \sum_i (X_i - \overline{X}_n)^2$, 与正态 MLE 相同. 当样本全部相同时, 经验矩落在 $v = 0$ 的边界, 不在原来 $v > 0$ 的像集中. 对非退化正态样本与 $n \geq 2$, 这一事件概率为 0. $\square$

例题 4.6 利用前两阶矩求 Gamma 分布形状与尺度的矩估计.

解答. 取形状 $a > 0$, 尺度 $b > 0$, 密度为

$$f_{a,b}(x) = \frac{x^{a-1}e^{-x/b}}{\Gamma(a)b^a}, \quad x > 0.$$

Gamma 函数递推 $\Gamma(a+1) = a\Gamma(a)$ 给 $\mathbb{E}X = ab$, $\mathbb{E}X^2 = a(a+1)b^2$, 因而 $\text{Var}(X) = ab^2$. 记 $u = m_1$, $w = m_2 - u^2$, 则

$$a = u^2/w, \quad b = w/u.$$

在 $u > 0, w > 0$ 时逆映射存在且光滑. 经验均值为正, 经验方差在至少两个不相等的观测时为正, 故

$$\hat{a}_n = \frac{\overline{X_n^2}}{\overline{X_n^2} - \overline{X_n}^2}, \quad \hat{b}_n = \frac{\overline{X_n^2} - \overline{X_n}^2}{\overline{X_n}}.$$

Gamma 似然关于形状的方程含 Gamma 函数的对数导数, 通常要数值求解; 上述矩估计则是直接可算的初值或替代估计. $\square$

例题 4.7 对 $\text{Unif}[a, b]$, 利用前两阶矩求两个端点的矩估计.

解答. 设 $X \sim \text{Unif}[a, b]$, $a < b$. 均值 $u = (a+b)/2$, 方差 $w = (b-a)^2/12$, 所以前两阶矩的逆为

$$a = u - \sqrt{3w}, \quad b = u + \sqrt{3w}.$$

以下要求分母为 n 的经验方差 $\hat{w}_n > 0$. 结合经验均值, 得矩估计 $\hat{a}_n = \overline{X}_n - \sqrt{3\hat{w}_n}$, $\hat{b}_n = \overline{X}_n + \sqrt{3\hat{w}_n}$. 若 $\hat{w}_n = 0$, 经验矩落在边界, 公式给出相同两 endpoint, 不属于 $a < b$ 的原模型, 因而该模型的精确矩估计不存在. 在正经验方差的条件下, 它们是矩方程的解, 但不一定包含样本极值; 精确拟合矩不等于让所有观测位于估计支撑内. 当样本极差严格为正, 并采用闭区间密度版本时, 最大似然用样本最小值与最大值估计两 endpoint: 必须包含所有观测, 而其似然随区间长度减小而增大. 如果 $n = 1$ 或全部观测相同, 在 $a < b$ 下可使区间长度趋于 0, 似然无界, 因而 MLE 不存在. $\square$

4.4 一致性与多元 Delta 方法

命题 4.7 (矩估计的一致性) 设所选 d 个绝对矩有限, 矩映射在真实参数处具有一个连续的逆 g ; 该逆定义在真实矩向量 $M = \psi(\theta)$ 的一个邻域内. 若在经验矩不属于此邻域的事件上任意延拓估计量, 则 $g(\widehat{M}_n) \rightarrow \theta$ 几乎处处, 从而弱一致.

证明. 对每个 X_i^k 使用强大数定律, 由于只有有限个坐标, 所有坐标同时收敛的事件仍有概率 1. 因而 $\widehat{M}_n \rightarrow M$ 几乎处处, 最终落在所指定的邻域. 逆映射在 M 的连续性给 $g(\widehat{M}_n) \rightarrow g(M) = \theta$. $\square$

连续的局部逆比“单射”更具体. 单射本身不能在任意参数空间上保证反函数连续. 若 ψ 在开邻域内连续可微, 且 Jacobian $D\psi(\theta)$ 非奇异, 逆函数定理提供局部连续可微逆. 逆函数定理在这里作为多元微积分先修使用, 其作用是保证附近经验矩确实有唯一的附近参数解.

定理 4.8 (多元 Delta 方法) 设 $T_n \in \mathbb{R}^p$, $\sqrt{n}(T_n - \eta) \xrightarrow{d} N_p(0, \Sigma)$, $g: \mathbb{R}^p \rightarrow \mathbb{R}^k$ 在 η 邻域可定义且在 η 可微. 以 $k \times p$ 的 Jacobian

$$J = Dg(\eta) = \left(\frac{\partial g_i}{\partial x_j}(\eta) \right)_{1 \leq i \leq k, 1 \leq j \leq p}$$

表示导数, 则

$$\sqrt{n}\{g(T_n) - g(\eta)\} \xrightarrow{d} N_k(0, J\Sigma J^\top).$$

Σ 可以半正定, 极限允许退化.

证明. 可微性给 $g(\eta + h) - g(\eta) = Jh + r(h)$, 且 $\|r(h)\|/\|h\| \rightarrow 0$. 分布收敛使 $A_n = \sqrt{n}(T_n - \eta)$ 依概率有界并使 $T_n \xrightarrow{\mathbb{P}} \eta$. 所以

$$\sqrt{n}\|r(T_n - \eta)\| = \|A_n\| \frac{\|r(T_n - \eta)\|}{\|T_n - \eta\|} \xrightarrow{\mathbb{P}} 0,$$

零分母时余项置 0. 于是所求向量为 JA_n 加一个概率趋零的向量. 线性变换正态向量的协方差为 $J\Sigma J^\top$, 再用 Slutsky 定理完成证明. $\square$

Jacobian 的行对应输出, 列对应输入, 这一约定固定了矩阵乘法的顺序. 若改用转置的梯度约定, 公式应相应转置; 不可同时保留两种约定的记号.

定理 4.9 (矩估计的渐近分布) 设 $\mathbb{E}_\theta |X|^{2d} < \infty$, 令 $H(X) = (X, X^2, \dots, X^d)^\top$, $M = \mathbb{E}_\theta H(X)$, 并令

$$\Sigma(\theta) = \text{Cov}_\theta(H(X)), \quad \Sigma_{jk}(\theta) = m_{j+k}(\theta) - m_j(\theta)m_k(\theta).$$

假设 ψ 在真实参数附近有可微逆 g , Jacobian 为 $J = Dg(M)$. 则矩估计满足

$$\sqrt{n}(\hat{\theta}_n^{\text{MM}} - \theta) \xrightarrow{d} N_d(0, \Gamma(\theta)), \quad \Gamma(\theta) = J\Sigma(\theta)J^\top.$$

若 $D\psi(\theta)$ 可逆, 则 $J = D\psi(\theta)^{-1}$.

证明. $2d$ 阶绝对矩保证每个 X^k 的二阶矩有限, 也保证各交叉矩有限. 多元中心极限定理给 $\sqrt{n}(\widehat{M}_n - M) \xrightarrow{d} N_d(0, \Sigma)$. 对 g 使用多元 Delta 方法即得结论. 逆映射恒等式 $g(\psi(\theta)) = \theta$ 求导给 $Dg(M)D\psi(\theta) = I_d$, 因而在可逆时得到导数公式. $\square$

一致性通常只需要所用的 d 阶绝对矩; 正态波动则需要这些函数的二阶矩, 普通幂矩方法因而通常需要 $2d$ 阶绝对矩. 不能把“一阶矩存在, 所以均值一致”直接加强为“均值必有中心极限定理”.

4.5 渐近协方差的实际计算

例题 4.8 计算正态均值与方差矩估计的联合渐近分布.

解答. 对正态模型 $X \sim N(\mu, v)$, $g(u, w) = (u, w - u^2)$, 故

$$J = \begin{pmatrix} 1 & 0 \\ -2\mu & 1 \end{pmatrix}.$$

计算 X, X^2 的协方差需要三、四阶矩. 将 $X = \mu + Z$, $\mathbb{E}Z = \mathbb{E}Z^3 = 0$, $\mathbb{E}Z^2 = v$, $\mathbb{E}Z^4 = 3v^2$, 展开得

$$\Sigma = \begin{pmatrix} v & 2\mu v \\ 2\mu v & 4\mu^2 v + 2v^2 \end{pmatrix}.$$

因此

$$\Gamma = J\Sigma J^\top = \begin{pmatrix} v & 0 \\ 0 & 2v^2 \end{pmatrix}, \quad \sqrt{n} \begin{pmatrix} \hat{\mu}_n - \mu \\ \hat{v}_n - v \end{pmatrix} \xrightarrow{d} N_2 \left(0, \begin{pmatrix} v & 0 \\ 0 & 2v^2 \end{pmatrix} \right).$$

这与前章的 $I(\mu, v)^{-1}$ 相同, 符合这两个矩估计恰为 MLE. 将 v 换成一致的 $\hat{v}_n$ 即可构造两个坐标各自的 Wald 区间. 两个各为 95% 的区间并不自动构成联合覆盖 95% 的矩形区域; 联合置信要求额外控制或使用联合正态分布. $\square$

例题 4.9 计算 Gamma 形状与尺度矩估计的联合渐近协方差.

解答. Gamma 矩公式为 $m_k = b^k a(a+1) \cdots (a+k-1)$. 对 $u = m_1 = ab$, $w = m_2 = a(a+1)b^2$, 记 $q = w - u^2 = ab^2$. 逆映射 $g(u, w) = (u^2/q, q/u)$ 的 Jacobian 为

$$J = \begin{pmatrix} 2uw/q^2 & -u^2/q^2 \\ -w/u^2 - 1 & 1/u \end{pmatrix} = \begin{pmatrix} 2(a+1)/b & -1/b^2 \\ -(2+1/a) & 1/(ab) \end{pmatrix}.$$

所需协方差为

$$\Sigma = \begin{pmatrix} ab^2 & 2a(a+1)b^3 \\ 2a(a+1)b^3 & 2a(a+1)(2a+3)b^4 \end{pmatrix}.$$

例如右下元由 $m_4 - m_2^2 = a(a+1)b^4\{(a+2)(a+3) - a(a+1)\}$ 得出. 矩阵相乘得到

$$\Gamma = \begin{pmatrix} 2a(a+1) & -2(a+1)b \\ -2(a+1)b & (2a+3)b^2/a \end{pmatrix}.$$

所以 $\sqrt{n}((\hat{a}_n, \hat{b}_n)^\top - (a, b)^\top)$ 收敛到此协方差的正态向量. 负交叉项反映形状与尺度的互相补偿: 在均值接近固定时, 形状增大往往伴随尺度减小. 将参数替换成一致矩估计可估计该协方差. $\square$

例题 4.10 计算均匀分布两端点矩估计的联合渐近分布.

解答. 设 $c = (a+b)/2$, $L = b-a > 0$, $X = c + Z$, 则 $Z \sim \text{Unif}[-L/2, L/2]$, $\mathbb{E}Z^2 = L^2/12$, $\mathbb{E}Z^3 = 0$, $\mathbb{E}Z^4 = L^4/80$. 在均值与方差坐标下, 一阶影响分别为 Z 与 $Z^2 - L^2/12$, 因而联合渐近协方差为

$$\begin{pmatrix} L^2/12 & 0 \\ 0 & L^4/180 \end{pmatrix}.$$

这是先对 $(\hat{m}_1, \hat{m}_2)$ 使用 Delta 方法得到的均值、方差极限. 对逆映射 $a = c - \sqrt{3v}$, $b = c + \sqrt{3v}$, 在 $v = L^2/12$ 处关于 v 的导数分别为 $-3/L, 3/L$. 再一次使用 Delta 方法, 得

$$\sqrt{n} \begin{pmatrix} \hat{a}_n - a \\ \hat{b}_n - b \end{pmatrix} \xrightarrow{d} N_2 \left(0, L^2 \begin{pmatrix} 2/15 & 1/30 \\ 1/30 & 2/15 \end{pmatrix} \right).$$

因为 $L > 0$, 这里开平方的逆映射在真实点光滑. 若参数区间长度退化到 0, 这个局部推导便不能直接照搬. $\square$

一般模型若不方便写出 $\Sigma(\theta)$, 可由样本估计

$$\hat{\Sigma}_n = \frac{1}{n} \sum_i (H(X_i) - \widehat{M}_n)(H(X_i) - \widehat{M}_n)^\top.$$

已有 $2d$ 阶绝对矩保证其中每个样本平均一致, 故 $\hat{\Sigma}_n \xrightarrow{\mathbb{P}} \Sigma$. 若 Dg 连续, 取 $\hat{\Gamma}_n = Dg(\widehat{M}_n) \hat{\Sigma}_n Dg(\widehat{M}_n)^\top$ 即得一致协方差估计. 对渐近方差正的第 j 个坐标, Wald 区间为 $[\hat{\theta}_{n,j} \pm z_{1-\alpha/2} \sqrt{\hat{\Gamma}_{n,jj}/n}]$. 若相应极限方差为 0, 不可机械地用零标准误来声称非退化正态覆盖率.

4.6 矩估计与最大似然的比较

两个方法有时完全重合, 如 Bernoulli、Poisson、指数以及正态均值方差模型. 它们重合时, 不能仅根据方法名称断言谁更准确. 一般正则模型中, MLE 使用完整分布结构, 渐近协方差常达到信息下界; 只使用几个矩会丢失部分信息, 但给出的方程可能易于计算. 有限样本二次风险受偏差、尾部与参数边界影响, 不存在不加条件的“MLE 风险总小于矩估计风险”定理.

命题 4.10 (正则矩估计的渐近信息比较) 设选择的向量特征 $H(X)$ 有协方差 Σ , 矩映射 $\psi(\theta) = \mathbb{E}_\theta H(X)$ 的 Jacobian $A = D\psi(\theta)$ 可逆. 假设正则得分 s_θ 有正定信息 I , 可交换特征期望的求导与积分. 则矩估计渐近协方差 $\Gamma = A^{-1}\Sigma A^{-\top}$ 满足 $\Gamma \succeq I^{-1}$.

证明. 微分期望给 $A = \mathbb{E}_\theta[(H - \psi)s_\theta^\top]$, 因为得分均值为 0. 定义 $U = A^{-1}(H - \psi)$, 则 $\mathbb{E}U = 0$, $\text{Cov}(U) = \Gamma$, $\mathbb{E}[Us_\theta^\top] = I_d$. 因而

$$\text{Cov}(U - I^{-1}s_\theta) = \Gamma - I^{-1} \succeq 0.$$

这就得到比较. 等号要求 $U = I^{-1}s_\theta$ 几乎处处, 即所选矩的一阶信息恰好重现完整得分. $\square$

该结论比较的是满足正则条件的一阶渐近协方差. 单凭分布收敛, 甚至不能自动推出 n 倍二次风险的收敛, 后者还需要平方误差的一致可积性. 因而不能以这个矩阵比较代替所有有限样本风险比较.

例题 4.11 对均匀上端点模型, 比较矩估计、MLE 及无偏最大值修正的二次风险与收敛速度.

解答. 对 $\text{Unif}[0, \theta]$, 矩估计 $T_n = 2\bar{X}_n$ 无偏, 且

$$R_\theta(T_n) = 4 \text{Var}(\bar{X}_n) = \frac{\theta^2}{3n}, \quad \sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \theta^2/3).$$

MLE M_n 的密度为 nx^{n-1}/θ^n ($0 < x < \theta$), 从而 $\mathbb{E}M_n = n\theta/(n+1)$, $\mathbb{E}M_n^2 = n\theta^2/(n+2)$. 直接展开二次风险得

$$R_\theta(M_n) = \theta^2 \left(\frac{n}{n+2} - \frac{2n}{n+1} + 1 \right) = \frac{2\theta^2}{(n+1)(n+2)}.$$

当 $n > 2$ 时此风险小于矩估计风险; $n = 1, 2$ 时相等. 若用无偏修正 $(n+1)M_n/n$, 其风险为 $\theta^2/(n(n+2))$. 上端点 MLE 有 n^{-1} 误差尺度, 矩估计只有 $n^{-1/2}$; 这一模型不正则, 所以上述正则信息比较不是证明其优势的途径, 这里依靠精确分布直接计算. $\square$

计算方面, 对数似然在凸参数域上凹时, 可以利用凸优化工具找到全局最大点, 仍须核对存在性与边界. 非凹目标可能有多个局部最大点, 常用 EM 等算法通常只保证特定条件下目标不下降, 不能普遍保证得到全局最大值. 矩估计则可能先得到闭式解, 也可能遇到多根、越界或病态的逆映射. 方法选择应结合模型信息、方程的可解性及所需的误差保证; 上面的定义、条件与例子给出逐项判断的依据.

5 参数假设检验

5.1 从实际问题到拒绝规则

樱花十英里长跑在 2009 年有 14974 名参赛者, 平均用时 103.5 分钟. 2012 年的选手是否更快? 随机抽取 2012 年的 n 名选手, 记用时为 $X_1, \dots, X_n$. 课程用正态分布近似用时, 并暂设两年的方差相同, 都为 373. 于是模型为 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, 373)$, 问题化为 $H_0: \mu = 103.5$ 对 $H_1: \mu < 103.5$. 这不是检验整个分布是否等于 $N(103.5, 373)$: 正态性和方差已经作为建模条件固定, 此时只考察均值.

仅因 $\bar{X}_n < 103.5$ 就宣布变快是不可靠的. 即使总体均值不变, 样本均值也会有随机波动, 而且在正态模型下落在均值下方的概率恰为一半. 应把下降幅度与标准误 $\sqrt{373/n}$ 比较. 后面将得到拒绝规则

$$\bar{X}_n < 103.5 - z_{1-\alpha} \sqrt{373/n},$$

其中 z_u 表示标准正态分布的 u 分位数. 样本增大时容许的误差带缩小, 但缩小的尺度是 $n^{-1/2}$, 不是任意趋零的数.

另一个问题来自止咳糖浆试验. 治疗组与安慰剂组每小时咳嗽次数的均值分别为 μ_{drug} 与 μ_{control} . 课程以独立泊松样本建模, 希望判断 $\mu_{\text{drug}} < \mu_{\text{control}}$. 这里没有固定的历史参照值, 两个均值都须由数据估计. 独立性使均值差的方差等于两个样本均值方差之和; 这将引出双样本检验.

定义 5.1 (检验与错误概率) 在模型 $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ 中, 取不相交的参数集合 Θ_0, Θ_1 , 考察 $H_0: \theta \in \Theta_0$ 对 $H_1: \theta \in \Theta_1$. 检验是可测函数 $\psi: E^n \rightarrow \{0, 1\}$, 值 1 表示拒绝原假设, 值 0 表示不拒绝. 拒绝域为 $R_\psi = \{x: \psi(x) = 1\}$. 第一类错误概率、第二类错误概率和功效函数分别为

$$\alpha_\psi(\theta) = \mathbb{P}_\theta(\psi = 1) \quad (\theta \in \Theta_0), \quad \beta_\psi(\theta) = \mathbb{P}_\theta(\psi = 0), \quad \pi_\psi(\theta) = 1 - \beta_\psi(\theta) \quad (\theta \in \Theta_1).$$

最坏情形功效为 $\inf_{\theta \in \Theta_1} \pi_\psi(\theta)$. 水平不超过 α 指 $\sup_{\theta \in \Theta_0} \alpha_\psi(\theta) \leq \alpha$. 渐近水平不超过 α 的逐点版本指对每个固定 $\theta \in \Theta_0$, $\limsup_n \mathbb{P}_\theta(\psi_n = 1) \leq \alpha$.

原假设和备择并不对称: 我们先控制错误拒绝原假设的概率, 再寻找能发现备择的规则. 不拒绝仅表示证据不足, 不证明原假设为真. 逐点渐近水平也不自动等于对所有参数一致控制的渐近水平. 若 Θ_0 只有一个点, 原假设称为简单假设; 否则称为复合假设. 含未知干扰参数的原假设通常是复合的.

例题 5.1 80 次掷币得到 54 次正面, 与 30 次掷币得到 13 次正面, 哪一组更不符合公平硬币?

解答. 设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p)$, $H_0 : p = 1/2$, $H_1 : p \neq 1/2$. 在原假设下

$$T_n = \frac{\sqrt{n}(\hat{p} - 1/2)}{\sqrt{(1/2)(1 - 1/2)}} \xrightarrow{d} N(0, 1), \quad \hat{p} = \bar{X}_n.$$

第一组 $T_{80} = \sqrt{80}(54/80 - 1/2)/(1/2) \approx 3.13$, 第二组 $T_{30} \approx -0.73$. 因而用双侧 5% 临界值 1.96, 第一组拒绝, 第二组不拒绝. 必须取绝对值, 否则只能发现正面过多而不能发现正面过少. 原幻灯片把 54/80 先近似为 .68, 得到约 3.22; 本文直接用实际计数计算, 避免中途舍入改变统计量. 第二组的 .77 同样来自先把 13/30 近似为 .43. $\square$

定义 5.2 (p 值) 对随水平 α 增大而扩张的拒绝域族, p 值定义为使观测样本进入拒绝域的水平下确界. 连续情形下, 若拒绝规则取 $p \leq \alpha$, 此等价逐点成立; 若用严格统计量阈值, 两者在边界概率为零时几乎必然等价. 对上述正态近似双侧检验, $p = 2\{1 - \Phi(|T_n|)\}$.

两组硬币数据的近似 p 值分别为 .00175 和 .465. p 值是原假设下出现至少同样极端统计量的概率, 不是原假设为真的概率. 若样本小, 可直接计算二项分布的尾概率得到精确检验; 因离散性, 无随机化时水平可能严格小于名义值.

5.2 正态模型的精确检验

定义 5.3 (χ^2 与 Student 分布) 独立标准正态变量 $Z_1, \dots, Z_d$ 的平方和服从 χ_d^2 . 若 $Z \sim N(0, 1)$ 与 $V \sim \chi_d^2$ 独立, 则 $Z/\sqrt{V/d}$ 服从 t_d . 特别地 χ_2^2 是率参数 1/2 的指数分布.

定理 5.4 (正态样本的正交分解) 设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $n \geq 2$, 并记

$$S_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad s^2 = \frac{n}{n-1} S_n.$$

则 $\bar{X}_n \sim N(\mu, \sigma^2/n)$, $nS_n/\sigma^2 \sim \chi_{n-1}^2$, 且 $\bar{X}_n$ 与 S_n 独立. 因而 $\sqrt{n}(\bar{X}_n - \mu)/s \sim t_{n-1}$.

证明. 标准化向量 $Z = (X - \mu \mathbf{1})/\sigma$ 为 n 维标准正态. 选正交矩阵, 第一行是 $\mathbf{1}^\top/\sqrt{n}$. 变换后的坐标仍独立标准正态, 第一坐标为 $\sqrt{n}(\bar{X}_n - \mu)/\sigma$, 其余 $n-1$ 个坐标的平方和恰为 $\sum (X_i - \bar{X}_n)^2/\sigma^2$. 第一坐标与其余坐标独立, 于是得到全部结论. 最后按 t 分布定义取比值. $\square$

检验 $H_0 : \mu = \mu_0$ 对双侧备择, 已知 σ 时用 $Z = \sqrt{n}(\bar{X}_n - \mu_0)/\sigma$ 并在 $|Z| > z_{1-\alpha/2}$ 时拒绝; 未知 σ 时用 $T = \sqrt{n}(\bar{X}_n - \mu_0)/s$, 在 $|T| > t_{n-1, 1-\alpha/2}$ 时拒绝. 单侧 $\mu > \mu_0$ 把临界值改成 $t_{n-1, 1-\alpha}$ 并只看右尾; 单侧 $\mu < \mu_0$ 只看左尾. 正态条件下这些结论是有限样本精确结果, 不要求 n 很大.

例题 5.2 在方差 373 已知的长跑模型中, 求左侧水平 α 检验在真实均值 $\mu < 103.5$ 时的功效.

解答. 拒绝事件是 $\bar{X}_n < 103.5 - z_{1-\alpha}\sqrt{373/n}$. 对真实均值标准化得到

$$\pi(\mu) = \Phi\left(\frac{\sqrt{n}(103.5 - \mu)}{\sqrt{373}} - z_{1-\alpha}\right).$$

对每个固定的严格备择, 功效随 n 增大趋于 1. 但若备择包含任意接近 103.5 的均值, 最坏情形功效的下确界只有 α . 因而最坏功效与逐个固定备择的一致性须分开理解. $\square$

5.3 似然与最强检验

永不拒绝的检验第一类错误为零, 但功效也为零. Neyman–Pearson 观点是在水平约束下比较功效, 而不是单独追求第一类错误最小.

定理 5.5 (简单假设的 Neyman–Pearson 引理) 设两种假设的联合密度为 f_0, f_1 , 相对于同一支配测度定义. 允许随机化检验 $\varphi(x) \in [0, 1]$. 取 $c \geq 0$, 使 φ_* 在 $f_1 > cf_0$ 时为 1, 在 $f_1 < cf_0$ 时为 0, 并在等号集合适当随机化以满足 $\mathbb{E}_0\varphi_* = \alpha$. 则对所有 $\mathbb{E}_0\varphi \leq \alpha$ 的检验, $\mathbb{E}_1\varphi \leq \mathbb{E}_1\varphi_*$.

证明. 由拒绝规则, 逐点有 $(\varphi_* - \varphi)(f_1 - cf_0) \geq 0$. 积分得

$$\mathbb{E}_1\varphi_* - \mathbb{E}_1\varphi \geq c(\mathbb{E}_0\varphi_* - \mathbb{E}_0\varphi) \geq 0.$$

这证明了水平限制下功效最大. 连续似然比常可不随机化; 离散分布的阈值原子则可能需要随机化. $\square$

例题 5.3 对 $N(\mu, \sigma^2)$ 样本, 比较 μ_0 与 $\mu_1 > \mu_0$.

解答. 联合似然比的对数为

$$\log \frac{f_{\mu_1}(X)}{f_{\mu_0}(X)} = \frac{n(\mu_1 - \mu_0)}{\sigma^2} \bar{X}_n - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2}.$$

它随 $\bar{X}_n$ 严格递增, 所以最强检验拒绝大均值. 其水平 α 阈值只依赖 μ_0 , 对每个 $\mu_1 > \mu_0$ 都是同一规则. 因而这里得到整个单侧备择的一致最强检验. 这并不意味着所有复合备择都有这样的检验. $\square$

5.4 Wald 检验与隐式约束

设 $\theta \in \mathbb{R}^d$, 正则模型中的极大似然估计满足

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_d(0, I(\theta)^{-1}),$$

其中 $I(\theta)$ 为单个观测的 Fisher 信息. 假定 I 连续且正定, $\hat{\theta} \xrightarrow{\mathbb{P}} \theta$. 检验 $H_0: \theta = \theta_0$ 时, Slutsky 定理与连续映射定理给出

$$W_n = n(\hat{\theta} - \theta_0)^\top I(\hat{\theta})(\hat{\theta} - \theta_0) \xrightarrow{d} \chi_d^2.$$

于是用 χ_d^2 的 $1 - \alpha$ 分位数作上尾阈值. 这是估计误差在信息度量下的平方长度. 标量有方向的备择更适合使用带符号的标准化误差; 无符号平方统计量仍控制水平, 却忽略方向信息.

命题 5.6 (一般约束的 Wald 检验) 设 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_d(0, \Sigma(\theta))$, $\hat{\theta} \xrightarrow{\mathbb{P}} \theta$, 且 $g: \mathbb{R}^d \rightarrow \mathbb{R}^k$ 在真值附近连续可微. 记 $Dg(\theta)$ 为 $k \times d$ 导数矩阵. 若 $\Gamma(\theta) = Dg(\theta)\Sigma(\theta)Dg(\theta)^\top$ 正定且有一致估计 $\hat{\Gamma}$, 则在 $H_0: g(\theta) = 0$ 下

$$ng(\hat{\theta})^\top \hat{\Gamma}^{-1}g(\hat{\theta}) \xrightarrow{d} \chi_k^2.$$

证明. 一阶展开为 $g(\hat{\theta}) = g(\theta) + Dg(\theta)(\hat{\theta} - \theta) + o_{\mathbb{P}}(n^{-1/2})$. 在原假设下首项为零. 标准化后趋于 $N_k(0, I_k)$, 再取平方长度得到结论. 若 Σ 正定且 Dg 行满秩, 对非零 v , $v^\top \Gamma v = (Dg^\top v)^\top \Sigma (Dg^\top v) > 0$, 正定性因而得到保证. $\square$

例如 $g(\theta) = \theta_1 - \theta_2$ 用于比较两个参数, $g(\theta) = (\theta_1, \theta_2)$ 用于同时检验两个系数为零. 约束的个数应按独立约束的秩计算, 不能仅数表达式.

5.5 似然比与 Wilks 定理

令 ℓ_n 为联合对数似然, $\hat{\theta}$ 为无约束 MLE, $\hat{\theta}^c$ 为 Θ_0 上的约束 MLE. 似然比统计量写为

$$L_n = 2\{\ell_n(\hat{\theta}) - \ell_n(\hat{\theta}^c)\} \geq 0.$$

它衡量施加原假设后拟合损失多少. 若 Θ 局部为 d 维光滑参数空间, Θ_0 在真值附近是 r 维光滑子流形, 则正则 Wilks 结论是 $L_n \xrightarrow{d} \chi_{d-r}^2$.

定理 5.7 (正则 Wilks 结论及其局部推导) 假设真参数 θ_0 是参数空间内点, 信息 I_0 正定, MLE 与约束 MLE 具有 $n^{-1/2}$ 尺度的一致性, 并且局部对数似然在相关有界集合上一致具有展开

$$\ell_n(\theta_0 + h/\sqrt{n}) - \ell_n(\theta_0) = h^\top \Delta_n - \frac{1}{2}h^\top I_0 h + o_{\mathbb{P}}(1), \quad \Delta_n \xrightarrow{d} N_d(0, I_0).$$

若局部约束趋于 r 维切空间, 则 $L_n \xrightarrow{d} \chi_{d-r}^2$.

证明. 置 $u = I_0^{1/2}h$, $Z_n = I_0^{-1/2}\Delta_n$. 局部目标为 $u^\top Z_n - \|u\|^2/2 = \|Z_n\|^2/2 - \|u - Z_n\|^2/2$. 无约束最大值在 $u = Z_n$ 取得; 约束最大值在 Z_n 对变换后切空间 V 的正交投影取得. 两个最大值差的两倍为 $\|(I - P_V)Z_n\|^2 + o_{\mathbb{P}}(1)$. 极限标准正态的 $d - r$ 个正交坐标平方和就是所述卡方分布. $\square$

这里明确把局部一致展开及 MLE 定位作为正则性条件, 而没有声称任何模型都适用. 边界参数、不可识别参数、奇异信息或随参数变化的支持可能破坏条件, 此时不能机械使用维数差. 对原课件固定末 $d - r$ 个坐标的原假设, 切空间正好有维数 r .

5.6 多项分布中的 Pearson 统计量

设类别空间 $\{a_1, \dots, a_K\}$, 各类概率 $p_j > 0$, $\sum_j p_j = 1$. 记 $N_j = \sum_i \mathbf{1}_{\{X_i = a_j\}}$, $\hat{p}_j = N_j/n$. 联合似然为 $\prod_j p_j^{N_j}$; 拉格朗日乘子或严格凹性给出 MLE $\hat{p}$. 若某类没有观测, MLE 可能在闭单纯形边界, 这不影响内点真参数下的渐近结论. 检验指定 p^0 时定义

$$Q_n = \sum_{j=1}^K \frac{(N_j - np_j^0)^2}{np_j^0} = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j^0)^2}{p_j^0}.$$

命题 5.8 在 $H_0: p = p^0$ 且各 $p_j^0 > 0$ 时, $Q_n \xrightarrow{d} \chi_{K-1}^2$.

证明. 单个类别指示向量的协方差为 $D - pp^\top$, $D = \text{diag}(p)$. 多元 CLT 给出 $\sqrt{n}(\hat{p} - p) \xrightarrow{d} N_K(0, D - pp^\top)$. 乘 $D^{-1/2}$ 后协方差为 $I - vv^\top$, $v = (\sqrt{p_j})$, $\|v\| = 1$. 它是对 $v^\perp$ 的秩 $K - 1$ 正交投影. 所以标准化误差的平方长度趋于 $K - 1$ 个独立正态平方和. $\square$

均匀性检验取 $p_j^0 = 1/K$. 一个自由度损失来自概率之和固定为 1, 并不是所有 K 类计数独立. 下一章进一步允许原假设内估计参数.

5.7 双样本均值比较

两组样本分别来自均值 μ_X, μ_Y , 方差 σ_X^2, σ_Y^2 的总体, 两组互相独立, 组内独立同分布. 在有限正方差及 $n, m \rightarrow \infty$, n/m 趋于正有限常数时,

$$Z_{n,m} = \frac{\bar{X}_n - \bar{Y}_m - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \xrightarrow{d} N(0, 1).$$

这是两个独立 CLT 的线性组合; 若方差未知, 用各组一致样本方差替代并应用 Slutsky. 检验相等均值时双侧拒绝 $|Z| > z_{1-\alpha/2}$; 止咳糖浆问题按治疗组减控制组的次序取左尾. 泊松模型可用均值估计方差, 标准误为 $\sqrt{\bar{X}_n/n + \bar{Y}_m/m}$.

注 课件双样本大样本页的比例存在倒置: 若方差均为 1, 正确标准误为 $\sqrt{1/n + 1/m}$, 因而乘 $\sqrt{n}$ 后的分母是 $\sqrt{1 + n/m}$. 直接写方差和可以避免 n/m 与 m/n 混淆.

正态、未知且允许不等方差时, 常用 Welch 统计量

$$T_W = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{s_X^2/n + s_Y^2/m}}, \quad \nu = \frac{(s_X^2/n + s_Y^2/m)^2}{s_X^4/[n^2(n-1)] + s_Y^4/[m^2(m-1)]}.$$

用 t_ν 近似校准, 不是一般精确分布. 若额外知道两组方差相同, 则合并估计

$$s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}, \quad T_p = \frac{\bar{X}_n - \bar{Y}_m}{s_p \sqrt{1/n + 1/m}} \sim t_{n+m-2}$$

在原假设下精确成立: 均值差为正态, 合并残差平方和为独立的 χ_{n+m-2}^2 . 方差相等条件不可从公式里省掉.

5.8 对称性与有限样本随机化检验

本节补充用户考纲要求的“基于对称性的检验”, 不属于本章 MIT 幻灯片的原有内容. 它用原假设下可验证的对称性给出有限样本校准, 无须正态近似. 对称性要求比“均值为零”强, 必须根据原假设说明.

定义 5.9 (对称分布与符号翻转) 实值变量 D 关于 0 对称指 D 与 $-D$ 同分布. 设独立配对差 $D_1, \dots, D_n$ 各自关于 0 对称, 且 $\mathbb{P}(D_i = 0) = 0$. 写 $A_i = |D_i|$, $S_i = \text{sign}(D_i)$. 在原假设下, 条件于 $(A_1, \dots, A_n)$, 符号向量 S 在 $\{-1, 1\}^n$ 的 2^n 种取值中均匀分布.

为什么可以固定绝对值而随机符号? 对任意正半轴可测集 C , 对称性给出 $\mathbb{P}(A_i \in C, S_i = 1) = \mathbb{P}(A_i \in C, S_i = -1) = \mathbb{P}(A_i \in C)/2$. 因而符号与绝对值独立且公平; 不同配对差的独立性进一步使所有符号独立. 独立样本可以分

布不同, 只要每个差都对称, 结论仍成立. 若来自配对测量, 必须说明不同配对单位独立, 不能把同一人的多次测量自动当作独立配对差.

可取检验统计量 $T(D) = \sum_i D_i$ 来发现正方向变化, 或取 $|\sum_i D_i|$ 进行双侧检验. 对观测 d , 定义符号翻转 p 值

$$p(d) = \frac{1}{2^n} \# \{s \in \{-1, 1\}^n : T(s_1|d_1|, \dots, s_n|d_n|) \geq T(d)\}.$$

用 $p \leq \alpha$ 拒绝. 也可以取正差数 $B = \sum_i \mathbf{1}_{\{D_i > 0\}}$, 这就是符号检验; 原假设下 $B \sim \text{Bin}(n, 1/2)$, 不需要知道差值的大小分布.

引理 5.10 (有限均匀样本的尾秩) 设有限集合 Ω 有 m 个元素, ω 均匀分布, $T : \Omega \rightarrow \mathbb{R}$. 令 $p(\omega) = m^{-1} \# \{v : T(v) \geq T(\omega)\}$. 则对所有 $\alpha \in [0, 1]$, $\mathbb{P}(p \leq \alpha) \leq \alpha$.

证明. 按 T 值从大到小把元素分组, 相同值归为一组. 每组的 p 值等于从最高组到本组的累计元素数除以 m . 满足 $p \leq \alpha$ 的组必是前面的若干完整组, 累计元素数至多 $m\alpha$, 因而其概率至多 α . 无合适累计数时事件为空, 这解释离散检验的保守性. $\square$

条件于绝对值应用此引理得到 $\mathbb{P}(p \leq \alpha | A) \leq \alpha$, 再取期望便得到无条件有限样本水平. 因包含等号, 相同统计量全部计入尾部; 无须假装统计量一定没有并列. 如要精确实现任意水平, 可在临界组独立随机化, 但不随机化的保守规则已有效.

例题 5.4 四个独立配对差为 1, 2, 3, 4, 检验差分布关于 0 对称, 对正方向备择用和统计量.

解答. 固定绝对值后有 16 种符号, 观测和为 10, 只有全正号达到 10, 故 $p = 1/16$. 在 5% 水平不拒绝, 在 10% 水平拒绝. 若用绝对和作双侧统计量, 全正与全负都达到 10, $p = 2/16 = 1/8$. 单侧与双侧的极端性定义不同, 不能在看见结果后任选较小者. 用正号数作单侧符号检验同样有 $p = \mathbb{P}(\text{Bin}(4, 1/2) \geq 4) = 1/16$. $\square$

连续无零假设便于直接记 n 个独立符号. 若有零差, 可固定零的位置, 只翻转非零差, 并以其个数代替 n ; 对称性仍给出非零符号条件均匀. 绝对值重复不妨碍符号向量均匀, 但统计量可能并列, 仍须按上述含等号规则处理. 原假设仅说 $\mathbb{E}D_i = 0$ 时, 偏斜分布不保证符号公平, 此校准可能失效.

两独立样本也可使用另一个对称性. 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$, $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} F$, 两组独立. 原假设是同分布, 不仅是同均值. 合并后 $N = n + m$ 个观测独立同分布, 所以联合分布在任意指标排列下不变, 即具有交换性. 固定合并样本, 遍历所有大小为 n 的标签子集 $S \subset \{1, \dots, N\}$, 以它作为第一组, 补集作为第二组. 例如统计量取

$$T_S = \left| \frac{1}{n} \sum_{i \in S} Z_i - \frac{1}{m} \sum_{i \notin S} Z_i \right|, \quad p = \binom{N}{n}^{-1} \# \{S : T_S \geq T_{S_0}\}.$$

命题 5.11 (标签置换检验的水平) 上述同分布原假设下, 标签置换规则 $p \leq \alpha$ 具有有限样本水平不超过 α .

证明. 在观测值互不相同, 条件于排序后的合并样本, 每一种将 n 个观测分配给第一组的标签子集具有相同概率 $1/\binom{N}{n}$. 应用尾秩引理并取期望即得结论. 有重复值时, 仍按观测指标而非不同数值列举标签; 可附加独立连续辅助标记打破排序并列, 条件于带标记的排序样本后标签仍均匀. 检验统计量不使用辅助标记, 因而同一尾秩证明对原统计量成立. $\square$

例题 5.5 两组为 $X = (1, 2), Y = (3, 4)$, 用均值差绝对值作置换检验.

解答. 六个第一组子集 $\{1, 2\}, \{1, 3\}, \{1, 4\}, \{2, 3\}, \{2, 4\}, \{3, 4\}$ 的统计量分别为 $2, 1, 0, 0, 1, 2$. 观测值为 2, 所以 $p = 2/6 = 1/3$. 这是精确离散校准, 数据看起来两组分开并不足以使四个观测提供很小的 p 值. $\square$

若两总体均值相等但方差或形状不同, 合并样本一般不交换, 上述朴素置换规则不保证有限样本水平. 这与前节检验均值相等的大样本或正态双样本 t 检验是不同原假设. 枚举过大时可随机抽取置换近似尾概率, 但必须区分 Monte Carlo 近似与已经证明的全枚举水平.

6 拟合优度检验

6.1 经验分布与整条分布曲线

参数检验在选定模型内问参数是否等于某个值; 拟合优度检验则问模型本身是否合适. 例如数据是否正态, 是否来自某个泊松分布, 或是否符合一个完全给定的分布? 后两种问题还须区分参数已知与参数由数据估计的情形.

定义 6.1 (经验分布函数) 实值样本 $X_1, \dots, X_n$ 的经验分布函数为

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq t\}}.$$

它是右连续、非减的阶梯函数, 每个观测贡献质量 $1/n$. 总体分布函数 $F(t) = \mathbb{P}(X \leq t)$ 唯一决定实值变量的分布.

固定 t 后, 指示变量是参数 $F(t)$ 的 Bernoulli 样本, 所以大数定律与 CLT 给出

$$F_n(t) \rightarrow F(t) \text{ 几乎处处}, \quad \sqrt{n}(F_n(t) - F(t)) \xrightarrow{d} N(0, F(t)(1 - F(t))).$$

不过检验整条曲线要考察所有 t , 单个 t 的 CLT 不够. 以下一致大数定律填补第一层缺口.

定理 6.2 (Glivenko–Cantelli) 独立同分布实值样本满足 $\sup_t |F_n(t) - F(t)| \rightarrow 0$ 几乎处处.

证明. 先对均匀样本 U_i 证明. 固定整数 k , 在有限网格 j/k 上大数定律同时成立. 若 $j/k \leq t \leq (j+1)/k$, 经验分布的单调性给出

$$|G_n(t) - t| \leq \max_{0 \leq j \leq k} |G_n(j/k) - j/k| + 1/k.$$

在所有整数 k 所对应的概率 1 事件的交集上, 先令 $n \rightarrow \infty$, 再令 $k \rightarrow \infty$, 得到一致收敛. 对任意 F , 用广义逆 $F^{-1}(u) = \inf\{x : F(x) \geq u\}$ 表示 $X_i = F^{-1}(U_i)$; 对 $u \in (0, 1)$, $F^{-1}(u) \leq t$ 等价于 $u \leq F(t)$. 因而 $F_n(t) = G_n(F(t))$,

所述上确界不超过 $\sup_{u \in [0,1]} |G_n(u) - u|$. 任意原样本与这一构造同分布, 故结论成立. $\square$

定义 6.3 (Brownian 桥) 标准 Brownian 桥 B 是 $[0, 1]$ 上的连续中心高斯过程, 协方差为 $\mathbb{E}[B(s)B(t)] = \min(s, t) - st$. 它可由标准 Brownian 运动 W 写成 $B(t) = W(t) - tW(1)$.

本章调用经验过程的 Donsker 定理: 当 F 连续时,

$$\sqrt{n} \sup_t |F_n(t) - F(t)| \xrightarrow{d} \sup_{0 \leq u \leq 1} |B(u)|.$$

固定点 CLT 只能说明有限个点的波动; 此定理还控制点之间的振荡, 属于函数空间极限定理. 完整证明需要紧性理论, 本章把它明确作为外部经验过程工具, 不把固定点 CLT 冒充证明.

6.2 Kolmogorov-Smirnov 检验

对一个完全给定的连续分布函数 F_0 , 检验 $H_0: F = F_0$ 对 $H_1: F \neq F_0$. 取

$$D_n = \sup_{t \in \mathbb{R}} |F_n(t) - F_0(t)|, \quad T_n = \sqrt{n} D_n.$$

若 $K = \sup_{0 \leq u \leq 1} |B(u)|$, 则用 K 的 $1 - \alpha$ 分位数校准得到渐近水平 α 的 KS 检验, 渐近 p 值为 $\mathbb{P}(K \geq T_n)$, 这里尾概率的自变量代入观测统计量.

命题 6.4 (实际计算与枢轴性) 在连续 F_0 下, 排序样本 $X_{(1)} \leq \dots \leq X_{(n)}$ 满足

$$D_n = \max_{1 \leq i \leq n} \left\{ \frac{i}{n} - F_0(X_{(i)}), F_0(X_{(i)}) - \frac{i-1}{n} \right\}.$$

在原假设下, D_n 的有限样本分布与具体 F_0 无关, 等于均匀样本经验分布与恒等函数的上确界距离.

证明. 连续分布下几乎必然没有重复值. 每个跳点右侧 $F_n = i/n$, 左极限为 $(i-1)/n$. 在相邻跳点之间 F_n 常数而 F_0 非减, 最大差只能出现在两端极限; 两侧尾部也由首末跳点控制, 得到公式. 原假设下概率积分变换 $U_i = F_0(X_i)$ 为独立均匀变量. 将公式中的 $F_0(X_{(i)})$ 换为 $U_{(i)}$, 就得到均匀样本对应的同一公式. 连续但不严格递增时, F_0 的平坦区间没有样本质量, 故结论仍成立. $\square$

例题 6.1 三个排序后的观测在 F_0 下的分布函数值为 .1, .4, .8. 求 D_3 .

解答. 右侧差分别为 $1/3 - .1 = 7/30$, $2/3 - .4 = 4/15$, $1 - .8 = 1/5$; 左侧差分别为 .1, $.4 - 1/3 = 1/15$, $.8 - 2/3 = 2/15$. 最大值为 $4/15$, 因而 $T_3 = 4\sqrt{3}/15$. 这里只须检查六个数. $\square$

枢轴性允许有限样本模拟: 固定 n , 独立生成 M 组均匀样本, 每组计算 $T_n^{(b)}$, 取这些值的经验 $1 - \alpha$ 分位数. 模拟尾概率可用 $M^{-1} \sum_b \mathbf{1}_{\{T_n^{(b)} \geq T_n\}}$ 估计. 这是带 Monte Carlo 误差的近似校准; 使用有限样本分布的精确分位数则是精确 KS 检验. 分位数表也必须区分有限 n 与渐近表. 若 F_0 离散, 概率积分变换不再是上述连续均匀形式, 常用连续 KS 表不能直接套用.

6.3 其他距离与估计参数的影响

上确界距离关注最大的局部差别. 标准 Cramér-von Mises 统计量使用整体平方距离, Anderson-Darling 则加重尾部:

$$C_n = n \int (F_n - F_0)^2 dF_0, \quad A_n = n \int \frac{(F_n - F_0)^2}{F_0(1 - F_0)} dF_0.$$

积分限是整条实轴, 第二式在 $0 < F_0 < 1$ 的部分解释. 使用 dF_0 后可变换到均匀尺度. 课程展示了以 dt 积分的距离表达式; 那也可以作为某种加权距离, 但一般不具有上述标准统计量的分布无关性质, 甚至可能因尾部行为而发散. 选择距离时连积分测度也要说明.

若原假设是“某个正态分布”, 均值和方差未知, 自然会计算

$$D_n^{\text{fit}} = \sup_t |F_n(t) - \Phi((t - \bar{X}_n)/\hat{\sigma})|, \quad \hat{\sigma}^2 = n^{-1} \sum_i (X_i - \bar{X}_n)^2.$$

然而同一数据既估计分布又衡量拟合, 拟合后距离通常变小. 不能再以完全给定分布的 KS 表校准. 一阶看, $F_{\hat{\theta}}(t) - F_{\theta}(t)$ 也是 $n^{-1/2}$ 尺度, 会从经验过程里减去与估计量相关的一项; 它并不因 $\hat{\theta} \xrightarrow{\mathbb{P}} \theta$ 就消失在 $\sqrt{n}$ 尺度上.

命题 6.5 (正态族的 Lilliefors 枢轴性) 对 $n \geq 2$ 的独立正态样本, D_n^{fit} 的分布不依赖真实均值和正方差. 可通过标准正态模拟并在每次模拟中重新估计均值与方差校准.

证明. 写 $X_i = \mu + \sigma Z_i$. 则 $\bar{X} = \mu + \sigma \bar{Z}$, $\hat{\sigma}_X = \sigma \hat{\sigma}_Z$, 因而 $(X_{(i)} - \bar{X})/\hat{\sigma}_X = (Z_{(i)} - \bar{Z})/\hat{\sigma}_Z$. 用跳点计算公式后所有未知参数消去. 正态连续样本的样本方差几乎必然正, 所以比值有定义. $\square$

这就是 Kolmogorov-Lilliefors 检验的校准原则. 若模拟时不重新拟合, 模拟的是另一个统计量. 对一般复合族, 未必能消去参数; 参数 bootstrap 可模拟拟合模型、每次重新估计、重新算距离, 其有效性仍须相应正则条件.

6.4 QQ 图

定义 6.6 (分位数图) 广义分位数为 $F^{-1}(u) = \inf\{x : F(x) \geq u\}$, $0 < u < 1$. QQ 图用同一概率水平比较理论分位数与经验分位数. 课程取 $u = i/n$, $i = 1, \dots, n-1$, 画 $(F_0^{-1}(i/n), X_{(i)})$. 实务也常取 $u_i = (i - 1/2)/n$, 避免 0 和 1 端点.

完全给定分布正确时点应在 $y = x$ 附近; 正态族但位置和尺度未知时, 用标准正态分位数作横轴, 点应近似落在某条直线 $y = \mu + \sigma x$ 上. 系统弯曲反映形状偏离, 两端特别偏离可能反映尾部差别. QQ 图是诊断图, 本身不提供指定第一类错误概率. 经验分位数由从小到大的顺序统计量给出; 原课件文字中的 “ith largest” 应读为第 i 小, 否则方向相反.

6.5 复合多项模型的卡方检验

设有 K 个类别, 原假设指定光滑概率族 $p(\theta) = (p_1(\theta), \dots, p_K(\theta))$, $\theta \in \mathbb{R}^d$. 在原假设模型中用计数似然估计 $\hat{\theta}$,

然后比较实际频率与拟合频率:

$$Q_n = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})}.$$

定理 6.7 (估计参数后的自由度) 假设真值为内点, 每类真概率为正, 概率映射连续可微且导数秩为 $d < K - 1$, 模型局部可识别并满足 MLE 正则展开. 则 $Q_n \xrightarrow{d} \chi_{K-1-d}^2$.

证明. 记 $p = p(\theta_0)$, $D = \text{diag}(p)$, $v = (\sqrt{p_j})$, J 为 $K \times d$ 概率导数矩阵. 前章的标准化频率误差 $Z_n = \sqrt{n}D^{-1/2}(\hat{p} - p)$ 趋于 $v^\perp$ 上的标准正态. 因为 $\sum_j p_j(\theta) = 1$, 有 $v^\top D^{-1/2}J = 0$. 记 $A = D^{-1/2}J$. 多项似然得分展开给出

$$\sqrt{n}(\hat{\theta} - \theta_0) = (A^\top A)^{-1}A^\top Z_n + o_{\mathbb{P}}(1).$$

故拟合后残差标准化为 $(I - P_A)Z_n + o_{\mathbb{P}}(1)$, $P_A = A(A^\top A)^{-1}A^\top$. 拟合消去 $v^\perp$ 中的 d 个正交方向, 剩余 $K - 1 - d$ 个. 分母 $p_j(\hat{\theta})$ 趋于正数 p_j , 所以平方长度得到所述极限. $\square$

例题 6.2 观测变量可能取 $0, 1, \dots, r$, 检验它是否服从某个 $\text{Bin}(r, p)$, r 已知.

解答. 类别数 $K = r + 1$, 参数维数 $d = 1$, 概率为 $p_j(p) = \binom{r}{j} p^j (1-p)^{r-j}$. 对未合并的计数, $\hat{p} = \bar{X}/r$. 代入 Pearson 统计量, 内点 $p \in (0, 1)$ 且 $r \geq 2$ 时自由度为 $r - 1$. 课程列出的支持 $\{1, \dots, K\}$ 与 $\text{Bin}(K, p)$ 不相容; 二项分布必须包含 0. 端点 $p = 0, 1$ 有零概率格, 不适用此正则结论. $\square$

6.6 分箱、独立性与实践条件

当原空间无限, 预先选互不相交且覆盖全空间的箱 $A_1, \dots, A_K$, 将观测转成类别. 令 $p_j(\theta) = \mathbb{P}_\theta(X \in A_j)$, 再应用上述有限模型. 分箱只检验各箱概率是否吻合; 某些箱内形状差异可能被隐藏. 箱数固定是这里的渐近框架, 不能让它随 n 任意增大而照搬相同证明.

泊松例可取 $A_1 = \{0\}, \dots, A_{K-1} = \{K-2\}$, $A_K = \{K-1, K, \dots\}$. 此时

$$p_j(\lambda) = e^{-\lambda} \lambda^{j-1} / (j-1)! \quad (j < K), \quad p_K(\lambda) = 1 - \sum_{l=0}^{K-2} e^{-\lambda} \lambda^l / l!.$$

尾部须合并成箱以覆盖全空间. 不能只追求尾概率极小: 预期频数太小会使卡方近似很差. 常用每箱预期频数至少约 5 作为经验检查, 它不是有限样本定理. 参数维数及概率导数秩也要在合并后重新核对.

注 上面的 $K - 1 - d$ 自由度证明依赖按箱计数似然得到的 MLE, 或具有同一投影展开的估计量. 若先在连续原始数据上估计参数再分箱, 参数估计的渐近协方差一般不同, 未必仍得到同一个卡方极限. 可改用分组 MLE, 或对完整“估计再分箱”程序作校准. 数据驱动选择箱界同样需要额外处理.

例题 6.3 两个分类变量分别有 r, c 类, 用同一批 n 个独立个体形成计数 N_{ab} . 检验两个变量独立.

解答. 独立模型为 $p_{ab} = u_a v_b$, 其中边际概率各和为 1. 计数似然在约束下的 MLE 是 $\hat{u}_a = N_{a+}/n$, $\hat{v}_b = N_{+b}/n$. 于是预期计数为 $E_{ab} = N_{a+}N_{+b}/n$, 统计量为

$$Q = \sum_{a,b} \frac{(N_{ab} - E_{ab})^2}{E_{ab}}.$$

类别数为 rc , 独立模型维数为 $(r-1) + (c-1)$, 故自由度 $rc - 1 - r - c + 2 = (r-1)(c-1)$. 条件是总体各格概率正且固定类别数; 零边际使公式无定义, 须先处理空类别. 独立性是联合概率可分解, 并不表示表中的各格计数独立. $\square$

此列联表例是前述有限拟合模型的补充应用, 原课件未单独展开. 所有卡方检验都应同时报告拟合模型、类别数、估计的独立参数数目和频数条件, 使使用的自由度可复核.

7 回归与预测

7.1 总体的最佳直线

在需求与价格、温度与气压等数据中, 我们观察成对变量 (X_i, Y_i) , 希望用 X_i 说明 Y_i 的变化. 经济学中的需求可近似写成 $D_i = a + bp_i + \varepsilon_i$. 理想气体关系 $PV = nRT$ 取对数后成为 $\log P = \log(nR) - \log V + \log T$, 因而可以用 $\log V, \log T$ 作为解释变量建立线性模型. “线性”指对待估系数线性, 不要求对原始物理变量线性.

定义 7.1 (总体线性回归) 设实值变量 X, Y 二阶矩有限, $\text{Var}(X) > 0$. Y 对 X 的总体线性回归是使 $\mathbb{E}[(Y - a - bX)^2]$ 最小的随机变量 $a + bX$.

命题 7.2 最优系数唯一, 且

$$b = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \quad a = \mathbb{E}Y - b\mathbb{E}X.$$

记 $\varepsilon = Y - a - bX$, 则 $\mathbb{E}\varepsilon = 0$, $\text{Cov}(X, \varepsilon) = 0$. 反之, 若某种分解满足这两个正交条件, 则其直线就是总体线性回归.

证明. 先固定 b , 用 $\mathbb{E}[(W - a)^2] = \text{Var}(W) + (\mathbb{E}W - a)^2$ 知最优 $a = \mathbb{E}Y - b\mathbb{E}X$. 代入得

$$\mathbb{E}[(Y - a - bX)^2] = \text{Var}(Y) - 2b\text{Cov}(X, Y) + b^2\text{Var}(X).$$

因 $\text{Var}(X) > 0$, 配方后的唯一最小点如上. 正交条件由代入直接得到. 反之, 对任意增量 u, v , 有

$$\mathbb{E}[(\varepsilon - u - vX)^2] = \mathbb{E}\varepsilon^2 + \mathbb{E}[(u + vX)^2],$$

因为交叉项 $\mathbb{E}[\varepsilon(u + vX)]$ 为零. 最后一项非负, 且在 $\text{Var}(X) > 0$ 下仅当 $u = v = 0$ 取零. $\square$

独立且中心的误差足以保证正交, 条件均值 $\mathbb{E}[\varepsilon | X] = 0$ 也足够. 但零协方差较弱, 不保证独立, 也不保证条件均值为零. 最佳线性近似可能不同于完整回归函数 $\mathbb{E}[Y | X]$, 后者可以是非线性曲线.

注 这是为用户考纲补充的总体解释. 若还假设 $\text{Var}(Y) > 0$, 记 σ_X, σ_Y 为两总体标准差, $r = \text{Cov}(X, Y)/(\sigma_X\sigma_Y)$

为相关系数. 对标准化变量 $X^* = (X - \mathbb{E}X)/\sigma_X$, $Y^* = (Y - \mathbb{E}Y)/\sigma_Y$, 前述公式给出最佳线性预测 $\widehat{Y^*} = rX^*$. Cauchy-Schwarz 不等式给出 $|r| \leq 1$. 当 $|r| < 1$ 时, 一个距离自身均值 $|x|$ 个标准差的解释变量, 所对应的最佳线性预测只距响应均值 $|rx|$ 个标准差. 这就是向均值回归的含义. 它讨论预测位置, 不声称每个个体的下一次观测都更接近均值, 更不证明时间变化的因果机制. 若 (X, Y) 联合正态, 则条件均值恰为这条直线, 条件方差为 $\sigma_Y^2(1 - r^2)$; 一般分布中这里只保证最佳线性预测, 不能自动把它认作条件均值.

7.2 样本最小二乘与残差

定义 7.3 (简单回归的最小二乘) 对观测对 (X_i, Y_i) , 最小二乘估计 $(\hat{a}, \hat{b})$ 最小化 $\sum_i (Y_i - a - bX_i)^2$. 拟合值为 $\hat{Y}_i = \hat{a} + \hat{b}X_i$, 残差为 $e_i = Y_i - \hat{Y}_i$.

命题 7.4 若 $S_{XX} = \sum_i (X_i - \bar{X})^2 > 0$, 则

$$\hat{b} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{S_{XX}}, \quad \hat{a} = \bar{Y} - \hat{b}\bar{X}.$$

并有 $\sum_i e_i = 0$, $\sum_i X_i e_i = 0$.

证明. 平方和对 a, b 求偏导得到 $\sum_i (Y_i - a - bX_i) = 0$ 与 $\sum_i X_i (Y_i - a - bX_i) = 0$. 第一式给出 $a = \bar{Y} - b\bar{X}$, 代入第二式得到斜率公式. $S_{XX} > 0$ 使二次目标的 Hessian 正定, 因而驻点是唯一全局最小点. 两个残差条件就是原正规方程. $\square$

课件的连续图示依次显示散点、真实直线、估计直线、两条直线并列以及观测点到拟合直线的竖直距离. 其中真实直线是一种总体关系, 拟合直线是随机样本算出的关系, 二者通常不同. 最小二乘最小化这些竖直残差的平方, 不最小化点到直线的垂直几何距离. 截距保证拟合直线经过 $(\bar{X}, \bar{Y})$.

例题 7.1 对三点 $(0, 1), (1, 2), (2, 2)$ 求拟合直线与残差平方和.

解答. $\bar{X} = 1$, $\bar{Y} = 5/3$, $S_{XX} = 2$, $S_{XY} = 1$, 所以 $\hat{b} = 1/2$, $\hat{a} = 7/6$. 拟合值为 $(7/6, 5/3, 13/6)$, 残差为 $(-1/6, 1/3, -1/6)$, 平方和为 $1/6$. 残差和为 0, 与 X 的内积也为 $1/3 - 2/6 = 0$, 可直接验证正规方程. $\square$

独立同分布观测对满足所需二阶矩时, 大数定律使样本方差与协方差趋于总体量, 因总体 $\text{Var}(X) > 0$, 上述比值给出 $\hat{b} \xrightarrow{\mathbb{P}} b$, $\hat{a} \xrightarrow{\mathbb{P}} a$. 此一致性不要求误差正态; 精确有限样本推断则需要后面的更强模型.

7.3 多元回归与正交投影

设第 i 个观测有列向量 $x_i \in \mathbb{R}^p$, 通常第一坐标为 1 以容纳截距. 设计矩阵 $X \in \mathbb{R}^{n \times p}$ 的第 i 行为 $x_i^\top$, 响应向量 $Y \in \mathbb{R}^n$, 模型为

$$Y = X\beta + \varepsilon, \quad \beta \in \mathbb{R}^p.$$

注意设计矩阵 X 与前一节的标量解释变量同名, 对象类型已发生变化. 最小二乘选择使 $\|Y - Xb\|^2$ 最小的 b .

定理 7.5 (满列秩正规方程) 若 $\text{rank}(X) = p$, 则 $X^\top X$ 正定, 最小二乘解唯一并等于

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y.$$

帽子矩阵 $H = X(X^\top X)^{-1} X^\top$ 是到 $\text{col}(X)$ 的正交投影. 拟合值 $\hat{Y} = HY$, 残差 $e = (I - H)Y$, 满足 $X^\top e = 0$.

证明. 对非零 b , $b^\top X^\top X b = \|Xb\|^2 > 0$. 求导给出正规方程 $X^\top X \hat{\beta} = X^\top Y$, 可逆性给出解. $H^\top = H$, $H^2 = H$, 且 $HX = X$, 故它固定列空间并将其正交补送到 0. 还可将目标写为

$$\|Y - Xb\|^2 = \|(I - H)Y\|^2 + \|HY - Xb\|^2,$$

两项正交, 因而拟合值确为最佳投影. □

如果列之间线性相关, 参数的某些组合无法从 $X\beta$ 分辨, 不能继续写逆矩阵公式. 计算上即使满秩, 严重共线性也会使 $X^\top X$ 条件数很大, 从而放大系数估计误差; 这与数学上的唯一性是不同层次的问题.

7.4 正态固定设计模型

以下假设 X 固定、满列秩, $n > p$, 以及 $\varepsilon \sim N_n(0, \sigma^2 I_n)$, $\sigma^2 > 0$. 这同时要求误差中心、同方差、相互独立和正态. 若设计随机, 可以在条件于整个 X 后假设 $\varepsilon | X \sim N_n(0, \sigma^2 I_n)$; 仅有逐个误差与某个解释变量不相关还不够.

定理 7.6 (最小二乘的精确分布) 在上述条件下,

$$\hat{\beta} \sim N_p(\beta, \sigma^2 (X^\top X)^{-1}), \quad \frac{\text{RSS}}{\sigma^2} \sim \chi_{n-p}^2, \quad \text{RSS} = \|Y - X\hat{\beta}\|^2,$$

而且 $\hat{\beta}$ 与 RSS 独立. $s^2 = \text{RSS} / (n - p)$ 是 σ^2 的无偏估计. 同时

$$\mathbb{E}\|\hat{\beta} - \beta\|^2 = \sigma^2 \text{tr}((X^\top X)^{-1}), \quad \mathbb{E} \text{RSS} = (n - p)\sigma^2, \quad \mathbb{E}\|\hat{Y} - X\beta\|^2 = p\sigma^2.$$

证明. $\hat{\beta} - \beta = (X^\top X)^{-1} X^\top \varepsilon$, 是正态向量的线性变换, 协方差按矩阵相乘得到. $e = (I - H)\varepsilon$, $I - H$ 为秩 $n - p$ 的正交投影. 在适合列空间与正交补的标准正交基中, 投影噪声和残差噪声取自独立标准正态坐标, 于是得到卡方分布与独立性. 平方范数的期望等于协方差的迹, 故三条风险公式分别来自 $(X^\top X)^{-1}$ 、 $I - H$ 、 H 的迹. □

正态对数似然关于 β 只通过 $-\text{RSS} / (2\sigma^2)$ 变化, 所以 $\hat{\beta}$ 也是 MLE. 若方差未知, 其 MLE 为 RSS / n , 不同于无偏估计 s^2 . 课件把 $\mathbb{E}\|Y - X\hat{\beta}\|^2$ 称为预测误差; 它实际是训练残差. 对独立新响应向量 $Y^{\text{new}} = X\beta + \varepsilon^{\text{new}}$, 同一设计上的预测风险为

$$\mathbb{E}\|Y^{\text{new}} - \hat{Y}\|^2 = n\sigma^2 + p\sigma^2,$$

因为新噪声与估计误差独立. 区分训练残差与未来预测误差可以看清过拟合.

7.5 系数、均值与新观测的区间

命题 7.7 (线性对比的 t 枢轴) 对固定非零 $c \in \mathbb{R}^p$, 记 $v_c = c^\top (X^\top X)^{-1} c > 0$. 则

$$\frac{c^\top \hat{\beta} - c^\top \beta}{s\sqrt{v_c}} \sim t_{n-p}.$$

证明. 分子除以 $\sigma\sqrt{v_c}$ 是标准正态; s^2/σ^2 是独立的 $\chi^2_{n-p}/(n-p)$, 因而比值按定义服从 Student 分布. $\square$

取 c 为第 j 个坐标向量, 得到检验 $H_0: \beta_j = 0$ 的统计量 $\hat{\beta}_j/[s\sqrt{((X^\top X)^{-1})_{jj}}]$. 双侧水平 α 用 $t_{n-p, 1-\alpha/2}$ 校准. 同一枢轴反演出置信区间

$$c^\top \hat{\beta} \pm t_{n-p, 1-\alpha/2} s\sqrt{v_c}.$$

取 $c = x_0$ 便得到设计点 x_0 处均值 $x_0^\top \beta$ 的区间. 若要预测独立新观测 $Y_0 = x_0^\top \beta + \varepsilon_0$, 新噪声的方差还要加上 σ^2 , 所以预测区间为

$$x_0^\top \hat{\beta} \pm t_{n-p, 1-\alpha/2} s\sqrt{1 + x_0^\top (X^\top X)^{-1} x_0}.$$

其枢轴精确性来自 ε_0 与原样本独立且正态. 同一点的预测区间比均值区间宽, 因为未来个体自身仍会波动.

例题 7.2 沿用 $(0, 1), (1, 2), (2, 2)$, 在 $x_0 = 1$ 处比较标准误.

解答. 设计列为截距与 x , 故 $n = 3, p = 2, s^2 = (1/6)/(3-2) = 1/6$. 中心点均值的 $v_{x_0} = 1/3 + (x_0 - \bar{X})^2/S_{XX} = 1/3$. 均值估计为 $5/3$, 标准误 $\sqrt{1/18}$; 新观测标准误 $\sqrt{(1/6)(1 + 1/3)} = \sqrt{2/9}$. 两个区间都用 t_1 分位数, 因自由度只有 1, 不能拿 1.96 替代. $\square$

7.6 联合显著性、F 检验与方差分析

同时检查 k 个系数时, 若分别使用水平 α , “至少一个误拒绝”的概率可能超过 α . Bonferroni 规则把每个检验水平设为 α/k , 只要一个拒绝便拒绝联合原假设. 联合原假设下由并集界

$$\mathbb{P}\left(\bigcup_{j \in S} \{\text{第 } j \text{ 项拒绝}\}\right) \leq \sum_{j \in S} \alpha/k = \alpha.$$

不要求各检验独立. 对一个预先指定的整体线性约束, F 检验则直接测量联合偏离.

定义 7.8 (Fisher 分布) 若 $U \sim \chi_k^2, V \sim \chi_q^2$ 独立, 则 $(U/k)/(V/q)$ 服从 $F_{k,q}$.

定理 7.9 (一般线性约束检验) 设 $G \in \mathbb{R}^{k \times p}$ 行满秩, $\lambda \in \mathbb{R}^k$ 固定, $H_0: G\beta = \lambda$. 则

$$F = \frac{(G\hat{\beta} - \lambda)^\top [G(X^\top X)^{-1}G^\top]^{-1}(G\hat{\beta} - \lambda)}{ks^2} \sim F_{k, n-p}$$

在原假设下精确成立, 用其 $1 - \alpha$ 分位数作上尾阈值.

证明. 设 $C = G(X^\top X)^{-1}G^\top$. 因 G 满行秩且中间矩阵正定, C 正定. 在原假设下, $C^{-1/2}(G\hat{\beta} - \lambda)/\sigma$ 为 k 维标准正态, 故分子除以 σ^2 为 χ_k^2 . 它是 $\hat{\beta}$ 的函数, 与 s^2 独立. 分母的卡方表示随即给出 F 分布. $\square$

分子也等于约束模型与完整模型的残差平方和差 $\text{RSS}_0 - \text{RSS}$, 因而

$$F = \frac{(\text{RSS}_0 - \text{RSS})/k}{\text{RSS}/(n-p)}.$$

确实, 令 $A = X^\top X$. 目标为 $\text{RSS} + (b - \hat{\beta})^\top A(b - \hat{\beta})$. 用乘子最小化第二项且 $Gb = \lambda$, 得约束解

$$\hat{\beta}_0 = \hat{\beta} - A^{-1}G^\top(GA^{-1}G^\top)^{-1}(G\hat{\beta} - \lambda).$$

代回二次项便得到分子. 这说明 F 检验比较为满足约束而增加的误差与剩余噪声水平.

若模型含截距, 置 $\text{TSS} = \sum_i (Y_i - \bar{Y})^2$, $\text{ESS} = \sum_i (\hat{Y}_i - \bar{Y})^2$. 正交性给出 $\text{TSS} = \text{ESS} + \text{RSS}$. 当 $p > 1$ 时, 检验所有非截距系数为零可写成

$$F = \frac{\text{ESS}/(p-1)}{\text{RSS}/(n-p)}.$$

这是回归方差分析的平方和分解; 在原假设下两个平方和除以 σ^2 独立, 自由度分别为 $p-1$ 与 $n-p$. 决定系数 $R^2 = 1 - \text{RSS}/\text{TSS}$ 在 $\text{TSS} > 0$ 时定义, 衡量训练样本中的解释比例; 加变量会提高或保持 R^2 , 不保证未来预测改善.

7.7 杠杆、残差与模型诊断

帽子矩阵对角元 $h_{ii} = x_i^\top (X^\top X)^{-1} x_i$ 称为杠杆值. 投影性质给出 $0 \leq h_{ii} \leq 1$, 且 $\sum_i h_{ii} = \text{tr } H = p$. 第一条可由 $h_{ii} = \|He_i^{\text{coord}}\|^2$ 及投影不增范数得到. 简单回归含截距时

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{S_{XX}},$$

所以远离解释变量中心的点杠杆更高. 高杠杆是设计位置的性质, 不等于响应一定异常.

误差 ε 不可直接观察, 残差 $e = (I - H)\varepsilon$ 虽为正态, 却满足

$$\text{Cov}(e) = \sigma^2(I - H), \quad \text{Var}(e_i) = \sigma^2(1 - h_{ii}), \quad \text{Cov}(e_i, e_j) = -\sigma^2 h_{ij} \quad (i \neq j).$$

它们一般不独立也不同意方差. 因而对残差作 QQ 图可帮助诊断, 但不能把残差当独立同分布样本直接套普通 KS 或 Lilliefors 表. 合适的模拟诊断应在同一设计下生成模型数据、重新拟合, 并校准整个残差统计量. 回归揭示变量之间的关联; 因果解释需要实验设计或额外识别条件, 不来自显著系数本身.

7.8 秩亏时仍可拟合什么

当 $k = \text{rank}(X) < p$, 若 $v \in \ker X$ 非零, 则 $X(\beta + v) = X\beta$, 所以分布无法区分 β 与 $\beta + v$. 系数不再整体可识别, 但均值向量 $\mu = X\beta \in \text{col}(X)$ 仍可识别.

命题 7.10 (秩亏设计) 令 H 为到 $\text{col}(X)$ 的正交投影, 可写成 $H = X(X^\top X)^\dagger X^\top$, 其中 $\dagger$ 为 Moore–Penrose 广义

逆. 所有最小二乘解给出同一拟合值 HY . 正态同方差模型下

$$\|(I-H)Y\|^2/\sigma^2 \sim \chi_{n-k}^2, \quad HY \text{ 与 } \|(I-H)Y\|^2 \text{ 独立.}$$

其中 $k=n$ 时 χ_0^2 约定表示集中于 0 的点质量. 若 $k < n$, $\|(I-H)Y\|^2/(n-k)$ 仍是方差无偏估计.

证明. 取列空间的标准正交基组成 $U \in \mathbb{R}^{n \times k}$, 则 $H = UU^\top$. 对任意 Xb , 正交分解证明最小残差只能是 $(I-H)Y$, 可达到的拟合值为 HY . 用 X 的奇异值分解核对广义逆表达式. 高斯噪声在列空间与正交补的坐标独立, 残差有 $n-k$ 个标准正态坐标, 得分布与独立性. $\square$

当 $k=n$ 时训练残差恒为 0, 没有剩余自由度估计噪声方差. 这不说明噪声不存在. 某些系数组合仍可识别: $c^\top \beta$ 可识别当且仅当 c 属于 X 的行空间, 因为它必须对所有 $v \in \ker X$ 满足 $c^\top v = 0$. 类似地, 新点预测 $x_0^\top \beta$ 只有在 x_0 属于行空间时由训练设计识别.

7.9 高维变量选择与惩罚

当 p 大于 n 或接近 n , 即使许多变量无关, 仍可用大量自由参数逼近训练数据. 课程提出稀疏假设: 只有少数系数非零, 但其位置未知. 对子集 $S \subset \{1, \dots, p\}$, 用子矩阵 X_S 拟合 $\hat{\beta}_S$, 比较

$$\text{RSS}_S + \lambda|S|, \quad \lambda > 0.$$

残差项鼓励拟合, 惩罚项限制模型复杂度. 单比较训练残差会偏向最大模型, 因为扩大拟合空间不会增加残差.

在固定候选设计、已知同方差高斯噪声下, Mallows 的 C_p 可写为

$$C_p(S) = \text{RSS}_S / \sigma^2 - n + 2k_S, \quad k_S = \text{rank}(X_S).$$

常数项与缩放不影响选择, 故等价于最小化 $\text{RSS}_S + 2\sigma^2 k_S$. 对满列秩子模型 $k_S = |S|$. 其意义可由直接风险计算说明: 对任意真实均值 μ , 子模型投影 H_S 满足

$$\mathbb{E} \text{RSS}_S = \|(I-H_S)\mu\|^2 + (n-k_S)\sigma^2,$$

而均值预测风险为 $\mathbb{E}\|H_S Y - \mu\|^2 = \|(I-H_S)\mu\|^2 + k_S \sigma^2$. 所以 $\text{RSS}_S - n\sigma^2 + 2k_S \sigma^2$ 是后者的无偏估计. 这里子模型须预先固定; 从很多模型中挑最小者后, 不能再把选中模型的误差估计直接视为无选择偏差.

已知方差正态似然的 AIC 为 $\text{RSS}_S / \sigma^2 + 2k_S$ 加共同常数, BIC 为 $\text{RSS}_S / \sigma^2 + k_S \log n$ 加共同常数. 所以对 $\lambda = 2\sigma^2$ 与 $\sigma^2 \log n$. 课件用 $\hat{\sigma}^2$ 代替作为实践形式; 若每个模型分别最大化未知方差, 精确似然形式则是 $n \log(\text{RSS}_S / n) + 2(k_S + 1)$ 或 $n \log(\text{RSS}_S / n) + (k_S + 1) \log n$. 因此 “AIC 等于残差加固定惩罚” 须注明方差处理方式.

定义 7.11 (ℓ_0 与 Lasso) $\|b\|_0 = \sum_j \mathbf{1}_{\{b_j \neq 0\}}$ 记非零坐标数, 它不是通常意义下的范数. 最佳子集问题可写成最小化 $\|Y - Xb\|^2 + \lambda\|b\|_0$. Lasso 用 ℓ_1 惩罚替换它:

$$\hat{\beta}^L \in \arg \min_{b \in \mathbb{R}^p} \left\{ \|Y - Xb\|^2 + \lambda \sum_{j=1}^p |b_j| \right\}.$$

最佳子集通常要面对 2^p 个候选子集, 不是课件所写的 2^n . Lasso 目标是凸函数, 且 $\lambda > 0$ 使它随 $\|b\| \rightarrow \infty$ 趋于无穷, 所以存在最小点. 设计秩亏时系数解未必唯一. 截距在实践中常不惩罚, 变量通常先标准化; 两种选择均须在定义计算程序时固定.

例题 7.3 若 $X^\top X = I_p$, 求 Lasso 解.

解答. 记 $z = X^\top Y$, 忽略与 b 无关的常数, 目标为 $\sum_j \{(b_j - z_j)^2 + \lambda|b_j|\}$. 对 $b_j > 0$ 求导得到 $b_j = z_j - \lambda/2$, 仅在 $z_j > \lambda/2$ 可行; 对负半轴得到 $b_j = z_j + \lambda/2$, 仅在 $z_j < -\lambda/2$ 可行; 其余情形最小点在 0. 因而

$$\hat{b}_j = \text{sign}(z_j)(|z_j| - \lambda/2)_+.$$

随着 λ 增大, 系数收缩且依次成为 0, 这解释了原课件的系数路径图. 阈值 $\lambda/2$ 取决于本文未在平方损失前乘 $1/2$ 的约定. $\square$

一般设计的路径可以改变斜率, 个别坐标也可能进入后再退出模型; 不能把正交例的单调坐标行为当作一般结论. 惩罚参数常用验证数据或交叉验证选择. 要从小预测误差进一步推断真实支持集恢复, 还需设计条件、信号大小与噪声控制, 并非选择任意 λ 就能保证. 课程把这些问题留给高维统计课程.

7.10 非参数回归与局部平均

线性条件均值并非总合理. 设 $Y_i = f(X_i) + \varepsilon_i$, $\mathbb{E}[\varepsilon_i | X_i] = 0$, 希望估计 $f(x) = \mathbb{E}[Y_i | X_i = x]$. 参数假设 $f(x) = a + bx$, $a + bx + cx^2$ 或 e^{a+bx} 把问题缩成有限参数估计. 前两式对系数线性, 第三式一般是非线性回归; 不能把所有非线性均值函数都直接套线性矩阵公式.

定义 7.12 (局部常数估计) 对一维设计、带宽 $h > 0$, 令 $I_x = \{i : |X_i - x| < h\}$, $N_x = |I_x|$. 定义

$$\hat{f}_{n,h}(x) = \begin{cases} N_x^{-1} \sum_{i \in I_x} Y_i, & N_x > 0, \\ 0, & N_x = 0. \end{cases}$$

空窗取 0 是课程的一种约定, 不是有数据支持的估计; 实际可选择扩大窗口或报告缺少局部观测.

思路是只在 x 附近以常数 $f(x)$ 近似 f . 课程示意图取 $x = .6, h = .1$, 对 $.5 < X_i < .7$ 的响应取平均, 图中得到约 .27. 区间的宽度是 $2h$, 而不是 h . 如果 h 太小, 可用观测少且曲线随个别点跳动; 如果 h 太大, 局部结构被平均掉.

命题 7.13 (条件偏差与方差) 条件于设计, 假设各误差独立、条件均值 0、条件方差 σ^2 , 且 $N_x > 0$. 则

$$\mathbb{E}[\hat{f}_{n,h}(x) | X] = \frac{1}{N_x} \sum_{i \in I_x} f(X_i), \quad \text{Var}(\hat{f}_{n,h}(x) | X) = \frac{\sigma^2}{N_x}.$$

若在该窗口内 $|f(t) - f(x)| \leq L|t - x|^s$, $0 < s \leq 1$, 则条件均方误差不超过 $L^2 h^{2s} + \sigma^2/N_x$.

证明. 条件期望对平均逐项作用, 条件独立使平均的方差为 $N_x \sigma^2 / N_x^2$. 偏差是 $f(X_i) - f(x)$ 的平均, 绝对值不超过 Lh^s . 使用均方误差等于偏差平方加方差即可. $\square$

例如课程用 $n = 100, f(x) = x(1 - x)$ 比较 $h = .005, 1, .2$. 极窄窗口 .005 使估计受到稀少点的强烈扰动并可能出现空窗; $h = 1$ 在 $[0, 1]$ 内几乎把所有样本纳入, 得到接近水平的总体平均, 不能表达抛物线; .2 在降噪与保留弯曲间折中. 这些图展示同一估计规则的不同带宽, 不证明 .2 总是最优.

若设计在 x 附近有正且连续密度 $q(x)$, 局部点数典型规模约为 $2nhq(x)$, 方差规模为 $1/(nh)$, 偏差平方规模不超过 h^{2s} . 平衡两者得到 h 的规模 $n^{-1/(2s+1)}$, 因此既要 $h \rightarrow 0$ 以控制偏差, 又要 $nh \rightarrow \infty$ 以积累局部观测. 这是含密度与平滑条件的尺度分析; 若光滑性更高, 对称窗口的消去效应或局部多项式可能给出更好偏差阶, 本式没有声称覆盖这些改进.

平滑性未知时可用交叉验证: 逐个删去观测, 用其余数据计算 $\hat{f}_{-i,h}(X_i)$, 比较

$$CV(h) = \frac{1}{n} \sum_i \{Y_i - \hat{f}_{-i,h}(X_i)\}^2.$$

必须先固定空窗处理规则并在全部候选带宽中保持一致. 删去自身避免极小带宽仅靠 Y_i 预测 Y_i 而得到虚假的小训练误差. 这里选择的是预测表现良好的带宽, 对其统计最优性仍需另行条件与证明.

8 贝叶斯统计

8.1 参数、数据与先验信息

频率学派与贝叶斯学派都从观测数据出发, 也都必须说明数据怎样产生. 区别在于怎样表达未知参数. 在频率学派模型 $(\mathbb{P}_\theta)_{\theta \in \Theta}$ 中, 真实参数 θ 是未知而固定的; 随机性来自样本. 估计量的偏差、方差、置信区间覆盖率, 都是在反复产生样本的意义下定义的. 贝叶斯方法则给参数空间加上一个概率分布, 用它表达观察数据之前的不确定性, 再借助数据更新这个分布. 这不要求现实中的参数每次实验都会随机变化: 参数分布可以是认识状态的数学模型.

例题 8.1 设 p 是某人口中女性所占比例. 有放回地随机抽取 n 人, 以 $X_i = 1$ 表示第 i 人为女性, 以 $X_i = 0$ 表示其他情况. 条件于 p , 假设

$$X_1, \dots, X_n \mid p \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p).$$

频率学派可以用 $\bar{X}$ 估计 p , 构造置信区间, 或检验 $p = 1/2$. 若事先相信 p 接近 $1/2$, 贝叶斯方法允许把这种信息放入分析, 而不是只在分析结束后作口头解释.

定义 8.1 (先验与后验) 观察样本之前赋予参数 θ 的概率分布称为先验分布, 记作 Π ; 若它对选定参考测度有密度, 记作 $\pi(\theta)$. 条件于参数的样本联合密度记作 $p_n(x \mid \theta)$. 观察 $X = x$ 后, 参数的条件分布 $\Pi(\cdot \mid x)$ 称为后验分布.

这里有两个不同层次的概率对象: $p_n(\cdot \mid \theta)$ 描述给定参数时数据的不确定性; Π 描述给定数据之前参数的不确定性. 条件独立并不意味着边际独立. 若所有 X_i 共用一个随机 p , 把 p 积分掉之后, 观测之间一般相关.

对于人口比例, 可以选择对称的 Beta 先验. 定义

$$B(a, b) = \int_0^1 t^{a-1}(1-t)^{b-1} dt = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}, \quad a, b > 0.$$

Beta(a, b) 的密度为

$$\pi(p) = \frac{p^{a-1}(1-p)^{b-1}}{B(a, b)}, \quad 0 < p < 1.$$

它的均值为 $a/(a+b)$, 方差为 $ab/[(a+b)^2(a+b+1)]$. 这两个公式可直接由 $\mathbb{E}[p^r] = B(a+r, b)/B(a, b)$ 取 $r = 1, 2$ 得到. 对称先验 Beta(a, a) 均值为 $1/2$, 方差为 $1/[4(2a+1)]$; a 越大, 越集中于 $1/2$. 关于“有 90% 把握落在 (0.4, 0.6)”这样的陈述, 需要用 Beta 分布的区间概率实际校准, 不能任意指定一个 a 就同时保证多组百分比.

8.2 贝叶斯公式与共轭更新

定理 8.2 (后验密度) 若先验是概率密度, 且对实际观察 x 有

$$0 < m(x) := \int_{\Theta} p_n(x | t) \pi(t) dt < \infty,$$

则后验密度为

$$\pi(\theta | x) = \frac{p_n(x | \theta) \pi(\theta)}{m(x)}.$$

因此, 作为参数的函数, 后验密度正比于先验密度乘似然.

证明. 参数与数据的联合密度为 $\pi(\theta)p_n(x | \theta)$. 对参数积分给出数据的边际密度 $m(x)$. 联合密度除以边际密度就是条件密度; 分母有限且严格为正, 保证所得函数可积且积分为一. 对于连续数据, 条件分布只需在边际分布几乎处处的 x 上定义. $\square$

计算时先找后验的函数形状通常更有效, 最后再识别归一化常数. 不过, 在使用不正常先验时, 最后的可积性检查不可省略.

例题 8.2 令 $s = \sum_{i=1}^n X_i$, 先验为 Beta(a, b). 求后验、后验均值与下一次观测成功的预测概率.

解答. 对于观测到的有序二元样本, 似然为 $p^s(1-p)^{n-s}$, 故

$$\pi(p | X) \propto p^{a+s-1}(1-p)^{b+n-s-1}.$$

因为 $a+s > 0$ 、 $b+n-s > 0$, 这个核可积, 于是

$$p | X \sim \text{Beta}(a+s, b+n-s), \quad \mathbb{E}[p | X] = \frac{a+s}{a+b+n}.$$

下一次观测的预测概率须先条件于 p 再平均:

$$\mathbb{P}(X_{n+1} = 1 | X) = \int_0^1 p \pi(p | X) dp = \frac{a+s}{a+b+n}.$$

后验均值还可以写成

$$\frac{a+s}{a+b+n} = \frac{a+b}{a+b+n} \frac{a}{a+b} + \frac{n}{a+b+n} \bar{X}.$$

因此先验均值与样本比例按信息量加权. a, b 可看作更新公式里的先验伪计数, 但并不一定来自真实的额外观测. $\square$

定义 8.3 (共轭先验) 若某类先验在给定抽样模型下更新后仍属于同一分布族, 就称该先验族与这个抽样模型共轭. 共轭是先验族与似然的关系, 并不是先验本身脱离模型后的性质.

例题 8.3 设 $X_i | \theta \stackrel{\text{i.i.d.}}{\sim} N(\theta, \sigma^2)$, $\sigma^2 > 0$ 已知, 先验为 $\theta \sim N(m_0, \tau^2)$, $\tau^2 > 0$. 求后验.

解答. 利用平方和分解

$$\sum_i (X_i - \theta)^2 = \sum_i (X_i - \bar{X})^2 + n(\theta - \bar{X})^2,$$

后验中依赖 θ 的指数为

$$-\frac{1}{2} \left\{ \frac{n}{\sigma^2} (\theta - \bar{X})^2 + \frac{1}{\tau^2} (\theta - m_0)^2 \right\}.$$

展开二次项并配方, 令

$$v_n = \left(\frac{n}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1}, \quad m_n = v_n \left(\frac{n\bar{X}}{\sigma^2} + \frac{m_0}{\tau^2} \right),$$

便得到 $\theta | X \sim N(m_n, v_n)$. 这里加起来的是精度, 即方差的倒数. 数据精度越大, 后验均值越接近 $\bar{X}$; 先验精度越大, 越接近 m_0 . 独立的新观测满足 $X_{n+1} | X \sim N(m_n, \sigma^2 + v_n)$, 预测方差同时包含新观测噪声和参数不确定性. $\square$

8.3 平坦先验、非正常先验与 Jeffreys 先验

没有明确先验信息时, 人们常试图采用“尽量少提供信息”的先验. 这个说法必须联系参数化理解: 对 p 均匀不等于对 $\log[p/(1-p)]$ 均匀.

定义 8.4 (非正常先验) 相对于指定参考测度, 非负可测函数 π 若积分无限, 就不能归一化为概率密度, 称为非正常先验. 此时把 $p_n(x | \theta)\pi(\theta)$ 归一化得到的后验, 只有在归一化积分严格为正且有限时才有意义.

常数密度在有限正体积的参数空间上可归一化为均匀分布; 在 $\mathbb{R}$ 上则不能. 仅说参数空间有界还不够, 仍应明确参考测度和有限正体积.

对于 Bernoulli 参数, $\pi(p) = 1$, $0 < p < 1$ 是 Beta(1, 1), 后验为 Beta(1 + s, 1 + n - s). 对于 $X_i | \theta \stackrel{\text{i.i.d.}}{\sim} N(\theta, 1)$, $\theta \in \mathbb{R}$, 采用 $\pi(\theta) = 1$ 则是非正常先验. 只要 $n \geq 1$, 平方和分解给出

$$\pi(\theta | X) \propto \exp\{-n(\theta - \bar{X})^2/2\}, \quad \theta | X \sim N(\bar{X}, 1/n).$$

这里后验正常并不能把原先验变成真正的概率分布; 例如先验预测分布依然不能照正常先验的方式解释.

定义 8.5 (Jeffreys 先验) 在正则模型中, 若 Fisher 信息矩阵 $I(\theta)$ 正定, Jeffreys 先验的密度核定义为

$$\pi_J(\theta) \propto \sqrt{\det I(\theta)}.$$

它可能正常, 也可能非正常. 使用单次观测信息还是独立样本总信息, 只相差一个与参数无关的常数.

Bernoulli 单次观测的信息为 $I(p) = 1/[p(1-p)]$, 所以 Jeffreys 先验为 $\text{Beta}(1/2, 1/2)$. 已知方差的正态位置模型信息为 $1/\sigma^2$, 因此 Jeffreys 先验在均值坐标中为常数.

命题 8.6 (光滑重参数化不变性) 设 $\eta = \varphi(\theta)$ 是参数空间之间的光滑一一对应, 逆映射 $\theta = \psi(\eta)$ 的 Jacobian 矩阵 $J(\eta)$ 可逆. 则在 θ 坐标下的 Jeffreys 密度经变量替换后, 仍为 η 坐标下的 Jeffreys 密度.

证明. 得分向量按链式法则变为 $s_\eta = J^\top s_\theta$, 于是

$$I_\eta(\eta) = J(\eta)^\top I_\theta(\psi(\eta)) J(\eta).$$

取行列式平方根得

$$\sqrt{\det I_\eta(\eta)} = |\det J(\eta)| \sqrt{\det I_\theta(\psi(\eta))}.$$

右边正是密度变量替换公式. 因此不变的是概率测度或先验测度, 不是把同一个数值函数原封不动地写在两种坐标中. $\square$

这解释了 Jeffreys 先验相对于简单“平坦先验”的优势, 但它不意味着任何问题都存在唯一客观的先验, 也不免除后验正常性的检查.

8.4 可信区域与频率覆盖

定义 8.7 (后验可信区域) 给定 $0 < \alpha < 1$, 依赖数据的集合 $C(X) \subseteq \Theta$ 若满足

$$\Pi(\theta \in C(X) \mid X) = 1 - \alpha,$$

就称为后验概率 $1 - \alpha$ 的可信区域. 若后验有原子, 指定概率的区域未必存在; 此时常用后验概率至少 $1 - \alpha$ 的版本.

原幻灯片把这种区域称为 Bayesian confidence region. 为避免混淆, 本稿采用“可信区域”. 频率置信区间的条件是, 对固定真值 θ , $\mathbb{P}_\theta\{\theta \in C(X)\} \geq 1 - \alpha$; 可信区域的条件则是在已观测数据下对参数分布求概率. 两者积分的对象不同, 通常不能相互替代.

对连续一维后验, 等尾可信区间是两个后验分位数之间的区间, 每侧尾概率为 $\alpha/2$. 例如平坦先验正态位置模型给出

$$\left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

它恰好也具有精确频率覆盖率, 因为固定 θ 时 $\sqrt{n}(\bar{X} - \theta)/\sigma \sim N(0, 1)$. 这是一种特定模型下的重合, 并不是两种定义相同的理由. 对于正常先验, 由全期望公式还有先验平均覆盖率

$$\int_{\Theta} \mathbb{P}_\theta\{\theta \in C(X)\} \Pi(d\theta) = 1 - \alpha,$$

但这个平均等式不保证每一个固定参数的覆盖率都等于 $1 - \alpha$.

8.5 损失函数、贝叶斯估计与 MAP

后验分布包含比一个点估计更多的信息. 要把它压缩成一个决策, 需要说明错误的代价. 设行动为 a , 损失为 $L(\theta, a)$. 观察数据后, 选择使后验期望损失最小的行动:

$$\hat{a}(X) \in \arg \min_a \int_{\Theta} L(\theta, a) \Pi(d\theta | X).$$

这是贝叶斯决策的一般形式. 原讲义的 “Bayes estimator” 特指下面的平方损失估计.

命题 8.8 (平方损失与绝对损失) 若后验二阶矩有限, 在平方损失 $L(\theta, a) = (\theta - a)^2$ 下, 唯一最优行动是后验均值. 若后验一阶矩有限, 在绝对损失 $L(\theta, a) = |\theta - a|$ 下, 最优行动是任意后验中位数.

证明. 令 $m = \mathbb{E}[\theta | X]$. 平方损失的后验期望分解为

$$\mathbb{E}[(\theta - a)^2 | X] = \text{Var}(\theta | X) + (m - a)^2,$$

交叉项为零, 故唯一极小点为 $a = m$. 对于绝对损失, 行动向右移动时, 左侧参数点贡献正斜率, 右侧参数点贡献负斜率. 在 a 处的左右导数分别为 $2F(a-) - 1$ 与 $2F(a) - 1$, 其中 F 是后验分布函数. 凸函数取得极小值当且仅当左导数不大于零、右导数不小于零, 即 $F(a-) \leq 1/2 \leq F(a)$, 这正是中位数条件. $\square$

对于正常先验, 后验风险的逐数据最小化也使先验平均风险最小: 对任意其他决策规则, 先条件于数据比较后验风险, 再对数据积分即可. 非正常先验对应的估计规则常称广义贝叶斯规则, 不能直接调用正常先验的平均风险解释.

定义 8.9 (最大后验估计) 若后验密度有最大值, 最大后验估计 (MAP) 为

$$\hat{\theta}_{\text{MAP}} \in \arg \max_{\theta} \pi(\theta | X) = \arg \max_{\theta} \{\log p_n(X | \theta) + \log \pi(\theta)\}.$$

在离散参数空间及零一损失下, MAP 正是最优分类行动. 对连续参数, 精确命中的零一损失几乎总为一, 不能直接用这个论证; MAP 可从小邻域误差的极限解释, 但它依赖密度坐标, 通常不具重参数化不变性. 正态先验使 MAP 相当于带二次惩罚的似然最大化.

Beta 后验参数记为 $A = a + s$, $B = b + n - s$. 若 $A, B > 1$, 对数后验求导给出内部 MAP

$$\hat{p}_{\text{MAP}} = \frac{A - 1}{A + B - 2}.$$

当参数不满足这两个不等式时, 众数可能在边界、可能有两个边界峰, 甚至在开区间上只有上确界而无最大点; 不能机械使用该公式. 相反, 后验均值 $(a + s)/(a + b + n)$ 对所有 $a, b > 0$ 均有定义.

8.6 作为频率估计量的贝叶斯规则

贝叶斯构造也可以作为产生频率估计量的工具: 先选一个先验, 再计算后验均值, 最后在固定真实参数下评价它. 这时先验未必表示实际信念, 而可能只是规定收缩强度的方法.

命题 8.10 (Beta 后验均值的频率性质) 固定 $a, b > 0$, 设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p)$, $0 < p < 1$. 则

$$\hat{p} = \frac{a + n\bar{X}}{a + b + n} \xrightarrow{\mathbb{P}} p, \quad \sqrt{n}(\hat{p} - p) \xrightarrow{d} N(0, p(1-p)).$$

其偏差与方差为

$$\mathbb{E}_p \hat{p} - p = \frac{a - (a+b)p}{a + b + n}, \quad \text{Var}_p \hat{p} = \frac{np(1-p)}{(a + b + n)^2}.$$

证明. 期望和方差公式由二项总数的均值 np 、方差 $np(1-p)$ 直接得到. 又

$$\hat{p} - \bar{X} = \frac{a - (a+b)\bar{X}}{a + b + n},$$

因 $0 \leq \bar{X} \leq 1$, 差为 $O(n^{-1})$. 大数定律给一致性; 乘 $\sqrt{n}$ 后这个差趋于零, 再用 Bernoulli 中心极限定理和 Slutsky 定理得渐近正态性. $\square$

对称先验给出 $(a + n\bar{X})/(2a + n)$; Jeffreys 先验给出 $(1/2 + n\bar{X})/(1 + n)$. 正态共轭模型中, 固定 m_0, τ^2 时 $m_n - \bar{X} = O_{\mathbb{P}_\theta}(n^{-1})$, 因此同样有一致性以及 $\sqrt{n}(m_n - \theta) \xrightarrow{d} N(0, \sigma^2)$. 平坦正态先验则直接给出 $\bar{X}$.

注 在上述正则、固定先验的例子中, 先验造成的改动比 $n^{-1/2}$ 小, 所以不改变一阶渐近分布. 原讲义把这一观察概括为先验一般不影响渐近性质; 若不加条件, 这并不成立. 先验若把真值附近排除, 或随 n 变得过度集中, 后验可能不一致; 非正则模型也可能有不同极限. 更一般的渐近正态结论需要可辨识性、局部光滑性、非退化信息及先验在真值附近为正等条件.

9 主成分分析

9.1 多元数据与协方差

一组观测往往同时记录许多变量. 把第 i 个观测写为列向量 $X_i = (X_i^{(1)}, \dots, X_i^{(d)})^\top \in \mathbb{R}^d$, 把观测按行放入数据矩阵

$$\mathbf{X} = \begin{pmatrix} X_1^\top \\ \vdots \\ X_n^\top \end{pmatrix} \in \mathbb{R}^{n \times d}.$$

若 d 很大, 逐坐标作图既困难, 也可能掩盖变量间的共同变化. 主成分分析 (PCA) 的目标是在较低维空间中表示这个点云, 同时尽量保留它的变异. 它首先是一种确定性数据变换; 只有讨论总体推断时才需要把这些点看成随机样本.

定义 9.1 (总体与样本协方差) 若随机向量 $X \in \mathbb{R}^d$ 满足 $\mathbb{E}\|X\|^2 < \infty$, 其均值与协方差矩阵定义为

$$m = \mathbb{E}X, \quad \Sigma = \mathbb{E}[(X - m)(X - m)^\top] = \mathbb{E}[XX^\top] - mm^\top.$$

对 n 个观测, 令

$$\bar{X} = \frac{1}{n} \sum_i X_i, \quad S = \frac{1}{n} \sum_i (X_i - \bar{X})(X_i - \bar{X})^\top = \frac{1}{n} \sum_i X_i X_i^\top - \bar{X} \bar{X}^\top.$$

本章使用分母 n , 与原讲义一致; 使用 $n-1$ 的无偏版本仅整体缩放特征值, 不改变主成分方向.

矩阵的第 (j, k) 个元素是第 j 与第 k 个坐标的协方差. 矩阵形式把所有坐标关系放在一起, 更重要的是, 它可以表达任意方向上的方差.

命题 9.2 (方向方差) 对任意 $u \in \mathbb{R}^d$,

$$\text{Var}(u^\top X) = u^\top \Sigma u, \quad \frac{1}{n} \sum_i \{u^\top (X_i - \bar{X})\}^2 = u^\top S u.$$

因此 Σ 与 S 均为实对称半正定矩阵.

证明. $u^\top X$ 的中心化量为 $u^\top (X - m)$. 其平方等于 $u^\top (X - m)(X - m)^\top u$, 取期望即得第一式; 把期望换为经验平均得到第二式. 对称性来自每个外积矩阵的对称性, 半正定性来自方差非负. $\square$

若 $u \neq 0$ 且 $u^\top S u = 0$, 每个非负平方项都必须为零, 所以所有数据点都在仿射超平面 $u^\top x = u^\top \bar{X}$ 上. 总体版本中, 非负随机变量期望为零意味着其几乎处处为零, 故 $u^\top \Sigma u = 0$ 等价于 $u^\top X = u^\top m$ 几乎必然成立. 反之, 较大的单位方向方差表示点云在该方向铺展较广.

9.2 中心化是一次正交投影

令 $\mathbf{1} = (1, \dots, 1)^\top \in \mathbb{R}^n$, 定义

$$H = I_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top, \quad Z = HX.$$

Z 的第 i 行是 $(X_i - \bar{X})^\top$. 于是

$$\bar{X} = \frac{1}{n} X^\top \mathbf{1}, \quad S = \frac{1}{n} Z^\top Z = \frac{1}{n} X^\top H X.$$

这里 $\mathbf{1}$ 属于 $\mathbb{R}^n$, 不是 $\mathbb{R}^d$; 这些维数对检查矩阵公式很有用.

命题 9.3 (中心化矩阵) H 是到 $\mathbf{1}^\perp = \{v \in \mathbb{R}^n : \sum_i v_i = 0\}$ 的正交投影, 且 $\text{rank}(H) = n - 1$.

证明. 直接计算得 $H^\top = H$, 并利用 $\mathbf{1}^\top \mathbf{1} = n$ 得 $H^2 = H$. 任意 v 都分解为

$$v = \frac{\mathbf{1}^\top v}{n} \mathbf{1} + H v,$$

其中第一项在 $\text{span}(\mathbf{1})$ 中, 第二项与 $\mathbf{1}$ 正交; 故 H 删除均值分量并保留零和分量. 像空间维数为 $n - 1$. $\square$

因此 $\text{rank}(S) \leq \min(d, n - 1)$. 特别是 $d \geq n$ 时, 样本协方差必然奇异, 即使总体协方差满秩也一样. 这是高维协方差估计中无法回避的结构限制.

9.3 谱分解与逐方向最大方差

定理 9.4 (实对称矩阵的谱分解) 对实对称矩阵 $A \in \mathbb{R}^{d \times d}$, 存在正交矩阵 $P = (v_1, \dots, v_d)$ 与实数 $\lambda_1, \dots, \lambda_d$, 使

$$A = P \operatorname{diag}(\lambda_1, \dots, \lambda_d) P^\top = \sum_{j=1}^d \lambda_j v_j v_j^\top.$$

若 A 半正定, 则所有特征值非负.

证明. 函数 $u \mapsto u^\top A u$ 在紧的单位球面上有最大点 v . 对任意 $w \perp v$, 沿曲线 $(v + tw)/\|v + tw\|$ 求导, 极值条件给出 $w^\top A v = 0$. 因此 $A v$ 与 v 平行, 即 $A v = \lambda v$. 由于 A 对称, $v^\perp$ 在 A 下不变: 若 $w \perp v$, 则 $v^\top A w = (A v)^\top w = 0$. 在这个维数少一的空间重复论证, 归纳得到正交特征向量基. 若 A 半正定, $\lambda_j = v_j^\top A v_j \geq 0$. $\square$

将 S 的特征值按 $\lambda_1 \geq \dots \geq \lambda_d \geq 0$ 排列. 变换后的观测 $P^\top X_i$ 的协方差为 $P^\top S P = \operatorname{diag}(\lambda_1, \dots, \lambda_d)$. 因而不同坐标经验不相关, 第 j 个坐标的经验方差为 λ_j . 不相关不等于独立; PCA 本身并未作独立性断言.

定理 9.5 (主成分的变分刻画) 上述特征向量可依次选择为

$$v_j \in \arg \max_{\|u\|=1, u \perp v_1, \dots, v_{j-1}} u^\top S u, \quad j = 1, \dots, d,$$

相应最大值为 λ_j .

证明. 把单位向量展开为 $u = \sum_\ell c_\ell v_\ell$, 有 $\sum_\ell c_\ell^2 = 1$. 于是

$$u^\top S u = \sum_\ell \lambda_\ell c_\ell^2 \leq \lambda_1.$$

$u = v_1$ 取得等号. 若还要求 $u \perp v_1, \dots, v_{j-1}$, 则前 $j-1$ 个系数为零, 余下特征值均不大于 λ_j , 同样得到上界 λ_j , 并由 $u = v_j$ 达到. $\square$

当特征值有重数时, 方向并不唯一. 在最大特征值对应的特征子空间中, 任意单位向量均可作为第一主成分. 若 $1 \leq k < d$ 且 $\lambda_k > \lambda_{k+1}$, 前 k 个方向张成的子空间唯一, 但各特征向量仍可能有符号或重根内的基选择自由.

9.4 投影、重构与最小误差

给定 $0 \leq k \leq d$, 取 $P_k = (v_1, \dots, v_k) \in \mathbb{R}^{d \times k}$. 中心化主成分得分为

$$Y_i = P_k^\top (X_i - \bar{X}), \quad \hat{X}_i = \bar{X} + P_k Y_i.$$

$\hat{X}_i$ 是 X_i 到仿射子空间 $\bar{X} + \operatorname{span}(v_1, \dots, v_k)$ 的正交投影. 原讲义输出 $P_k^\top X_i$; 它与这里的得分只差所有点共有的平移 $P_k^\top \bar{X}$, 经验协方差相同. 但重构时显式中心化更清楚.

定理 9.6 (PCA 的最优重构性质) 设 $0 \leq k \leq d$. 对任意 $d \times k$ 矩阵 Q , $Q^\top Q = I_k$, 投影到 $\bar{X} + \operatorname{im} Q$ 的平均平方重构误差为

$$\frac{1}{n} \sum_i \|(I_d - Q Q^\top)(X_i - \bar{X})\|^2 = \operatorname{tr}(S) - \operatorname{tr}(Q^\top S Q).$$

其最小值为 $\sum_{j=k+1}^d \lambda_j$, 由 $Q = P_k$ 达到. 允许任意仿射子空间也不会得到更小的值.

证明. 令 $\Pi = QQ^\top$. 它对称且幂等, 故 $\|(I - \Pi)z\|^2 = z^\top(I - \Pi)z$. 平均后用迹的循环性质得到误差公式. 再令

$$a_j = \|Q^\top v_j\|^2.$$

正交投影不增加长度, 所以 $0 \leq a_j \leq 1$; 且 $\sum_j a_j = \text{tr}(Q^\top Q) = k$. 因此

$$\text{tr}(Q^\top SQ) = \sum_j \lambda_j a_j \leq \sum_{j=1}^k \lambda_j.$$

当 $k = 0$ 或 $k = d$ 时该上界直接是等式. 对 $1 \leq k < d$, 最后一个不等式可从差值直接验证: 前 k 项损失为 $\sum_{j \leq k} \lambda_j(1 - a_j)$, 后面获得的量为 $\sum_{j > k} \lambda_j a_j$; 两组系数的和相同, 而前组特征值不小于 λ_k 、后组不大于 λ_k . $Q = P_k$ 给 $a_j = 1 (j \leq k)$ 和 $0 (j > k)$, 达到上界.

若投影到 $a + \text{im } Q$, 把 $X_i - a = (X_i - \bar{X}) + (\bar{X} - a)$ 代入, 交叉项的平均为零, 误差额外增加 $\|(I - QQ^\top)(\bar{X} - a)\|^2$. 取 $a = \bar{X}$ 可使它为零, 所以一般仿射子空间也不能改善这个最小值. $\square$

这一结论明确了“保留信息”的含义: PCA 对欧氏距离下的平均平方重构误差最优. 它不保证保留分类标签、因果结构或一切有用信息, 方差小的方向也可能含有重要信号.

例题 9.1 设经验协方差为

$$S = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

求一个主成分的方向、解释方差比例与重构误差.

解答. 特征值为 3, 1, 对应单位方向 $v_1 = (1, 1)^\top / \sqrt{2}$ 与 $v_2 = (1, -1)^\top / \sqrt{2}$. 保留一个主成分时, 得分是两坐标中心化后的和除以 $\sqrt{2}$, 重构把两坐标的共同变化保留下来. 解释方差比例为 3/4, 平均平方误差为 1. 直接保留任一原始坐标的轴方向, 解释方差仅为 2, 误差为 2, 故斜方向更合适. $\square$

9.5 SVD 实现与维数选择

对于中心化矩阵 Z , 奇异值分解写成

$$Z = U \text{diag}(s_1, \dots, s_r) V^\top, \quad s_1 \geq \dots \geq s_r > 0,$$

其中 $r = \text{rank}(Z)$, U, V 的列分别正交归一. 因为

$$S = \frac{1}{n} Z^\top Z = V \text{diag}(s_1^2/n, \dots, s_r^2/n) V^\top,$$

右奇异向量就是非零主成分方向, $\lambda_j = s_j^2/n$. 当 $0 \leq k \leq r$ 时, 得分矩阵为 $ZV_k = U_k \text{diag}(s_1, \dots, s_k)$, 重构矩阵为 $ZV_k V_k^\top$. 若选择 $r < k \leq d$, 则把右奇异向量补成正交基, 新增方向对应零特征值, 得分为零, 重构和保留前 r 个方向相同. 对 $k = d$, 所有方向都保留, 重构误差为零. 对 $k = 0$, 得分为空, 每个点重构为均值, 误差为总方差.

命题 9.7 (截断 SVD 的最优性) 若 $0 \leq k \leq r$, 则截断矩阵 $Z_k = \sum_{j=1}^k s_j u_j v_j^\top$ 在所有秩不大于 k 的矩阵中, 使 Frobenius 平方误差最小, 最小值为 $\sum_{j>k} s_j^2$.

证明. 任取秩不大于 k 的矩阵 B , 把其行空间包含在一个 k 维子空间中, 令对应正交投影为 Π . 每一行上, $Z - B$ 分解成与该子空间正交的 $Z(I - \Pi)$ 和子空间内的 $Z\Pi - B$, 所以

$$\|Z - B\|_F^2 = \|Z(I - \Pi)\|_F^2 + \|Z\Pi - B\|_F^2 \geq n \sum_{j>k} \lambda_j.$$

上一节的最优投影定理给出这个下界; 取 $B = Z_k = ZV_k V_k^\top$ 达到. 因此不仅在投影形式中最优, 在所有秩不大于 k 的重构矩阵中也最优. $\square$

实际算法就是中心化、计算协方差谱分解或 SVD、选择 k 、输出得分与方向. 若总方差 $\text{tr}(S) > 0$, 累计解释方差比例为

$$r_k = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_d}.$$

选择最小 k 使 $r_k \geq 1 - \alpha$, 等价于把平均平方重构误差限制在总方差的 α 倍以内. 若总方差为零, 所有观测相同, 该比值是 $0/0$, 应直接报告无需保留变异方向. 另一经验方法是观察碎石图中特征值下降由快转慢的“肘部”; 它是启发式判断, 不是总能找到的唯一拐点. 二维或三维显示则通常直接取 $k = 2$ 或 3 .

不同变量的单位会改变 PCA. 例如把米改为毫米, 协方差中的相关行列会相应放大, 主方向也可能改变. 若研究的是相对变化, 可以先把每个非零方差坐标标准化, 等价于对相关矩阵做 PCA; 这改变了所优化的距离, 须依据问题选择, 不能把标准化当作无影响的步骤.

9.6 可视化与协方差估计

原讲义用约 1400 名欧洲个体、约 500000 个遗传标记的数据展示 PCA 得分与地理结构的联系. 这说明高维坐标的共同变化可以在少数主成分上呈现可解释结构; 它不是证明每个数据集都能得到地理或其他语义坐标. 本稿不复制该页另有出版商许可声明的地图或图像.

若 $X_i \stackrel{\text{i.i.d.}}{\sim} X$, 固定维数 d 且 $\mathbb{E}\|X\|^2 < \infty$, 每个 $X^{(j)} X^{(k)}$ 可积, 由 Cauchy-Schwarz 不等式可知这一点. 逐元素大数定律于是给出

$$\frac{1}{n} \sum_i X_i X_i^\top \xrightarrow{\mathbb{P}} \mathbb{E}[X X^\top], \quad \bar{X} \bar{X}^\top \xrightarrow{\mathbb{P}} m m^\top,$$

故 $S \xrightarrow{\mathbb{P}} \Sigma$. 固定维数下矩阵范数等价, 也有范数一致性. 原稿的 $n \gg d$ 是实践提示; 当 d 随 n 增长时, 上述固定维数论证不能直接保证谱范数一致性.

如果总体协方差近似低秩, 可以保留前 k 个特征值, 构造

$$S_k = \sum_{j=1}^k \lambda_j v_j v_j^\top.$$

它把样本中小特征值方向删除, 可能在适当的结构假设、损失函数与 k 选择下改善对 Σ 的估计. 但不能无条件说它比 S 更好: 如果目标就是样本矩阵 S , S 本身误差为零; 如果总体有被截去的重要方向, 则截断会引入偏差. 估计收

益取决于降低噪声与增加偏差之间的平衡.

在 $d \gg n$ 的问题中, 还可能知道真实主方向只有少数非零坐标. 这引出稀疏 PCA: 在最大方差目标之外加坐标稀疏约束或惩罚, 使方向更易估计和解释. 它与仅仅截断特征值不同, 且涉及额外假设与优化问题; 原讲义在此只提示方向, 不给稀疏 PCA 的算法或普遍保证.

10 广义线性模型

10.1 从线性回归到响应分布与连接函数

正态线性回归同时规定两个部分: 条件分布为正态, 且条件均值是协变量的线性函数. 对于独立观测 (x_i, Y_i) , $x_i \in \mathbb{R}^p$, 其形式为

$$Y_i | x_i \sim N(\mu_i, \sigma^2), \quad \mu_i = x_i^\top \beta.$$

若 Y_i 是计数, 正态分布可能产生没有意义的负值; 若 Y_i 是二元变量, 线性均值也可能跑出 $(0, 1)$. 广义线性模型保留线性预测子 $\eta_i = x_i^\top \beta$, 同时放宽响应分布, 并把线性关系放在变换后的均值上.

定义 10.1 (广义线性模型) 一个 GLM 由以下部分组成: 条件于给定设计, 响应独立且属于指定的单参数指数离散族; 均值 $\mu_i = \mathbb{E}[Y_i | x_i]$ 通过可逆、可微的连接函数 g 满足

$$g(\mu_i) = \eta_i = x_i^\top \beta.$$

连接函数应把允许的均值映到线性预测子的允许范围. 后面的微分推导还要求所用位置上 $g'(\mu_i) \neq 0$.

原稿有一页要求连接函数单调递增, 但其倒数连接例子单调递减; 通用定义应允许严格单调的可微连接. 典型的对数、logit 与 probit 连接都递增, 某些其他连接则限制线性预测子的定义域.

例题 10.1 流行初期第 t_i 天新增病例的期望可能近似为 $\mu_i = \gamma \exp(\delta t_i)$, 其中 $\gamma > 0$. 取对数得到

$$\log \mu_i = \log \gamma + \delta t_i = \beta_0 + \beta_1 t_i.$$

响应是计数, 可尝试 $Y_i \sim \text{Pois}(\mu_i)$ 与对数连接. $\exp(\beta_1)$ 表示时间增加一个单位时条件均值的倍数. Poisson 模型要求方差等于均值, 实际数据若存在聚集、过度离散或时间依赖, 应重新评估这个随机部分.

例题 10.2 令 $x_i > 0$ 为猎物密度, 假定期望捕食率

$$\mu_i = \frac{\alpha x_i}{h + x_i}, \quad \alpha, h > 0.$$

当 x_i 增大时, 均值趋于最大率 α ; 当 $x_i = h$ 时达到最大率的一半. 倒数变换给出

$$\frac{1}{\mu_i} = \frac{1}{\alpha} + \frac{h}{\alpha} \frac{1}{x_i} = \beta_0 + \beta_1 \frac{1}{x_i}.$$

它对原参数非线性, 但对变换后的参数 $\beta_0 = 1/\alpha$ 、 $\beta_1 = h/\alpha$ 线性. 若标准差近似正比于均值, 可采用固定形状的

Gamma 响应. 这里线性预测子必须为正, 且若保留原生物解释, 还应限制 $\beta_0, \beta_1 > 0$. 原稿的曲线表达的正是上升后逐渐平缓这一形状.

例题 10.3 原讲义介绍 81 名儿童矫正脊柱手术后的资料, 响应为术后是否出现脊柱后凸, 协变量包括年龄 (月)、涉及的椎骨数与起始椎骨位置. 二元响应的条件分布为 Bernoulli, 均值是发生概率 p_i . 为了使预测保持在 $(0, 1)$, 可设

$$p_i = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \quad \text{或} \quad p_i = \Phi(x_i^\top \beta).$$

这分别给出 logistic 与 probit 回归. 数据例子说明建模需要, 不据此宣称某个协变量具有因果作用.

10.2 指数族与指数离散族

定义 10.2 (指数族) 相对于固定参考测度, 若一族密度或概率质量函数可写成

$$p_\vartheta(y) = \exp \left\{ \sum_{j=1}^k \zeta_j(\vartheta) T_j(y) - B(\vartheta) \right\} h(y),$$

则称它具有 k 个统计量的指数族表示. T_j 是统计量, ζ_j 是自然参数, B 负责归一化; 支持应在所讨论的正则范围内不依赖参数.

这里 “ k 参数” 需要注意可辨识性: 若自然参数只取低维曲面上的值, 或统计量线性相关, 有效自由度可能少于 k .

正态 $N(\mu, \sigma^2)$ 的密度展开为

$$\exp \left\{ \frac{\mu}{\sigma^2} y - \frac{1}{2\sigma^2} y^2 - \frac{\mu^2}{2\sigma^2} - \log(\sigma\sqrt{2\pi}) \right\}.$$

因此未知均值与方差时可以取两个统计量 y, y^2 , 自然参数为 $\mu/\sigma^2, -1/(2\sigma^2)$. 方差已知时只需统计量 y , 把含 y^2 的部分放进 $h(y)$.

Bernoulli 与 Poisson 分别有表示

$$p^y(1-p)^{1-y} = \exp \left\{ y \log \frac{p}{1-p} + \log(1-p) \right\}, \quad y \in \{0, 1\},$$

$$\frac{\lambda^y e^{-\lambda}}{y!} = \exp \{ y \log \lambda - \lambda - \log(y!) \}, \quad y \in \mathbb{N} \cup \{0\}.$$

Gamma 分布用形状 $a > 0$ 、尺度 $b > 0$ 参数化时, 密度为

$$f(y) = \frac{1}{\Gamma(a)b^a} y^{a-1} e^{-y/b}, \quad y > 0.$$

对数密度为 $(a-1) \log y - y/b - \log \Gamma(a) - a \log b$, 因此统计量可以取 $\log y, y$; 均值 $\mu = ab$ 时, 也可写为 $\Gamma(a)^{-1} (a/\mu)^a y^{a-1} e^{-ay/\mu}$.

原稿还列出逆 Gamma 和逆高斯作为指数族例子. 逆 Gamma 密度为

$$f(y) = \frac{\kappa^a}{\Gamma(a)} y^{-a-1} e^{-\kappa/y}, \quad y > 0,$$

其统计量是 $\log y, 1/y$. 逆高斯采用无歧义的均值 $\mu > 0$ 与形状 $\lambda > 0$ 参数化:

$$f(y) = \sqrt{\frac{\lambda}{2\pi y^3}} \exp \left\{ -\frac{\lambda(y - \mu)^2}{2\mu^2 y} \right\}, \quad y > 0.$$

展开指数为 $-\lambda y/(2\mu^2) - \lambda/(2y) + \lambda/\mu$, 故也是指数族. 它与逆 Gamma 是不同分布. 卡方、Beta、二项以及负二项分布也有相应指数族表示; Beta 的统计量是 $\log y, \log(1 - y)$, 二项在试验次数固定时与 Bernoulli 使用同一个 logit 自然参数, 负二项在形状固定时也可作为均值回归的响应族.

定义 10.3 (GLM 的指数离散族形式) 本章的 GLM 响应采用

$$f_\theta(y; \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right\}, \quad \phi > 0,$$

其中 θ 是自然参数, ϕ 是离散参数, 支持不依赖 θ . 在本章推导中 ϕ 视为已知, b, c 为指定函数. 若 ϕ 也未知, 整个模型不一定自动成为通常意义下的两参数指数族.

相较前面的通用指数族, 这个形式要求核心统计量就是响应 y . 并非每一种指数族都能直接作为这种单均值 GLM 的响应.

10.3 均值、方差与典则连接

定理 10.4 (均值与方差公式) 若允许在归一化积分中对 θ 微分两次, 且相应矩有限, 则

$$\mu = \mathbb{E}_\theta Y = b'(\theta), \quad \text{Var}_\theta(Y) = \phi b''(\theta).$$

非退化响应满足 $b''(\theta) > 0$, 故自然参数到均值的映射严格递增.

证明. 对 $\int f_\theta(y; \phi) dy = 1$ 求导, 得

$$0 = \mathbb{E}_\theta \left[\frac{\partial \log f_\theta(Y; \phi)}{\partial \theta} \right] = \mathbb{E}_\theta \left[\frac{Y - b'(\theta)}{\phi} \right],$$

于是均值为 $b'(\theta)$. 再微分一次, 有

$$0 = \mathbb{E}_\theta \left[\frac{\partial^2 \log f_\theta}{\partial \theta^2} + \left(\frac{\partial \log f_\theta}{\partial \theta} \right)^2 \right] = -\frac{b''(\theta)}{\phi} + \frac{\text{Var}_\theta(Y)}{\phi^2}.$$

这给出方差公式; 正方差和 $\phi > 0$ 则给 $b'' > 0$. 离散响应把积分换成求和即可. $\square$

定义方差函数 $V(\mu) = b''((b')^{-1}(\mu))$, 于是条件方差为 $\phi V(\mu)$. V 只给出均值与方差的关系, 不能单独确定整个条件分布.

定义 10.5 (典则连接) 使线性预测子等于自然参数的连接称为典则连接:

$$g(\mu) = (b')^{-1}(\mu), \quad \theta = \eta = x^\top \beta.$$

下面四个基本响应族同时给出均值、方差与典则连接:

分布	$b(\theta)$	ϕ	$V(\mu)$	$g(\mu)$
$N(\mu, \sigma^2)$	$\theta^2/2$	σ^2	1	μ
$\text{Pois}(\mu)$	e^θ	1	μ	$\log \mu$
$\text{Ber}(\mu)$	$\log(1 + e^\theta)$	1	$\mu(1 - \mu)$	$\log[\mu/(1 - \mu)]$
$\text{Gamma}(a, \mu/a)$	$-\log(-\theta)$	$1/a$	μ^2	$-1/\mu$

Gamma 的自然参数域是 $\theta < 0$. 其典则连接是负倒数, 严格递增; 前面捕食率用的正倒数连接是非典则连接, 严格递减. 这也说明典则连接的值域未必是整个 $\mathbb{R}$, 设计与参数必须满足预测子的域限制.

以 Gamma 为例, 取 $\theta = -1/\mu$ 、 $\phi = 1/a$, 则

$$\frac{y\theta - b(\theta)}{\phi} = -\frac{ay}{\mu} - a \log \mu,$$

剩余项为 $c(y, \phi) = a \log a - \log \Gamma(a) + (a - 1) \log y$. 所以 $\text{Var}(Y) = \mu^2/a$, 标准差与均值成正比, 符合捕食率例子中的假设.

Bernoulli 的其他常用连接是

$$g_{\text{probit}}(p) = \Phi^{-1}(p), \quad g_{\text{cloglog}}(p) = \log\{-\log(1 - p)\}.$$

对应逆连接为 $\Phi(\eta)$ 与 $1 - \exp\{-e^\eta\}$, 都把 $\mathbb{R}$ 映入 $(0, 1)$. logistic 与标准正态分布函数都是 S 形曲线, 但尾部不同; 两者未经尺度调整并不一致. 连接函数的图像是这些 S 形曲线的反函数, 靠近概率 0, 1 时趋向无穷.

10.4 似然、得分与严格凹性

令设计矩阵 $\mathbf{X}$ 的第 i 行为 $x_i^\top$, $Y = (Y_1, \dots, Y_n)^\top$. 设

$$\eta_i = x_i^\top \beta, \quad \mu_i = g^{-1}(\eta_i), \quad \theta_i = (b')^{-1}(\mu_i) = h(\eta_i), \quad h = (b')^{-1} \circ g^{-1}.$$

在 ϕ 已知时, 略去不依赖 β 的项, 条件对数似然为

$$\ell(\beta) = \frac{1}{\phi} \sum_i \{Y_i h(\eta_i) - b(h(\eta_i))\}.$$

求一次与两次导数分别得到

$$U(\beta) = \nabla \ell(\beta) = \frac{1}{\phi} \sum_i (Y_i - \mu_i) h'(\eta_i) x_i,$$

$$\nabla^2 \ell(\beta) = \frac{1}{\phi} \sum_i \{(Y_i - \mu_i) h''(\eta_i) - b''(\theta_i) [h'(\eta_i)]^2\} x_i x_i^\top.$$

第二式用到了 $\partial \mu_i / \partial \eta_i = b''(\theta_i) h'(\eta_i)$. 每个矩阵项都是 $p \times p$, 指标形式的乘积应为 $x_{ij} x_{ik}$.

命题 10.6 (典则连接下的凹性) 若采用典则连接, $\phi > 0$, 每个响应非退化, 且设计矩阵列满秩, 则对数似然在自然参数允许的凸参数域上严格凹. 因此若有限最大值确实达到, 最大似然估计唯一.

证明. 典则连接给 $h(\eta) = \eta$, 于是

$$U(\beta) = \phi^{-1} \mathbf{X}^\top (Y - \mu), \quad \nabla^2 \ell(\beta) = -\phi^{-1} \mathbf{X}^\top \text{diag}\{b''(\eta_i)\} \mathbf{X}.$$

对任何非零 a , 列满秩保证至少一个 $x_i^\top a \neq 0$; 因 $b''(\eta_i) > 0$, 有

$$a^\top \nabla^2 \ell(\beta) a = -\phi^{-1} \sum_i b''(\eta_i) (x_i^\top a)^2 < 0.$$

沿任意非平凡线段二阶导数为负, 故严格凹. 若有两个不同最大点, 中点会有更大的值, 矛盾. $\square$

严格凹性排除了两个有限最大点, 却不保证最大点存在. 若设计不满秩, 某些系数变化不改变预测子, 此时参数本身不可辨识. 非典则连接下 Hessian 含有残差项, 通常不能直接给出全局凹性的同一保证.

10.5 二次近似、Newton 方法与 Fisher scoring

对二阶连续可微函数 f , 在 a 附近的 Taylor 展开为

$$f(a + d) = f(a) + \nabla f(a)^\top d + \frac{1}{2} d^\top \nabla^2 f(a) d + o(\|d\|^2).$$

把梯度的线性近似置零, 若 Hessian 可逆, 得到 Newton 步

$$a_{\text{new}} = a - [\nabla^2 f(a)]^{-1} \nabla f(a).$$

用于最大化似然时, 负定 Hessian 使这个步成为局部二次近似的最大点. 实际算法重复计算, 而不是把近似解误当成真实极值的精确公式.

注 负定 Hessian 是严格凹性的充分条件; 严格凹函数的 Hessian 不必处处负定, 例如 $f(t) = -t^4$ 在零处的二阶导数为零. 普通 Newton 方法也不会仅凭凹性和二阶连续可微就从任意起点全局二次收敛. 局部二次收敛通常要求解附近 Hessian 非奇异及适当的光滑性; 全局稳定性常需阻尼、线搜索或信赖域. 更新还须留在模型参数域内.

Fisher scoring 用信息矩阵替代观测 Hessian. 在正确模型及常规可微条件下,

$$I(\beta) = -\mathbb{E}_\beta[\nabla^2 \ell(\beta) \mid \mathbf{X}] = \frac{1}{\phi} \sum_i b''(\theta_i) [h'(\eta_i)]^2 x_i x_i^\top.$$

因为 $\mathbb{E}[Y_i - \mu_i \mid \mathbf{X}] = 0$, Hessian 的残差项在期望下消失. 更新为

$$\beta_{\text{new}} = \beta + I(\beta)^{-1} U(\beta).$$

信息矩阵是半正定; 只有设计可辨识、权重为正等条件成立时才正定. 典则连接下观测 Hessian 不含 Y , 故 $I = -\nabla^2 \ell$, Newton 与 Fisher scoring 完全一致. 非典则连接下两者一般不同.

似然与 KL 的关系也解释了取期望的动机: 若真实条件密度为 f_{β_0} , 则

$$\mathbb{E}_{\beta_0} \log f_\beta(Y) = \mathbb{E}_{\beta_0} \log f_{\beta_0}(Y) - \text{KL}(f_{\beta_0} \| f_\beta).$$

因此最大化期望对数似然等价于最小化 KL; 这个恒等式并不是说每个观测似然本身就是负 KL, 也不单独给出迭代收敛保证.

10.6 加权最小二乘与 IRLS 的完整推导

先考虑已知异方差的正态模型 $Y = \mathbf{X}\beta + \varepsilon$, $\varepsilon \sim N_n(0, W^{-1})$, W 为正对角矩阵. 对数似然中依赖 β 的部分为

$$-\frac{1}{2}(\mathbf{Y} - \mathbf{X}\beta)^\top W(\mathbf{Y} - \mathbf{X}\beta).$$

其梯度置零给正规方程 $\mathbf{X}^\top W \mathbf{X} \beta = \mathbf{X}^\top W \mathbf{Y}$. 若设计列满秩, 则

$$\hat{\beta} = (\mathbf{X}^\top W \mathbf{X})^{-1} \mathbf{X}^\top W \mathbf{Y}.$$

这就是加权最小二乘 (WLS). 方差大的观测权重小. 若设计不满秩, 应讨论预测值或采用广义逆, 不能直接使用矩阵逆公式.

现在回到 GLM. 由 $g(b'(\theta_i)) = \eta_i$ 求导得

$$g'(\mu_i) b''(\theta_i) h'(\eta_i) = 1.$$

令 $V_i = b''(\theta_i) = V(\mu_i)$, 定义

$$w_i = \frac{h'(\eta_i)}{\phi g'(\mu_i)} = \frac{1}{\phi V_i [g'(\mu_i)]^2} > 0, \quad W = \text{diag}(w_1, \dots, w_n).$$

于是信息矩阵与得分可以统一写为

$$I = \mathbf{X}^\top W \mathbf{X}, \quad U = \mathbf{X}^\top W d, \quad d_i = g'(\mu_i)(Y_i - \mu_i).$$

第二式的第 i 项为 $x_i w_i d_i = x_i (Y_i - \mu_i) h'(\eta_i) / \phi$, 确实等于此前得分. 引入工作响应

$$z_i = \eta_i + g'(\mu_i)(Y_i - \mu_i) = \eta_i + d_i,$$

Fisher scoring 便变成

$$\begin{aligned} \beta_{\text{new}} &= \beta + (\mathbf{X}^\top W \mathbf{X})^{-1} \mathbf{X}^\top W (z - \mathbf{X}\beta) \\ &= (\mathbf{X}^\top W \mathbf{X})^{-1} \mathbf{X}^\top W z. \end{aligned}$$

这正是对工作响应 z 的 WLS 拟合. z 不是新观察到的数据, 而是当前均值处的线性化量; 权重也必须随当前参数更新.

定义 10.7 (迭代重加权最小二乘) 给定可行初值 $\beta^{(0)}$, 第 k 次迭代依次计算

$$\begin{aligned} \eta_i^{(k)} &= x_i^\top \beta^{(k)}, \quad \mu_i^{(k)} = g^{-1}(\eta_i^{(k)}), \quad z_i^{(k)} = \eta_i^{(k)} + g'(\mu_i^{(k)})(Y_i - \mu_i^{(k)}), \\ w_i^{(k)} &= \frac{1}{\phi V(\mu_i^{(k)}) [g'(\mu_i^{(k)})]^2}, \quad \beta^{(k+1)} = (\mathbf{X}^\top W^{(k)} \mathbf{X})^{-1} \mathbf{X}^\top W^{(k)} z^{(k)}. \end{aligned}$$

这个由 Fisher scoring 得到的算法称为 IRLS.

实际实现解线性方程即可, 无需显式形成逆矩阵. 对共享已知 ϕ , 它在 WLS 更新中作为公共比例抵消, 但在信息矩阵与标准误中不能漏掉. 对于 Bernoulli 的 0/1 数据, 不能不加处理地用 $\mu_i^{(0)} = Y_i$: logit 在端点无穷大, 权重为零. 可取有限的系数初值, 或在均值域内部取初始值, 并检查后续可行性、似然变化与得分.

10.7 Logistic 回归与完全分离

Bernoulli 响应配典则 logit 连接时, 令

$$p_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}, \quad \eta_i = x_i^\top \beta.$$

对数似然、得分与 Hessian 为

$$\ell(\beta) = \sum_i \{Y_i x_i^\top \beta - \log(1 + e^{x_i^\top \beta})\},$$

$$U = X^\top (Y - p), \quad \nabla^2 \ell = -X^\top \text{diag}\{p_i(1 - p_i)\}X.$$

由于所有有限预测子给 $0 < p_i < 1$, 列满秩保证 Hessian 负定. Logistic IRLS 使用

$$w_i = p_i(1 - p_i), \quad z_i = \eta_i + \frac{Y_i - p_i}{p_i(1 - p_i)}.$$

这也直接给出 Newton 更新 $\beta_{\text{new}} = \beta + (X^\top W X)^{-1} X^\top (Y - p)$.

logit 方程还说明系数的解释: 固定其他变量, 某坐标增加一单位时, 优势比 $p/(1 - p)$ 乘以对应的 e^{β_j} . 优势比的倍数通常不等于概率的倍数.

例题 10.4 若存在向量 a 使所有 $Y_i = 1$ 的点满足 $x_i^\top a > 0$, 所有 $Y_i = 0$ 的点满足 $x_i^\top a < 0$, 则称样本完全线性分离. 沿 $\beta = ta$, $t \rightarrow \infty$, 成功点的预测概率趋于 1, 失败点的预测概率趋于 0, 因此每项观测的对数概率趋于零, $\ell(ta) \rightarrow 0$. 然而任意有限 β 下每个观测的概率严格小于一, 所以 $\ell(\beta) < 0$. 故上确界为零却不在有限参数处取得.

例如用截距和一个坐标, 两个观测 $(x, Y) = (-1, 0), (1, 1)$ 的设计列满秩, $\beta = (0, t)^\top$ 就是上述路径. 信息矩阵随 t 增大趋向奇异, IRLS 系数可能持续增大; 这不能单凭停止阈值解释为一个正常的有限估计. 若存在使所有分类不等式弱成立、至少一个严格成立的方向, 也可能发生准完全分离. 惩罚似然或先验可以给出有限规则, 但那时优化目标已包含额外约束或惩罚.

若有限 MLE 存在并处于内部, 在固定 p 、适当设计与正则渐近条件下, 可用 $I(\hat{\beta})^{-1}$ 近似协方差, 构造 Wald 标准误. 满秩与局部曲率本身不保证小样本正态近似的准确性, 分离情形更不能套用这个正常结论.

10.8 Probit、Poisson 与正态回归的工作量

对 probit 回归, $\mu_i = \Phi(\eta_i)$. 以 φ 表示标准正态密度, 则

$$g'(\mu_i) = \frac{1}{\varphi(\eta_i)}, \quad w_i = \frac{\varphi(\eta_i)^2}{\mu_i(1 - \mu_i)}, \quad z_i = \eta_i + \frac{Y_i - \mu_i}{\varphi(\eta_i)}.$$

响应仍为 Bernoulli, 自然参数仍是 $\log[\mu_i/(1 - \mu_i)]$, 只是它不等于 η_i . 因此这是非典则连接, IRLS 对应 Fisher scoring 而一般不对应观测 Hessian 的 Newton 步. 若设潜在变量 $Y_i^* = x_i^\top \beta + \varepsilon_i$, $\varepsilon_i \sim N(0, 1)$, 观察 $Y_i = \mathbf{1}\{Y_i^* > 0\}$, 则 $\mathbb{P}(Y_i = 1 | x_i) = \Phi(x_i^\top \beta)$, 给出一个常见的潜变量解释.

Poisson 对数连接有 $\mu_i = e^{\eta_i}$, $V(\mu_i) = \mu_i$, 因此

$$\ell(\beta) = \sum_i \{Y_i \eta_i - e^{\eta_i} - \log(Y_i!)\}, \quad U = X^\top (Y - \mu),$$

$$w_i = \mu_i, \quad z_i = \eta_i + \frac{Y_i - \mu_i}{\mu_i}.$$

若不同观测具有已知暴露时长 $t_i > 0$, 可以建模 $\mu_i = t_i e^{x_i^\top \beta}$, 即在线性预测子中加入已知偏置 $\log t_i$, 其系数固定为一. 这把手事件总数与单位暴露率区分开来.

Poisson 条件均值正确并不意味着条件方差也正确. 若真实方差大于均值而仍用 $\phi = 1$ 的 Poisson 信息矩阵报告标准误, 通常会低估不确定性. 过度离散可能来自个体异质性、聚集或遗漏结构, 需要检查其来源. 可以在适当条件下考虑准似然估计、额外离散参数或稳健协方差估计; 这些方法需要各自的独立性或相关结构假设, 不由本章的 Poisson 似然公式自动保证.

正态恒等连接则有 $V(\mu) = 1$ 、 $g' = 1$ 、 $w_i = 1/\sigma^2$ 、 $z_i = Y_i$. 因此 IRLS 第一次更新就是普通最小二乘, 以后不再改变. 这说明 GLM 的迭代计算确实包含线性回归作为特例.

Gamma 正倒数连接给 $V(\mu) = \mu^2$ 、 $g' = -1/\mu^2$, 于是 $w_i = \mu_i^2/\phi$, $z_i = \eta_i - (Y_i - \mu_i)/\mu_i^2$. 虽然连接导数为负, 权重仍为正, 因为其定义中出现平方; 这也是一般 IRLS 公式比只记某个模型的特殊公式更可靠的原因.

10.9 饱和模型与离差

模型拟合好坏可以与“每个观测都有独立均值”的饱和模型比较. 饱和模型不再要求 $g(\mu_i) = x_i^\top \beta$, 而让每个 μ_i 自由变化. 若观测值在均值域内部, 单项似然对自然参数求导给 $Y_i - b'(\theta_i) = 0$, 故饱和拟合为 $\tilde{\mu}_i = Y_i$. 对于 Bernoulli 的端点或 Poisson 零值, 应把它理解为参数边界上的似然上确界.

给定离散参数, 定义离差

$$D = 2\{\ell_{\text{sat}} - \ell(\hat{\beta})\} \geq 0.$$

它衡量 GLM 相对于完美逐点拟合丢失的对数似然. Poisson 例子为

$$D = 2 \sum_i \left\{ Y_i \log \frac{Y_i}{\hat{\mu}_i} - (Y_i - \hat{\mu}_i) \right\},$$

其中 $0 \log 0$ 项按极限取零. 正态已知方差时为 $\sum_i (Y_i - \hat{\mu}_i)^2 / \sigma^2$. 这些量的比较意义来自同一响应分布; 它们不是不加条件就服从某个精确卡方分布. 似然比的渐近卡方近似需要内部真值、可辨识性与适当渐近框架, 不能直接对每个只有一次 Bernoulli 观测的饱和模型作无条件推广.

注 饱和模型、离差、分离、probit 的工作权重与 Poisson 暴露量是对原讲义的补充, 用来澄清最大值存在性、模型比较以及通用公式的应用. 原件主体着重指数族、连接函数与拟合算法; 这些补充不冒充原幻灯片中已给出的定理.

参考文献

- [1] Philippe Rigollet. *18.650 Statistics for Applications, Fall 2016*. Massachusetts Institute of Technology, MIT OpenCourseWare. [当前十份讲义内容页](#). 第 1–24 讲. 逐文件原链接、物理页序及 SHA-256 见 source-manifest.json 与 source-coverage.json.
- [2] Massachusetts Institute of Technology. [MIT OCW Privacy and Terms of Use](#); [Creative Commons Attribution–NonCommercial–ShareAlike 4.0 International](#). 第三方单独权利声明不由默认许可覆盖.
- [3] 清华大学招生办公室、清华大学求真书院. [清华大学 2027 年丘成桐数学科学领军人才培养计划招生简章](#), 2026-09-28. 第六条第 3 项包含概率与统计; 本书未据此认定各章均为逐项必考内容.